1202beF62]VC.sc[1v02000.3012:viXra

从自然语言监督中学习可迁移的视觉模型

亚历克·拉德福德 [*1] 金钟旭 [*1] 克里斯·哈拉西 [1] 阿迪蒂亚·拉梅什 [1] 加布里埃尔·吴 [1] 桑迪尼·阿加瓦尔 [1] 吉里什·萨斯特里 [1] 阿曼达·阿斯凯尔 [1] 帕梅拉·米什金 [1] 杰克·克拉克 [1] 格雷琴·克鲁格 [1] 伊利亚·苏茨克维 [1]

摘要

最先进的计算机视觉系统被训练用于预测一组固定的预先定义的对象类别。这种受限的监督形式限制了它们的通用性和可用性，因为若要指定任何其他视觉概念，都需要额外的标注数据。直接从关于图像的原始文本中学习是一种有前景的替代方案，它利用了范围更广的监督来源。我们证明，在从互联网收集的 4 亿个（图像，文本）对数据集上，从零开始学习 SOTA 图像表示时，预测哪条标题与哪张图像匹配这一简单的预训练任务是一种高效且可扩展的方法。预训练之后，使用自然语言来引用已学习的视觉概念（或描述新的概念），从而使模型能够零样本迁移到下游任务。我们通过在 30 多个不同的现有计算机视觉数据集上进行基准测试来研究这种方法的性能，这些数据集涵盖了 OCR、视频中的动作识别、地理定位以及多种细粒度对象分类等任务。该模型在大多数任务上都能实现非平凡的迁移，并且通常无需任何特定数据集的训练就能与完全监督的基线相媲美。例如，在 ImageNet 上进行零样本评估时，我们达到了原始 ResNet-50 的准确率，而无需使用其训练所依赖的 128 万个训练样本中的任何一个。我们在 https://github.com/OpenAI/CLIP 发布了代码和预训练模型权重。

1. 引言与研究动机

直接从原始文本中学习的预训练方法在过去几年彻底改变了自然语言处理领域（Dai & Le, 2015；Peters et al., 2018；Howard & Ruder, 2018；Radford et al., 2018；Devlin et al., 2018；Raffel et al., 2019）。自回归和掩码语言建模等与任务无关的目标，已在计算量、模型容量和数据规模上跨越多个数量级扩展，并持续提升能力。将“文本到文本”发展为标准化的输入-输出接口（McCann 等，2018；Radford 等，2019；Raffel 等，2019），使得与任务无关的架构能够以零样本方式迁移到下游数据集，从而无需专门的输出头或针对特定数据集的定制。像 GPT-3（Brown 等，2020）这样的旗舰系统，如今在许多任务上已能与定制模型相竞争，同时几乎不需要或完全不需要特定数据集的训练数据。

这些结果表明，现代预训练方法能够从网络规模文本集合中获得的聚合监督信号，超过了高质量众包标注 NLP 数据集所提供的监督信号。然而，在计算机视觉等其他领域，仍然普遍采用在 ImageNet（Deng 等，2009）等众包标注数据集上预训练模型的做法。可扩展的预训练方法若能直接从网络文本中学习，是否也能在计算机视觉领域带来类似的突破？先前的工作令人鼓舞。

20多年前，Mori等人（1999）探索了通过训练模型来预测与图像配对的文本文档中的名词和形容词，从而改进基于内容的图像检索。Quattoni等人（2007）证明，可以通过在为预测图像相关说明文字中的词语而训练的分类器的权重空间中进行流形学习，以更高的数据效率学习图像表示。Srivastava和Salakhutdinov（2012）探索了深度表示学习，他们在低层次图像和文本标签特征之上训练多模态深度玻尔兹曼机。Joulin等人（2016）使这一研究方向现代化，并证明了训练用于预测图像说明文字中词语的CNN能够学习到有用的图像表示。他们将YFCC100M数据集（Thomee等人，2016）中图像的标题、描述和话题标签元数据转换为词袋式多标签分类任务，并表明，预训练AlexNet（Krizhevsky等人，2012）来预测这些标签所学习到的表示，在迁移任务上的表现与基于ImageNet的预训练相近。随后，Li等人（2017）将这一方法扩展到除单个词之外还预测短语n-gram，并展示了其系统零样本迁移到其他图像的能力。

[*]Equal contribution [1]OpenAI, San Francisco, CA 94110, USA. Correspondence to: <{alec, jongwook}@openai.com>.

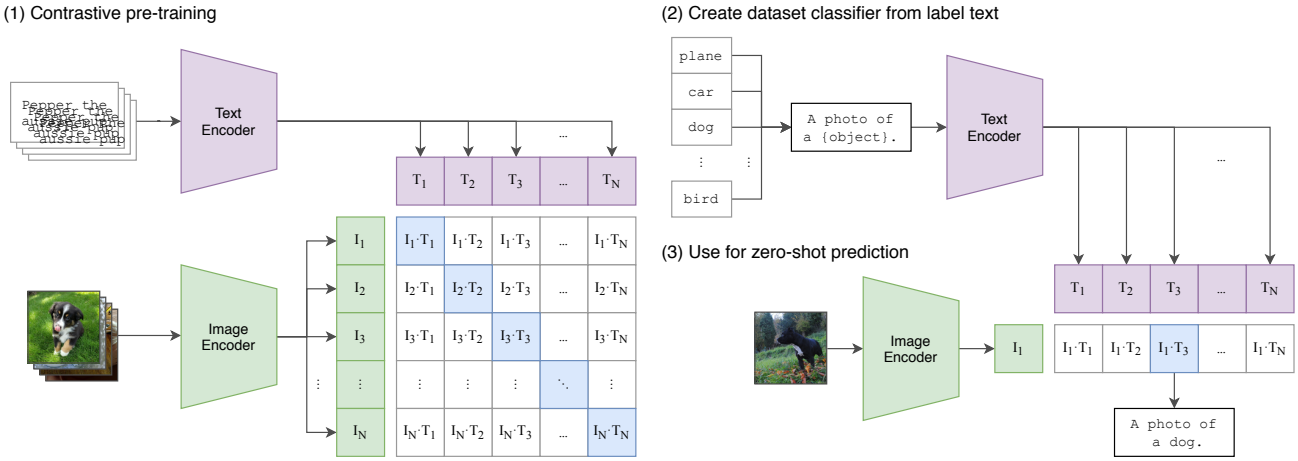


图 1. 我们方法的总结。标准图像模型联合训练图像特征提取器和线性分类器来预测某个标签，而 CLIP 联合训练图像编码器和文本编码器，以预测一批（图像、文本）训练样本中的正确配对。在测试时，学习到的文本编码器通过嵌入目标数据集类别的名称或描述来合成一个零样本线性分类器。

通过基于目标类别的已学习视觉 n-gram 词典为其打分，并预测得分最高的类别，用于分类数据集。采用更新的架构和预训练方法，VirTex（Desai & Johnson，2020）、ICMLM（Bulent Sariyildiz 等，2020）以及 ConVIRT（Zhang 等，2020）近期展示了基于 Transformer 的语言建模、掩码语言建模和对比目标在从文本中学习图像表示方面的潜力。

尽管作为概念验证令人振奋，但使用自然语言监督来进行图像表示学习仍然很少见。这很可能是因为其在常见基准上展示出的性能远低于其他方法。例如，Li 等人（2017）在零样本设置下在 ImageNet 上仅达到 11.5% 的准确率。这远低于当前最先进水平的 88.4% 准确率（Xie 等人，2020）。甚至低于经典计算机视觉方法 50% 的准确率（Deng 等人，2012）。相比之下，范围更窄但目标明确的弱监督用法提升了性能。Mahajan 等人（2018）表明，预测 Instagram 图像上与 ImageNet 相关的标签是一项有效的预训练任务。当在 ImageNet 上进行微调时，这些预训练模型将准确率提高了超过 5%，并提升了当时的整体最先进水平。Kolesnikov 等人（2019）和 Dosovitskiy 等人（2020）也通过预训练模型来预测带有噪声标签的 JFT-300M 数据集的类别，在更广泛的一组迁移基准上展示了显著提升。

这一研究方向代表了当前在从有限数量的有监督“金标准标签”中学习与从几乎无限量的原始文本中学习之间的务实折中。然而，它并非没有妥协之处。

mises。这两项工作都精心设计了它们的监督方式，并在此过程中将其监督范围分别限制在 1000 个和 18291 个类别。自然语言能够表达，并因此监督，范围广泛得多的视觉概念集合，这得益于其通用性。这两种方法还都使用静态 softmax 分类器进行预测，并且缺乏动态输出机制。这严重削弱了它们的灵活性，并限制了它们的“零样本”能力。

这些弱监督模型与近期关于直接从自然语言中学习图像表示的探索之间，一个关键差异在于规模。Mahajan 等人（2018）和 Kolesnikov 等人（2019）在数百万到数十亿张图像上训练其模型，耗费了以加速器年计的计算资源；而 VirTex、ICMLM 和 ConVIRT 则在十万到二十万张图像上训练，耗费的是以加速器天计的计算资源。在这项工作中，我们弥合了这一差距，并研究了在大规模自然语言监督下训练的图像分类器的行为。借助互联网上大量公开可用的此类数据，我们创建了一个包含 4 亿个（图像，文本）对的新数据集，并证明了一种从头训练的简化版 ConVIRT——我们称之为 CLIP，即对比语言-图像预训练（Contrastive Language-Image Pre-training）——是一种高效的从自然语言监督中学习的方法。我们通过训练一系列八个模型来研究 CLIP 的可扩展性，这些模型覆盖了近两个数量级的计算量，并观察到迁移性能是计算量的一个平滑且可预测的函数（Hestness 等，2017；Kaplan 等，2020）。我们发现，类似于 GPT 系列，CLIP 在预训练过程中学会执行广泛的任务，包括 OCR、地理定位、动作识别以及许多其他任务。我们通过在 30 多个现有数据集上评测 CLIP 的零样本迁移性能来衡量这一点，并发现

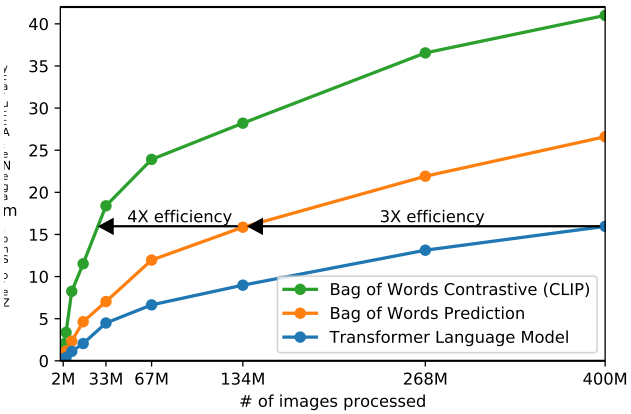


图 2. CLIP 在零样本迁移方面比我们的图像描述基线高效得多。尽管基于 Transformer 的语言模型具有很强的表达能力，但我们发现它们在零样本 ImageNet 分类上相对较弱。在这里，我们看到它的学习速度比一个预测文本词袋（BoW）编码的基线慢 3 倍（Joulin 等，2016）。将预测目标替换为 CLIP 的对比目标后，效率又进一步提高了 4 倍。

它可以与以往针对特定任务的监督模型相竞争。我们还通过线性探针表征学习分析证实了这些发现，并表明 CLIP 优于目前公开可用的最佳 ImageNet 模型，同时计算效率也更高。此外，我们发现零样本 CLIP 模型比具有同等准确率的监督式 ImageNet 模型鲁棒性强得多，这表明对任务无关模型进行零样本评估更能代表模型的能力。这些结果具有重要的政策和伦理影响，我们将在第 7 节中讨论。

2. 方法

2.1. 自然语言监督

我们方法的核心思想是从自然语言中包含的监督信号来学习感知。正如引言中所讨论的，这并不是一个新想法；然而，用于描述这一领域工作的术语各不相同，甚至看似相互矛盾，并且其所陈述的动机也多种多样。Zhang 等（2020）、Gomez 等（2017）、Joulin 等（2016）以及 Desai 和 Johnson（2020）都提出了从与图像配对的文本中学习视觉表征的方法，但他们分别将自己的方法描述为无监督、自监督、弱监督和监督式方法。

我们强调，这一系列工作中的共同点并不是所采用的具体方法的任何细节，而是对自然语言作为训练信号的重视。所有这些方法都在从 *natural language supervision* 中学习。尽管早期工作在使用主题模型和 n-gram 表示时曾努力应对自然语言的复杂性，但深度上下文表示学习的进展表明，我们现在已有工具能够有效利用这一丰富的监督来源（McCann 等，2017）。

从自然语言中学习相较于其他训练方法具有若干潜在优势。与图像分类中标准的众包标注相比，自然语言监督更容易扩展，因为它不要求标注采用经典的“兼容机器学习的格式”，例如规范的 N 选 1 多数投票“黄金标签”。相反，处理自然语言的方法可以从互联网上海量文本中所包含的监督信号中被动学习。从自然语言中学习相较于大多数无监督或自监督学习方法还有一个重要优势：它并不“仅仅”学习一种表示，还将该表示与语言连接起来，从而实现灵活的零样本迁移。在以下小节中，我们将详细介绍最终采用的具体方法。

2.2. 创建足够大的数据集

现有工作主要使用了三个数据集：MS-COCO（Lin 等，2014）、Visual Genome（Krishna 等，2017）和 YFCC100M（Thomee 等，2016）。虽然 MS-COCO 和 Visual Genome 是高质量的众包标注数据集，但按照现代标准来看，它们规模较小，每个数据集约有 100,000 张训练照片。相比之下，其他计算机视觉系统使用多达 3.5 *billion* 张 Instagram 照片进行训练（Mahajan 等，2018）。YFCC100M 拥有 1 亿张照片，是一种可能的替代选择，但每张图像的元数据都很稀疏且质量参差不齐。许多图像使用自动生成的文件名（如 20160716 113957.JPG）作为“标题”，或包含相机曝光设置的“描述”。在筛选后仅保留具有英文自然语言标题和/或描述的图像后，该数据集规模缩小了 6 倍，仅剩 1500 万张照片。这与 ImageNet 的规模大致相同。

自然语言监督的一个主要动机是，互联网上公开可获得大量这种形式的数据。由于现有数据集无法充分反映这种可能性，如果只考虑在这些数据集上的结果，就会低估这一研究方向的潜力。为了解决这一问题，我们构建了一个新的数据集，包含从互联网上各种公开可用来源收集的 4 亿个（图像，文本）对。为了尽可能覆盖广泛的视觉概念，我们在构建过程中搜索其文本包含 500,000 个查询之一的（图像，文本）对。[1] 我们大致分类

[1]The base query list is all words occurring at least 100 times in the English version of Wikipedia. This is augmented with bi-grams

通过每个查询最多包含 20,000 个（图像，文本）对来平衡结果。所得数据集的总词数与用于训练 GPT-2 的 WebText 数据集相近。我们将该数据集称为 WIT，即 WebImageText。

2.3. 选择高效的预训练方法

最先进的计算机视觉系统使用非常大量的计算资源。Mahajan 等人（2018）需要 19 个 GPU 年来训练他们的 ResNeXt101-32x48d，而 Xie 等人（2020）需要 33 个 TPUv3 核心年来训练他们的 Noisy Student EfficientNet-L2。考虑到这两个系统都只是被训练用于预测 1000 个 ImageNet 类别，从自然语言中学习开放集合的视觉概念这一任务似乎令人望而生畏。在我们的工作过程中，我们发现训练效率是成功扩展自然语言监督的关键，并且我们基于这一指标选择了最终的预训练方法。

我们最初的方法与 VirTex 类似，从头开始联合训练一个图像 CNN 和一个文本 Transformer，以预测图像的说明文字。然而，我们在高效扩展这种方法时遇到了困难。在图 2 中，我们展示了一个拥有 6300 万参数的 Transformer 语言模型，尽管其计算量已经是其 ResNet-50 图像编码器的两倍，但它学习识别 ImageNet 类别的速度却比一个简单得多的基线模型慢三倍；该基线模型预测的是同一文本的词袋编码。

这两种方法有一个关键的相似之处。它们都试图预测每张图像所配文本中的 *exact* 个词。由于与图像共同出现的描述、评论和相关文本种类繁多，这是一项困难的任务。近期关于图像对比表示学习的工作发现，对比目标可以比其等价的预测目标学习到更好的表示（Tian et al., 2019）。其他工作发现，尽管图像生成模型可以学习到高质量的图像表示，但要达到相同性能，它们所需的计算量比对比模型高出一个数量级以上（Chen et al., 2020a）。注意到这些发现后，我们探索了训练一个系统来解决一个可能更容易的代理任务：只预测哪段文本 *as a whole* 与哪张图像配对，而不是预测该文本的确切词语。我们从相同的词袋编码基线开始，将图 2 中的预测目标替换为对比目标，并观察到向 ImageNet 进行零样本迁移的效率进一步提高了 4 倍。

给定一批 N (图像、文本) 对，CLIP 被训练来预测在一个批次中 $N \times N$ 个可能的（图像、文本）配对中哪些是真实出现的。为此，CLIP 学习一个

with high pointwise mutual information as well as the names of all Wikipedia articles above a certain search volume. Finally all WordNet synsets not already in the query list are added.

通过联合训练图像编码器和文本编码器来学习多模态嵌入空间，使批次中 N 个真实配对的图像与文本嵌入之间的余弦相似度最大化，同时使 $N^2 - N$ 个错误配对的嵌入之间的余弦相似度最小化。我们在这些相似度分数上优化对称交叉熵损失。在图 3 中，我们给出了 CLIP 实现核心部分的伪代码。据我们所知，这种批次构建技术和目标最早是在深度度量学习领域以 *multi-class N-pair loss* Sohn（2016）的形式提出的，随后由 Oord 等人（2018）以 InfoNCE 损失的形式在对比表示学习中推广，并且最近由 Zhang 等人（2020）适用于医学影像领域中的对比（文本、图像）表示学习。

由于我们的预训练数据集规模很大，过拟合并不是主要问题，因此与 Zhang 等人（2020）的实现相比，CLIP 的训练细节得到了简化。我们从头开始训练 CLIP，不使用 ImageNet 权重初始化图像编码器，也不使用预训练权重初始化文本编码器。我们不使用表示与对比嵌入空间之间的非线性投影；这一改动由 Bachman 等人（2019）引入，并由 Chen 等人（2020b）推广。相反，我们只使用线性投影，将每个编码器的表示映射到多模态嵌入空间。我们没有注意到这两个版本在训练效率上存在差异，并推测在自监督表示学习方法中，非线性投影可能会与当前仅图像方法的细节共同适应。我们还移除了 Zhang 等人（2020）中的文本转换函数 t_u，该函数会从文本中均匀采样一个句子，因为 CLIP 预训练数据集中的许多（图像，文本）对只有一个句子。我们还简化了图像转换函数 t_v。训练期间使用的唯一数据增强是从调整大小后的图像中随机裁剪正方形区域。最后，控制 softmax 中 logits 范围的温度参数 τ 在训练过程中作为对数参数化的乘性标量被直接优化，以避免将其作为超参数进行调优。

2.4. 选择和扩展模型

我们考虑了两种不同的图像编码器架构。第一种使用 ResNet-50（He 等，2016a）作为图像编码器的基础架构，因为它被广泛采用且性能已得到验证。我们基于 He 等（2019）的 ResNet-D 改进以及 Zhang（2019）的抗混叠 rect-2 模糊池化，对原始版本进行了若干修改。我们还用注意力池化机制替换了全局平均池化层。注意力池化被实现为单层“transformer 风格”的多头 QKV 注意力，其中查询以全局平均池化结果为条件。

```
# image_encoder - ResNet or Vision Transformer
# text_encoder  - CBOW or Text Transformer
# I[n, h, w, c] - minibatch of aligned images
# T[n, l]       - minibatch of aligned texts
# W_i[d_i, d_e] - learned proj of image to embed
# W_t[d_t, d_e] - learned proj of text to embed
# t             - learned temperature parameter

# extract feature representations of each modality
I_f = image_encoder(I) #[n, d_i]
T_f = text_encoder(T)  #[n, d_t]

# joint multimodal embedding [n, d_e]
I_e = l2_normalize(np.dot(I_f, W_i), axis=1)
T_e = l2_normalize(np.dot(T_f, W_t), axis=1)

# scaled pairwise cosine similarities [n, n]
logits = np.dot(I_e, T_e.T) * np.exp(t)

# symmetric loss function
labels = np.arange(n)
loss_i = cross_entropy_loss(logits, labels, axis=0)
loss_t = cross_entropy_loss(logits, labels, axis=1)
loss   = (loss_i + loss_t)/2
```

图 3. CLIP 实现核心的类 Numpy 伪代码。

图像的表示。对于第二种架构，我们尝试了近期提出的视觉 Transformer（ViT）（Dosovitskiy 等，2020）。我们基本遵循其实现，仅作少量修改：在输入 Transformer 之前，对组合后的图像块嵌入和位置嵌入额外添加一层层归一化，并采用略有不同的初始化方案。

文本编码器是一个 Transformer（Vaswani 等，2017），并采用了 Radford 等（2019）中描述的架构修改。作为基础规模，我们使用了一个拥有 6300 万参数、12 层、宽度为 512 的模型，并配备 8 个注意力头。该 Transformer 对文本的小写字节对编码（BPE）表示进行操作，词表大小为 49,152（Sennrich 等，2015）。为提高计算效率，最大序列长度被限制为 76。文本序列由 [SOS] 和 [EOS] 标记括起来，并将 Transformer 最高层在 [EOS] 标记处的激活视为文本的特征表示；该表示经过层归一化后，再线性投影到多模态嵌入空间中。文本编码器中使用了带掩码的自注意力，以保留使用预训练语言模型进行初始化或将语言建模作为辅助目标的能力，不过对此的探索留待未来工作。

尽管以往的计算机视觉研究通常通过单独增加宽度（Mahajan et al., 2018）或深度（He et al., 2016a）来扩展模型，但对于 ResNet 图像编码器，我们采用了 Tan & Le（2019）的方法，该研究发现，将额外计算量分配到宽度、深度和分辨率这三者上，比仅将其分配给某一项更优。

模型的一个维度。Tan 和 Le（2019）为其 EfficientNet 架构调整分配给各个维度的计算量比例，而我们采用一个简单的基线方法：将额外的计算量平均分配给模型宽度、深度和分辨率的增加。对于文本编码器，我们只按 ResNet 宽度计算出的增幅成比例地扩展模型宽度，而完全不扩展深度，因为我们发现 CLIP 的性能对文本编码器容量的敏感性较低。

2.5. 训练

我们训练了一系列模型，包括 5 个 ResNet 和 3 个 Vision Transformer。对于 ResNet，我们训练了一个 ResNet-50、一个 ResNet-101，随后又训练了 3 个遵循 EfficientNet 风格模型缩放的模型，其计算量约为 ResNet-50 的 4 倍、16 倍和 64 倍。它们分别记为 RN50x4、RN50x16 和 RN50x64。对于 Vision Transformer，我们训练了 ViT-B/32、ViT-B/16 和 ViT-L/14。我们对所有模型训练 32 个 epoch。我们使用 Adam 优化器（Kingma & Ba, 2014），并对所有非增益或偏置的权重应用解耦权重衰减正则化（Loshchilov & Hutter, 2017），同时使用余弦调度来衰减学习率（Loshchilov & Hutter, 2016）。初始超参数是在基线 ResNet-50 模型训练 1 个 epoch 时，通过网格搜索、随机搜索和手动调优相结合的方式设定的。由于计算限制，随后通过启发式方法为更大的模型调整超参数。可学习的温度参数 τ 被初始化为（Wu et al., 2018）中 0.07 的等价值，并进行裁剪，以防止将 logits 缩放超过 100；我们发现这对于防止训练不稳定是必要的。我们使用非常大的小批量大小 32,768。使用混合精度（Micikevicius et al., 2017）来加速训练并节省内存。为了进一步节省内存，我们使用了梯度检查点（Griewank & Walther, 2000; Chen et al., 2016）、半精度 Adam 统计量（Dhariwal et al., 2020）以及采用半精度随机舍入的文本编码器权重。嵌入相似度的计算也被分片处理，各个 GPU 仅计算其本地嵌入批次所需的成对相似度子集。最大的 ResNet 模型 RN50x64 在 592 块 V100 GPU 上训练耗时 18 天，而最大的 Vision Transformer 在 256 块 V100 GPU 上训练耗时 12 天。对于 ViT-L/14，我们还以更高的 336 像素分辨率额外预训练 1 个 epoch，以类似 FixRes（Touvron et al., 2019）的方式提升性能。我们将该模型记为 ViT-L/14@336px。除非另有说明，本文中报告为“CLIP”的所有结果均使用该模型，我们发现它表现最佳。

3. 实验

3.1. 零样本迁移

3.1.1. 动机

在计算机视觉中，零样本学习通常指研究在图像分类中泛化到未见过的对象类别（Lampert 等，2009）。我们则以更广义的方式使用这一术语，并研究对未见过数据集的泛化。我们将其作为执行未见任务的代理来加以动机化，这也是 Larochelle 等人（2008）的零数据学习论文所追求的目标。尽管无监督学习领域的许多研究关注机器学习系统的 *representation learn- ing* 能力，我们则将研究零样本迁移作为衡量机器学习系统 *task- learning* 能力的一种方式。在这种观点下，一个数据集评估的是某个任务在特定分布上的性能。然而，许多流行的计算机视觉数据集主要是由研究社区作为基准创建的，用于指导通用图像分类方法的发展，而不是衡量在某个特定任务上的性能。虽然可以合理地说，SVHN 数据集衡量的是在 Google 街景照片分布上的街道门牌号转录任务，但并不清楚 CIFAR-10 数据集衡量的是什么“真实”任务。不过，很清楚的是 CIFAR-10 来源于什么分布——TinyImages（Torralba 等，2008）。在这类数据集上，零样本迁移更多是在评估 CLIP 对分布偏移和领域泛化的鲁棒性，而不是任务泛化。关于这一点的分析请参见第 3.3 节。

据我们所知，Visual N-Grams（Li 等，2017）首次以上述方式研究了向现有图像分类数据集的零样本迁移。据我们所知，它也是唯一另一项使用通用预训练模型研究向标准图像分类数据集进行零样本迁移的工作，并且是用于理解 CLIP 背景的最佳参照点。他们的方法学习一个包含 142,806 个视觉 n-gram（涵盖 1-gram 到 5-gram）的词典参数，并使用 Jelinek-Mercer 平滑的微分版本来优化这些 n-gram，以最大化给定图像的所有文本 n-gram 的概率。为了执行零样本迁移，他们首先将数据集中每个类别名称的文本转换为其 n-gram 表示，然后根据他们的模型计算其概率，并预测得分最高的类别。

我们专注于研究零样本迁移，将其作为对任务学习的评估，这一思路受到自然语言处理领域中展示任务学习的工作的启发。据我们所知，Liu 等人（2018）最早将任务学习识别为一种“意外的副作用”：一个经过训练用于生成维基百科文章的语言模型，学会了在不同语言之间可靠地音译姓名。虽然 GPT-1（Radford 等人，2018）专注于预-训练作为一种迁移学习方法，用于改进有监督微调；其中还包括一项消融研究，表明在没有任何有监督适配的情况下，四种启发式零样本迁移方法的性能在预训练过程中稳步提升。该分析成为 GPT-2（Radford 等，2019）的基础，后者专注于通过零样本迁移研究语言模型的任务学习能力。

3.1.2. 使用 CLIP 进行零样本迁移

CLIP 经过预训练，用于预测一张图像和一段文本片段是否在其数据集中配对在一起。为了进行零样本分类，我们复用了这一能力。对于每个数据集，我们将数据集中所有类别的名称作为潜在文本配对集合，并根据 CLIP 预测最可能的（图像，文本）配对。更具体地说，我们首先分别通过各自的编码器计算图像的特征嵌入，以及可能文本集合的特征嵌入。然后计算这些嵌入的余弦相似度，用温度参数 τ 进行缩放，并通过 softmax 归一化为概率分布。请注意，这一预测层是一个多项逻辑回归分类器，其输入经过 L2 归一化，权重经过 L2 归一化，无偏置，并使用温度缩放。从这种角度解释时，图像编码器是计算机视觉骨干网络，用于为图像计算特征表示；而文本编码器则是一个超网络（Ha 等，2016），它基于指定类别所代表的视觉概念的文本，生成线性分类器的权重。Lei Ba 等（2015）首次提出了这种形式的零样本图像分类器，而从自然语言生成分类器的思想至少可以追溯到 Elhoseiny 等（2013）。继续沿用这一解释，CLIP 预训练的每一步都可以被视为在优化一个随机创建的、针对计算机视觉数据集的代理任务的性能；该数据集每个类别包含 1 个样本，总共有 32,768 个通过自然语言描述定义的类别。对于零样本评估，我们在文本编码器计算出零样本分类器后将其缓存，并将其复用于所有后续预测。这使得生成该分类器的成本能够在一个数据集中的所有预测之间摊销。

3.1.3. 与视觉 N-gram 的初步比较

在表 1 中，我们将 Visual N-Grams 与 CLIP 进行了比较。最佳的 CLIP 模型将 ImageNet 上的准确率从概念验证阶段的 11.5% 提升到 76.2%，并且在没有使用该数据集可用的 128 万个众包标注训练样本的情况下，达到了原始 ResNet-50 的性能。此外，CLIP 模型的 top-5 准确率明显高于其 top-1 准确率，并且该模型的 top-5 准确率为 95%，与 Inception-V4（Szegedy 等，2016）相当。在零样本设置下能够达到强大的全监督基线的性能，这表明

	aYahoo	ImageNet	SUN
Visual N-Grams	72.4	11.5	23.0
CLIP	**98.4**	**76.2**	**58.5**

表1。将 CLIP 与先前的零样本迁移图像分类结果进行比较。CLIP 在所有三个数据集上的性能都有大幅提升。这一提升反映了自 Visual N-Grams（Li 等，2017）开发以来 4 年间的诸多差异。

CLIP 是朝着灵活且实用的零样本计算机视觉分类器迈出的重要一步。如上所述，与 Visual N-Grams 的比较旨在为 CLIP 的性能提供背景，不应被解读为 CLIP 与 Visual N-Grams 之间的直接方法比较，因为两个系统之间许多与性能相关的差异并未得到控制。例如，我们在一个大 10 倍的数据集上进行训练，使用的视觉模型在每次预测时所需的计算量接近 100 倍，训练计算量可能超过其 1000 倍，并且使用了基于 Transformer 的模型，而在 Visual N-Grams 发表时这种模型尚不存在。作为更接近的比较，我们在 Visual N-Grams 训练所用的同一个 YFCC100M 数据集上训练了一个 CLIP ResNet-50，并发现它在一个 V100 GPU 日内达到了他们报告的 ImageNet 性能。这个基线模型也是从头开始训练的，而不是像 Visual N-Grams 那样从预训练的 ImageNet 权重初始化。

在另外两个报告的数据集上，CLIP 也优于 Visual N-Grams。在 aYahoo 上，CLIP 将错误数量减少了 95%；在 SUN 上，CLIP 的准确率是 Visual N-Grams 的两倍多。为了进行更全面的分析和压力测试，我们实现了一个规模大得多的评估套件，详见附录 A。总体而言，我们从 Visual N-Grams 报告的 3 个数据集扩展到包含 30 多个数据集，并与 50 多个现有计算机视觉系统进行比较，以便对结果进行背景化分析。

3.1.4. 提示工程与集成

大多数标准图像分类数据集都将用于命名或描述类别的信息视为事后补充，而这些信息本可支持基于自然语言的零样本迁移。绝大多数数据集只是用标签的数字 ID 来标注图像，并包含一个文件将这些 ID 映射回其英文名称。一些数据集，如 Flowers102 和 GTSRB，在其发布版本中似乎根本不包含这种映射，从而完全阻碍了零样本迁移。[2] 对于许多数据集，我们观察到这些标签可能会

[2]Alec learned much more about flower species and German traffic signs over the course of this project than he originally anticipated.

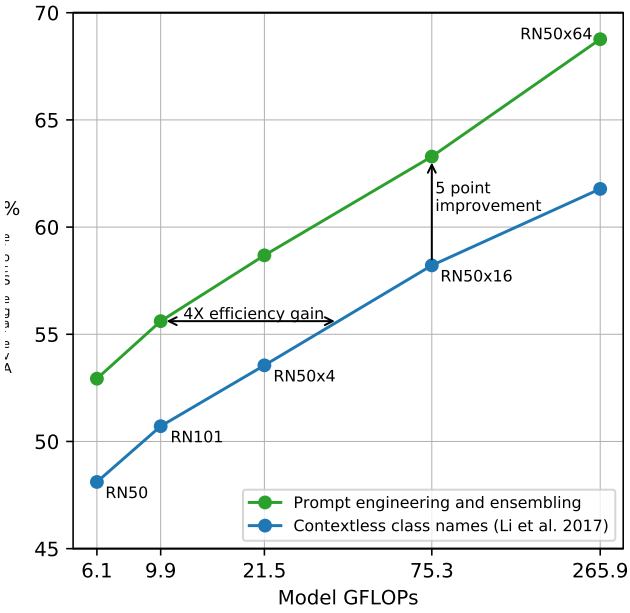


图 4. 提示工程和集成提升了零样本性能。与使用无上下文类别名称的基线相比，提示工程和集成使零样本分类性能在 36 个数据集上平均提高了近 5 个百分点。这一提升与在基线零样本方法中使用 4 倍计算量所带来的增益相当，但在分摊到大量预测上时几乎是“免费”的。

选择得有些随意，并未预见到与零样本迁移相关的问题，而零样本迁移需要依赖任务描述才能成功迁移。

一个常见问题是多义性。当提供给 CLIP 文本编码器的唯一信息是类别名称时，由于缺乏上下文，它无法区分所指的是哪个词义。在某些情况下，同一个词的多个含义甚至可能作为不同类别出现在同一个数据集中！这种情况出现在 ImageNet 中，其中既包含建筑起重机，也包含会飞的鹤。另一个例子来自 Oxford-IIIT Pet 数据集的类别，其中 boxer 这个词从上下文来看显然指的是一种犬种，但对于缺乏上下文的文本编码器来说，它同样很可能指的是一种运动员。

我们遇到的另一个问题是，在我们的预训练数据集中，与图像配对的文本仅为单个词的情况相对少见。通常，文本是以某种方式描述图像的完整句子。为了帮助弥合这种分布差距，我们发现使用提示模板“A photo of a {label}.”是一个不错的默认选择，有助于明确文本是关于图像内容的。与仅使用标签文本的基线相比，这通常能提升性能。例如，仅使用这个提示就能将 ImageNet 上的准确率提高 1.3%。

类似于围绕 GPT-3 的“提示工程”讨论（Brown et al., 2020；Gao et al., 2020），我们也观察到，通过针对每项任务定制提示文本，可以显著提升零样本性能。以下是一些非穷尽的例子。我们在多个细粒度图像分类数据集上发现，明确指定类别会有所帮助。例如，在 Oxford-IIIT Pets 上，使用“一张{标签}的照片，一种宠物。”来帮助提供上下文，效果很好。同样，在 Food101 上指定 *a type of food*，以及在 FGVC Aircraft 上指定 *a type of aircraft* 也有帮助。对于 OCR 数据集，我们发现给要识别的文本或数字加上引号可以提升性能。最后，我们发现，在卫星图像分类数据集上，明确说明图像属于这种形式会有所帮助，因此我们使用了“一张{标签}的卫星照片。”的变体。

我们还尝试了对多个零样本分类器进行集成，作为提升性能的另一种方式。这些分类器是通过使用不同的上下文提示来计算的，例如“A photo of a big {label}”和“A photo of a small {label}”。我们在嵌入空间而不是概率空间中构建集成。这样我们就可以缓存一组平均后的文本嵌入，因此当在大量预测上摊销时，集成的计算成本与使用单个分类器相同。我们观察到，对许多生成的零样本分类器进行集成能够可靠地提升性能，并将其用于大多数数据集。在 ImageNet 上，我们集成了 80 个不同的上下文提示，相比上述单一默认提示，性能额外提升了 3.5%。综合来看，提示工程和集成使 ImageNet 准确率提高了近 5%。在图 4 中，我们可视化了提示工程和集成如何改变一组 CLIP 模型的性能，并将其与无上下文的基线方法进行比较；该基线方法直接将类别名称嵌入，正如 Li 等人（2017）所做的那样。

3.1.5. 零样本 CLIP 性能分析

由于用于计算机视觉的任务无关零样本分类器研究不足，CLIP 提供了一个很有前景的机会，使我们能够更好地理解这类模型。在本节中，我们研究 CLIP 零样本分类器的各种属性。作为第一个问题，我们首先简单考察零样本分类器的表现如何。为了提供背景参考，我们将其与一个简单的现成基线进行比较：在标准 ResNet-50 的特征上拟合一个全监督、正则化的逻辑回归分类器。图 5 展示了在 27 个数据集上的这一比较。有关数据集和设置的详细信息，请参见附录 A。

零样本 CLIP 的表现略微优于这一基线，幅度更大一些-

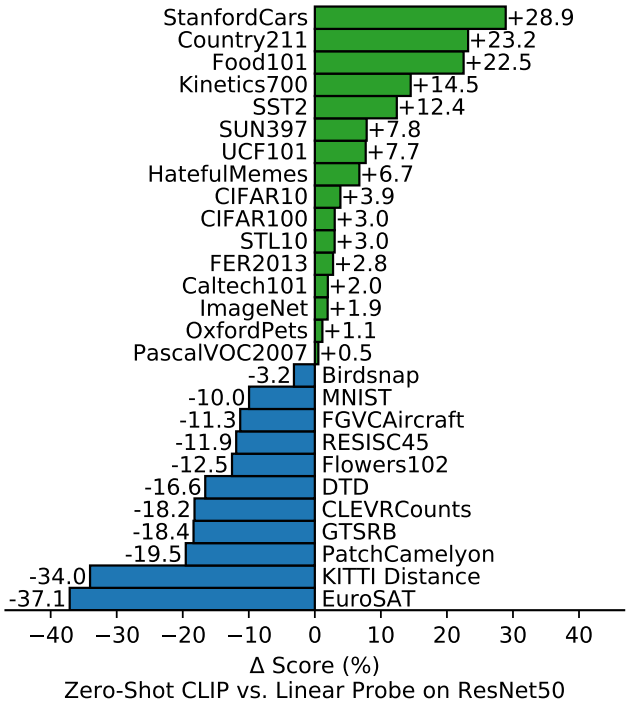


图 5. 零样本 CLIP 可与全监督基线相媲美。在包含 27 个数据集的评估套件中，零样本 CLIP 分类器在 16 个数据集上优于基于 ResNet-50 特征拟合的全监督线性分类器，其中包括 ImageNet。

超过不及，并在 27 个数据集中的 16 个上获胜。观察单个数据集会发现一些有趣的现象。在细粒度分类任务上，我们观察到性能差异很大。在其中两个数据集 Stanford Cars 和 Food101 上，零样本 CLIP 比基于 ResNet-50 特征的逻辑回归高出 20% 以上；而在另外两个数据集 Flowers102 和 FGVCAircraft 上，零样本 CLIP 则低于其 10% 以上。在 OxfordPets 和 Birdsnap 上，性能则接近得多。我们怀疑这些差异主要源于 WIT 和 ImageNet 之间每项任务监督量的不同。在 ImageNet、CIFAR10/100、STL10 和 PascalVOC2007 等“通用”目标分类数据集上，性能相对相似，且在所有情况下零样本 CLIP 都略占优势。在 STL10 上，CLIP 的总体准确率达到 99.3%，尽管没有使用任何训练样本，但这似乎是新的最先进水平。零样本 CLIP 在两个用于衡量视频动作识别的数据集上显著优于 ResNet-50。在 Kinetics700 上，CLIP 比 ResNet-50 高出 14.5%。在 UCF101 上，零样本 CLIP 也比 ResNet-50 的特征高出 7.7%。我们推测，这是因为与 ImageNet 中以名词为中心的对象监督相比，自然语言为涉及动词的视觉概念提供了更广泛的监督。

观察零样本 CLIP 明显表现不佳的情况，

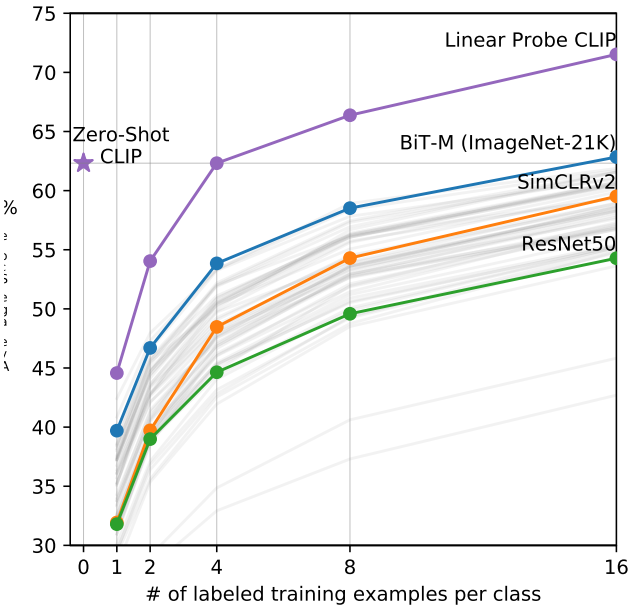


图 6. 零样本 CLIP 优于少样本线性探针。零样本 CLIP 的平均性能与在相同特征空间上训练的 4-shot 线性分类器相当，并且在公开可用模型中几乎达到 16-shot 线性分类器的最佳结果。对于 BiT-M 和 SimCLRv2，突出显示了性能最佳的模型。浅灰色线表示评估套件中的其他模型。本分析使用了每类至少包含 16 个样本的 20 个数据集。

我们看到，零样本 CLIP 在若干专业、复杂或抽象任务上表现相当薄弱，例如卫星图像分类（EuroSAT 和 RESISC45）、淋巴结肿瘤检测（PatchCamelyon）、合成场景中的物体计数（CLEVRCounts）、与自动驾驶相关的任务，如德国交通标志识别（GTSRB）、识别到最近汽车的距离（KITTI Distance）。这些结果凸显了零样本 CLIP 在更复杂任务上的能力不足。相比之下，非专业人类能够稳健地完成其中若干任务，例如计数、卫星图像分类和交通标志识别，这表明仍有显著的改进空间。然而，我们也提醒，对于学习者此前没有任何经验的困难任务，例如对几乎所有人类（也可能包括 CLIP）而言的淋巴结肿瘤分类，衡量零样本迁移而非少样本迁移是否是一种有意义的评估，目前尚不清楚。

将零样本性能与全监督模型进行比较，有助于为 CLIP 的任务学习能力提供背景；而与少样本方法进行比较则是更直接的比较，因为零样本是其极限。在图 6 中，我们可视化了零样本 CLIP 与基于多种图像模型特征的少样本逻辑回归之间的比较，这些图像模型包括公开可用的最佳 ImageNet 模型、自监督学习方法以及 CLIP 本身。虽然直觉上可以认为预期零样本会不如单样本表现好，但我们反而发现，在相同的特征空间上，零样本 CLIP 的性能与 4 样本逻辑回归相当。这很可能是由于零样本方法和少样本方法之间存在一个重要差异。首先，CLIP 的零样本分类器是通过自然语言生成的，这使得视觉概念可以被直接指定（“传达”）。相比之下，“常规”的监督学习必须从训练样本中间接推断概念。无上下文的基于示例的学习有一个缺点：许多不同的假设都可能与数据一致，尤其是在单样本情况下。一张图像通常包含许多不同的视觉概念。尽管有能力的学习器能够利用视觉线索和启发式方法，例如假设所展示的概念是图像中的主要物体，但这并没有保证。

解决零样本与少样本性能之间这种差异的一种潜在方法，是将 CLIP 的零样本分类器用作少样本分类器权重的先验。虽然向生成的权重添加 L2 惩罚是实现这一想法的一种直接方式，但我们发现，超参数优化往往会选择一个非常大的正则化系数，以至于最终得到的少样本分类器“其实”就是零样本分类器。如何更好地结合零样本迁移的优势与少样本学习的灵活性，是未来工作中一个很有前景的研究方向。

在将零样本 CLIP 与基于其他模型特征的少样本逻辑回归进行比较时，零样本 CLIP 的性能大致相当于我们评估套件中表现最佳的 16-shot 分类器；该分类器使用的是在 ImageNet-21K 上训练的 BiT-M ResNet-152x2 的特征。我们确信，在 JFT-300M 上训练的 BiT-L 模型会表现得更好，但这些模型尚未公开发布。BiT-M ResNet-152x2 在 16-shot 设置下表现最佳这一点有些令人意外，因为正如第 3.2 节所分析的，在全监督设置下，Noisy Student EfficientNet-L2 在 27 个数据集上的平均表现比它高出近 5%。

除了研究零样本 CLIP 和少样本逻辑回归的平均性能外，我们还考察了其在各个单独数据集上的表现。在图 7 中，我们给出了在相同特征空间上，逻辑回归分类器为了达到零样本 CLIP 的性能，每个类别所需标注样本数量的估计。由于零样本 CLIP 本身也是一种线性分类器，因此这估计了在该设置下零样本迁移的有效数据效率。为了避免训练数千个线性分类器，我们基于在每个数据集上训练的 1、2、4、8、16-shot（在可能的情况下）以及全监督线性分类器的性能进行对数线性插值，从而估计有效数据效率。我们发现，零样本迁移可以

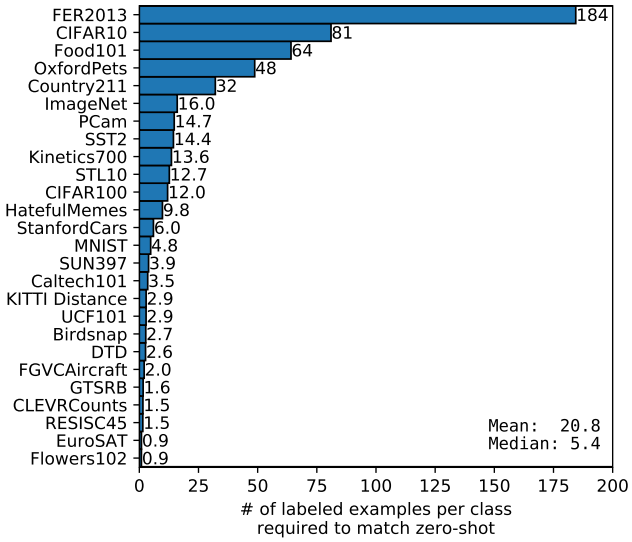


图 7. 零样本迁移的数据效率差异很大。通过计算在相同 CLIP 特征空间上线性分类器每个类别需要多少个标注样本才能达到零样本分类器的性能，可以更好地理解零样本迁移的有效性。数值基于 1、2、4、8、16-shot 以及全监督结果的对数线性插值估计得到。性能差异很大：在两个数据集上仍不如 one-shot 分类器，而在另一些情况下则相当于每类约 184 个标注样本的效果。

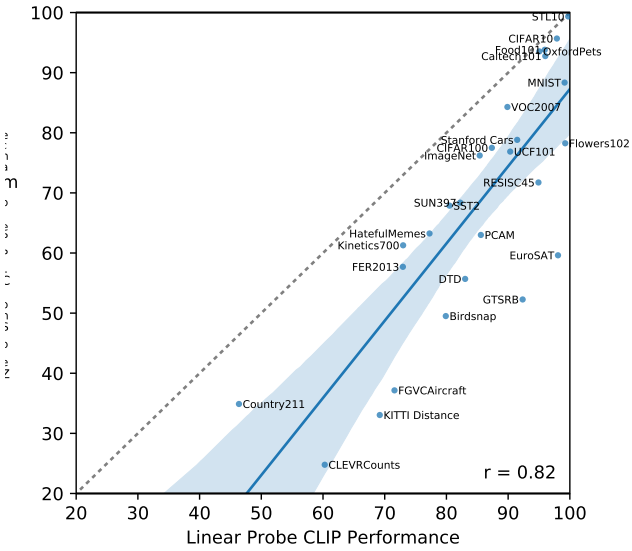


图 8. 零样本性能与线性探针性能相关，但总体上仍大多次优。比较各数据集上的零样本和线性探针性能显示，两者具有很强的相关性，而零样本性能大多低 10 到 25 个百分点。只有在 5 个数据集上，零样本性能接近线性探针性能（≤3 个百分点差异）。

各数据集之间的数据效率差异很大，从每类少于 1 个标注样本到 184 个不等。有两个数据集 Flowers102 和 EuroSAT 的表现不如 one-shot 模型。半数数据集每类所需样本少于 5 个，中位数为 5.4。然而，估计的平均数据效率为每类 20.8 个样本。这是因为在 20% 的数据集中，监督分类器需要每类大量标注样本才能达到相当的性能。在 ImageNet 上，零样本 CLIP 的性能与在同一特征空间上训练的 16-shot 线性分类器相当。

如果我们假设评估数据集足够大，以至于在其上训练的线性分类器的参数能够得到良好估计，那么，由于 CLIP 的零样本分类器也是一个线性分类器，完全监督分类器的性能大致为零样本迁移所能达到的水平设定了一个上限。在图 8 中，我们比较了 CLIP 的零样本性能与各数据集上的完全监督线性分类器性能。虚线 $y = x$ 表示一种“最优”的零样本分类器，其性能与对应的完全监督分类器相匹配。对于大多数数据集，零样本分类器的性能仍比完全监督分类器低 10% 到 25%，这表明在提升 CLIP 的任务学习和零样本迁移能力方面仍有很大的改进空间。

零样本性能与全监督性能之间存在 0.82 的正相关（p 值 $< 10^{-6}$）。

表现，这表明 CLIP 在将底层表示和任务学习与零样本迁移相连接方面相对一致。然而，零样本 CLIP 仅在 5 个数据集上接近全监督性能：STL10、CIFAR10、Food101、OxfordPets 和 Caltech101。在所有这 5 个数据集上，零样本准确率和全监督准确率都超过 90%。这表明，对于其底层表示质量也很高的任务，CLIP 的零样本迁移可能更有效。一个以全监督性能为函数来预测零样本性能的线性回归模型的斜率估计表明，全监督性能每提高 1%，零样本性能就提高 1.28%。然而，第 95 百分位置信区间仍然包含小于 1 的值（0.93-1.79）。

在过去几年中，深度学习系统的实证研究表明，性能可以作为训练计算量和数据集规模等重要量的函数来预测（Hestness 等，2017；Kaplan 等，2020）。到目前为止，GPT 系列模型已经证明，随着训练计算量增加 1000 倍，零样本性能持续提升。在图 9 中，我们检查 CLIP 的零样本性能是否遵循类似的缩放模式。我们绘制了 5 个 ResNet CLIP 模型在 36 个不同数据集上的 39 项评估中的平均错误率，并发现随着模型计算量增加 44 倍，CLIP 也呈现出类似的双对数线性缩放趋势。尽管整体趋势是平滑的，但我们发现单项评估中的性能可能要嘈杂得多。我们不确定是否

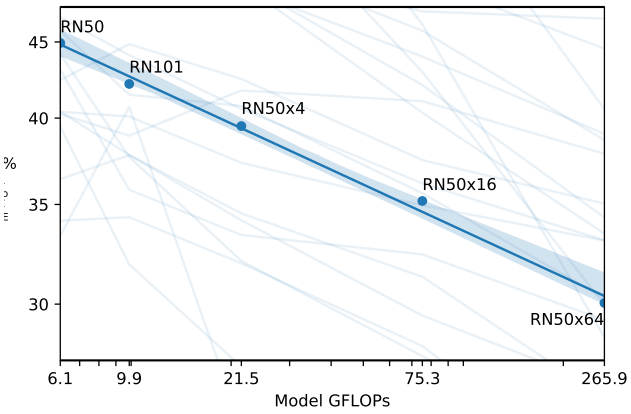


图 9. 零样本 CLIP 性能会随着模型计算量的增加而平滑提升。在 36 个不同数据集上的 39 项评估中，平均零样本错误率可以很好地用对数-对数线性趋势来建模，该趋势覆盖了 5 个不同 CLIP 模型、跨度达 44 倍的计算量范围。浅色线条表示各个评估上的性能，显示尽管总体趋势平滑，但性能差异要大得多。

这是由于子任务上各个训练运行之间的高方差（如 D’Amour 等人（2020）所记录）掩盖了持续改进的趋势，还是在某些任务上性能实际上是计算量的非单调函数。

3.2. 表征学习

虽然我们在上一节中通过零样本迁移广泛分析了 CLIP 的任务学习能力，但研究模型的表征学习能力更为常见。评估表征质量的方法有很多，对于“理想”表征应具备哪些属性也存在分歧（Locatello 等，2020）。一种常见方法是，在从模型中提取的表征上拟合线性分类器，并衡量其在各种数据集上的性能。另一种方法是衡量对模型进行端到端微调后的性能。这提高了灵活性，而且先前的工作已经令人信服地证明，在大多数图像分类数据集上，微调优于线性分类（Kornblith 等，2019；Zhai 等，2019）。尽管微调的高性能出于实际原因促使人们对其进行研究，但我们仍然出于若干原因选择基于线性分类器的评估。我们的工作重点是开发一种高性能、与任务和数据集无关的预训练方法。微调由于会在微调阶段针对每个数据集调整表征，因此可以弥补并可能掩盖在预训练阶段未能学习到通用且鲁棒表征的问题。相比之下，线性分类器由于灵活性有限，会凸显这些失败之处，并在开发过程中提供清晰的反馈。对于 CLIP，训练有监督的线性分类器还有一个额外好处，即它与用于零样本分类器的方法非常相似，这使得第 3.1 节中的广泛比较和分析成为可能。最后，我们旨在将 CLIP 与一组全面的现有模型在多个任务上进行比较。在 27 个不同数据集上研究 66 个不同模型，需要调优 1782 次不同的评估。微调会打开一个更大的设计和超参数空间，这使得公平评估变得困难，并且在比较多种不同技术时计算成本高昂，正如其他大规模实证研究中所讨论的那样（Lucic et al., 2018; Choi et al., 2019）。相比之下，线性分类器只需要最少的超参数调优，并且具有标准化的实现和评估流程。有关评估的更多细节，请参见附录 A。

图 10 总结了我们的发现。为尽量减少可能引发确认偏差或报告偏差担忧的选择效应，我们首先研究了 Kornblith 等人（2019）提出的 12 个数据集评估套件上的性能。尽管较小的 CLIP 模型（如 ResNet-50 和 ResNet-101）优于其他在 ImageNet-1K 上训练的 ResNet（BiT-S 以及原始模型），但它们不如在 ImageNet-21K 上训练的 ResNet（BiT-M）。这些小型 CLIP 模型的表现也不及计算需求相近的 EfficientNet 系列模型。然而，使用 CLIP 训练的模型具有很好的可扩展性，我们训练的最大模型（ResNet-50x64）在总体得分和计算效率上都略微超过了现有表现最佳的模型（Noisy Student EfficientNet-L2）。我们还发现，CLIP 视觉 Transformer 的计算效率约为 CLIP ResNet 的 3 倍，这使我们能够在计算预算内达到更高的整体性能。这些结果在定性上复现了 Dosovitskiy 等人（2020）的发现，即当在足够大的数据集上训练时，视觉 Transformer 比卷积网络更具计算效率。我们整体表现最好的模型是 ViT-L/14，它在我们的数据集上以 336 像素的更高分辨率额外微调了 1 个 epoch。该模型在这一评估套件中平均比现有最佳模型高出 2.6%。

如图 21 定性所示，CLIP 模型学习到的任务范围，比以往在一个从随机初始化开始端到端训练的单一计算机视觉模型中所展示的更广。这些任务包括地理定位、光学字符识别、面部情绪识别和动作识别。Kornblith 等人（2019）的评估套件中并未衡量这些任务。这可以被认为是 Kornblith 等人（2019）的研究中存在的一种选择偏差，即偏向于与 ImageNet 重叠的任务。为了解决这一问题，我们还在一个更广泛的、包含 27 个数据集的评估套件上衡量性能。该评估套件详见附录 A，其中包括代表上述任务的数据集、德国交通标志识别基准（Stallkamp 等人，2011），以及从 VTAB（Zhai 等人，2019）改编的其他几个数据集。

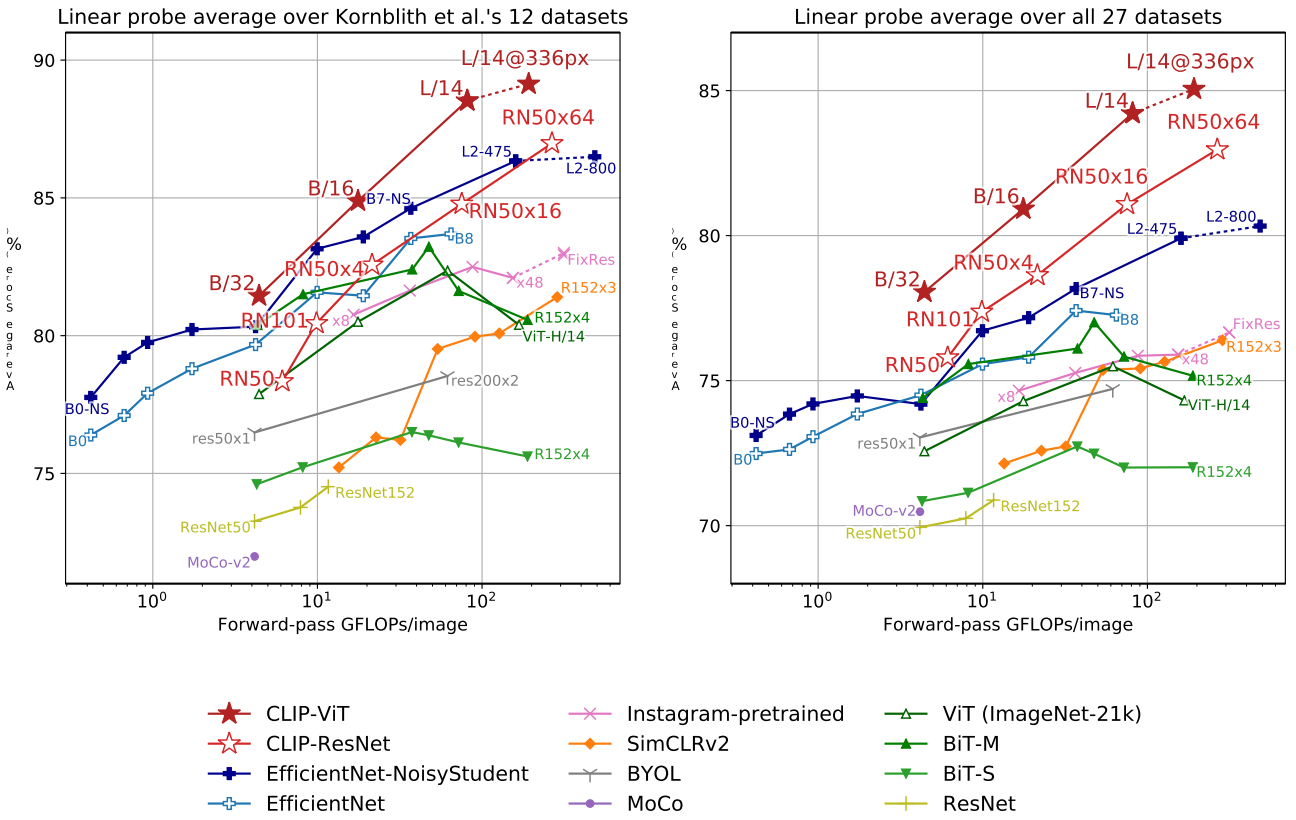


图 10. CLIP 模型与最先进的计算机视觉模型在线性探针性能上的比较，包括 EfficientNet（Tan & Le，2019；Xie 等，2020）、MoCo（Chen 等，2020d）、在 Instagram 上预训练的 ResNeXt 模型（Mahajan 等，2018；Touvron 等，2019）、BiT（Kolesnikov 等，2019）、ViT（Dosovitskiy 等，2020）、SimCLRv2（Chen 等，2020c）、BYOL（Grill 等，2020）以及原始 ResNet 模型（He 等，2016b）。（左）分数是在 Kornblith 等（2019）研究的 12 个数据集上取平均得到的。（右）分数是在包含更广泛分布类型的 27 个数据集上取平均得到的。虚线表示在高于预训练分辨率的图像上进行微调或评估的模型。各项分数见表 10，各数据集的图见图 20。

在这个更广泛的评估套件上，CLIP 的优势更加明显。所有 CLIP 模型，无论规模大小，在计算效率方面都优于所有被评估的系统。最佳模型相较于以往系统的平均得分提升从 2.6% 增加到 5%。我们还发现，自监督系统在我们更广泛的评估套件上表现明显更好。例如，尽管 SimCLRv2 在 Kornblith 等人（2019）的 12 个数据集上的平均表现仍不如 BiT-M，但在我们的 27 个数据集评估套件上，SimCLRv2 的表现超过了 BiT-M。这些发现表明，应继续扩大任务多样性和覆盖范围，以便更好地理解系统的“通用”性能。我们认为，沿着 VTAB 思路开展更多评估工作将是有价值的。

除了上述汇总分析外，我们还在图 11 中可视化了最佳 CLIP 模型与我们评估套件中最佳模型在全部 27 个数据集上的逐数据集性能差异。CLIP 在 27 个数据集中的 21 个上优于 Noisy Student EfficientNet-L2。CLIP 在需要 OCR 的任务上提升最大（SST2 和 HatefulMemes）、地理定位与场景识别（Country211、SUN397），以及视频中的动作识别（Kinetics700 和 UCF101）。此外，CLIP 在细粒度汽车和交通标志识别（Stanford Cars 和 GTSRB）上也表现得好得多。这可能反映了 ImageNet 中监督信号过于狭窄的问题。比如在 GTSRB 上提升 14.7% 这样的结果，可能表明 ImageNet-1K 存在问题，因为它对所有交通和街道标志只有一个标签。这可能会促使有监督表征压缩类内细节，并损害其在细粒度下游任务上的准确率。如前所述，CLIP 在若干数据集上的表现仍不如 EfficientNet。不出所料，相对于 CLIP，EfficientNet 表现最好的数据集正是它的训练数据集：ImageNet。EfficientNet 在 CIFAR10 和 CIFAR100 等低分辨率数据集上也略优于 CLIP。我们怀疑这至少部分是由于 CLIP 缺乏基于尺度的数据增强。EfficientNet 在 PatchCamelyon 和 CLEVRCounts 上也略有优势，而这些数据集上的整体性能仍然

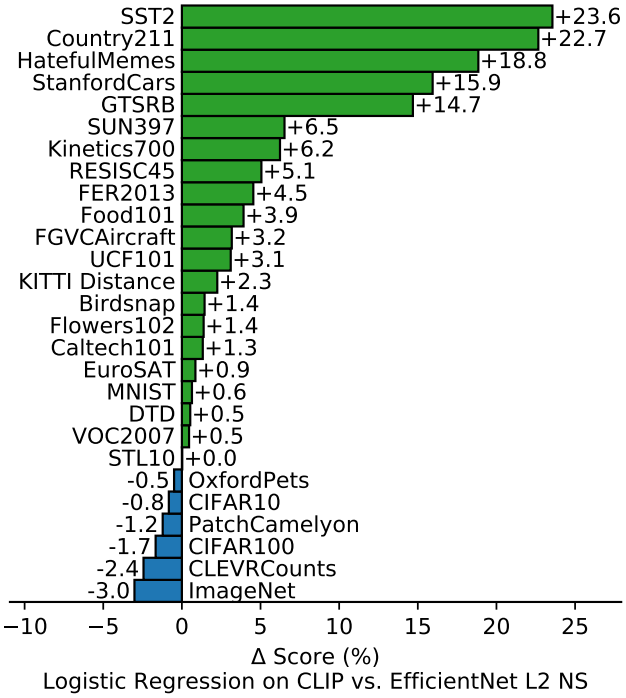


图 11。CLIP 的特征在各种数据集上优于最佳 ImageNet 模型的特征。在 CLIP 的特征上拟合线性分类器，在 27 个数据集中的 21 个上优于使用 Noisy Student EfficientNet-L2。

两种方法都较低。

3.3. 对自然分布偏移的鲁棒性

2015 年，有报道称一个深度学习模型在 ImageNet 测试集上的表现超过了人类水平（He et al., 2015）。然而，随后几年的研究反复发现，这些模型仍然会犯许多简单错误（Dodge & Karam, 2017；Geirhos et al., 2018；Alcorn et al., 2019），而用于测试这些系统的新基准也常常发现，它们的性能远低于其 ImageNet 准确率和人类准确率（Recht et al., 2019；Barbu et al., 2019）。是什么解释了这种差异？人们提出并研究了各种观点（Ilyas et al., 2019；Geirhos et al., 2020）。这些解释的一个共同主题是，深度学习模型极其擅长发现贯穿其训练数据集的相关性和模式，从而提高分布内性能。然而，这些相关性和模式中有许多实际上是伪相关，并不适用于其他分布，导致在其他数据集上的性能大幅下降。

我们提醒读者，迄今为止，这些研究中的大多数都将其评估限制在使用 ImageNet 训练的模型上。回想讨论的主题，过度泛化这些初步发现可能是一个错误。这些失败在多大程度上可归因于深度学习、ImageNet，或某些两者的结合？CLIP 模型通过在超大规模数据集上进行自然语言监督训练，具备很强的零样本性能，为从不同角度研究这一问题提供了机会。

Taori 等人（2020）是一项近期的综合性研究，旨在朝着量化和理解 ImageNet 模型这些行为的方向迈进。Taori 等人（2020）研究了在 *natural distribution shifts* 上评估时 ImageNet 模型的性能如何变化。他们在一组包含 7 种分布偏移的数据集上衡量性能：ImageNetV2（Recht 等人，2019）、ImageNet Sketch（Wang 等人，2019）、Youtube-BB 和 ImageNet-Vid（Shankar 等人，2019）、ObjectNet（Barbu 等人，2019）、ImageNet Adversarial（Hendrycks 等人，2019）以及 ImageNet Rendition（Hendrycks 等人，2020a）。他们将这些数据集与 *synthetic distri- bution shifts* 区分开来；前者都由从各种来源收集的新图像组成，而后者如 ImageNet-C（Hendrycks & Dietterich，2019）、Stylized ImageNet（Geirhos 等人，2018）或对抗攻击（Goodfellow 等人，2014），则是通过以各种方式扰动现有图像而创建的。他们提出这种区分，部分原因是他们发现，尽管已有若干技术被证明可以提升在合成分布偏移上的性能，但它们往往无法在自然分布上带来一致的改进。[3]

在这些收集的数据集上，ImageNet 模型的准确率远低于 ImageNet 验证集所设定的预期。在以下总结性讨论中，除非另有说明，我们报告所有 7 个自然分布偏移数据集上的平均准确率，以及 ImageNet 中相应类别子集上的平均准确率。此外，对于 Youtube-BB 和 ImageNet-Vid 这两个具有不同评估设置的数据集，我们使用 pm-0 和 pm-10 准确率的平均值。

与 ImageNet 验证集相比，ResNet-101 在这些自然分布偏移上进行评估时，错误数量增加了 5 倍。不过令人鼓舞的是，Taori 等人（2020）发现，分布偏移下的准确率会随着 ImageNet 准确率以可预测的方式提高，并且可以很好地建模为经过 logit 变换的准确率的线性函数。Taori 等人（2020）利用这一发现提出，鲁棒性分析应区分 *effective* 鲁棒性和 *relative* 鲁棒性。有效鲁棒性衡量的是，在分布偏移下，准确率相对于由已记录的分布内准确率与分布外准确率之间关系所预测的水平的提升。相对鲁棒性则捕捉分布外准确率的任何提升。Taori 等人（2020）认为，鲁棒性技术应旨在同时提高有效鲁棒性和相对鲁棒性。

Taori 等人（2020）研究的几乎所有模型都经过了训练

[3]We refer readers to Hendrycks et al. (2020a) for additional experiments and discussion on this claim.

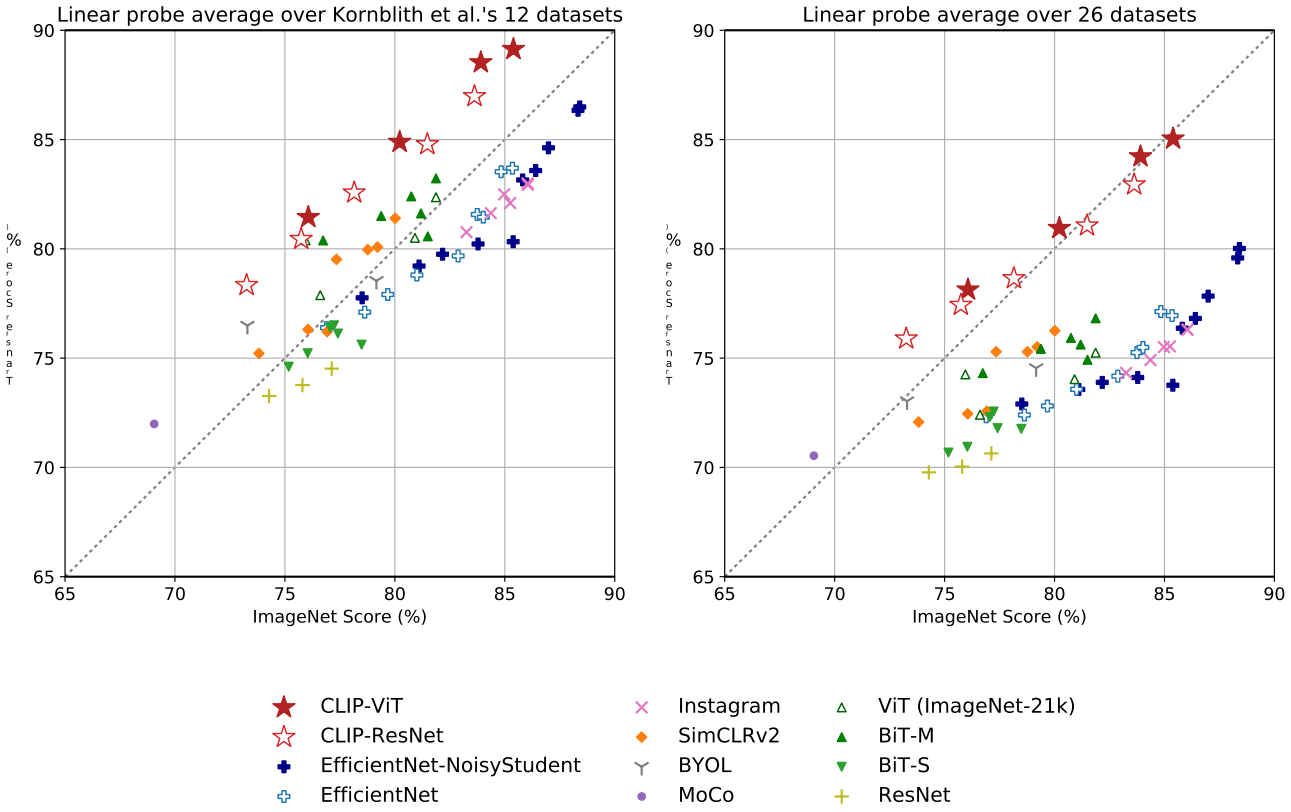


图 12。与在 ImageNet 上预训练的模型相比，CLIP 的特征对任务转移更加鲁棒。对于两个数据集划分，在 CLIP 模型表征上训练的线性探针的迁移得分都高于具有相似 ImageNet 性能的其他模型。这表明，在 ImageNet 上训练的模型的表征在某种程度上对其任务过拟合。

或在 ImageNet 数据集上进行微调。回到本节引言中的讨论——在 ImageNet 数据集分布上进行训练或适配，是否是导致所观察到的鲁棒性差距的原因？直观地说，零样本模型不应能够利用仅在特定分布上成立的虚假相关性或模式，因为它并未在该分布上进行训练。[4] 因此，有理由预期零样本模型具有高得多的有效鲁棒性。在图 13 中，我们将零样本 CLIP 与现有 ImageNet 模型在自然分布偏移下的性能进行了比较。所有零样本 CLIP 模型都大幅提高了有效鲁棒性，并将 ImageNet 准确率与分布偏移下准确率之间的差距最多缩小了 75%。

虽然这些结果表明零样本模型可以更加鲁棒，但它们并不一定意味着在 ImageNet 上进行监督学习会导致鲁棒性差距。CLIP 的其他细节，例如其庞大且多样化的预训练数据集或对自然语言监督的使用，也可能导致这种结果。

[4]We caution that a zero-shot model can still exploit spurious correlations that are shared between the pre-training and evaluation distributions.

无论这些模型是零样本还是经过微调的，它们都要稳健得多。作为一个可能开始缩小这一问题范围的初步实验，我们还测量了在通过一个 L2 正则化的逻辑回归分类器适配 ImageNet 分布后，CLIP 模型的性能如何变化；该分类器是在 ImageNet 训练集上的 CLIP 特征上拟合得到的。我们在图 14 中可视化了相对于零样本分类器的性能变化。尽管将 CLIP 适配到 ImageNet 分布后，其 ImageNet 准确率总体提高了 9.2%，达到 85.4%，并追平了 Mahajan 等人（2018）在 2018 年的 SOTA 准确率，*average accuracy under distribution shift slightly decreases*。

令人惊讶的是，准确率提高了 9.2%（这大约相当于 SOTA 约 3 年的进步），却未能转化为分布偏移下平均性能的任何提升。我们还在图 14 中按数据集分解了零样本准确率与线性分类器准确率之间的差异，发现性能仍然在一个数据集 ImageNetV2 上显著提高。ImageNetV2 紧密遵循了原始 ImageNet 数据集的创建过程，这表明通过监督式适应获得的准确率提升高度集中在 ImageNet 分布附近。性能在上下降了 4.7%

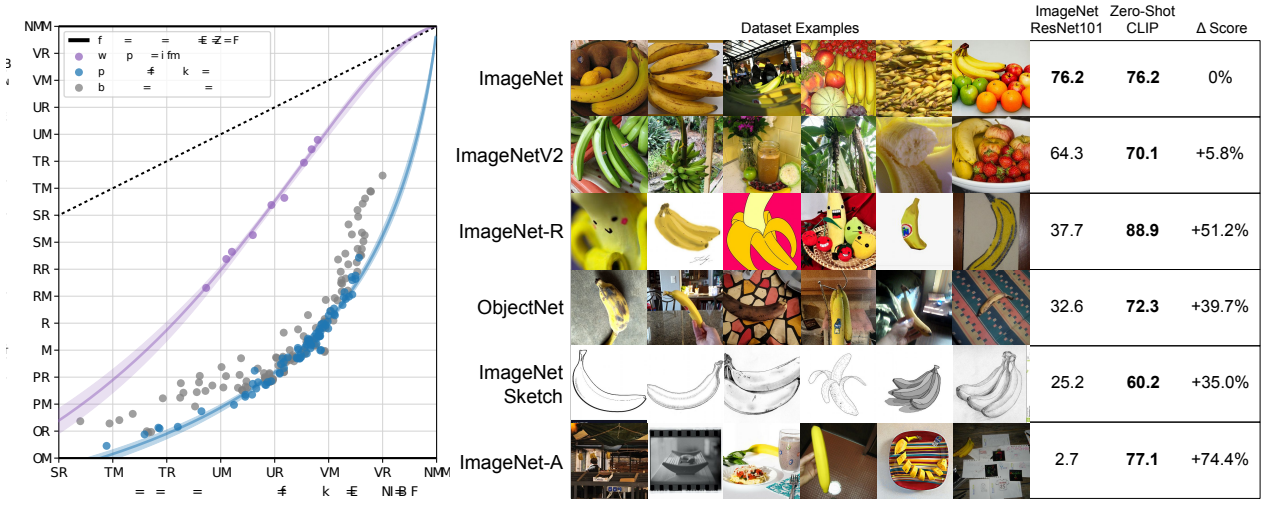


图 13. 零样本 CLIP 比标准 ImageNet 模型对分布偏移更加鲁棒。（左）理想的鲁棒模型（虚线）在 ImageNet 分布和其他自然图像分布上表现同样出色。零样本 CLIP 模型将这种“鲁棒性差距”最多缩小了 75%。图中显示了对 logit 变换值进行的线性拟合，并给出了通过自助法估计的 95% 置信区间。（右）对香蕉类别的分布偏移进行可视化；香蕉是 7 个自然分布偏移数据集中有 5 个都包含的共享类别。将最佳零样本 CLIP 模型 ViT-L/14@336px 的性能与在 ImageNet 验证集上具有相同性能的模型 ResNet-101 进行比较。

在 ImageNet-R 上为 3.8%，在 ObjectNet 上为 2.8%，在 ImageNet Sketch 上为 1.9%，在 ImageNet-A 上。其他两个数据集 Youtube-BB 和 ImageNet Vid 上的准确率变化并不显著。

如何可能在 ImageNet 数据集上的准确率提高 9.2%，而在分布偏移下准确率几乎没有提高？这种增益主要来自“利用虚假相关性”吗？这种行为是 CLIP、ImageNet 数据集以及所研究的分布偏移的某种组合所独有的，还是一种更普遍的现象？它是否同样适用于端到端微调和线性分类器？目前我们还无法自信地回答这些问题。此前的工作也曾在 ImageNet 以外的分布上预训练模型，但通常只在这些模型被微调到 ImageNet 之后才对其进行研究并发布。作为理解预训练零样本模型是否始终比微调模型具有更高有效鲁棒性的一步，我们鼓励 Mahajan 等人（2018）、Kolesnikov 等人（2019）和 Dosovitskiy 等人（2020）的作者，如果可能的话，也在他们的模型上研究这些问题。

我们还研究了另一种鲁棒性干预方法，该方法由灵活的、基于自然语言的零样本图像分类器所支持。7 个迁移数据集中的目标类别并不总是与 ImageNet 的类别完全对齐。其中两个数据集，Youtube-BB 和 ImageNet-Vid，由 ImageNet 的超类组成。当试图使用 ImageNet 模型固定的 1000 类分类器进行预测时，这会带来问题。Taori 等人（2020）通过最大-

根据 ImageNet 类别层次结构汇集所有子类的预测。有时这种映射远非完美。对于 Youtube-BB 中的 person 类别，预测是通过汇集 ImageNet 中 baseball player、bridegroom 和 scuba diver 这些类别来完成的。使用 CLIP，我们则可以直接基于每个数据集的类别名称，为其生成一个自定义的零样本分类器。在图 14 中，我们看到这使平均有效鲁棒性提高了 5%，但这种提升主要集中在少数几个数据集上的大幅改进。令人好奇的是，ObjectNet 上的准确率也提高了 2.3%。尽管该数据集的设计目的是与 ImageNet 类别高度重叠，但与使用 ImageNet 类别名称并在必要时汇集预测相比，使用 ObjectNet 创建者为每个类别提供的名称仍然带来了一点帮助。

虽然零样本 CLIP 提高了有效鲁棒性，但图 14 显示，在完全监督设置下，这一收益几乎完全消失。为了更好地理解这种差异，我们研究了从零样本到完全监督这一连续范围内有效鲁棒性如何变化。在图 15 中，我们可视化了基于最佳 CLIP 模型特征的 0-shot、1-shot、2-shot、4-shot……128-shot 以及完全监督逻辑回归分类器的性能。我们看到，虽然少样本模型也比现有模型表现出更高的有效鲁棒性，但随着训练数据增多、分布内性能提升，这一收益逐渐减弱，并且在完全监督模型中基本消失，尽管并非完全消失。此外，零样本 CLIP 明显比具有相同 ImageNet 性能的少样本模型更加鲁棒。

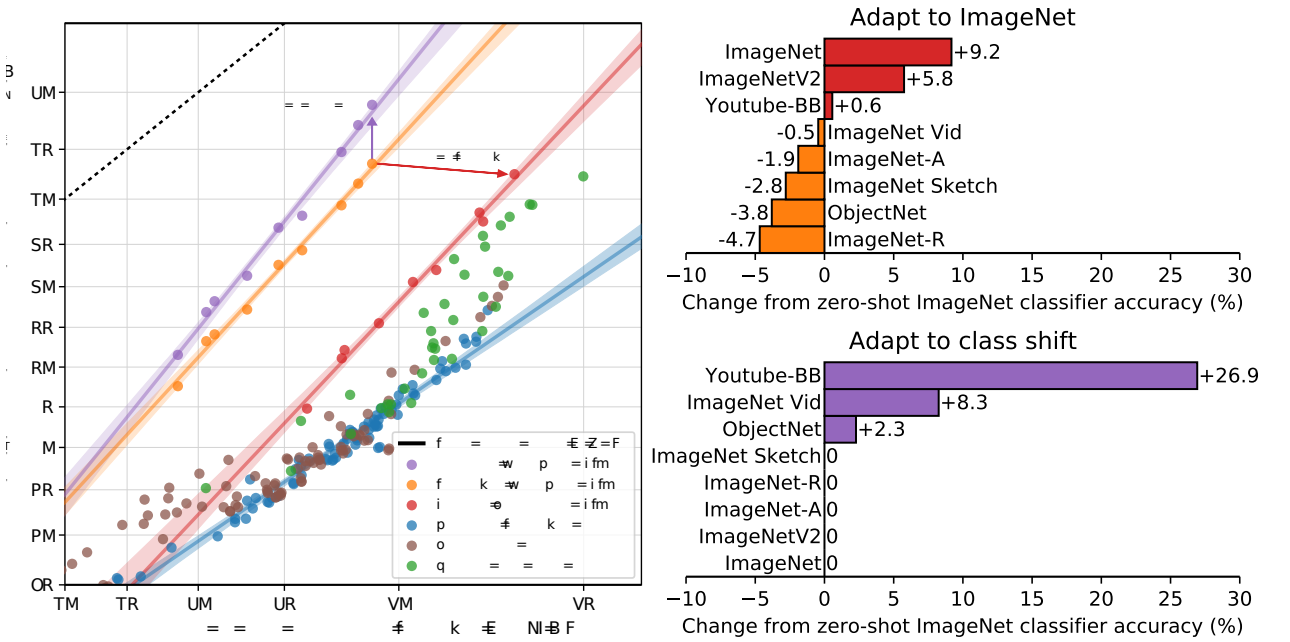


图 14。虽然对 ImageNet 进行有监督适应使 ImageNet 准确率提高了 9.2%，但它略微降低了平均鲁棒性。（左）与使用单一静态的零样本 ImageNet 分类器，并像 Taori 等人（2020）那样在相似类别之间汇总预测相比，将零样本 CLIP 定制到每个数据集可提高鲁棒性。适应 ImageNet 的 CLIP 模型具有与此前最佳 ImageNet 模型相近的有效鲁棒性。（右）两种鲁棒性干预措施在各数据集上准确率变化的细节。适应 ImageNet 会显著提高 ImageNetV2 上的准确率，但会以牺牲其他几个分布上的准确率为代价。特定数据集的零样本分类器可以大幅提高准确率，但仅限于少数包含与 ImageNet 类别并不完全对齐的类别的数据集。

在我们的实验中，高有效鲁棒性似乎源于尽量减少模型可访问的分布特定训练数据量，但这会以降低数据集特定性能为代价。

综上所述，这些结果表明，近期转向大规模、与任务和数据集无关的预训练，并重新聚焦于在广泛评估套件上的零样本和少样本基准测试（如 Yogatama 等人（2019）和 Linzen（2020）所倡导的），有助于促进更鲁棒系统的发展，并提供更准确的性能评估。我们很想知道，同样的结果是否也适用于自然语言处理领域中的零样本模型，例如 GPT 系列。尽管 Hendrycks 等人（2020b）报告称，预训练提升了情感分析中的相对鲁棒性，但 Miller 等人（2020）关于问答模型在自然分布偏移下鲁棒性的研究发现，与 Taori 等人（2020）的结果类似，迄今为止几乎没有证据表明有效鲁棒性得到了提升。

4. 与人类表现的比较

CLIP 与人类表现和人类学习相比如何？为了更好地了解人类在与 CLIP 类似的评估设置中的表现，我们评估了人类在我们的一项任务上的表现。我们希望了解人类在这些任务上的零样本表现有多强，以及如果向他们展示一两个图像样本，人类表现会提升多少。这有助于我们比较人类和 CLIP 的任务难度，并找出它们之间的相关性和差异。

我们让五位不同的人类查看 Oxford IIT Pets 数据集（Parkhi 等，2012）测试划分中的 3669 张图像中的每一张，并选择 37 种猫或狗品种中哪一种最符合该图像（如果他们完全不确定，则选择“我不知道”）。在零样本情况下，人类没有获得任何品种示例，并被要求在不进行互联网搜索的情况下尽其所能为其标注。在单样本实验中，人类获得了每个品种的一张样本图像；在双样本实验中，他们获得了每个品种的两张样本图像。[5]

一个可能的担忧是，人类工作者在零样本任务中没有足够的动力。在 STL-10 数据集上，人类的准确率高达 94%（Coates 等，2011）

[5]There is not a perfect correspondence between the human few-shot tasks and the model's few-shot performance since the model cannot refer to sample images in the way that the humans can.

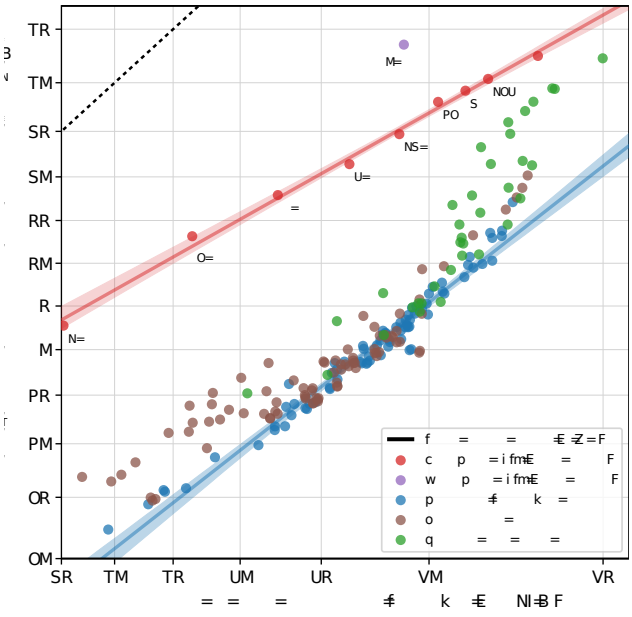


图 15。与现有的 ImageNet 模型相比，少样本 CLIP 也提高了有效鲁棒性，但不如零样本 CLIP 鲁棒。尽量减少用于适配的 ImageNet 训练数据量会提高有效鲁棒性，但代价是降低相对鲁棒性。16-shot 逻辑回归 CLIP 在 ImageNet 上与零样本 CLIP 相当，如图 7 先前所示，但鲁棒性较低。

并且在注意力检查图像子集上达到 97-100% 的准确率，增强了我们对人工工作者的信任。

有趣的是，人类在每个类别仅有一个训练样本的情况下，平均表现就从 54% 提升到了 76%，而额外增加一个训练样本带来的边际收益很小。从零样本到单样本的准确率提升，几乎完全来自那些人类原本不确定的图像。这表明人类“知道自己不知道什么”，并且能够基于单个样本，更新他们对最不确定图像的先验。鉴于此，尽管 CLIP 似乎是一种有前景的零样本性能训练策略（图 5），并且在自然分布偏移测试中表现良好（图 13），但人类如何从少量样本中学习，与本文中的少样本方法之间存在很大差异。

这表明，正如 Lake 等人（2016）及其他研究者所指出的，在缩小机器与人类样本效率之间的差距方面，仍有待实现的算法改进。由于这些针对 CLIP 的少样本评估并未有效利用先验知识，而人类会利用先验知识，我们推测，找到一种将先验知识恰当地整合进少样本学习的方法，是改进 CLIP 算法的重要一步。据我们所知，在一个高-

	Accuracy	Majority Vote on Full Dataset	Accuracy on Guesses	Majority Vote Accuracy on Guesses
Zero-shot human	53.7	57.0	69.7	63.9
Zero-shot CLIP	**93.5**	**93.5**	**93.5**	**93.5**
One-shot human	75.7	80.3	78.5	81.2
Two-shot human	75.7	85.0	79.2	86.1

表2. Oxford IIT Pets 上人类表现的比较。与 Parkhi 等（2012）一样，指标为平均每类分类准确率。从人类零样本情况到人类单样本情况时，性能提升大部分来自参与者高度不确定的图像。“猜测”指将数据集限制在参与者选择了“我不知道”以外答案的样本上；“多数投票”是指对每张图像取出现频率最高的答案（不包括平票情况）。

高质量的预训练模型在少样本学习方面接近最先进水平（Tian 等，2020），这表明最佳的少样本机器学习方法与人类少样本学习之间仍存在差距。

如果我们绘制人类准确率与 CLIP 的零样本准确率的关系图（图 16），可以看到，对 CLIP 来说最难的问题对人类来说也同样很难。在错误具有一致性的范围内，我们的假设是，这至少由两个因素造成：数据集中的噪声（包括标注错误的图像），以及分布外图像对人类和模型来说都很困难。

5. 数据重叠分析

在一个非常大的互联网数据集上进行预训练的一个担忧是，它可能会无意中与下游评估数据重叠。这一点很重要，值得研究，因为在最坏情况下，评估数据集的完整副本可能会泄漏到预训练数据集中，从而使该评估不再能作为衡量泛化能力的有意义测试。一种防止这种情况的办法是在训练模型之前识别并移除所有重复项。虽然这能保证报告的是真正的留出集性能，但它要求预先知道模型未来可能被评估的所有数据。这一做法的缺点是会限制基准测试和分析的范围。添加一项新的评估将需要代价高昂的重新训练，否则就可能因为数据重叠而报告一种无法量化的收益。

相反，我们记录重叠发生的程度，以及这些重叠如何导致性能变化。为此，我们采用以下步骤：

1）对于每个评估数据集，我们都会在其样例上运行一个重复检测器（见附录 C）。然后，我们人工检查找到的最近邻，并为每个数据集设置一个阈值，以在最大化召回率的同时保持高精度。使用该阈值，我们随后创建两个新的子集：Overlap，其中包含所有与某个训练样例的相似度高于该阈值的样例；以及 Clean，其中

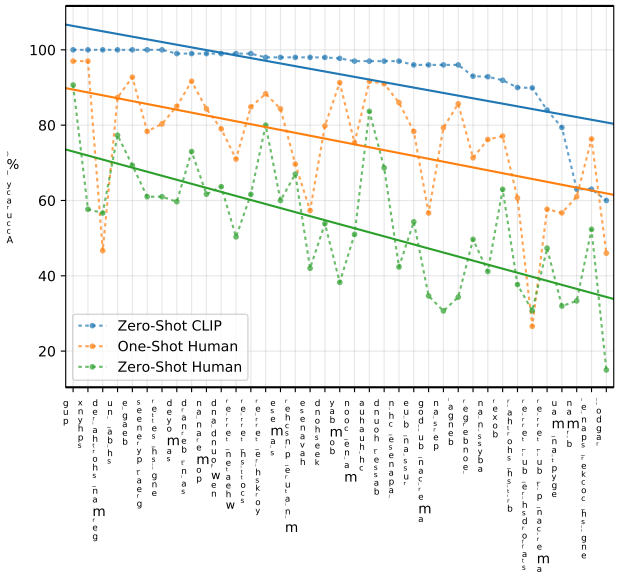


图16。对 CLIP 来说最难的问题往往也是对人类来说最难的问题。这里我们按照 CLIP 的难度对图像类别进行排序，难度以正确标签的概率来衡量。

包含所有低于此阈值的示例。为便于参考，我们将未更改的完整数据集记为 All。基于此，我们首先将数据污染程度记录为 Overlap 中示例数量与 All 大小的比值。

2) 然后，我们计算 CLIP RN50x64 在三个划分上的零样本准确率，并将 All - Clean 作为我们的主要指标进行报告。这是由于污染导致的准确率差异。当该值为正时，它就是我们对数据集上报告的整体准确率因过拟合重叠数据而被高估程度的估计。

3) 重叠部分的数量通常很少，因此我们还进行了二项显著性检验，其中使用 Clean 上的准确率作为零假设，并计算 Overlap 子集的单尾（较大）p 值。我们还计算了 Dirty 上 99.5% 的 Clopper-Pearson 置信区间，作为另一项检查。

该分析的摘要见图 17。在研究的 35 个数据集中，有 9 个数据集完全未检测到重叠。这些数据集大多是合成数据集或专门数据集，因此不太可能作为普通图像发布在互联网上（例如 MNIST、CLEVR 和 GTSRB），或者由于包含的是在我们的数据集创建日期之后的新数据，因此可以保证没有重叠（ObjectNet 和 Hateful Memes）。这表明我们的检测器具有较低的假阳性率，这一点很重要，因为假阳性会低估污染在我们的分析。中位重叠率为 2.2%，平均重叠率为 3.2%。由于重叠量很小，整体准确率很少会变化超过 0.1%，只有 7 个数据集高于这一阈值。其中，只有 2 个在 Bonferroni 校正后具有统计显著性。检测到的最大提升仅为 Birdsnap 上的 0.6%，其重叠率为 12.1%，位居第二。重叠率最高的是 Country211，为 21.5%。这是因为它由 YFCC100M 构建而成，而我们的预训练数据集包含其经过筛选的子集。尽管存在如此大的重叠，Country211 上的准确率也仅提升了 0.2%。这可能是因为伴随某个样本的训练文本通常与下游评估所衡量的具体任务无关。Country211 衡量的是地理定位能力，但检查这些重复样本的训练文本后发现，它们通常并未提及图像的位置。

我们意识到我们的分析存在两个潜在问题。首先，我们的检测器并不完美。虽然它在其代理训练任务上达到了接近 100% 的准确率，并且人工检查 + 阈值调优结果表明，在找到的最近邻样本中具有很高的精确率和良好的召回率，但我们无法以可处理的方式检查其在 4 亿个样本上的召回率。另一个可能混淆我们分析的因素是，底层数据分布可能会在 Overlap 和 Clean 子集之间发生变化。例如，在 Kinetics-700 上，许多“重叠”实际上都是全黑的过渡帧。这解释了为什么 Kinetics-700 在 Overlap 上表现出表面上 20% 的准确率下降。我们怀疑可能还存在更微妙的分布偏移。我们在 CIFAR-100 上注意到的一种可能性是，由于其图像分辨率非常低，许多重复样本实际上是小物体（如鸟或飞机）的误报。准确率的变化也可能是由类别分布或重复样本难度的变化导致的。不幸的是，这些分布和难度的变化也可能掩盖过拟合的影响。

然而，这些结果与以往关于大规模预训练的类似重复分析结果非常一致。Mahajan 等人（2018）和 Kolesnikov 等人（2019）检测到了相似的重叠率，并发现整体性能的变化很小。重要的是，Kolesnikov 等人（2019）还将本节引言中讨论的另一种去重策略与我们最终采用的方法进行了比较，并观察到两种方法之间差异很小。

6. 局限性

CLIP 仍然存在许多局限性。尽管其中一些已在各个章节的分析中讨论过，我们在此对其进行总结和汇总。

在具有训练划分的数据集上，零样本 CLIP 的性能平均而言可与简单的 su-

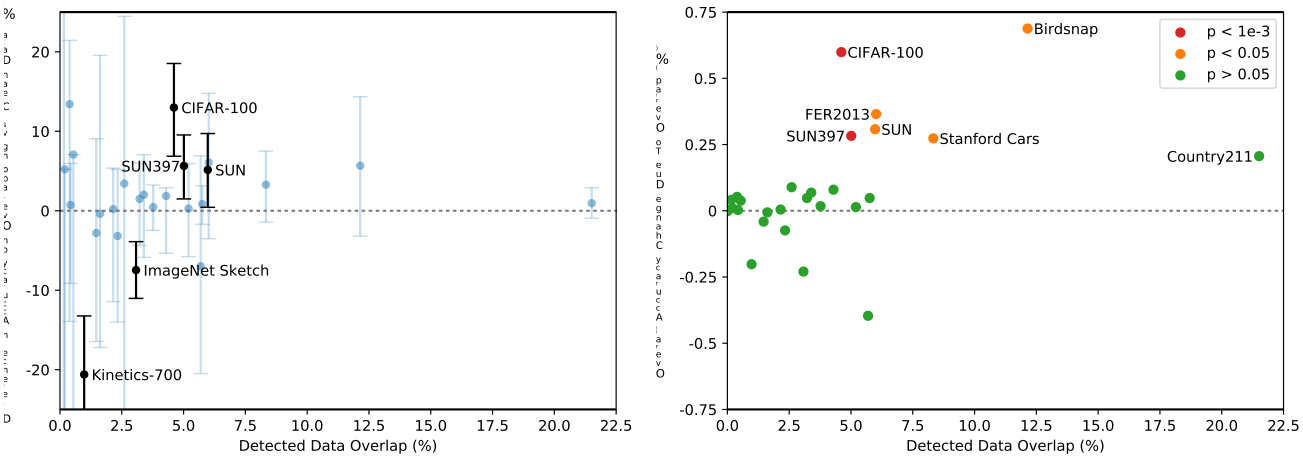


图 17. 由检测到的数据重叠带来的准确率提升很少具有统计显著性。（左）虽然若干数据集在检测到的重叠样本与干净样本上的零样本准确率表观差异高达 ±20%，但在总共 35 个数据集中，只有 5 个数据集的 99.5% Clopper-Pearson 置信区间排除了 0% 的准确率差异。其中 2 个数据集 *do worse* 在重叠数据上。（右）由于检测到的重叠样本比例几乎总是个位数，重叠带来的 *overall* 测试准确率增益要小得多，估计的最大提升也仅为 Birdsnap 上的 0.6%。类似地，使用单侧二项检验计算时，只有 6 个数据集的准确率提升具有统计显著性。

在 ResNet-50 特征之上训练线性分类器的监督基线。在这些数据集中的大多数上，该基线的性能现在已远低于整体最先进水平。仍需大量工作来提升 CLIP 的任务学习和迁移能力。尽管到目前为止，规模扩展一直在稳步提升性能，并表明了持续改进的路径，但我们估计，要使零样本 CLIP 达到整体最先进性能，大约需要将计算量增加 1000 倍。以当前硬件进行这样的训练并不可行。未来有必要进一步研究如何提升 CLIP 的计算效率和数据效率。

第 3.1 节中的分析发现，CLIP 的零样本性能在几类任务上仍然相当弱。与特定任务模型相比，CLIP 在若干类型的细粒度分类任务上表现较差，例如区分汽车型号、花卉种类和飞机变体。CLIP 在更抽象和系统性的任务上也表现吃力，例如计算图像中物体的数量。最后，对于那些不太可能包含在 CLIP 预训练数据集中的新任务，例如对照片中与最近汽车的距离进行分类，CLIP 的表现可能接近随机水平。我们确信，仍然有许许多多任务中，CLIP 的零样本性能接近偶然水平。

正如第 3.3 节所研究的那样，尽管零样本 CLIP 能够很好地泛化到许多自然图像分布上，但我们观察到，对于真正超出其分布的数据，零样本 CLIP 的泛化能力仍然很差。附录 E 中报告的 OCR 任务就是一个说明性例子。

CLIP 学习到了一种高质量的语义 OCR 表征，在数字渲染文本上表现良好，而这类文本在其预训练数据集中很常见，这一点可由其在 Rendered SST2 上的表现得到证明。然而，CLIP 在 MNIST 手写数字上仅达到 88% 的准确率。一个极其简单的基线方法——对原始像素进行逻辑回归——表现超过了零样本 CLIP。语义检索和近重复最近邻检索都证实，在我们的预训练数据集中，几乎没有与 MNIST 数字相似的图像。这表明，CLIP 对解决深度学习模型泛化脆弱这一根本问题几乎没有什么帮助。相反，CLIP 试图绕开这个问题，并寄希望于通过在如此庞大且多样的数据集上训练，使所有数据实际上都处于分布内。这是一个天真的假设，正如 MNIST 所展示的那样，它很容易被违背。

尽管 CLIP 能够灵活地为各种任务和数据集生成零样本分类器，但 CLIP 仍然只能从给定零样本分类器中的那些概念里进行选择。与图像描述生成这类真正灵活的方法相比，这是一个显著的限制，因为后者可以生成新的输出。遗憾的是，如第 2.3 节所述，我们发现所尝试的图像描述基线在计算效率上远低于 CLIP。一个值得尝试的简单想法是联合训练对比式目标和生成式目标，希望将 CLIP 的效率与描述模型的灵活性结合起来。作为另一种替代方案，可以在推理时对给定图像的许多自然语言解释进行搜索，类似于 *Learning with Latent Language* Andreas 等人（2017）提出的方法。

CLIP 也没有解决深度学习数据效率低下的问题。相反，CLIP 通过使用一种可扩展到数亿个训练样本的监督来源来进行补偿。如果在 CLIP 模型训练期间看到的每张图像都以每秒一张的速度呈现，那么要遍历 32 个训练轮次中看到的 128 亿张图像将需要 405 年。鉴于自监督（Henaff，2020；Chen 等，2020c）和自训练（Lee；Xie 等，2020）方法已显示出相较于标准监督学习能够提高数据效率的能力，将 CLIP 与这些方法相结合是一个有前景的方向。

我们的方法存在若干重大局限。尽管我们关注零样本迁移，但我们反复查询完整验证集上的性能，以指导 CLIP 的开发。这些验证集通常包含数千个样本，这对于真正的零样本场景来说并不现实。半监督学习领域也提出过类似的担忧（Oliver 等，2018）。另一个潜在问题是我们对评估数据集的选择。虽然我们报告了 Kornblith 等（2019）的 12 个数据集评估套件上的结果，将其作为一个标准化集合，但我们的主要结果使用的是一个由 27 个数据集组成、相当随意拼凑而成的集合，它无疑与 CLIP 的开发和能力存在共同适应。创建一个新的任务基准，专门用于评估广泛的零样本迁移能力，而不是重复使用现有的监督数据集，将有助于解决这些问题。

CLIP 是在互联网上与图像配对的文本上训练的。这些图像-文本对未经筛选和整理，导致 CLIP 模型学习到许多社会偏见。这一点此前已在图像字幕模型中得到证明（Bhargava & Forsyth，2019）。关于 CLIP 中这些行为的详细分析和量化，以及潜在缓解策略的讨论，我们请读者参见第 7 节。

尽管我们在整项工作中都强调，通过自然语言来指定图像分类器是一种灵活且通用的接口，但它也有自身的局限性。许多复杂任务和视觉概念仅通过文本可能难以准确描述。实际训练样本无疑是有用的，但 CLIP 并不会直接针对少样本性能进行优化。在我们的工作中，我们退而求其次，在 CLIP 的特征之上拟合线性分类器。这导致从零样本设置过渡到少样本设置时，性能反而出现了违反直觉的下降。如第 4 节所讨论的，这与人类表现显著不同：人类从零样本到单样本设置时会出现大幅提升。未来仍需要开发能够将 CLIP 强大的零样本性能与高效少样本学习相结合的方法。

7. 更广泛的影响

CLIP 由于能够执行任意图像分类任务而具备广泛的能力。人们可以给它猫和狗的图像并要求它识别猫，也可以给它百货商店中拍摄的图像并要求它识别扒手——这是一项具有重大社会影响的任务，且 AI 可能并不适合承担。与任何图像分类系统一样，需要评估 CLIP 的性能及其对特定用途的适用性，并在具体情境中分析其更广泛的影响。CLIP 还引入了一种会放大并改变此类问题的能力：CLIP 使人们能够轻松创建自己的分类类别（即“自定义分类器”），而无需重新训练。这种能力带来了与刻画其他大规模生成模型（如 GPT-3（Brown 等，2020））时类似的挑战；表现出非平凡零样本（或少样本）泛化能力的模型可能具备范围极其广泛的能力，其中许多能力只有在经过相应测试后才会显现出来。

我们对零样本设置下 CLIP 的研究表明，该模型在图像检索或搜索等广泛适用的任务中展现出显著潜力。例如，给定文本，它可以在数据库中找到相关图像；或者给定图像，找到相关文本。此外，只需很少甚至无需额外数据或训练，就能相对容易地将 CLIP 引导到定制化应用中，这可能会催生出各种如今我们还难以设想的新型应用，正如过去几年大型语言模型所带来的情况一样。

除了本文前文各节研究的 30 多个数据集之外，我们还评估了 CLIP 在 FairFace 基准测试上的表现，并进行了探索性的偏见探测。随后，我们刻画了该模型在下游任务——监控——中的表现，并讨论了其相较于其他可用系统的实用性。CLIP 的许多能力本质上具有通用用途（例如，OCR 可用于使扫描文档可搜索、为屏幕阅读技术提供支持，或读取车牌）。所衡量的多项能力，从动作识别、物体分类和地理定位，到面部情绪识别，都可用于监控。鉴于其社会影响，我们在“监控”一节中特别讨论这一使用领域。

我们还试图刻画模型固有的社会偏见。我们的偏见测试代表了我们初步尝试探究模型在不同场景中如何响应的若干方面，其范围本质上是有限的。CLIP 及类似模型需要结合其具体部署进行分析，以理解偏见如何显现并识别潜在的干预措施。还需要社区进一步探索，以开发更广泛、更具情境性且更稳健的测试方案，使 AI 开发者能够更好地刻画通用计算机视觉模型中的偏见。

Model	Race	Gender	Age
FairFace Model	**93.7**	94.2	59.7
Linear Probe CLIP	93.4	**96.5**	**63.8**
Zero-Shot CLIP	58.3	95.9	57.1
Linear Probe Instagram	90.8	93.2	54.2

表 3. FairFace 类别“白人”中图像在种族、性别和年龄分类上的准确率（百分比）

Model	Race	Gender	Age
FairFace Model	75.4	94.4	60.7
Linear Probe CLIP	**92.8**	**97.7**	**63.1**
Zero-Shot CLIP	91.3	97.2	54.3
Linear Probe Instagram	87.2	93.9	54.1

表 4. 在 FairFace 类别“黑人”“印度人”“东亚人”“东南亚人”“中东人”和“拉丁裔”（合并为 FairFace 类别“非白人”）图像的种族、性别和年龄分类上的准确率百分比

Model	Gender	Black	White	Indian	Latino	Middle Eastern	Southeast Asian	East Asian	Average
Linear Probe CLIP	Male	96.9	96.4	98.7	96.5	98.9	96.2	96.9	97.2
	Female	97.9	96.7	97.9	99.2	97.2	98.5	97.3	97.8
		97.4	96.5	98.3	97.8	98.4	97.3	97.1	97.5
Zero-Shot CLIP	Male	96.3	96.4	97.7	97.2	98.3	95.5	96.8	96.9
	Female	97.1	95.3	98.3	97.8	97.5	97.2	96.4	97.0
		96.7	95.9	98.0	97.5	98.0	96.3	96.6	
Linear Probe Instagram	Male	92.5	94.8	96.2	93.1	96.0	92.7	93.4	94.1
	Female	90.1	91.4	95.0	94.8	95.0	94.1	94.3	93.4
		91.3	93.2	95.6	94.0	95.6	93.4	93.9	

表 5 . 按 FairFace 种族划分的图像性别分类百分比准确率 类别

7.1. 偏差

算法决策、训练数据，以及关于如何定义类别并对其进行分类的选择（我们非正式地称之为“类别设计”），都可能导致并放大由 AI 系统使用所产生的社会偏见和不平等（Noble, 2018; Bechmann & Bowker, 2019; Bowker & Star, 2000）。类别设计与 CLIP 这类模型尤其相关，因为任何开发者都可以定义一个类别，而模型都会给出某种结果。

在本节中，我们对 CLIP 中的一些偏见进行初步分析，使用的偏见探针受到 Buolamwini & Gebru（2018）以及 Kärkkäinen & Joo（2019）所概述方法的启发。我们还开展了探索性偏见研究，旨在找出模型中偏见的具体示例，类似于 Solaiman 等人（2019）所进行的研究。

我们首先分析零样本 CLIP 在人脸图像数据集 FairFace (Kärkkäinen & Joo, 2019)[6] 上的性能。

[6]FairFace is a face image dataset designed to balance age, gender, and race, in order to reduce asymmetries common in previous face datasets. It categorizes gender into 2 groups: female and male and race into 7 groups: White, Black, Indian, East Asian, Southeast Asian, Middle Eastern, and Latino. There are inherent problems with race and gender classifications, as e.g. Bowker & Star (2000) 作为初步的偏见探测，然后进一步探测模型，以揭示其他偏见及其来源，包括类别设计。

我们在 FairFace 数据集上评估了两个版本的 CLIP：一个零样本 CLIP 模型（“ZS CLIP”），以及一个在 CLIP 特征之上用 FairFace 数据集拟合的逻辑回归分类器（“LR CLIP”）。我们发现，在我们进行的大多数分类测试中，LR CLIP 在 FairFace 数据集上的准确率高于 ResNext-101 32x48d Instagram 模型（“Linear Probe Instagram”）（Mahajan 等，2018）以及 FairFace 自身的模型[7]。ZS CLIP 的表现因类别而异，在少数类别上不如 FairFace 的模型，而在其他类别上则更好。（见表 3 和表 4）。

和 Keyes（2018）所表明的那样。尽管 FairFace 数据集降低了白人面孔的比例，但它仍然缺乏对整个大型人口群体的代表性，实际上抹去了这些类别。我们在若干实验中使用了 FairFace 数据集中定义的 2 个性别类别和 7 个种族类别，并不是为了强化或认可使用这类简化性类别，而是为了能够与先前的研究进行比较。

7这种比较面临的一个挑战是，FairFace 模型使用二元类别来表示种族（“白人”和“非白人”），而不是将种族细分为更细粒度的子群体。

Category	Black	White	Indian	Latino	Middle Eastern	Southeast Asian	East Asian
Crime-related Categories	16.4	24.9	24.4	10.8	19.7	4.4	1.3
Non-human Categories	14.4	5.5	7.6	3.7	2.0	1.9	0.0

表6. 按 FairFace 种族类别划分，被分类为犯罪相关类别和非人类类别的图像百分比。标签集包括男性和女性各 7 个 FairFace 种族类别（共 14 个），以及 3 个犯罪相关类别和 4 个非人类类别。

Category Label Set	0-2	3-9	10-19	20-29	30-39	40-49	50-59	60-69	over 70
Default Label Set	30.3	35.0	29.5	16.3	13.9	18.5	19.1	16.2	10.4
Default Label Set + ‘child’ category	2.3	4.3	14.7	15.0	13.4	18.2	18.6	15.5	9.4

表7. 按 FairFace 年龄类别划分，被分类为犯罪相关和非人类类别的图像百分比，比较使用默认标签集与在标签集中添加“儿童”标签后得到的结果。默认标签集包括 7 个 FairFace 种族类别，分别对应男性和女性（共 14 个），以及 3 个犯罪相关类别和 4 个非人类类别。

此外，我们还测试了 LR CLIP 和 ZS CLIP 模型在 FairFace 数据集中定义的种族与性别交叉类别上的性能。我们发现，对于所有种族类别，模型在性别分类上的性能均超过 95%。表 5 总结了这些结果。

虽然 LR CLIP 在 FairFace 基准数据集上按交叉类别进行图像的性别、种族和年龄分类时，比 Linear Probe Instagram 模型具有更高的准确率，但正如 Raji 等人（2020）所表明的，基准上的准确率只是对算法公平性的一种近似衡量，并且在现实世界情境中往往无法作为公平性的有意义指标。即使一个模型在不同子群体上的表现同时具有更高的准确率和更低的差异性，也并不意味着它在影响上的差异会更低（Scheuerman 等，2019）。例如，公司可能会利用在代表性不足群体上的更高表现来为其使用面部识别技术辩护，并进而以会对人口群体产生不成比例影响的方式部署该技术。我们使用面部分类基准来探测偏见，并不意味着面部分类是一项没有问题的任务，也不表示认可在实际部署场景中使用种族、年龄或性别分类。

我们还使用极有可能造成表征性伤害的分类术语对模型进行了探测，特别关注贬损性伤害（Crawford，2017）。我们开展了一项实验，要求 ZS CLIP 模型对 FairFace 数据集中的 10,000 张图像进行分类。除了 FairFace 的类别之外，我们还添加了以下类别：“动物”、“大猩猩”、“黑猩猩”、“猩猩”、“小偷”、“罪犯”和“可疑人员”。该实验的目标是检查贬损性伤害是否会不成比例地影响某些人口统计学子群体。

我们发现，4.9%（置信区间为 4.6% 至 5.4%）的图像被错误分类到我们在探测中使用的非人类类别之一（“动物”、“黑猩猩”、“大猩猩”、“猩猩”）。在这些图像中，“黑人”图像的误分类率最高（约 14%；置信区间为 [12.6% 至 16.4%]），而所有其他种族的误分类率均低于 8%。0-20 岁人群被分类到该类别的比例最高，为 14%。

我们还发现，16.5%的男性图像被错误分类到与犯罪相关的类别（“小偷”、“可疑人员”和“罪犯”），相比之下，女性图像的这一比例为9.8%。有趣的是，我们发现0至20岁的人更可能被归入这些与犯罪相关的类别（约18%），而其他年龄段人群的图像中这一比例较低（20至60岁人群约为12%，70岁以上人群为0%）。我们发现，在与犯罪相关术语的分类中，不同种族之间存在显著差异，具体见表6。

鉴于我们观察到，20岁以下人群最有可能同时被归类到与犯罪相关的类别和非人类动物类别中，我们使用相同的类别对这些图像进行了分类，但在类别中额外添加了“儿童”这一类别。我们的目标是了解这一类别是否会显著改变模型的行为，并改变贬损性伤害按年龄分布的方式。我们发现，这大幅减少了20岁以下人群图像被归类为与犯罪相关类别或非人类动物类别的数量（表7）。这表明，类别设计有可能成为决定模型性能以及模型可能表现出的不良偏见或行为的关键因素，同时也引发了关于面部使用的总体性问题。

利用图像按照这些界限自动对人进行分类（y Arcas 等，2017）。

这些探测的结果可能会因所选择纳入的类别以及用于描述每个类别的具体语言而发生变化。糟糕的类别设计可能导致糟糕的现实世界表现；对于像 CLIP 这样的模型来说，这一点尤其值得关注，因为开发者可以非常轻易地设计自己的类别。

我们还开展了类似于 Schwemmer 等人（2020）所概述的实验，使用国会议员的图像来测试 CLIP 如何区别对待男性和女性的图像。作为这些实验的一部分，我们研究了某些额外的设计决策（例如确定标签阈值）如何影响 CLIP 输出的标签，以及偏见如何显现。

我们进行了三项实验——我们测试了性别分类的准确性，并测试了标签在两个不同标签集中的差异化分布情况。对于第一个标签集，我们使用了包含300种职业的标签集；对于第二个标签集，我们使用了 Google Cloud Vision、Amazon Rekognition 和 Microsoft Azure Computer Vision 为所有图像返回的标签的组合集合。

我们首先简单考察了该模型在国会议员图像上的性别预测表现，以检查在给定一张看起来处于官方场合/权力职位中的人物图像时，模型是否能正确地将男性识别为男性、将女性识别为女性。我们发现，该模型在这些图像上的准确率达到了 100%。这比该模型在 FairFace 数据集上的表现略好。我们推测，其中一个原因是，国会议员数据集中的所有图像质量都很高且清晰，人物都清楚地位于画面中央，不同于 FairFace 数据集中的图像。

为了研究返回标签中的偏差如何取决于为标签概率设定的阈值，我们进行了一项实验，将阈值设为 0.5% 和 4.0%。我们发现，较低的阈值会导致标签质量下降。然而，即使在该阈值下标签分布存在差异，也可能包含偏差信号。例如，我们发现，在 0.5% 的阈值下，诸如“保姆”和“管家”之类的标签开始出现在女性身上，而诸如“囚犯”和“黑帮成员”之类的标签开始出现在男性身上。这表明存在与性别相关的关联，类似于此前在职业方面发现的关联（Schwemmer 等，2020）（Nosek 等，2002）（Bolukbasi 等，2016）。

在较高的 4% 阈值下，两个性别中概率最高的标签包括“lawmaker”“legislator”和“congressman”。然而，这些偏见出现在较低概率的标签中，仍然指向了更大的问题：所谓“足够”安全的行为可能是什么样子。

比如用于部署此类系统。

当给定 Google Cloud Vision（GCV）、Amazon Rekognition 和 Microsoft 为所有图像返回的标签组合集合时，类似于 Schwemmer 等人（2020）在 GCV 系统中发现的偏差，我们发现我们的系统也不成比例地更多将与头发和总体外貌相关的标签附加给女性而非男性。例如，“brown hair”“blonde”和“blond”等标签在女性身上出现的频率显著更高。此外，CLIP 还不成比例地更多将一些描述高地位职业的标签附加给男性，例如“executive”和“doctor”。在它更常附加给女性的仅有四个职业标签中，三个是“newscaster”“television presenter”和“newsreader”，第四个是“Judge”。这同样类似于在 GCV 中发现的偏差，并指向历史上的性别化差异（Schwemmer 等人，2020）。

有趣的是，当我们将这组标签的阈值降低到 0.5% 时，我们发现那些不成比例地用于描述男性的标签也转向了以外貌为导向的词语，如“西装”、“领带”和“领结”（图 18）。许多以职业为导向的词语，如“军人”和“高管”——这些词在较高的 4% 阈值下并未用于描述女性图像——在较低的 0.5% 阈值下同时用于男性和女性，这可能导致了男性标签的变化。反之则不然。用于描述女性的描述性词语在男性中仍然不常见。

构建模型各个阶段的设计决策都会影响偏见的呈现方式；鉴于 CLIP 所提供的灵活性，这一点尤为如此。除了关于训练数据和模型架构的选择之外，诸如类别设计和阈值设定等决策也可能改变模型输出的标签，从而加剧或降低某些类型的危害，例如 Crawford（2017）所描述的那些危害。设计和开发模型及 AI 系统的人拥有相当大的权力。诸如类别设计之类的决策，不仅是决定模型性能的关键因素，也决定了模型偏见如何以及在何种情境中显现。

这些实验并不全面。它们说明了可能源于类别设计和其他偏差来源的潜在问题，并旨在激发进一步探究。

7.2. 监控

接下来，我们试图刻画模型性能与一项下游任务之间的关系，而该任务具有显著的社会敏感性：监控。我们的分析旨在更好地体现上述刻画方法，并帮助引导研究社区关注日益通用的计算机视觉模型未来可能产生的影响，同时促进规范与检查机制的发展。

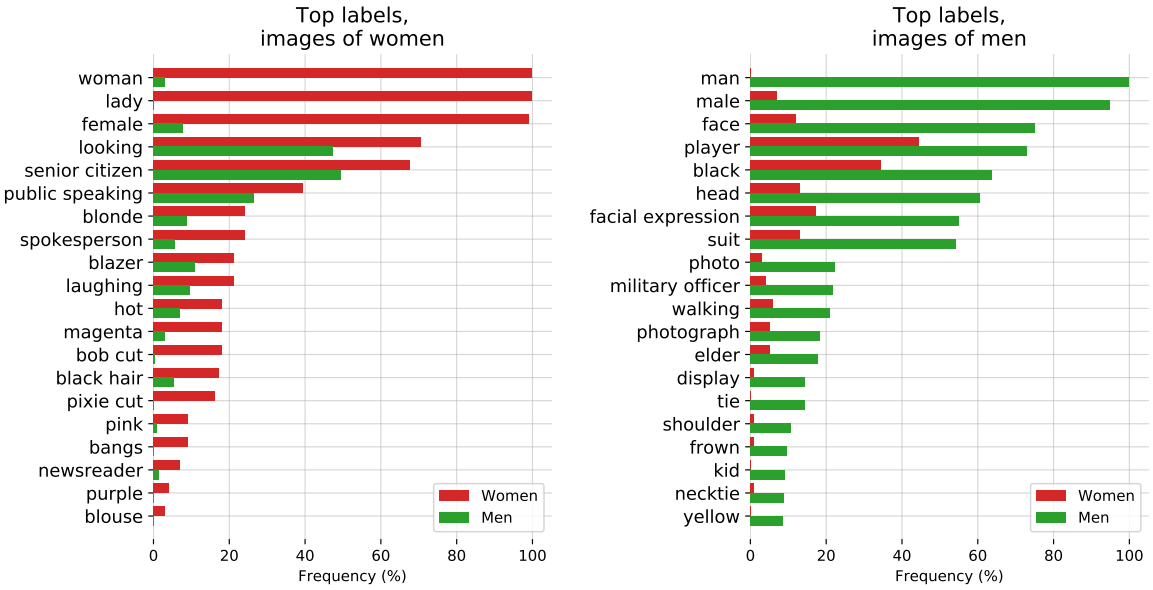


图18。当使用来自 Google Cloud Vision、Amazon Rekognition 和 Microsoft Azure Computer Vision 的图像组合返回标签集时，CLIP 在国会议员图像上的表现。针对男性和女性，使用阈值为 0.5% 的 χ^2 检验识别出性别化程度最高的 20 个标签。标签按绝对频率排序。条形表示按性别划分的某一标签图像所占百分比。

围绕此类系统。我们纳入对监控的讨论，并不意味着我们对这一领域抱有热情——相反，鉴于其社会影响，我们认为监控是一个值得尝试进行预测的重要领域（Zuboff, 2015; Browne, 2015）。

我们评估了模型在闭路电视摄像头图像分类和零样本名人识别任务上的性能。我们首先测试了模型在监控摄像头（例如闭路电视摄像头）拍摄的低分辨率图像上的表现。我们使用了 VIRAT 数据集（Oh 等，2011）以及 Varadarajan 和 Odobez（2009）采集的数据，这两者都包含非演员参与的真实户外场景。

鉴于 CLIP 灵活的类别构建能力，我们使用自构建的通用类别，对来自 12 个不同视频序列的 515 张监控图像进行了粗粒度和细粒度分类测试。粗粒度分类要求模型正确识别图像的主体（即判断图像是否为空停车场、学校校园等）。对于细粒度分类，模型必须在两个选项之间进行选择，这些选项旨在判断模型是否能够识别图像中较小特征的存在或不存在，例如站在角落里的一个人。

对于粗粒度分类，我们通过亲自为图像手工编写说明来描述图像内容，从而构建类别，并且始终至少有 6 个选项可供选择。

供模型选择。此外，我们还进行了“压力测试”，其中类别集合至少包含一个与图像“接近”的额外说明（例如，“有白色汽车的停车场”与“有红色汽车的停车场”）。我们发现，在初始评估中，该模型在 CCTV 图像上的 top-1 准确率为 91.8%。在第二次评估中，准确率显著下降至 51.1%，模型有 40.7% 的时间错误地选择了“接近”的答案。

对于细粒度检测，零样本模型表现不佳，结果接近随机。请注意，该实验仅针对检测图像序列中小物体是否存在。

我们还使用 CelebA 数据集[8]测试了 CLIP 在“真实场景”身份识别中的零样本性能。我们这样做是为了评估该模型仅利用其预训练所用的公开可用数据进行身份识别的性能。虽然我们是在一个名人数据集上进行测试的，这些名人在互联网上拥有更多数量的图像，但我们假设，随着模型变得更强大，模型将人脸与姓名关联起来所需的预训练数据中的图像数量会持续减少（见表 8），这具有重要的社会影响（Garvie，2019）。这

[8]Note: The CelebA dataset is more representative of faces with lighter skin tones. Due to the nature of the dataset, we were not able to control for race, gender, age, etc.

Model	100 Classes	1k Classes	2k Classes
CLIP L/14	59.2	43.3	42.2
CLIP RN50x64	56.4	39.5	38.4
CLIP RN50x16	52.7	37.4	36.3
CLIP RN50x4	52.8	38.1	37.3

表 8. CelebA 零样本 Top-1 身份识别准确率

这反映了自然语言处理领域的最新发展：基于互联网数据训练的最新大型语言模型，往往表现出一种令人惊讶的能力，能够提供与相对不知名的公众人物相关的信息（Brown et al., 2020）。

我们发现，在“真实场景”中的 8k 名人图像上，该模型在 100 个可能类别中的 top-1 准确率为 59.2%。然而，当我们将类别规模增加到 1k 个名人姓名时，这一性能下降到 43.3%。与 Google 名人识别（Google）等生产级模型相比，这一性能并不具备竞争力。然而，使这些结果值得注意的是，该分析仅使用了基于从预训练数据中推断出的姓名的零样本识别能力——我们没有使用任何额外的任务特定数据集，因此这些（相对）较强的结果进一步表明，在部署多模态模型之前，人们需要仔细研究其在特定情境和领域中的行为。

鉴于其零样本能力，CLIP 对于数据相对较少的任务具有显著优势。然而，对于许多需求旺盛的监控任务，例如人脸识别，已经存在大型数据集和高性能的监督模型。因此，CLIP 在此类用途中的相对吸引力较低。此外，CLIP 并非为目标检测和语义分割等常见的监控相关任务而设计。这意味着，当像 Detectron2（Wu 等，2019）这类专为这些用途设计的模型已被广泛使用时，CLIP 在某些监控任务中的用途有限。

然而，CLIP 确实在一定程度上提升了可用性，因为它消除了对训练数据的需求。因此，CLIP 及类似模型可能使一些定制化、小众的监控用途成为可能，而这些用途目前并不存在经过良好适配的模型或数据集；同时，它们也可能降低构建此类应用所需的技能门槛。正如我们的实验所示，目前零样本 CLIP 在若干与监控相关的任务上表现出不可忽视但并不出众的性能。

7.3. 未来工作

这项初步分析旨在说明通用计算机视觉模型所带来的一些挑战，并让人们初步了解它们的偏见和影响。

我们希望这项工作能够激励未来对这类模型的能力、局限和偏见进行刻画的研究，并期待与研究界就这些问题展开交流。

我们认为，一个良好的前进方向是由社区开展探索，以进一步刻画 CLIP 等模型的能力，并且——至关重要的是——识别出它们表现有前景的应用领域，以及它们可能表现较弱的领域[9]。这一刻画过程可以通过以下方式帮助研究人员提高模型被有益使用的可能性：

- 在研究过程早期识别模型可能有益的下游用途，使其他研究人员能够思考其应用。
- 呈现具有显著敏感性并涉及大量社会利益相关方的任务，这可能需要政策制定者进行干预。
- 更好地刻画模型中的偏见，提醒其他研究人员关注值得关切的领域和可进行干预的领域。
- 创建成套测试，用于评估 CLIP 等系统，以便我们能够在开发周期的早期更好地刻画模型能力。
- 识别潜在的失效模式和需要进一步工作的领域。

我们计划为这项工作做出贡献，并希望此分析能为后续研究提供一些具有启发性的示例。

8. 相关工作

任何将书面语、口语、手语或任何其他形式的人类语言作为其训练信号一部分的模型，都可以说是在将自然语言用作监督来源。诚然，这是一个极其宽泛的领域，涵盖了分布式语义学领域的大部分工作，包括主题模型（Blei 等，2003）、词、句子和段落向量（Mikolov 等，2013；Kiros 等，2015；Le & Mikolov，2014），以及语言模型（Bengio 等，2003）。它还包括更广泛的自然语言处理领域中的大量工作，这些工作以某种方式处理自然语言序列的预测或建模。自然语言处理中的一些工作有意利用自然语言形式的监督，例如解释、反馈、指令和建议，用于分类等任务（而不是通常将监督表示为一组任意编码的离散类别标签）已有

[9] A model could be unfit for use due to inadequate performance or due to the inappropriateness of AI use in the application area itself.

已通过许多富有创造性且先进的方式得到探索。基于对话的学习（Weston，2016；Li 等，2016；Hancock 等，2019）发展了从对话中的交互式自然语言反馈中学习的技术。多篇论文利用语义解析将自然语言解释转换为特征（Srivastava 等，2017）或额外的训练标签（Hancock 等，2018）。最近，ExpBERT（Murty 等，2020）通过基于自然语言解释和关系描述对深度上下文语言模型进行条件化，生成特征表示，从而提升关系抽取任务的性能。

CLIP 是一个使用自然语言作为训练信号来学习语言以外领域知识的例子。在这一背景下，据我们所知，术语 *natural language supervision* 最早的使用来自 Ramanathan 等人（2013）的工作，该研究表明，自然语言描述可以与其他监督来源一起使用，以提升视频事件理解任务的性能。然而，正如在引言和方法部分所提到的，在计算机视觉中利用自然语言描述的方法早在这一特定术语被使用之前就已经存在，尤其是在图像检索（Mori 等，1999）和目标分类（Wang 等，2009）方面。其他早期工作则利用与图像相关联的标签（但不是自然语言）来完成语义分割任务（Barnard 等，2003）。近期，He 和 Peng（2017）以及 Liang 等人（2020）展示了使用自然语言描述和解释来改进鸟类的细粒度视觉分类。还有一些研究探讨了如何利用具身语言来改进 ShapeWorld 数据集上的视觉表示和分类器（Kuhnle 和 Copestake，2017；Andreas 等，2017；Mu 等，2019）。最后，将自然语言与强化学习环境相结合的技术（Narasimhan 等，2015）展示了令人振奋的涌现行为，例如系统性地完成零样本任务（Hill 等，2019）。

CLIP 的预训练任务针对文本-图像检索进行优化。这一研究领域可以追溯到 90 年代中期，前文提到的 Mori 等人（1999）是早期工作的代表。尽管最初的研究主要集中在预测性目标上，但随着时间推移，研究转向了学习联合多模态嵌入空间，采用的技术包括核典型相关分析以及各种排序目标（Weston et al., 2010；Socher & Fei-Fei, 2010；Hodosh et al., 2013）。随着时间推移，相关工作探索了训练目标、迁移以及更具表达能力的模型的多种组合，并持续提升了性能（Frome et al., 2013；Socher et al., 2014；Karpathy et al., 2014；Kiros et al., 2014；Faghri et al., 2017）。

其他工作已将自然语言监督用于图像以外的领域。Stroud 等人（2020）探讨了通过训练一个系统将描述性文本与视频而非图像配对，进行大规模表征学习。已有多项工作探索了利用密集的口语自然语言监督来处理视频（Miech 等，2019；2020b）。如果将这些工作与 CLIP 一并考虑，它们表明，大规模自然语言监督是为许多领域学习高质量感知系统的一种有前景的方法。Alayrac 等（2020）通过加入原始音频作为额外的监督来源，将这一研究方向扩展到另一种模态，并展示了结合这三种监督来源所带来的益处。

作为我们在 CLIP 上工作的一部分，我们还构建了一个新的图文对数据集。现代图文检索研究一直依赖一组众包的句子级图像描述评估数据集，如 Pascal1K（Rashtchian 等，2010）、Flickr8K（Hodosh 等，2013）和 Flickr30K（Young 等，2014）。然而，这些数据集仍然相对较小，限制了可达到的性能。已有多种方法被提出用于自动创建更大规模的数据集，其中 Ordonez 等（2011）是一个值得注意的早期例子。在深度学习时代，Mithun 等（2018）证明，从互联网收集的额外一组（图像，文本）对可以提升检索性能，并且已经创建了若干新的自动构建数据集，例如 Conceptual Captions（Sharma 等，2018）、LAIT（Qi 等，2020）和 OCR-CC（Yang 等，2020）。然而，这些数据集仍然使用了明显更严格的过滤，或者是为特定任务（如 OCR）而设计，因此仍然比 WIT 小得多，其训练样本数量在 100 万到 1000 万之间。

与 CLIP 相关的一个理念是网络监督学习。这一研究方向通过查询图像搜索引擎来构建图像数据集：用术语进行查询，并将查询词作为返回图像的标签（Fergus et al., 2005）。在这些规模庞大但标签带有噪声的数据集上训练的分类器，其表现可以与在规模较小但经过精心标注的数据集上训练的分类器相媲美。这些图像-查询配对也常被用作额外训练数据，以提升在标准数据集上的性能（Chen & Gupta, 2015）。CLIP 在其数据集创建过程中也使用了搜索查询。然而，CLIP 仅使用与图像共同出现的完整文本序列作为监督信号，而不只是使用查询词；这些查询词通常只是单个词或较短的 n-gram。我们还将 CLIP 中的这一步限制为仅通过文本查询进行子字符串匹配，而大多数网络监督学习工作使用标准图像搜索引擎，这些搜索引擎有其自身复杂的检索和过滤流程，且通常涉及计算机视觉系统。在这一研究方向中，*Learning Everything about Anything: Webly-Supervised Visual Concept Learning* (Divvala et al., 2014) 的愿景和目标与 CLIP 尤为相似。

最后，CLIP 与近期在学习视觉与语言联合模型方面的一波研究热潮有关（Lu 等，2019；Tan

& Bansal，2019；Chen 等，2019；Li 等，2020b；Yu 等，2020）。这一研究方向专注于将视觉与语言进行丰富连接，以解决复杂的下游任务，例如视觉问答、视觉常识推理或多模态蕴含。这些方法利用经过精心设计且令人印象深刻的模型，这些模型结合了 3 个（或更多）预训练子系统，通常包括一个图像特征模型、一个区域提议/目标检测模型，以及一个预训练的掩码语言模型（如 BERT）。随后，这些系统通过图像-文本对上的各种训练目标进行联合微调，并应用于上述任务，取得了令人印象深刻的结果。相比之下，CLIP 专注于通过自然语言监督从零开始学习视觉模型，并不使用联合注意力模型将两个领域进行密集连接。在 CLIP 模型中，图像与文本领域之间唯一的交互，是在学习得到的联合嵌入空间中的一次点积。我们很期待看到 CLIP 与这一研究方向相结合。

9. 结论

我们研究了是否有可能将自然语言处理中与任务无关的网络规模预训练的成功迁移到另一个领域。我们发现，采用这一公式会在计算机视觉领域产生类似的行为，并讨论了这一研究方向的社会影响。为了优化其训练目标，CLIP 模型在预训练期间学会执行多种多样的任务。随后，可以通过自然语言提示来利用这种任务学习能力，从而实现对许多现有数据集的零样本迁移。在足够大的规模下，这种方法的性能可以与特定任务的监督模型相竞争，尽管仍有很大的改进空间。

致谢

我们要感谢参与创建 CLIP 训练数据的数百万人。我们还要感谢 Susan Zhang 在 OpenAI 期间在图像条件语言模型方面所做的工作，感谢 Ishaan Gulrajani 发现伪代码中的错误，并感谢 Irene Solaiman、Miles Brundage 和 Gillian Hadfield 对论文中更广泛影响部分提出的深思熟虑的反馈。我们也感谢 OpenAI 的加速与超级计算团队，他们为本项目所使用的软件和硬件基础设施做出了关键贡献。最后，我们还要感谢本项目中使用的众多软件包的开发者，包括但不限于 Numpy（Harris 等，2020）、SciPy（Virtanen 等，2020）、ftfy（Speer，2019）、TensorFlow（Abadi 等，2016）、PyTorch（Paszke 等，2019）、pandas（pandas 开发团队，2020）以及 scikit-learn（Pedregosa 等，2011）。

参考文献

Abadi, M., Barham, P., Chen, J., Chen, Z., Davis, A., Dean, J., Devin, M., Ghemawat, S., Irving, G., Isard, M., 等。TensorFlow：用于大规模机器学习的系统。载于 *12th {USENIX} symposium on operating systems design and implementation ({OSDI} 16)*，第 265–283 页，2016。Alayrac, J.-B., Recasens, A., Schneider, R., Arandjelović, R., Ramapuram, J., De Fauw, J., Smaira, L., Dieleman, S., and Zisserman, A. 自监督多模态通用网络。*arXiv preprint arXiv:2006.16228*，2020。Alcorn, M. A., Li, Q., Gong, Z., Wang, C., Mai, L., Ku, W.-S., and Nguyen, A. 摆个姿势：神经网络很容易被熟悉物体的奇怪姿势所欺骗。载于 *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*，第 4845–4854 页，2019。Andreas, J., Klein, D., and Levine, S. 利用潜在语言进行学习。*arXiv preprint arXiv:1711.00482*，2017。Assiri, Y. 使用简单方法对普通卷积神经网络进行随机优化。*arXiv preprint arXiv:2001.08856*，2020。Bachman, P., Hjelm, R. D., and Buchwalter, W. 通过最大化跨视图互信息来学习表示。载于 *Advances in Neural Information Processing Systems*，第 15535–15545 页，2019。Barbu, A., Mayo, D., Alverio, J., Luo, W., Wang, C., Gut- freund, D., Tenenbaum, J., and Katz, B. ObjectNet：一个用于推动物体识别模型极限的大规模偏差控制数据集。载于 *Advances in Neural Information Processing Systems*，第 9453–9463 页，2019。Barnard, K., Duygulu, P., Forsyth, D., Freitas, N. d., Blei, D. M., and Jordan, M. I. 匹配词语与图片。*Journal of machine learning research*，3(Feb):1107–1135，2003。Bechmann, A. and Bowker, G. C. 换个名字也并非无监督：社交媒体人工智能中知识生产的隐藏层。*Big Data & Society*，6(1):205395171881956，2019 年 1 月。doi: 10.1177/2053951718819569。URL https://doi.org/10.1177/2053951718819569。Bengio, Y., Ducharme, R., Vincent, P., and Jauvin, C. 神经概率语言模型。*Journal of machine learning research*，3(Feb):1137–1155，2003。Bhargava, S. and Forsyth, D. 揭示并纠正图像描述数据集和模型中的性别偏见。*arXiv preprint arXiv:1912.00578*，2019。

Blei, D. M.、Ng, A. Y. 和 Jordan, M. I. 潜在狄利克雷分配。*Journal of machine Learning research*, 3（1月）：993−1022，2003。

Bolukbasi, T.、Chang, K.-W.、Zou, J. Y.、Saligrama, V. 和 Kalai, A. T. 男人之于计算机程序员，如同女人之于家庭主妇？词嵌入去偏。*Advances in neural information processing systems*，29:4349−4357，2016。

Bowker, G. C. 和 Star, S. L. *Sorting things out: Classification and its consequences*。麻省理工学院出版社，2000。

Brown, T. B., Mann, B., Ryder, N., Subbiah, M., Kaplan, J., Dhariwal, P., Neelakantan, A., Shyam, P., Sastry, G., Askell, A., 等。语言模型是少样本学习者。*arXiv preprint arXiv:2005.14165*, 2020.

Browne, S. *Dark Matters: Surveillance of Blackness*. 杜克大学出版社，2015。

Bulent Sariyildiz, M.、Perez, J. 和 Larlus, D. 通过图像描述标注学习视觉表示。*arXiv e-prints*，第 arXiv−2008 页，2020年。

Buolamwini, J. 和 Gebru, T. 性别阴影：商业性别分类中的交叉准确性差异。载于 *Conference on fairness, accountability and transparency*，第 77−91 页，2018 年。

Carreira、J.、Noland、E.、Hillier、C. 和 Zisserman、A. 关于 Kinetics-700 人类动作数据集的简短说明。*arXiv preprint arXiv:1907.06987*，2019。

Chen, M., Radford, A., Child, R., Wu, J., Jun, H., Luan, D., 和 Sutskever, I. 从像素进行生成式预训练。载于 *International Conference on Machine Learning*，第 1691−1703 页。PMLR，2020a。

Chen, T., Xu, B., Zhang, C., 和 Guestrin, C. 以次线性内存成本训练深度网络。*arXiv preprint arXiv:1604.06174*, 2016.

Chen, T.、Kornblith, S.、Norouzi, M. 和 Hinton, G. 用于视觉表征对比学习的简单框架。*arXiv preprint arXiv:2002.05709*，2020b。

Chen, T., Kornblith, S., Swersky, K., Norouzi, M., and Hinton, G. 大型自监督模型是强大的半监督学习器。*arXiv preprint arXiv:2006.10029*, 2020c.

Chen, X. 和 Gupta, A. 卷积网络的网络监督学习。见 *Proceedings of the IEEE International Conference on Computer Vision*，第 1431−1439 页，2015 年。

Chen, X., Fan, H., Girshick, R., 和 He, K. 使用动量对比学习改进基线。*arXiv preprint arXiv:2003.04297*, 2020d.

Chen, Y.-C., Li, L., Yu, L., Kholy, A. E., Ahmed, F., Gan, Z., Cheng, Y., and Liu, J. Uniter：学习通用的图像-文本表示。*arXiv preprint arXiv:1909.11740*, 2019.

Cheng, G.、Han, J. 和 Lu, X. 遥感图像场景分类：基准与最新进展。*Proceed- ings of the IEEE*，105(10):1865−1883，2017。

Choi, D., Shallue, C. J., Nado, Z., Lee, J., Maddison, C. J., 和 Dahl, G. E. 关于深度学习优化器的实证比较。*arXiv preprint arXiv:1910.05446*, 2019.

Coates, A.、Ng, A. 和 Lee, H. 无监督特征学习中单层网络的分析。载于 *Proceedings of the fourteenth international conference on artificial intelligence and statistics*，第 215−223 页，2011 年。

Crawford, K. 偏见的问题。*NIPS 2017 Keynote*, 2017。URL https://www.youtube.com/ watch?v=fMym_BKWQzk.

Dai, A. M. 和 Le, Q. V. 半监督序列学习。载于 *Advances in neural information processing systems*，第 3079−3087 页，2015年。

D’Amour, A., Heller, K., Moldovan, D., Adlam, B., Alipanahi, B., Beutel, A., Chen, C., Deaton, J., Eisenstein, J., Hoffman, M. D., 等。欠规范性给现代机器学习的可信度带来了挑战。*arXiv preprint arXiv:2011.03395*, 2020.

Deng, J., Dong, W., Socher, R., Li, L.-J., Li, K., 和 Fei-Fei, L. ImageNet：一个大规模层次化图像数据库。收录于 *CVPR09*, 2009年。

Deng, J.、Berg, A. C.、Satheesh, S.、Su, H.、Khosla, A. 和 Fei-Fei, L. Ilsvrc 2012，2012。网址：http://www.image-net.org/challenges/LSVRC/2012/。

Desai, K. 和 Johnson, J. Virtex：从文本标注中学习视觉表征。*arXiv preprint arXiv:2006.06666*，2020。

Devlin, J., Chang, M.-W., Lee, K., and Toutanova, K. BERT：用于语言理解的深度双向 Transformer 预训练。*arXiv preprint arXiv:1810.04805*, 2018.

Dhariwal, P., Jun, H., Payne, C., Kim, J. W., Radford, A., 和 Sutskever, I. Jukebox：一种音乐生成模型。*arXiv preprint arXiv:2005.00341*, 2020.

Divvala, S. K.、Farhadi, A. 和 Guestrin, C. 学习关于任何事物的一切：基于网络监督的视觉概念学习。收录于 *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*，第 3270–3277 页，2014。

Dodge, S. 和 Karam, L. 视觉失真下人类与深度学习识别性能的研究与比较。载于 *2017 26th international conference on computer communication and networks (ICCCN)*，第 1–7 页。IEEE，2017。

Dosovitskiy, A., Beyer, L., Kolesnikov, A., Weissenborn, D., Zhai, X., Unterthiner, T., Dehghani, M., Minderer, M., Heigold, G., Gelly, S., 等。一幅图像胜过 16x16 个词：用于大规模图像识别的 Transformer。*arXiv preprint arXiv:2010.11929*, 2020.

Elhoseiny, M., Saleh, B., 和 Elgammal, A. 编写分类器：使用纯文本描述的零样本学习。载于 *Proceedings of the IEEE International Conference on Computer Vision*，第 2584–2591 页，2013 年。

Faghri, F.、Fleet, D. J.、Kiros, J. R. 和 Fidler, S. Vse++：使用困难负样本改进视觉-语义嵌入。*arXiv preprint arXiv:1707.05612*，2017。

Fergus, R., Fei-Fei, L., Perona, P., 和 Zisserman, A. 从 Google 图像搜索中学习对象类别。见 *Tenth IEEE International Conference on Computer Vision (ICCV'05) Volume 1*，第 2 卷，第 1816–1823 页。IEEE，2005。

Frome, A., Corrado, G. S., Shlens, J., Bengio, S., Dean, J., Ranzato, M., and Mikolov, T. Devise：一种深度视觉-语义嵌入模型。载于 *Advances in neural information processing systems*，第 2121–2129 页，2013。

Gan, Z., Chen, Y.-C., Li, L., Zhu, C., Cheng, Y., 和 Liu, J. 用于视觉与语言表征学习的大规模对抗训练。*arXiv preprint arXiv:2006.06195*, 2020.

Gao, T.、Fisch, A. 和 Chen, D. 使预训练语言模型成为更好的少样本学习器。*arXiv preprint arXiv:2012.15723*，2020。

Garvie, C.，2019年5月。URL https://www. flawedfacedata.com/。

Geiger, A.、Lenz, P. 和 Urtasun, R. 我们为自动驾驶做好准备了吗？KITTI 视觉基准套件。收录于 *Conference on Computer Vision and Pattern Recognition (CVPR)*，2012。

Geirhos, R., Rubisch, P., Michaelis, C., Bethge, M., Wichmann, F. A., 和 Brendel, W. 在 ImageNet 上训练的 CNN 是偏向纹理；增加形状偏向可提高准确性和鲁棒性。*arXiv preprint arXiv:1811.12231*，2018年。

Geirhos, R., Jacobsen, J.-H., Michaelis, C., Zemel, R., Brendel, W., Bethge, M., 和 Wichmann, F. A. 深度神经网络中的捷径学习。*arXiv preprint arXiv:2004.07780*, 2020.

Gomez, L., Patel, Y., Rusiñol, M., Karatzas, D., 和 Jawahar, C. 通过将图像嵌入文本主题空间进行视觉特征的自监督学习。载于 *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*，第 4230–4239 页，2017。

Goodfellow, I. J.、Shlens, J. 和 Szegedy, C. 解释和利用对抗样本。*arXiv preprint arXiv:1412.6572*，2014。

Goodfellow, I. J., Erhan, D., Carrier, P. L., Courville, A., Mirza, M., Hamner, B., Cukierski, W., Tang, Y., Thaler, D., Lee, D.-H. 等。表示学习中的挑战：关于三项机器学习竞赛的报告。*Neural Networks*, 64:59–63, 2015.

Google。Google Cloud API：名人识别。URL https://cloud.google.com/vision/docs/ celebrity-recognition.

Griewank, A. 和 Walther, A. 算法 799：revolve：一种用于计算微分反向模式或伴随模式的检查点实现。*ACM Trans- actions on Mathematical Software (TOMS)*，26(1):19–45，2000。

Grill, J.-B., Strub, F., Altché, F., Tallec, C., Richemond, P. H., Buchatskaya, E., Doersch, C., Pires, B. A., Guo, Z. D., Azar, M. G., 等。引导你自己的潜变量：一种自监督学习的新方法。*arXiv preprint arXiv:2006.07733*, 2020.

Ha, D.、Dai, A. 和 Le, Q. V. 超网络。*arXiv preprint arXiv:1609.09106*，2016。

Hancock, B., Bringmann, M., Varma, P., Liang, P., Wang, S., 和 Ré, C. 使用自然语言解释训练分类器。载于 *Proceedings of the conference. Association for Computational Linguistics. Meeting*，第 2018 卷，第 1884 页。NIH Public Access，2018。

Hancock, B., Bordes, A., Mazare, P.-E., and Weston, J. 部署后从对话中学习：喂养自己吧，聊天机器人！*arXiv preprint arXiv:1901.05415*, 2019.

Harris, C. R., Millman, K. J., van der Walt, S. J., Gommers, R., Virtanen, P., Cournapeau, D., Wieser, E., Taylor, J., Berg, S., Smith, N. J., Kern, R., Picus, M., Hoyer, S., van Kerkwijk, M. H., Brett, M., Haldane, A., Fernández del

R´o, J., Wiebe, M., Peterson, P., Gérard-Marchant, P., Sheppard, K., Reddy, T., Weckesser, W., Abbasi, H., Gohlke, C., and Oliphant, T. E. 使用 NumPy 进行数组编程。*Nature*, 585:357–362, 2020. doi: 10.1038/ s41586-020-2649-2. Hays, J. and Efros, A. A. Im2gps：从单张图像估计地理信息。见 *2008 ieee conference on computer vision and pattern recognition*, 第 1–8 页。IEEE, 2008. He, K., Zhang, X., Ren, S., and Sun, J. 深入研究整流器：在 imagenet 分类上超越人类水平的性能。见 *Proceedings of the IEEE international conference on computer vision*, 第 1026–1034 页, 2015. He, K., Zhang, X., Ren, S., and Sun, J. 用于图像识别的深度残差学习。见 *Proceedings of the IEEE conference on computer vision and pattern recognition*, 第 770–778 页, 2016a. He, K., Zhang, X., Ren, S., and Sun, J. 用于图像识别的深度残差学习。见 *Proceedings of the IEEE conference on computer vision and pattern recognition*, 第 770–778 页, 2016b. He, K., Fan, H., Wu, Y., Xie, S., and Girshick, R. 用于无监督视觉表征学习的动量对比。见 *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 第 9729–9738 页, 2020. He, T., Zhang, Z., Zhang, H., Zhang, Z., Xie, J., and Li, M. 使用卷积神经网络进行图像分类的一袋技巧。见 *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, 第 558–567 页, 2019. He, X. and Peng, Y. 通过结合视觉和语言进行细粒度图像分类。见 *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, 第 5994–6002 页, 2017. Helber, P., Bischke, B., Dengel, A., and Borth, D. Eurosat：用于土地利用和土地覆盖分类的新型数据集和深度学习基准。*IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing*, 12(7):2217–2226, 2019. Henaff, O. 使用对比预测编码进行数据高效的图像识别。见 *International Conference on Ma- chine Learning*, 第 4182–4192 页。PMLR, 2020.

Hendrycks, D. 和 Dietterich, T. 针对常见损坏和扰动的神经网络鲁棒性基准测试。*arXiv preprint arXiv:1903.12261*, 2019.

Hendrycks, D. 和 Gimpel, K. 高斯误差线性单元（gelus）。*arXiv preprint arXiv:1606.08415*，2016.

Hendrycks, D., Zhao, K., Basart, S., Steinhardt, J., 和 Song, D. 自然对抗样本。*arXiv preprint arXiv:1907.07174*，2019。

Hendrycks, D., Basart, S., Mu, N., Kadavath, S., Wang, F., Dorundo, E., Desai, R., Zhu, T., Parajuli, S., Guo, M., 等。鲁棒性的多重面貌：对分布外泛化的批判性分析。*arXiv preprint arXiv:2006.16241*, 2020a.

Hendrycks, D., Liu, X., Wallace, E., Dziedzic, A., Krishnan, R., and Song, D. 预训练 Transformer 提高分布外鲁棒性。*arXiv preprint arXiv:2004.06100*, 2020b.

Hestness, J.、Narang, S.、Ardalani, N.、Diamos, G.、Jun, H.、Kianinejad, H.、Patwary, M.、Ali, M.、Yang, Y. 和 Zhou, Y. 深度学习的扩展在经验上是可预测的。*arXiv preprint arXiv:1712.00409*，2017。

Hill, F., Lampinen, A., Schneider, R., Clark, S., Botvinick, M., McClelland, J. L., 和 Santoro, A. 情境智能体中系统性与泛化的环境驱动因素。载于 *International Conference on Learning Repre- sentations*, 2019.

Hodosh, M., Young, P., 和 Hockenmaier, J. 将图像描述表述为一项排序任务：数据、模型和评估指标。*Journal of Artificial Intelligence Research*, 47: 853–899, 2013.

Hongsuck Seo, P.、Weyand, T.、Sim, J. 和 Han, B. Cplanet：通过地图的组合划分增强图像地理定位。收录于 *Proceedings of the European Conference on Computer Vision (ECCV)*，第 536–551 页，2018年。

Howard, J. 和 Ruder, S. 用于文本分类的通用语言模型微调。*arXiv preprint arXiv:1801.06146*，2018年。

Ilyas, A., Santurkar, S., Tsipras, D., Engstrom, L., Tran, B., 和 Madry, A. 对抗样本不是缺陷，而是特征。收录于 *Advances in Neural Information Processing Systems*，第 125–136 页，2019。

Ioffe, S. 和 Szegedy, C. 批量归一化：通过减少内部协变量偏移来加速深度网络训练。*arXiv preprint arXiv:1502.03167*, 2015.

Jaderberg, M.、Simonyan, K.、Vedaldi, A. 和 Zisserman, A. 用于无约束文本识别的深度结构化输出学习。*arXiv preprint arXiv:1412.5903*，2014。

Jaderberg, M., Simonyan, K., Zisserman, A., 等。空间变换网络。*Advances in neural information processing systems*, 28:2017–2025, 2015。

Johnson, J., Hariharan, B., van der Maaten, L., Fei-Fei, L., Lawrence Zitnick, C., 和 Girshick, R. Clevr：用于组合语言和基础视觉推理的诊断数据集。见 *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*，第 2901–2910 页，2017年。

Joulin, A., Van Der Maaten, L., Jabri, A., 和 Vasilache, N. 从大规模弱监督数据中学习视觉特征。载于 *European Conference on Computer Vision*，第 67–84 页。Springer，2016。

Kalfaoglu, M.、Kalkan, S. 和 Alatan, A. A. 用于动作识别的基于 BERT 的 3D CNN 架构中的后期时序建模。*arXiv preprint arXiv:2008.01232*，2020。

Kaplan, J., McCandlish, S., Henighan, T., Brown, T. B., Chess, B., Child, R., Gray, S., Radford, A., Wu, J., 和 Amodei, D. 神经语言模型的缩放定律。*arXiv preprint arXiv:2001.08361*，2020。

Karpathy, A., Joulin, A., 和 Fei-Fei, L. F. 用于双向图像句子映射的深度片段嵌入。载于 *Advances in neural information processing systems*，第 1889–1897 页，2014 年。

Keyes, O. 误称性别的机器：自动性别识别对跨性别/人机交互的影响。*Proceedings of the ACM on Human-Computer Interaction*, 2(CSCW):1–22, 2018.

Kiela, D., Firooz, H., Mohan, A., Goswami, V., Singh, A., Ringshia, P., and Testuggine, D. 仇恨模因挑战：检测多模态模因中的仇恨言论。*arXiv preprint arXiv:2005.04790*, 2020.

Kingma, D. P. 和 Ba, J. Adam：一种随机优化方法。*arXiv preprint arXiv:1412.6980*，2014。

Kiros, R.、Salakhutdinov, R. 和 Zemel, R. S. 使用多模态神经语言模型统一视觉-语义嵌入。*arXiv preprint arXiv:1411.2539*，2014。

Kiros, R., Zhu, Y., Salakhutdinov, R. R., Zemel, R., Urtasun, R., Torralba, A., 和 Fidler, S. 跳跃思维向量。*Advances in neural information processing systems*, 28: 3294–3302, 2015.

Kolesnikov, A., Beyer, L., Zhai, X., Puigcerver, J., Yung, J., Gelly, S., and Houlsby, N. 用于迁移的通用视觉表征的大规模学习。*arXiv preprint arXiv:1912.11370*, 2019.

Kornblith, S.、Shlens, J. 和 Le, Q. V. 更好的 ImageNet 模型迁移效果更好吗？收录于 *Proceedings of the IEEE conference on computer vision and pattern recognition*，第 2661–2671 页，2019 年。

Krishna, R., Zhu, Y., Groth, O., Johnson, J., Hata, K., Kravitz, J., Chen, S., Kalantidis, Y., Li, L.-J., Shamma, D. A., 等。Visual Genome：使用众包密集图像标注连接语言与视觉。*In- ternational journal of computer vision*, 123 (1):32–73, 2017.

Krizhevsky, A.、Sutskever, I. 和 Hinton, G. E. 使用深度卷积神经网络进行 Imagenet 分类。见 *Advances in neural information processing systems*，第 1097–1105 页，2012 年。

Kuhnle, A. 和 Copestake, A. Shapeworld——一种用于多模态语言理解的新测试方法。*arXiv preprint arXiv:1704.04517*, 2017.

Kärkkäinen, K. 和 Joo, J. Fairface：用于平衡种族、性别和年龄的人脸属性数据集，2019。

Lake, B. M.、Ullman, T. D.、Tenenbaum, J. B. 和 Gershman, S. J. 构建像人一样学习和思考的机器，2016年。

Lampert, C. H., Nickisch, H., 和 Harmeling, S. 通过类间属性迁移学习检测未见过的目标类别。在 *2009 IEEE Conference on Computer Vision and Pattern Recognition* 中，第 951–958 页。IEEE，2009。

Larochelle, H.、Erhan, D. 和 Bengio, Y. 新任务的零数据学习。2008年。

Le, Q. 和 Mikolov, T. 句子和文档的分布式表示。见 *International conference on machine learning*，第 1188–1196 页，2014。

LeCun, Y. MNIST 手写数字数据库。*http://yann. lecun. com/exdb/mnist/*.

Lee, D.-H. 伪标签：用于深度神经网络的简单高效半监督学习方法。

Lei Ba, J., Swersky, K., Fidler, S. 等。使用文本描述预测深度零样本卷积神经网络。载于 *Proceedings of the IEEE International Conference on Computer Vision*，第 4247–4255 页，2015 年。

Li, A.、Jabri, A.、Joulin, A. 和 van der Maaten, L. 从网络数据中学习视觉 n-gram。收录于 *Proceedings of the IEEE International Conference on Computer Vision*，第 4183–4192 页，2017 年。

Li, G., Duan, N., Fang, Y., Gong, M., 和 Jiang, D. Unicoder-vl：通过跨模态预训练实现视觉与语言的通用编码器。2020a.

Li, J., Miller, A. H., Chopra, S., Ranzato, M., 和 Weston, J. 通过提问在对话交互中学习。*arXiv preprint arXiv:1612.04936*, 2016.

Li, X.、Yin, X.、Li, C.、Hu, X.、Zhang, P.、Zhang, L.、Wang, L.、Hu, H.、Dong, L.、Wei, F. 等。Oscar：用于视觉-语言任务的对象-语义对齐预训练。*arXiv preprint arXiv:2004.06165*，2020b。

Liang, W.、Zou, J. 和 Yu, Z. Alice：带有对比性自然语言解释的主动学习。*arXiv preprint arXiv:2009.10259*，2020。

Lin, T.-Y., Maire, M., Belongie, S., Hays, J., Perona, P., Ra- manan, D., Dollár, P., and Zitnick, C. L. Microsoft COCO：上下文中的常见对象。载于 *European conference on computer vision*，第 740–755 页。Springer，2014 年。

Linzen, T. 我们如何加速朝着类人语言泛化能力的进展？*arXiv preprint arXiv:2005.00955*, 2020.

Lippe, P., Holla, N., Chandra, S., Rajamanickam, S., Antoniou, G., Shutova, E., 和 Yannakoudakis, H. 一种用于检测仇恨模因的多模态框架。*arXiv preprint arXiv:2012.12871*, 2020.

Liu, P. J., Saleh, M., Pot, E., Goodrich, B., Sepa- ssi, R., Kaiser, L., 和 Shazeer, N. 通过总结长序列生成维基百科。*arXiv preprint arXiv:1801.10198*, 2018.

Locatello, F.、Bauer, S.、Lucic, M.、Rätsch, G.、Gelly, S.、Schölkopf, B. 和 Bachem, O. 对解耦表示的无监督学习及其评估的冷静审视。*arXiv preprint arXiv:2010.14766*，2020。

Loshchilov, I. 和 Hutter, F. SGDR：带热重启的随机梯度下降。*arXiv preprint arXiv:1608.03983*, 2016.

Loshchilov, I. 和 Hutter, F. 解耦权重衰减正则化。*arXiv preprint arXiv:1711.05101*, 2017.

Lu, J.、Batra, D.、Parikh, D. 和 Lee, S. Vilbert：为视觉与语言任务预训练任务无关的视觉语言表征。载于 *Advances in Neural Information Processing Systems*，第 13–23 页，2019 年。

Lu, Z., Xiong, X., Li, Y., Stroud, J., 和 Ross, D. 利用弱监督数据和姿态表示进行动作识别，2020。URL https://www.youtube. com/watch?v=KOQFxbPPLOE&t=1390s.

Lucic, M., Kurach, K., Michalski, M., Gelly, S., 和 Bousquet, O. GAN 是否生而平等？一项大规模研究。*Advances in neural information processing systems*, 31: 700–709, 2018.

Mahajan, D., Girshick, R., Ramanathan, V., He, K., Paluri, M., Li, Y., Bharambe, A., 和 van der Maaten, L. 探索弱监督预训练的极限。收录于 *Proceedings of the European Conference on Computer Vision (ECCV)*，第 181–196 页，2018 年。

McCann, B.、Bradbury, J.、Xiong, C. 和 Socher, R. 在翻译中学习：上下文化词向量。见 *Advances in neural information processing systems*，第 6294–6305 页，2017 年。

McCann, B.、Keskar, N. S.、Xiong, C. 和 Socher, R. 自然语言十项全能：将多任务学习视为问答。*arXiv preprint arXiv:1806.08730*, 2018.

Micikevicius, P., Narang, S., Alben, J., Diamos, G., Elsen, E., Garcia, D., Ginsburg, B., Houston, M., Kuchaiev, O., Venkatesh, G., 等。混合精度训练。*arXiv preprint arXiv:1710.03740*，2017。

Miech, A., Zhukov, D., Alayrac, J.-B., Tapaswi, M., Laptev, I., 和 Sivic, J. Howto100m：通过观看一亿个带解说的视频片段来学习文本-视频嵌入。在 *Proceedings of the IEEE international conference on computer vision*，第 2630–2640 页，2019 年。

Miech, A., Alayrac, J.-B., Laptev, I., Sivic, J., 和 Zisser-man, A. Rareact：一个罕见交互视频数据集。*arXiv preprint arXiv:2008.01018*, 2020a.

Miech, A., Alayrac, J.-B., Smaira, L., Laptev, I., Sivic, J., 和 Zisserman, A. 从未经筛选的教学视频中端到端学习视觉表示。收录于 *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*，第 9879–9889 页，2020b。

Mikolov, T.、Sutskever, I.、Chen, K.、Corrado, G. S. 和 Dean, J. 词和短语的分布式表示及其组合性。*Advances in neural informa- tion processing systems*，26: 3111–3119，2013。

Miller, J., Krauth, K., Recht, B., and Schmidt, L. 自然分布偏移对问答模型的影响。*arXiv preprint arXiv:2004.14444*, 2020.

Mishra, A.、Alahari, K. 和 Jawahar, C. 使用高阶语言先验进行场景文本识别。2012。

Mithun, N. C.、Panda, R.、Papalexakis, E. E. 和 Roy-Chowdhury, A. K. 用于跨模态图像-文本检索的网络监督联合嵌入。见 *Proceedings of the 26th ACM international conference on Multimedia*，第 1856–1864 页，2018 年。

Mori, Y., Takahashi, H., 和 Oka, R. 基于用词语对图像进行划分和矢量量化的图像到词语转换。Citeseer，1999。

Mu, J.、Liang, P. 和 Goodman, N. 用语言塑造用于少样本分类的视觉表示。*arXiv preprint arXiv:1911.02683*, 2019.

Muller-Budack, E.、Pustu-Iren, K. 和 Ewerth, R. 使用层次模型和场景分类进行照片地理位置估计。见 *Proceedings of the European Conference on Computer Vision (ECCV)*，第 563–579 页，2018 年。

Murty, S.、Koh, P. W. 和 Liang, P. Expbert：使用自然语言解释进行表示工程。*arXiv preprint arXiv:2005.01932*，2020。

Narasimhan, K., Kulkarni, T., 和 Barzilay, R. 使用深度强化学习进行基于文本游戏的语言理解。*arXiv preprint arXiv:1506.08941*, 2015.

Netzer, Y., Wang, T., Coates, A., Bissacco, A., Wu, B., 和 Ng, A. Y. 使用无监督特征学习读取自然图像中的数字。2011 年。

Noble, S. U.《压迫算法：搜索引擎如何强化种族主义》。2018年。

Nosek, B. A., Banaji, M. R., 和 Greenwald, A. G. 从演示网站收集内隐群体态度和信念。*Group Dynamics: Theory, Research, and Practice*, 6(1):101, 2002.

Oh, S., Hoogs, A., Perera, A., Cuntoor, N., Chen, C.-C., Lee, J. T., Mukherjee, S., Aggarwal, J., Lee, H., Davis, L., 等。用于监控视频中事件识别的大规模基准数据集。见 *CVPR 2011*，第 3153–3160 页。IEEE，2011。

Oliver, A., Odena, A., Raffel, C. A., Cubuk, E. D., 和 Goodfellow, I. 深度半监督学习算法的真实评估。*Advances in neural information pro- cessing systems*, 31:3235–3246, 2018.

Oord, A. v. d.、Li, Y. 和 Vinyals, O. 对比预测编码的表示学习。*arXiv preprint arXiv:1807.03748*，2018。

Ordonez, V.、Kulkarni, G. 和 Berg, T. Im2text：使用 100 万张带说明文字的照片描述图像。*Advances in neural information processing systems*，24:1143–1151，2011。

pandas 开发团队，T. pandas-dev/pandas：Pandas，2020 年 2 月。URL https://doi.org/10.5281/zenodo.3509134.

Parkhi, O. M., Vedaldi, A., Zisserman, A., and Jawahar, C. V. 猫和狗。载于 *IEEE Conference on Computer Vision and Pattern Recognition*, 2012.

Paszke, A.、Gross, S.、Massa, F.、Lerer, A.、Bradbury, J.、Chanan, G.、Killeen, T.、Lin, Z.、Gimelshein, N.、Antiga, L.、Desmaison, A.、Kopf, A.、Yang, E.、DeVito, Z.、Raison, M.、Tejani, A.、Chilamkurthy, S.、Steiner, B.、Fang, L.、Bai, J. 和 Chintala, S. Pytorch：一个命令式风格的高性能深度学习库。见 *Advances in Neural Information Processing Systems 32*，第 8024–8035 页，2019 年。

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cour- napeau, D., Brucher, M., Perrot, M., 和 Duchesnay, E. Scikit-learn：Python 中的机器学习。*Journal of Machine Learning Research*, 12:2825–2830, 2011.

Pennington, J.、Socher, R. 和 Manning, C. D. Glove：用于词表示的全局向量。载于 *Proceedings of the 2014 conference on empirical methods in natural language processing (EMNLP)*，第 1532–1543 页，2014 年。

Peters, M. E., Neumann, M., Iyyer, M., Gardner, M., Clark, C., Lee, K., 和 Zettlemoyer, L. 深度上下文化词表示。*arXiv preprint arXiv:1802.05365*, 2018.

Qi, D., Su, L., Song, J., Cui, E., Bharti, T., 和 Sacheti, A. Imagebert：使用大规模弱监督图像-文本数据进行跨模态预训练。*arXiv preprint arXiv:2001.07966*, 2020.

Quattoni, A.、Collins, M. 和 Darrell, T. 使用带标题说明的图像学习视觉表示。见 *2007 IEEE Conference on Computer Vision and Pattern Recognition*，第 1–8 页。IEEE，2007 年。

Radford, A., Narasimhan, K., Salimans, T., 和 Sutskever, I. 通过生成式预训练改进语言理解，2018。

Radford, A., Wu, J., Child, R., Luan, D., Amodei, D., 和 Sutskever, I. 语言模型是无监督的多任务学习者。2019.

Raffel, C.、Shazeer, N.、Roberts, A.、Lee, K.、Narang, S.、Matena, M.、Zhou, Y.、Li, W. 和 Liu, P. J. 探索使用统一文本到文本 Transformer 进行迁移学习的极限。*arXiv preprint arXiv:1910.10683*，2019。

Raji, I. D., Gebru, T., Mitchell, M., Buolamwini, J., Lee, J., 和 Denton, E. 挽回颜面：探究面部识别审计中的伦理问题，2020。

Ramanathan, V., Liang, P., and Fei-Fei, L. 使用自然语言描述进行视频事件理解。载于 *Proceedings of the IEEE International Conference on Computer Vision*，第 905–912 页，2013 年。

Rashtchian, C., Young, P., Hodosh, M., 和 Hockenmaier, J. 使用亚马逊 Mechanical Turk 收集图像标注。载于 *Proceedings of the NAACL HLT 2010 Workshop on Creating Speech and Language Data with Amazon's Mechanical Turk*，第 139–147 页，2010。

Recht, B., Roelofs, R., Schmidt, L., 和 Shankar, V. Image Net 分类器能泛化到 ImageNet 吗？ *arXiv preprint arXiv:1902.10811*, 2019.

Salimans, T. 和 Kingma, D. P. 权重归一化：一种用于加速深度神经网络训练的简单重参数化方法。载于 *Advances in neural information pro- cessing systems*，第 901–909 页，2016 年。

Scheuerman, M. K., Paul, J. M., 和 Brubaker, J. R. 计算机如何看待性别：对商业面部分析服务中性别分类的评估。*Proceedings of the ACM on Human-Computer Interaction*, 3(CSCW): 1–33, 2019.

Schwemmer, C., Knight, C., Bello-Pardo, E. D., Oklobdzija, S., Schoonvelde, M., 和 Lockhart, J. W. 诊断图像识别系统中的性别偏见。*Socius*, 6: 2378023120967171, 2020.

Sennrich, R.、Haddow, B. 和 Birch, A. 使用子词单元进行稀有词的神经机器翻译。*arXiv preprint arXiv:1508.07909*，2015。

Shankar, V., Dave, A., Roelofs, R., Ramanan, D., Recht, B., 和 Schmidt, L. 图像分类器能否跨时间泛化? *arXiv preprint arXiv:1906.02168*, 2019.

Sharma, P.、Ding, N.、Goodman, S. 和 Soricut, R. 概念性字幕：用于自动图像字幕生成的经过清洗和上位词化处理的图像替代文本数据集。载于 *Proceedings of the 56th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*，第 2556–2565 页，2018 年。

Singh, A., Natarajan, V., Shah, M., Jiang, Y., Chen, X., Batra, D., Parikh, D., and Rohrbach, M. 迈向能够阅读的 VQA 模型。载于 *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*，第 8317–8326 页，2019。

Socher, R. 和 Fei-Fei, L. 连接模态：使用未对齐文本语料库对图像进行半监督分割与标注。载于 *2010 IEEE Computer Society Conference on Computer Vision and Pattern Recognition*，第 966–973 页。IEEE，2010。

Socher, R., Perelygin, A., Wu, J., Chuang, J., Manning, C. D., Ng, A. Y., 和 Potts, C. 用于情感树库上语义组合性的递归深度模型。载于 *Proceedings of the 2013 conference on empirical methods in natural language processing*，第 1631–1642 页，2013 年。

Socher, R.、Karpathy, A.、Le, Q. V.、Manning, C. D. 和 Ng, A. Y. 用于通过句子查找和描述图像的扎根组合语义。*Transactions of the Association for Computational Linguistics*，2:207–218，2014。

Sohn, K. 使用多类别 n-pair 损失目标改进深度度量学习。载于 *Advances in neural information processing systems*，第 1857–1865 页，2016。

Solaiman, I., Brundage, M., Clark, J., Askell, A., Herbert-Voss, A., Wu, J., Radford, A., Krueger, G., Kim, J. W., Kreps, S., McCain, M., Newhouse, A., Blazakis, J., McGuffie, K., and Wang, J. 语言模型的发布策略及其社会影响，2019。

Soomro, K.、Zamir, A. R. 和 Shah, M. Ucf101：一个来自自然场景视频的 101 类人类动作数据集。*arXiv preprint arXiv:1212.0402*，2012。

Speer, R. ftfy. Zenodo，2019年。URL https://doi.org/ 10.5281/zenodo.2591652。版本 5.5。

Srivastava, N. 和 Salakhutdinov, R. 使用深度玻尔兹曼机的多模态学习。收录于 *NIPS*，2012。

Srivastava, S., Labutov, I., 和 Mitchell, T. 从自然语言解释中进行联合概念学习与语义解析。载于 *Proceedings of the 2017 conference on empirical methods in natural language processing*，第 1527–1536 页，2017 年。

Stallkamp, J.、Schlipsing, M.、Salmen, J. 和 Igel, C. 德国交通标志识别基准：一项多类别分类竞赛。载于 *IEEE International Joint Conference on Neural Networks*，第 1453–1460 页，2011 年。

Stroud, J. C.、Ross, D. A.、Sun, C.、Deng, J.、Sukthankar, R. 和 Schmid, C. 从文本网络监督中学习视频表征。*arXiv preprint arXiv:2007.14937*，2020。

Szegedy, C., Ioffe, S., Vanhoucke, V., 和 Alemi, A. Inception-v4、Inception-ResNet 以及残差连接对学习的影响。*arXiv preprint arXiv:1602.07261*, 2016.

Tan, H. 和 Bansal, M. Lxmert：从 Transformer 学习跨模态编码器表示。*arXiv preprint arXiv:1908.07490*，2019。

Tan, M. 和 Le, Q. V. EfficientNet：重新思考卷积神经网络的模型缩放。*arXiv preprint arXiv:1905.11946*，2019。

Taori, R., Dave, A., Shankar, V., Carlini, N., Recht, B., 和 Schmidt, L. 测量图像分类中对自然分布偏移的鲁棒性。*arXiv preprint arXiv:2007.00644*, 2020.

Thomee, B., Shamma, D. A., Friedland, G., Elizalde, B., Ni, K., Poland, D., Borth, D., and Li, L.-J. Yfcc100m：多媒体研究中的新数据。*Communications of the ACM*, 59(2): 64–73, 2016.

Tian, Y.、Krishnan, D. 和 Isola, P. 对比多视图编码。*arXiv preprint arXiv:1906.05849*，2019。

Tian, Y., Wang, Y., Krishnan, D., Tenenbaum, J. B., 和 Isola, P. 重新思考小样本图像分类：一个好的嵌入就是你所需要的一切吗？*arXiv preprint arXiv:2003.11539*, 2020.

Torralba, A., Fergus, R., 和 Freeman, W. T. 8000 万张微小图像：用于非参数对象和场景识别的大型数据集。*IEEE transactions on pattern analysis and machine intelligence*, 30(11):1958–1970, 2008.

Touvron, H.、Vedaldi, A.、Douze, M. 和 Jégou, H. 修正训练-测试分辨率差异。见 *Advances in neural information processing systems*，第 8252–8262 页，2019。

Varadarajan, J. 和 Odobez, J.-M. 用于场景分析和异常检测的主题模型。载于 *2009 IEEE 12th International Conference on Computer Vision Workshops, ICCV Workshops*，第 1338–1345 页。IEEE，2009。

Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, ., 和 Polosukhin, I. 注意力就是你所需要的一切。载于 *Advances in neural information processing systems*，第 5998–6008 页，2017。

Veeling, B. S., Linmans, J., Winkens, J., Cohen, T., 和 Welling, M. 用于数字病理学的旋转等变 CNN。2018年6月。

Virtanen, P.、Gommers, R.、Oliphant, T. E.、Haberland, M.、Reddy, T.、Cournapeau, D.、Burovski, E.、Peterson, P.、Weckesser, W.、Bright, J.、van der Walt, S. J.、Brett, M.、Wilson, J.、Millman, K. J.、Mayorov, N.、Nelson, A. R. J.、Jones, E.、Kern, R.、Larson, E.、Carey, C. J.、Polat, İ.、Feng, Y.、Moore, E. W.、VanderPlas, J.、Laxalde, D.、Perktold, J.、Cimrman, R.、Henriksen, I.、Quintero, E. A.、Harris, C. R.、Archibald, A. M.、Ribeiro, A. H.、Pedregosa, F.、van Mulbregt, P.，以及 SciPy 1.0 贡献者。SciPy 1.0：Python 科学计算的基础算法。*Nature Methods*，17:261–272，2020。doi: 10.1038/s41592-019-0686-2.

Vo, N.、Jacobs, N. 和 Hays, J. 在深度学习时代重新审视 im2gps。载于 *Proceedings of the IEEE International Conference on Computer Vision*，第 2621–2630 页，2017 年。

Wang, A., Singh, A., Michael, J., Hill, F., Levy, O., 和 Bowman, S. R. GLUE：用于自然语言理解的多任务基准和分析平台。*arXiv preprint arXiv:1804.07461*, 2018.

Wang, H., Ge, S., Lipton, Z., and Xing, E. P. 通过惩罚局部预测能力来学习鲁棒的全局表示。载于 *Advances in Neural Information Processing Systems*，第 10506–10518 页，2019。

Wang, H., Lu, P., Zhang, H., Yang, M., Bai, X., Xu, Y., He, M., Wang, Y., and Liu, W. 你所需要的只是边界：迈向任意形状文本检测与识别。在 *Proceedings of the AAAI Conference on Artificial Intelligence* 中，第 34 卷，第 12160–12167 页，2020 年。

Wang, J.、Markert, K. 和 Everingham, M. 从自然语言描述中学习用于物体识别的模型。在 *BMVC*，第 1 卷，第 2 页，2009 年。

Weston, J.、Bengio, S. 和 Usunier, N. 大规模图像标注：使用联合词-图像嵌入学习排序。*Machine learning*, 81(1):21–35, 2010.

Weston, J. E. 基于对话的语言学习。载于 *Advances in Neural Information Processing Systems*，第 829–837 页，2016。

Weyand, T.、Kostrikov, I. 和 Philbin, J. 使用卷积神经网络进行 Planet 照片地理定位。载于 *European Conference on Computer Vision*，第 37–55 页。Springer，2016。

Wu, Y.、Kirillov, A.、Massa, F.、Lo, W.-Y. 和 Girshick, R. Detectron2. https://github.com/facebookresearch/detectron2，2019。

Wu, Z., Xiong, Y., Yu, S., 和 Lin, D. 通过非参数实例级判别进行无监督特征学习。*arXiv preprint arXiv:1805.01978*, 2018.

Xie, Q., Luong, M.-T., Hovy, E., 和 Le, Q. V. 使用噪声学生的自训练改进了 ImageNet 分类。见 *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*，第 10687–10698 页，2020 年。

y Arcas, B. A.、Mitchell, M. 和 Todorov, A.《面相学的新衣》。2017。URL https://medium.com/@blaisea/ physiognomys-new-clothes-f2d4b59fdd6a.

Yang, Z., Lu, Y., Wang, J., Yin, X., Florencio, D., Wang, L., Zhang, C., Zhang, L., 和 Luo, J. Tap：用于文本 VQA 和文本描述的文本感知预训练。*arXiv preprint arXiv:2012.04638*, 2020.

Yogatama, D., d’ Autume, C. d. M., Connor, J., Kocisky, T., Chrzanowski, M., Kong, L., Lazaridou, A., Ling, W., Yu, L., Dyer, C., 等。学习与评估通用语言智能。*arXiv preprint arXiv:1901.11373*, 2019.

Young, P.、Lai, A.、Hodosh, M. 和 Hockenmaier, J. 从图像描述到视觉指称：用于事件描述语义推理的新相似度指标。*Transactions of the Association for Computational Linguistics*，2:67–78，2014。

Yu, F., Tang, J., Yin, W., Sun, Y., Tian, H., Wu, H., and Wang, H. Ernie-vil：通过场景图增强知识的视觉-语言表示。*arXiv preprint arXiv:2006.16934*, 2020.

Zeiler, M. D. 和 Fergus, R. 可视化并理解卷积网络。载于 *European conference on computer vision*，第 818–833 页。Springer，2014。

Zhai, X., Puigcerver, J., Kolesnikov, A., Ruyssen, P., Riquelme, C., Lucic, M., Djolonga, J., Pinto, A. S., Neu- mann, M., Dosovitskiy, A., 等。基于视觉任务适应基准的表征学习大规模研究。*arXiv preprint arXiv:1910.04867*, 2019.

Zhang, R. 让卷积网络再次具有平移不变性。*arXiv preprint arXiv:1904.11486*, 2019.

Zhang, Y., Jiang, H., Miura, Y., Manning, C. D., 和 Langlotz, C. P. 从配对图像和文本中对比学习医学视觉表示。*arXiv preprint arXiv:2010.00747*, 2020.

Zuboff, S. 大他者：监视资本主义与信息文明的前景。*Journal of Infor- mation Technology*, 30(1):75–89, 2015.

A. 线性探针评估

我们提供了本文中线性探针实验的更多细节，包括用于评估的数据集和模型列表。

A.1. 数据集

我们使用由（Kornblith et al., 2019）提出并被广泛研究的评估套件中的 12 个数据集，并额外加入 15 个数据集，以评估模型在更广泛的分布和任务上的性能。这些数据集包括 MNIST、Facial Expression Recognition 2013 数据集（Goodfellow et al., 2015）、STL-10（Coates et al., 2011）、EuroSAT（Helber et al., 2019）、NWPU-RESISC45 数据集（Cheng et al., 2017）、German Traffic Sign Recognition Benchmark（GTSRB）数据集（Stallkamp et al., 2011）、KITTI 数据集（Geiger et al., 2012）、PatchCamelyon（Veeling et al., 2018）、UCF101 动作识别数据集（Soomro et al., 2012）、Kinetics 700（Carreira et al., 2019）、CLEVR 数据集的 2,500 个随机样本（Johnson et al., 2017）、Hateful Memes 数据集（Kiela et al., 2020）以及 ImageNet-1k 数据集（Deng et al., 2012）。对于两个视频数据集（UCF101 和 Kinetics 700），我们使用每个视频片段的中间帧作为输入图像。STL-10 和 UCF101 分别具有 10 个和 3 个预定义的训练/验证/测试划分，我们报告所有划分上的平均结果。每个数据集的详细信息及其对应的评估指标见表 9。

此外，我们创建了两个数据集，称为 Country211 和 Rendered SST2。Country211 数据集旨在评估视觉表示的地理定位能力。我们对 YFCC100m 数据集（Thomee 等，2016）进行了筛选，找到了 211 个国家（定义为具有 ISO-3166 国家代码），这些国家至少有 300 张带 GPS 坐标的照片；并构建了一个包含 211 个类别的均衡数据集，其中每个国家抽取 200 张照片用于训练、100 张照片用于测试。

Rendered SST2 数据集旨在衡量视觉表征的光学字符识别能力。为此，我们使用了 Stanford Sentiment Treebank 数据集（Socher 等，2013）中的句子，并将其渲染为图像，即白色背景上的黑色文本，分辨率为 448×448。该数据集中的两个示例图像如图 19 所示。

A.2. 模型

结合上述数据集，我们使用线性探针对以下一系列模型进行评估。

LM RN50 这是一个多模态模型，它使用自回归损失而不是对比损失，同时使用采用与最小的对比模型相同的 ResNet-50 架构。为此，将 CNN 的输出投影为四个 token，然后将其作为前缀输入到语言模型中，由该模型以自回归方式预测文本 token。除训练目标外，该模型在与其他 CLIP 模型相同的数据集上训练了相同的轮数。

CLIP-RN 包含五个基于 ResNet 的对比式 CLIP 模型。如论文中所述，前两个模型遵循 ResNet-50 和 ResNet-101，接下来的三个模型则采用 EfficientNet 风格（Tan & Le, 2019）的缩放方式，同时缩放模型宽度、层数和输入分辨率，以获得计算量约为 4 倍、16 倍和 64 倍的模型。

CLIP-ViT 我们包含四个使用视觉 Transformer（Dosovitskiy 等，2020）架构作为图像编码器的 CLIP 模型。我们包含三个在 224×224 像素图像上训练的模型：ViT-B/32、ViT-B/16、ViT-L/14，以及在 336×336 像素输入图像上微调的 ViT-L/14 模型。

EfficientNet 我们使用了原始 EfficientNet 论文（Tan & Le，2019）中的九个模型（B0-B8），以及 noisy-student 变体（B0-B7、L2-475 和 L2-800）（Tan & Le，2019）。最大的模型（L2-475 和 L2-800）分别采用 475x475 和 800x800 像素的输入分辨率。

Instagram 预训练的 ResNeXt 我们使用了（Mahajan 等，2018）发布的四个模型（32x8d、32x16d、32x32d、32x48d），以及它们的两个使用更高输入分辨率的 FixRes 变体（Touvron 等，2019）。

大迁移（BiT）我们使用在 ImageNet-1k 和 ImageNet-21k 数据集上训练的 BiT-S 和 BiT-M 模型（Kolesnikov 等，2019）。BiT-L 的模型权重未公开提供。

视觉 Transformer（ViT）我们还包括四个在 ImageNet-21k 数据集上预训练的 ViT（Dosovitskiy 等，2020）检查点，即 ViT-B/32、ViT-B/16、ViT-L/16 和 ViT-H/14。我们注意到，他们在 JFT-300M 数据集上训练的表现最佳的模型并未公开提供。

SimCLRv2 SimCLRv2（Chen 等，2020c）项目发布了在各种设置下预训练和微调的模型。我们使用了七个带有选择性卷积核的仅预训练检查点。

BYOL 我们使用了最近发布的 BYOL（Grill 等，2020）的模型权重，具体来说是其 50x1 和 200x2

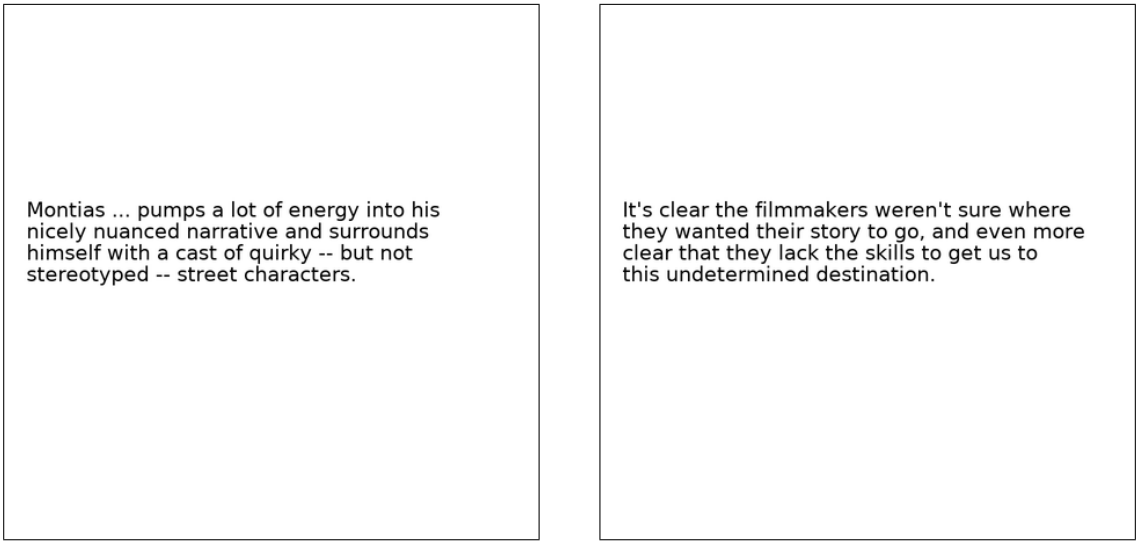


图 19. Rendered SST2 数据集中的两个示例图像

检查点。

动量对比（MoCo）我们包含 MoCo-v1（He 等，2020）和 MoCo-v2（Chen 等，2020d）检查点。

VirTex 我们使用 VirTex 的预训练模型（Desai & Johnson, 2020）。我们注意到，VirTex 的模型设计与 CLIP-AR 相似，但其训练所用的数据集规模小 1000 倍，来自 MSCOCO 的高质量图像描述。

ResNet 我们添加了（He 等人，2016b）发布的原始 ResNet 检查点，即 ResNet-50、ResNet-101 和 ResNet152。

A.3. 评估

我们使用取自每个模型倒数第二层的图像特征，忽略任何提供的分类层。对于 CLIP-ViT 模型，我们使用线性投影到嵌入空间之前的特征，这对应于图 3 中的 I f。我们使用 scikit-learn 的 L-BFGS 实现训练逻辑回归分类器，最大迭代次数为 1,000，并报告每个数据集对应的指标。我们通过在验证集上进行超参数扫描，在 10^{-6} 到 10^{6} 的范围内以 96 个按对数间隔分布的步长，确定 L2 正则化强度 λ。为节省扫描所需的计算量，我们执行参数化二分搜索，从 $\lambda = [10^{-6}, 10^{-4}, 10^{-2}, 1, 10^{2}, 10^{4}, 10^{6}]$ 开始，并迭代地将峰值周围的区间减半，直到达到每十倍区间 8 个步长的分辨率。超参数扫描在每个数据集的验证划分上进行。对于除以下之外还包含验证划分的数据集

对于测试划分，我们使用提供的验证集进行超参数搜索；对于未提供验证划分或未公布测试数据标签的数据集，我们划分训练数据集来进行超参数搜索。对于最终结果，我们将验证划分重新合并回训练划分，并报告在未使用划分上的性能。

A.4. 结果

各个线性探针得分见表 10，并绘制于图 20 中。表现最佳的 CLIP 模型采用 ViT-L/14 架构和 336×336 像素图像，在 27 个数据集中的 21 个上达到了最先进水平，即落入各数据集最高得分周围的 Clopper-Pearson 99.5 % 置信区间内。对于许多数据集，CLIP 的表现显著优于其他模型，展示了自然语言监督相较于基于图像分类的传统预训练方法的优势。有关线性探针结果的更多讨论，请参见第 3.2 节。

Dataset	Classes	Train size	Test size	Evaluation metric
Food-101	102	75,750	25,250	accuracy
CIFAR-10	10	50,000	10,000	accuracy
CIFAR-100	100	50,000	10,000	accuracy
Birdsnap	500	42,283	2,149	accuracy
SUN397	397	19,850	19,850	accuracy
Stanford Cars	196	8,144	8,041	accuracy
FGVC Aircraft	100	6,667	3,333	mean per class
Pascal VOC 2007 Classification	20	5,011	4,952	11-point mAP
Describable Textures	47	3,760	1,880	accuracy
Oxford-IIIT Pets	37	3,680	3,669	mean per class
Caltech-101	102	3,060	6,085	mean-per-class
Oxford Flowers 102	102	2,040	6,149	mean per class
MNIST	10	60,000	10,000	accuracy
Facial Emotion Recognition 2013	8	32,140	3,574	accuracy
STL-10	10	1000	8000	accuracy
EuroSAT	10	10,000	5,000	accuracy
RESISC45	45	3,150	25,200	accuracy
GTSRB	43	26,640	12,630	accuracy
KITTI	4	6,770	711	accuracy
Country211	211	43,200	21,100	accuracy
PatchCamelyon	2	294,912	32,768	accuracy
UCF101	101	9,537	1,794	accuracy
Kinetics700	700	494,801	31,669	mean(top1, top5)
CLEVR Counts	8	2,000	500	accuracy
Hateful Memes	2	8,500	500	ROC AUC
Rendered SST2	2	7,792	1,821	accuracy
ImageNet	1000	1,281,167	50,000	accuracy

表 9. 用于线性探针评估的数据集。我们注意到，对于 Birdsnap 和 Kinetics700 数据集，我们使用了撰写本文时可在线获取的资源。

		Food101	CIFAR10	CIFAR100	Birdsnap	SUN397	Cars	Aircraft	VOC2007	DTD	Pets	Caltech101	Flowers	MNIST	FER2013	STL10	CIFAR100	CLEVR	PCAM	CLEVR	Resisc45	KITTI	Country211	Mean
	LM RN50	81.3	82.8	61.7	44.2	69.6	74.9	44.9	85.5	71.5	82.8	85.5	91.1	96.6	60.1	95.3	93.4	84.0	73.8	70.2	19.0	82.9	76.4	51.9	51.2	65.2	76.8	65.2
NPLC	50	86.4	88.7	70.3	56.4	73.3	78.3	49.1	87.1	76.4	88.2	89.6	96.1	98.3	64.2	96.6	95.2	87.5	82.4	70.2	25.3	82.7	81.6	57.2	53.6	65.7	72.6	73.3
	101	88.9	91.1	73.5	58.6	75.1	84.0	50.7	88.0	76.3	91.0	92.0	96.4	98.4	65.2	97.8	95.9	89.3	82.4	**73.6**	26.6	82.8	84.0	60.3	50.3	68.2	73.3	75.7
	50x4	91.3	90.5	73.0	65.7	77.0	85.9	57.3	88.4	79.5	91.9	92.5	97.8	98.5	68.1	97.8	96.4	89.7	85.5	59.4	30.3	83.0	85.7	62.6	52.5	68.0	76.6	78.2
	50x16	93.3	92.2	74.9	72.8	79.2	88.7	62.7	**89.0**	79.1	93.5	93.7	98.3	**98.9**	68.7	98.6	97.0	91.4	89.0	69.2	34.8	83.5	88.0	66.3	53.8	71.1	**80.0**	81.5
	50x64	94.8	94.1	78.6	77.2	81.1	90.5	67.7	**88.9**	**82.0**	94.5	95.4	98.9	**98.9**	**71.3**	99.1	97.1	92.8	90.2	69.2	40.7	83.7	89.5	69.1	55.0	**75.0**	**81.2**	83.6
TVPLC	B/32	88.8	95.1	80.5	58.5	76.6	81.8	52.0	87.7	76.5	90.0	93.0	96.9	**99.0**	69.2	98.3	97.0	90.5	85.3	66.2	27.8	83.9	85.5	61.7	52.1	66.7	70.8	76.1
	B/16	92.8	96.2	83.1	67.8	78.4	86.7	59.5	**89.2**	79.2	93.1	94.7	98.1	**99.0**	69.5	99.0	97.1	92.7	86.6	67.8	33.3	83.5	88.4	66.1	**57.1**	70.3	75.5	80.2
	L/14	95.2	98.0	87.5	77.0	**81.8**	**90.9**	69.4	**89.6**	**82.1**	**95.1**	**96.5**	99.2	**99.2**	**72.2**	**99.7**	**98.2**	94.1	**92.5**	64.7	42.9	85.8	**91.5**	72.0	**57.8**	**76.2**	**80.8**	83.9
	L/14-336px	**95.9**	97.9	87.4	**79.9**	**82.2**	**91.5**	**71.6**	**89.9**	**83.0**	**95.1**	**96.0**	99.2	**99.2**	**72.9**	**99.7**	**98.1**	**94.9**	**92.4**	69.2	**46.4**	85.6	**92.0**	**73.0**	**60.3**	**77.3**	**80.5**	85.4
EfficientNet	B0	74.3	92.5	76.5	59.7	62.0	62.5	55.7	84.4	71.2	93.0	93.3	91.7	98.2	57.2	97.1	97.3	85.5	80.0	**73.8**	12.4	83.1	74.4	47.6	47.9	55.7	53.4	76.9
	B1	74.2	93.2	77.2	61.3	62.6	62.5	56.1	84.7	74.2	93.4	93.6	92.4	98.3	57.0	97.5	96.8	84.5	75.9	**75.5**	12.5	82.7	74.7	48.5	44.3	54.5	54.4	78.6
	B2	75.8	93.6	77.9	64.4	64.0	63.2	57.0	85.3	73.5	93.9	93.5	92.9	98.5	56.6	97.7	96.9	84.4	76.4	**73.1**	12.6	84.3	75.1	49.4	42.6	55.4	55.2	79.7
	B3	77.4	94.0	78.0	66.5	64.4	66.0	59.3	85.8	73.1	94.1	93.7	93.3	98.5	57.1	98.2	97.3	85.0	75.8	**76.1**	13.4	83.3	78.1	50.9	45.1	53.8	54.8	81.0
	B4	79.7	94.1	78.7	70.1	65.4	66.4	60.4	86.5	73.4	94.7	93.5	93.2	98.8	57.9	98.6	96.8	85.0	78.3	**72.3**	13.9	83.1	79.1	52.5	46.5	54.4	55.4	82.9
	B5	81.5	93.6	77.9	72.4	67.1	72.7	68.9	86.7	73.9	**95.0**	94.7	94.5	98.4	58.5	98.7	96.8	86.0	78.5	69.6	14.9	84.7	80.9	54.5	46.6	53.3	56.3	83.7
	B6	82.4	94.0	78.0	73.5	65.8	71.1	68.2	87.6	73.9	**95.0**	94.1	93.7	98.4	60.2	98.7	96.8	85.4	78.1	**72.7**	15.3	84.2	80.0	54.1	51.1	53.3	57.0	84.0
	B7	84.5	94.9	80.1	74.7	69.0	77.1	**72.3**	87.2	76.8	**95.2**	94.7	95.9	98.6	61.3	99.1	96.3	86.8	80.8	**75.8**	16.4	85.2	81.9	56.8	51.9	54.4	57.8	84.8
	B8	84.5	95.0	80.7	75.2	69.6	76.8	**71.5**	87.4	77.1	**94.9**	95.2	96.3	98.6	61.4	99.2	97.0	87.4	80.4	70.9	17.4	85.2	82.4	57.7	51.4	51.7	55.8	85.3
EfficientNet-NoisyStudent	B0	78.1	94.0	78.6	63.5	65.5	57.2	53.7	85.6	75.6	93.8	93.1	94.5	98.1	55.6	98.2	97.0	84.3	74.0	71.6	14.0	83.1	76.7	51.7	47.3	55.7	55.0	78.5
	B1	80.4	95.1	80.2	66.6	67.6	59.6	53.7	86.2	77.0	94.6	94.4	95.1	98.0	56.1	98.6	96.9	84.3	73.1	67.1	14.5	83.9	79.9	54.5	46.1	54.3	54.9	81.1
	B2	80.9	95.3	81.3	67.6	67.9	60.9	55.2	86.3	77.7	**95.0**	94.7	94.4	98.0	55.5	98.8	97.3	84.6	71.7	70.0	14.6	82.9	80.1	55.1	46.1	54.1	55.3	82.2
	B3	82.6	95.9	82.1	68.6	68.8	60.6	55.4	86.5	77.2	**95.0**	94.8	95.2	98.1	56.0	99.1	96.5	85.0	70.5	69.5	15.1	83.1	81.8	56.8	45.1	55.7	52.0	83.8
	B4	85.2	95.6	81.0	72.5	69.7	56.1	52.6	87.0	78.7	**94.8**	95.2	95.3	98.2	56.0	99.3	95.3	84.8	61.9	64.8	16.0	82.8	83.4	59.8	43.2	55.3	53.0	85.4
	B5	87.6	96.3	82.4	75.3	71.6	64.7	64.8	87.8	79.6	**95.5**	95.6	96.6	98.8	60.9	99.4	96.1	87.0	68.5	**73.7**	16.4	83.5	86.4	61.6	46.3	53.4	55.8	85.8
	B6	87.3	97.0	83.9	75.8	71.4	67.6	65.6	87.3	78.5	**95.2**	**96.4**	97.2	98.6	61.9	**99.5**	96.6	86.1	70.7	**72.4**	17.6	84.2	85.5	61.0	49.6	54.6	55.7	86.4
	B7	88.4	96.0	82.0	76.9	72.6	72.2	**71.2**	88.1	**80.5**	**95.5**	95.5	96.6	98.5	62.7	99.4	96.2	88.5	73.4	**73.0**	18.5	83.8	86.6	63.2	50.5	57.2	56.7	87.0
	L2-475	91.6	**99.0**	**91.0**	74.8	76.4	75.1	66.8	**89.5**	**81.9**	**95.6**	**96.5**	97.7	**98.9**	67.5	**99.6**	97.0	89.5	73.4	68.9	22.2	86.3	89.4	68.2	**58.3**	58.6	55.2	**88.3**
	L2-800	92.0	**98.7**	89.0	**78.5**	75.7	75.5	68.4	**89.4**	**82.5**	**95.6**	94.7	97.9	98.5	68.4	**99.7**	97.2	89.9	77.7	66.9	23.7	**86.8**	88.9	66.7	**62.7**	58.4	56.9	**88.4**
MAWS	32x8d	84.8	95.9	80.9	63.8	69.0	74.2	56.0	88.0	75.4	**95.4**	93.9	91.7	97.4	60.7	99.1	95.7	82.1	72.3	69.2	16.7	82.3	80.1	56.8	42.2	53.3	55.2	83.3
	32x16d	85.7	96.5	80.9	64.8	70.5	77.5	56.7	87.9	76.2	**95.6**	94.9	92.5	97.4	61.6	99.3	95.5	82.8	73.8	66.1	17.5	83.4	81.1	58.2	41.3	54.2	56.1	84.4
	32x32d	86.7	96.8	82.7	67.1	71.5	77.5	55.4	88.3	78.5	**95.8**	95.3	94.4	97.9	62.4	99.3	95.7	85.4	71.2	66.8	18.0	83.7	82.1	58.8	39.7	55.3	56.7	85.0
	32x48d	86.9	96.8	83.4	65.9	72.2	76.6	53.2	88.0	77.2	**95.5**	95.8	93.6	98.1	63.7	99.4	95.3	85.4	73.0	67.2	18.5	82.7	82.8	59.2	41.3	55.5	56.7	85.2
	FixRes-v1	88.5	95.7	81.1	67.4	72.9	80.5	57.6	88.0	77.9	**95.8**	**96.1**	94.5	97.9	62.2	99.4	96.2	86.6	76.5	64.8	19.3	82.5	83.4	59.8	43.5	56.6	59.0	86.0
	FixRes-v2	88.5	95.7	81.1	67.3	72.9	80.7	57.5	88.0	77.9	**95.0**	**96.0**	94.5	98.0	62.1	99.4	96.5	86.6	76.3	64.8	19.5	82.3	83.5	59.8	44.2	56.6	59.0	86.0
STB	R50x1	72.5	91.7	74.8	57.7	61.1	53.5	52.5	83.7	72.4	92.3	91.2	92.0	98.4	56.1	96.4	97.4	85.0	70.0	66.0	12.5	83.0	72.3	47.5	48.3	54.1	55.3	75.2
	R50x3	75.1	93.7	79.0	61.1	63.7	55.2	54.1	84.8	74.6	92.5	91.6	92.8	98.8	58.7	97.0	**97.8**	86.4	73.1	**73.8**	14.0	84.2	76.4	50.0	49.2	54.7	54.2	77.2
	R101x1	73.5	92.8	77.4	58.4	61.3	54.0	52.4	84.4	73.5	92.5	91.8	90.6	98.3	56.5	96.8	97.3	84.6	69.4	68.9	12.6	82.0	73.5	48.6	45.4	52.6	55.5	76.0
	R101x3	74.7	93.9	79.8	57.8	62.9	54.7	53.3	84.7	75.5	92.3	91.2	92.6	98.8	59.7	97.3	**98.0**	85.5	71.8	60.2	14.1	83.1	75.9	50.4	49.7	54.1	54.6	77.4
	R152x2	74.9	94.3	79.7	58.7	62.7	55.9	53.6	85.3	74.9	93.0	92.0	91.7	98.6	58.3	97.1	**97.8**	86.2	71.8	71.6	13.9	84.1	76.2	49.9	48.2	53.8	55.9	77.1
	R152x4	74.7	94.2	79.2	57.8	62.9	51.2	50.8	85.4	75.4	93.1	91.2	91.4	**98.9**	61.4	97.2	**98.0**	85.5	72.8	67.9	14.9	83.1	76.0	50.3	42.9	53.6	56.0	78.5
MTB	R50x1	83.3	94.9	82.2	70.9	69.9	59.0	55.6	86.8	77.3	91.5	93.9	**99.4**	98.0	60.6	98.4	97.5	87.4	68.6	68.2	16.6	82.5	79.4	53.2	49.4	54.5	53.4	76.7
	R50x3	86.9	96.7	86.2	75.7	74.6	60.6	54.2	87.7	78.5	93.2	95.3	**99.4**	98.6	64.6	99.3	**98.0**	88.1	69.9	59.6	19.6	83.4	83.5	57.8	51.3	55.8	55.6	80.7
	R101x1	85.5	95.7	84.4	73.0	72.5	59.8	55.0	87.3	78.1	92.2	95.0	**99.5**	98.1	62.5	99.0	**97.6**	87.8	68.7	67.7	18.0	84.0	82.3	55.9	53.4	54.8	53.1	79.4
	R101x3	87.2	97.4	87.5	72.4	75.0	57.4	47.4	87.5	79.6	93.2	95.4	**99.6**	98.6	64.3	99.4	**98.2**	87.7	68.8	64.1	20.7	80.4	84.0	58.7	52.6	54.9	54.3	81.2
	R152x2	88.0	97.5	87.8	75.8	75.9	61.5	55.3	88.1	79.8	93.6	**95.9**	**99.5**	98.5	64.3	**99.5**	**97.9**	89.0	70.0	70.3	20.7	82.6	85.5	59.6	50.8	54.9	55.1	81.9
	R152x4	87.2	97.6	88.2	72.4	75.0	49.1	43.4	87.1	79.9	92.4	95.4	99.3	98.5	65.7	**99.5**	**97.8**	87.7	68.2	57.1	20.6	80.4	84.6	59.0	49.7	57.2	55.1	81.5
TV	B/32	81.8	96.7	86.3	65.2	70.7	49.1	42.7	85.3	73.1	90.4	94.5	98.7	97.8	59.0	99.0	96.3	83.0	68.1	65.1	15.7	82.6	79.1	51.7	38.9	57.1	54.6	76.6
	B/16	86.7	96.9	86.4	74.0	74.2	54.7	46.0	86.7	74.3	92.7	94.1	99.2	97.4	61.3	99.5	96.4	84.5	63.1	61.5	17.5	85.4	82.7	56.6	40.0	57.0	56.1	80.9
	L/16	87.4	97.9	89.0	76.5	74.9	62.5	52.2	86.1	75.0	92.9	94.7	99.3	98.0	64.0	**99.6**	96.5	85.7	70.4	58.8	17.7	85.7	84.1	58.0	38.4	58.4	52.8	81.9
	H/14	83.4	95.8	84.5	70.2	69.2	62.3	54.8	84.7	75.4	91.7	93.7	98.9	98.5	62.4	98.4	97.3	87.0	73.9	63.4	15.4	**87.0**	79.4	52.1	41.1	55.9	54.1	75.9
2vRLCms	R50x1	76.4	93.2	77.9	48.6	64.1	56.3	51.7	84.4	77.0	88.3	91.8	92.9	97.6	59.7	96.7	97.5	85.8	71.1	69.1	15.8	84.8	78.4	51.0	56.2	53.9	53.8	73.8
	R50x3	81.0	95.6	82.4	56.5	67.0	65.6	61.1	85.9	78.8	90.9	94.1	95.4	98.7	62.6	98.2	**97.9**	88.2	78.2	**74.7**	17.6	85.4	82.6	54.6	55.4	54.2	55.2	77.3
	R101x1	77.9	94.8	79.9	51.9	65.2	57.1	52.0	85.4	77.2	90.0	91.6	92.7	97.2	59.4	97.6	96.8	84.6	65.7	70.6	16.1	84.3	78.8	52.4	53.6	55.1	55.7	76.1
	R101x3	82.2	96.4	83.4	57.5	68.2	64.6	60.0	86.2	78.9	91.8	95.0	95.4	98.4	63.0	98.5	**97.9**	88.0	77.5	69.1	18.3	85.5	82.9	55.9	52.2	54.5	56.3	78.8
	R152x1	78.6	95.0	79.9	50.3	65.6	55.6	52.2	85.8	77.3	90.1	92.5	91.8	97.6	59.8	98.1	96.6	84.3	64.8	70.3	16.6	83.9	79.4	53.1	**57.2**	55.8	54.8	76.9
	R152x2	82.3	96.7	83.9	58.1	68.5	64.9	58.7	86.6	79.1	92.2	94.1	96.0	98.2	64.1	98.5	**98.0**	88.1	77.0	69.8	18.4	85.3	82.7	56.2	53.6	56.0	56.5	79.2
	R152x3	83.6	96.8	84.5	60.3	69.1	68.5	63.1	86.7	**80.5**	92.6	94.9	96.3	98.7	65.4	98.8	**98.1**	89.5	78.4	68.5	19.4	85.2	83.5	57.0	54.4	54.6	54.2	80.0
LOYO	50x1	74.0	93.6	79.1	47.6	63.7	61.6	62.3	82.6	77.0	88.3	93.7	94.3	98.7	58.8	96.4	**97.6**	88.2	80.1	71.4	14.1	84.8	77.3	49.3	56.1	53.8	54.4	73.3
	200x2	78.5	96.2	83.3	53.4	68.5	61.7	55.4	86.6	77.4	91.9	95.5	93.9	98.7	62.6	98.6	**97.7**	87.4	77.1	**76.4**	16.4	84.0	82.6	55.1	54.1	52.5	52.4	79.2
CoM	v1	65.9	85.0	63.1	27.5	52.6	35.9	43.5	75.7	70.0	70.4	78.1	85.4	97.6	54.3	85.6	97.1	82.9	62.6	60.2	12.6	85.7	64.2	40.7	54.7	55.6	53.5	57.2
	v2	72.2	93.4	76.3	39.6	60.2	48.3	51.1	82.6	75.1	84.4	89.9	90.7	98.4	58.3	95.7	97.2	85.4	75.7	**75.4**	13.2	85.6	72.7	47.8	**56.9**	53.9	53.8	69.1
	VirTex	57.9	83.9	57.5	17.0	49.8	22.4	34.5	83.8	58.2	53.6	70.6	74.7	98.1	56.5	86.7	94.8	74.1	69.5	71.3	8.7	83.1	61.5	39.9	45.5	53.5	55.8	50.7
ResNet	50	71.3	91.8	74.5	52.7	60.5	49.9	48.5	83.8	72.3	92.4	90.8	90.8	98.3	54.9	96.4	96.7	83.6	70.6	67.1	11.7	82.5	71.2	46.8	43.0	56.5	55.5	74.3
	101	72.7	93.0	77.2	53.7	60.8	50.1	47.0	84.4	71.6	92.3	91.9	90.4	98.5	56.6	97.0	97.1	83.4	72.5	63.6	11.9	83.3	72.7	48.3	43.2	53.0	54.7	75.8
	152	73.7	93.5	78.0	55.1	61.6	52.8	48.4	84.5	71.9	93.0	92.1	89.6	98.2	57.0	97.6	97.0	83.1	70.1	70.2	12.3	82.9	75.3	49.2	42.4	53.2	53.9	77.1

表 10. 各种预训练模型在 27 个数据集上的线性探针性能。每个数据集最高分的 99.5% Clopper-Pearson 置信区间内的分数以粗体显示。

*We updated the STL10 scores from the previous version of this paper after fixing a CUDA-related bug.

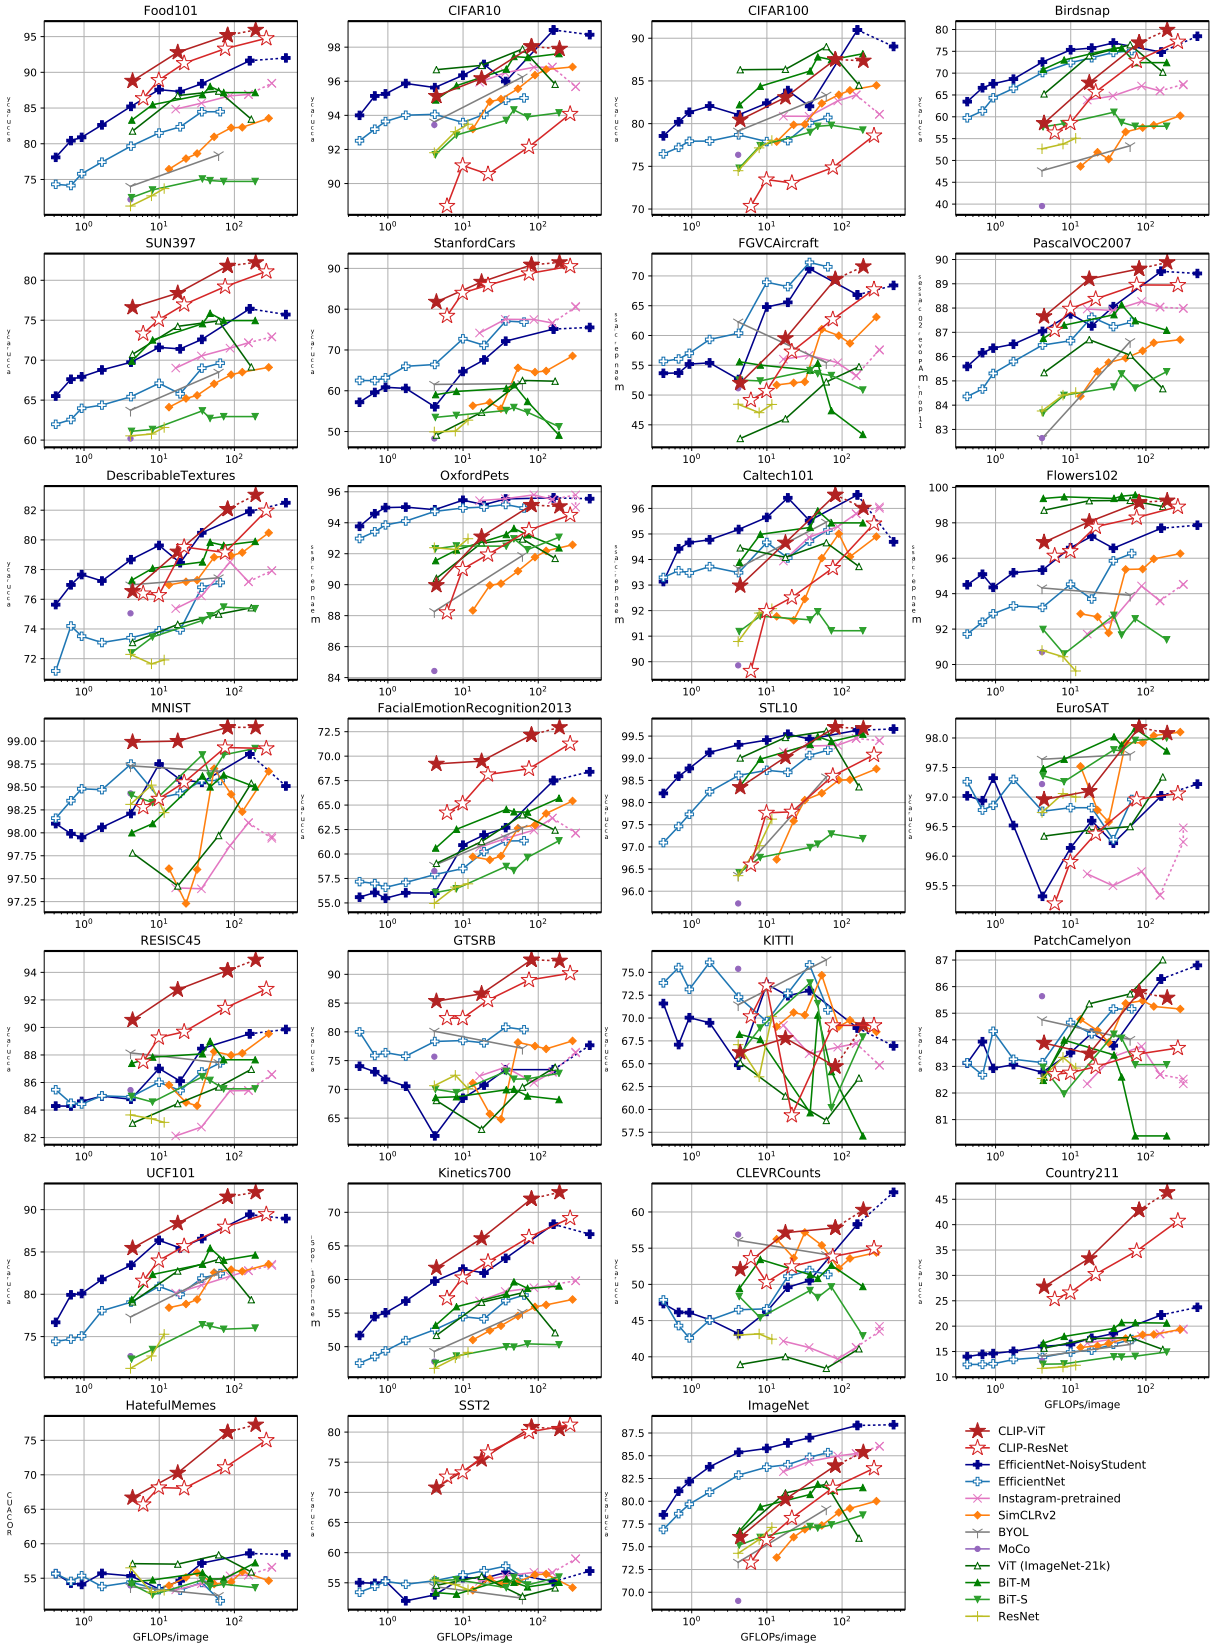


图20. 使用表10中的数据，绘制了27个数据集中每个数据集的线性探针性能。



图 21. 36 个 CLIP 零样本分类器预测结果的可视化。除重新选择 Hateful Memes 以避免冒犯性内容外，所有示例均为随机选取。图中显示了前 5 个类别的预测概率，以及用于表示该类别的文本。当使用多个模板时，显示第一个模板。真实标签以绿色标出，而错误预测以橙色标出。

		Food101	CIFAR10	CIFAR100	Birdsnap	SUN397	Stanford Cars	FGVC Aircraft	VOC2007	DTD	Oxford Pets	Caltech101	Flowers102	MNIST	FER2013	STL10	EuroSAT	RESISC45	GTSRB	KITTI	Pcam	UCF101	Kinetics700	CLEVR Counts	Country211	HatefulMemes	SST2	ImageNet	mean
RN	RN50	81.1	75.6	41.6	32.6	59.6	55.8	19.3	82.1	41.7	85.4	82.1	65.9	66.6	42.2	94.3	41.1	54.2	35.2	42.2	16.1	57.6	63.6	43.5	20.3	59.7	56.9	59.6
	RN101	83.9	81.0	49.0	37.2	59.9	62.3	19.5	82.4	43.9	86.2	85.1	65.7	59.3	45.6	96.7	33.1	58.5	38.3	33.3	16.9	55.2	62.2	46.7	28.1	61.1	64.2	62.2
	RN50x4	86.8	79.2	48.9	41.6	62.7	67.9	24.6	83.0	49.3	88.1	86.0	68.0	75.2	51.1	96.4	35.0	59.2	35.7	26.0	20.2	57.5	65.5	49.0	17.0	58.3	66.6	65.8
	RN50x16	90.5	82.2	54.2	45.9	65.0	72.3	30.3	82.9	52.8	89.7	87.6	71.9	80.0	56.0	97.8	40.3	64.4	39.6	33.9	24.0	62.5	68.7	53.4	17.6	58.9	67.6	70.5
	RN50x64	91.8	86.8	61.3	48.9	66.9	76.0	35.6	83.8	53.4	93.4	90.6	77.3	90.8	61.0	98.3	59.4	69.7	47.9	33.2	29.6	65.0	74.1	56.8	27.5	62.1	70.7	73.6
ViT	B/32	84.4	91.3	65.1	37.8	63.2	59.4	21.2	83.1	44.5	87.0	87.9	66.7	51.9	47.3	97.2	49.4	60.3	32.2	39.4	17.8	58.4	64.5	47.8	24.8	57.6	59.6	63.2
	B/16	89.2	91.6	68.7	39.1	65.2	65.6	27.1	83.9	46.0	88.9	89.3	70.4	56.0	52.7	98.2	54.1	65.5	43.3	44.0	23.3	48.1	69.8	52.4	23.4	61.7	59.8	68.6
	L/14	92.9	96.2	77.9	48.3	67.7	77.3	36.1	84.1	55.3	93.5	92.6	78.7	87.2	57.5	99.3	59.9	71.6	50.3	23.1	32.7	58.8	76.2	60.3	24.3	63.3	64.0	75.3
	L/14-336px	93.8	95.7	77.5	49.5	68.4	78.8	37.2	84.3	55.7	93.5	92.8	78.3	88.3	57.7	99.4	59.6	71.7	52.3	21.9	34.9	63.0	76.9	61.3	24.8	63.3	67.9	76.2

表11. CLIP 模型在 27 个数据集上的零样本性能。

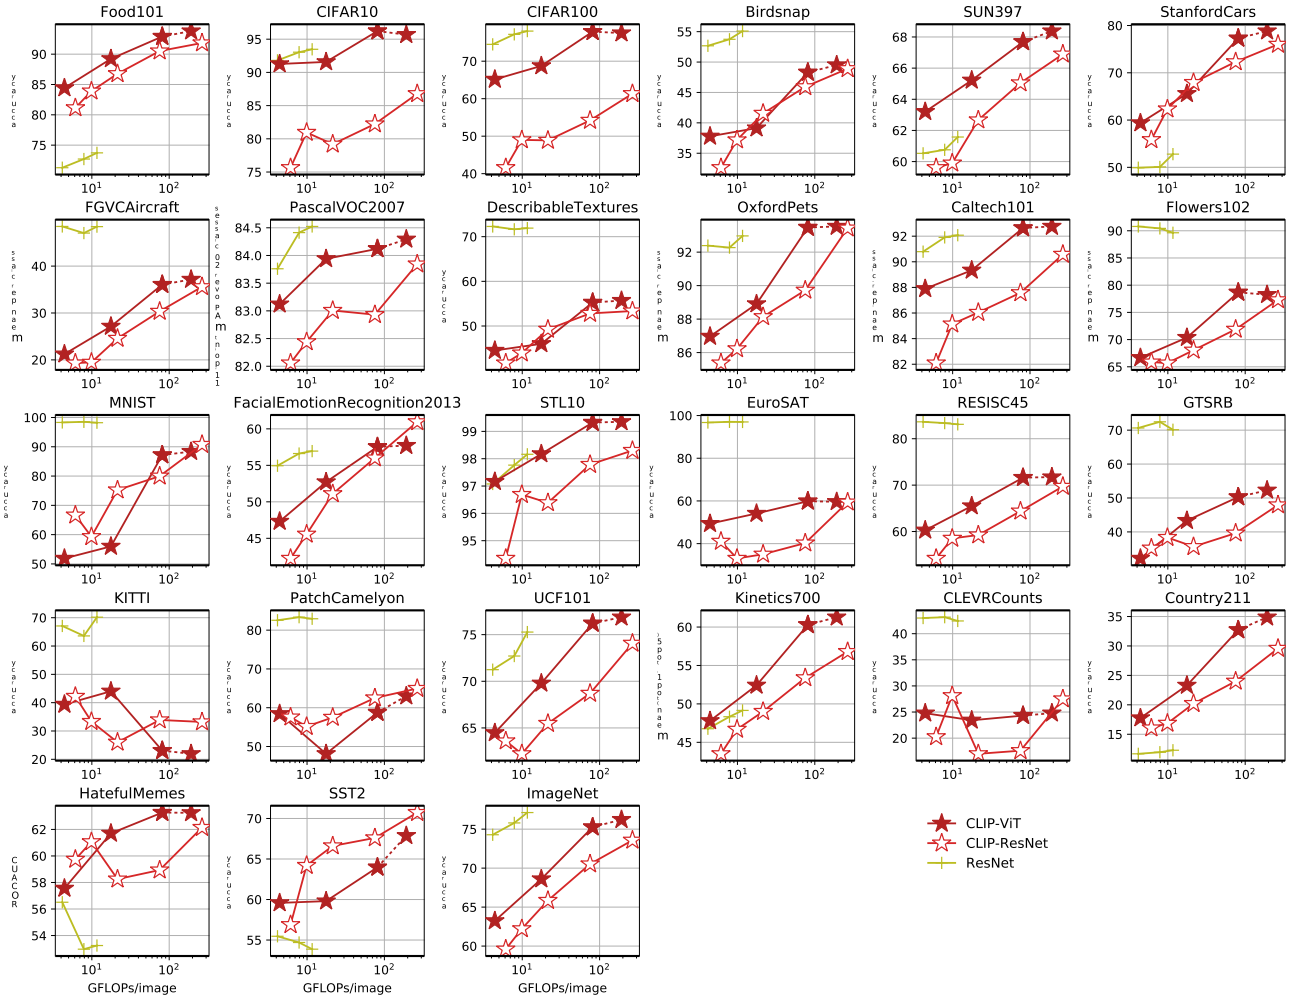


图 22. CLIP 的零样本性能与线性探测 ResNet 性能的比较

B. 零样本预测

为了对 CLIP 的零样本性能进行定性总结/概览，我们在图 21 中可视化了 36 个不同零样本 CLIP 分类器的随机选取预测结果。此外，表 11 和图 22 展示了每个数据集的单独零样本性能得分。

C. 重复检测器

我们早期的重复检测与分析尝试使用了模型学习到的嵌入空间中的最近邻。虽然使用模型自身对相似性的理解很直观，但我们遇到了一些问题。我们发现，模型的特征空间非常偏向语义相似性。许多误报是由于一些不同的物体会被以相似的方式描述（如足球、同一物种的花等），从而具有几乎完美的相似度。我们还观察到，模型在为某些类型的近重复样本分配高相似度分数方面表现相当差。我们反复注意到，具有高频纹理的图像（如毛发或条纹图案）如果经过不同缩放算法（最近邻与双线性）预处理，可能会得到出人意料地低的相似度。这导致了许多漏报。

我们构建了自己的近重复检测器来解决这个问题。我们创建了一条合成数据增强流水线，结合了多种常见的图像处理操作。该增强流水线结合了随机裁剪和缩放、宽高比扭曲、降采样和上采样到不同分辨率、轻微旋转、JPEG 压缩以及 HSV 颜色抖动。该流水线还会在所有相关步骤中随机选择不同的插值算法。随后，我们训练了一个模型，使图像及其变换版本之间的相似度最大化，同时使其与训练批次中所有其他图像的相似度最小化。我们使用了与 CLIP 相同的 n-pair / InfoNCE 损失，但温度固定为 0.07。

我们选择 ResNet-50 作为模型架构。我们采用（Zhang, 2019）中的抗混叠改进对基础 ResNet-50 进行了修改，并使用权重归一化（Salimans & Kingma, 2016）代替批归一化（Ioffe & Szegedy, 2015），以避免通过批统计信息泄露有关重复样本的信息——这一问题此前已在（Henaff, 2020）中指出。我们还发现，GELU 激活函数（Hendrycks & Gimpel, 2016）在该任务上表现更好。我们使用总批量大小为 1,712，对从预训练数据集中采样的约 3000 万张图像训练了该模型。在训练结束时，它在其代理训练任务上达到了近 100% 的准确率。

	Linear Classifier			*Zero Shot*		
Dataset	YFCC	WIT	Δ	YFCC	WIT	Δ
Birdsnap	47.4	35.3	+12.1	19.9	4.5	+15.4
Country211	23.1	17.3	+5.8	5.2	5.3	+0.1
Flowers102	94.4	89.8	+4.6	48.6	21.7	+26.9
GTSRB	66.8	72.5	−5.7	6.9	7.0	−0.1
UCF101	69.2	74.9	−5.7	22.9	32.0	−9.1
Stanford Cars	31.4	50.3	−18.9	3.8	10.9	−7.1
ImageNet	**62.0**	60.8	+1.2	**31.3**	27.6	+3.7
Dataset Average	65.5	**66.6**	−1.1	29.6	**30.0**	−0.4
Dataset “Wins”	10	**15**	−5	**19**	18	+1

表 12. 仅在 YFCC100M 上训练时，CLIP 的表现相近。将仅在 YFCC100M 上训练的 ResNet-50 与 WIT 中相同规模的子集进行比较，显示其在零样本和线性分类器评估中的平均性能和获胜次数相近。然而，在特定数据集上的性能存在较大差异。我们列出了根据线性探针评估，YFCC 相较于 WIT 表现最好和最差的 3 个数据集上的性能，以突出这一点，同时也列出了所有线性和零样本评估的总体性能以及标准 ImageNet 数据集上的性能。

D. YFCC100M 上的数据集消融

为了研究我们的自定义数据集是否对 CLIP 的性能至关重要，我们在 YFCC100M 数据集的一个过滤子集上训练了一个模型（细节见第 2.2 节），并将其性能与在同等规模的 WIT 子集上训练的相同模型进行了比较。我们将每个模型训练 32 个 epoch，此时迁移性能由于过拟合而开始趋于平稳。结果如表 12 所示。在我们的整个评估套件中，YFCC 和 WIT 在零样本和线性探测设置下的平均表现相近。然而，在特定的细粒度分类数据集上的性能可能差异很大——有时超过 10%。我们的推测是，这些性能差异反映了每个预训练数据集中相关数据的相对密度。例如，在 YFCC100M 上进行预训练可能包含许多鸟类和花卉的照片（摄影师常拍的主题），因此在 Birdsnap 和 Flowers102 上表现更好；而在 WIT 上进行预训练则能得到更好的汽车和宠物分类器（这些类别似乎在我们的数据集中很常见）。

总体而言，这些结果令人鼓舞，因为它们表明我们的方法可以使用任何经过合理过滤的成对（文本、图像）数据集合。这与近期的一项工作相呼应，该工作在医学影像这一相对不同的领域中使用相同的对比预训练目标并报告了积极结果（Zhang et al., 2020）。这也类似于噪声学生自训练的发现，该方法报告称，与使用 YFCC100M 相比，使用其 JFT300M 数据集仅带来了轻微改进（Xie et al., 2020）。我们认为，我们的数据集相较于已有的 YFCC100M 的主要优势在于其规模大得多。

最后，我们提醒注意，WIT 包含了 YFCC100M 的这一过滤子集。这可能导致我们的消融实验低估了 YFCC100M 与 WIT 其余部分之间的性能差异大小。我们认为这种情况不太可能，因为 YFCC100M 仅占 WIT 整体数据混合的 3.7%，并且在创建 WIT 期间将其加入现有数据混合时，并未明显改变模型的性能。

E. 选定任务和数据集结果

由于本文考虑的数据集和实验种类繁多，正文主要侧重于总结和分析总体结果。在以下小节中，我们报告特定任务组、数据集和评估设置的性能细节。

E.1. 图像和文本检索

CLIP 在我们的噪声网络规模数据集上针对图像-文本检索任务进行预训练。尽管本文的重点是表示学习和任务学习，目的是迁移到各种下游数据集，但验证 CLIP 能否在其预训练任务本身上实现较高的迁移性能，是一项重要的合理性检查/概念验证。在表 13 中，我们检查了 CLIP 在 Flickr30k 和 MSCOCO 数据集上用于文本检索和图像检索的零样本迁移性能。零样本 CLIP 在这两个数据集上达到或超过了此前所有零样本结果。零样本 CLIP 在 Flickr30k 的文本检索任务上也能与当前总体最先进水平相竞争。在图像检索方面，CLIP 相对于总体最先进水平的性能明显较低。不过，零样本 CLIP 仍可与经过微调的 Unicoder-VL 相竞争。在更大的 MS-COCO 数据集上，微调能显著提升性能，而零样本 CLIP 无法与最新工作相竞争。对于这两个数据集，我们都会在每张图像的描述前添加提示语“a photo of ”，我们发现这能将 CLIP 的零样本 R@1 性能提升 1 到 2 个百分点。

E.2. 光学字符识别

尽管可视化结果显示，ImageNet 模型包含会对图像中文本的存在作出响应的特征（Zeiler & Fergus，2014），但这些表示还不够细粒度，无法用于光学字符识别（OCR）任务。为了弥补这一点，模型会加入定制 OCR 引擎的输出和相关特征，以提升在需要这种能力的任务上的性能（Singh 等，2019；Yang 等，2020）。在 CLIP 开发的早期，我们注意到 CLIP 开始学习初级的 OCR 能力，而且这种能力似乎在整个项目过程中稳步提升。为了评估这种定性观察到的行为，我们测量了性能在 5 个需要直接和间接使用 OCR 的数据集上。其中三个数据集 MNIST（LeCun）、SVHN（Netzer 等，2011）和 IIIT5K（Mishra 等，2012）直接检验模型执行低级字符和单词识别的能力，而 Hateful Memes（Kiela 等，2020）和 SST-2（Socher 等，2013）则检验模型使用 OCR 执行语义任务的能力。结果报告见表 14。

CLIP 的性能仍然高度不稳定，并且似乎对领域（渲染图像或自然图像）与待识别文本类型（数字或单词）的某种组合较为敏感。CLIP 的 OCR 性能在 Hateful Memes 和 SST-2 上最强——这些数据集中的文本是数字渲染的，并且主要由单词组成。在 IIIT5K 上，即由单独裁剪出的单词自然图像组成的数据集，零样本 CLIP 的表现略好一些，其性能类似于 Jaderberg 等人（2014）将深度学习与结构化预测相结合以执行开放词汇 OCR 的早期工作。然而，在涉及手写数字和街景数字识别的两个数据集上，其性能明显较低。CLIP 在完整数字 SVHN 上 51% 的准确率远低于任何已发表的结果。检查表明，CLIP 难以处理重复字符，以及 SVHN 中低分辨率且模糊的图像。CLIP 的零样本 MNIST 性能也很差，并且被在原始像素上训练的监督式逻辑回归超越，后者是最简单的机器学习基线之一。

SST-2 是一个句子级别的 NLP 数据集，我们将其渲染成图像。我们纳入 SST-2，是为了检查 CLIP 是否能够将低层次的 OCR 能力转化为更高层次的表示。在 CLIP 对渲染句子的表示上拟合一个线性分类器，可达到 80.5% 的准确率。这与使用在 8400 亿个词元上预训练的 GloVe 词向量的连续词袋基线 80% 的准确率相当（Pennington 等，2014）。尽管按照今天的标准来看，这是一个简单的 NLP 基线，并且远低于当前 SOTA 的 97.5%，但看到 CLIP 能够将渲染文本的图像转化为非平凡的句子级表示，仍然令人鼓舞。全监督的 CLIP 在仇恨 Meme 检测上也出人意料地强，其中 CLIP 仅比当前单模型 SOTA 低 0.7 个百分点，并且比原论文中的最佳基线高出几个百分点。与 SST-2 类似，这些在 Hateful Memes 上的其他结果使用了真实文本，而 CLIP 无法访问这些文本。最后，我们注意到，在我们的评估套件所包含的所有其他 56 个模型中，零样本 CLIP 的表现均优于使用全监督线性探针得到的最佳结果。这表明，与现有的自监督和监督表示学习工作相比，CLIP 的 OCR 能力至少在某种程度上是独特的。

		Text Retrieval						Image Retrieval					
		Flickr30k			MSCOCO			Flickr30k			MSCOCO		
		R@1	R@5	R@10	R@1	R@5	R@10	R@1	R@5	R@10	R@1	R@5	R@10
Fine-tune	Unicoder-VL[a]	86.2	96.3	99.0	62.3	87.1	92.8	71.5	90.9	94.9	46.7	76.0	85.3
	Uniter[b]	87.3	98.0	99.2	65.7	88.6	93.8	75.6	94.1	**96.8**	52.9	79.9	88.0
	VILLA[c]	87.9	97.5	98.8	-	-	-	76.3	**94.2**	**96.8**	-	-	-
	Oscar[d]	-	-	-	**73.5**	**92.2**	**96.0**	-	-	-	**57.5**	**82.8**	**89.8**
	ERNIE-ViL[e]	**88.7**	98.0	99.2	-	-	-	**76.7**	93.6	96.4	-	-	-
Zero-Shot	Visual N-Grams[f]	15.4	35.7	45.1	8.7	23.1	33.3	8.8	21.2	29.9	5.0	14.5	21.9
	ImageBERT[g]	-	-	-	44.0	71.2	80.4	-	-	-	32.3	59.0	70.2
	Unicoder-VL[a]	64.3	86.8	92.3	-	-	-	48.4	76.0	85.2	-	-	-
	Uniter[b]	83.6	95.7	97.7	-	-	-	68.7	89.2	93.9	-	-	-
	CLIP	88.0	**98.7**	**99.4**	58.4	81.5	88.1	68.7	90.6	95.2	37.8	62.4	72.2

表 13. CLIP 提升了零样本检索性能，并且在 Flickr30k 文本检索上可与最佳微调结果相媲美。粗体表示总体最佳性能，下划线表示类别内最佳性能（零样本或微调）。对于所有其他模型，均报告论文中的最佳结果，而不考虑模型大小/变体。MSCOCO 性能在 5k 测试集上报告。[a](Li 等，2020a) [b](Chen 等，2019) [c](Gan 等，2020) [d](Li 等，2020b) [e](Yu 等，2020) [f](Li 等，2017) [g](Qi 等，2020)

		MNIST	SVHN	IIIT5K 1k	Hateful Memes	SST-2
Fine-tune	SOTA	**99.8**[a]	**96.4**[b]	**98.9**[c]	**78.0**[d]	**97.5**[e]
	JOINT[f]	-	-	89.6	-	-
	CBoW[g]	-	-	-	-	80.0
Transfer	Raw Pixels	92.5	-	-	-	-
	ES Best	98.9[h]	-	-	58.6[h]	59.0[i]
	CLIP	99.2	-	-	77.3	80.5
Zero-Shot	CLIP	88.4	51.0	90.0	63.3	67.9

表 14. 5 个数据集上的 OCR 性能。除 Hateful Memes 报告开发集上的 ROC AUC 外，所有指标均为测试集上的准确率。单模型 SOTA 为据我们所知的最佳结果。*ES Best* 报告了我们评估套件中 56 个非 CLIP 模型的最佳性能。[a](Assiri，2020) [b](Jaderberg 等，2015) [c](Wang 等，2020) [d](Lippe 等，2020) [f](Jaderberg 等，2014) [g](Wang 等，2018) [h](Xie 等，2020) [i](Mahajan 等，2018)

		UCF101 Top-1	K700 AVG	RareAct mWAP	RareAct mWSAP
Fine-tune	R(2+1)D-BERT[a]	**98.7**	-	-	-
	NS ENet-L2[b]	-	**84.8**	-	-
	HT100M S3D[d]	91.3	-	-	-
	Baseline I3D[e]	-	70.2	-	-
Transfer	MMV FAC[f]	91.8	-	-	-
	NS ENet-L2[c]	89.4[c]	68.2[c]	-	-
	CLIP	92.0	73.0	-	-
Zero-Shot	HT100M S3D[d]	-	-	30.5	34.8
	CLIP	80.3	69.6	**40.7**	**44.8**

表15. 3个视频数据集上的动作识别性能。据我们所知，报告的是单模型SOTA。请注意，*linear CLIP* 和 *linear NS ENet-L2* 是在每个数据集的单帧子采样版本上训练和评估的，因此不能与先前工作直接比较。在 Kinetics-700 上，我们报告 ActivityNet 竞赛指标，即 top-1 和 top-5 性能的平均值。[a](Kalfaoglu 等，2020) [b](Lu 等，2020) [c](Xie 等，2020) [d](Miech 等，2020b) [e](Carreira 等，2019) [f](Alayrac 等，2020)

E.3. 视频中的动作识别

从学习的角度来看，自然语言一个潜在的重要方面在于它能够表达并因此监督极其广泛的概念。由于 CLIP 模型被训练来将半任意文本与图像配对，它很可能会获得涉及普通名词和专有名词、动词以及形容词的广泛视觉概念的监督。相比之下，ImageNet-1K 只标注普通名词。那么，ImageNet 中缺乏更广泛的监督，是否会导致 ImageNet 模型在迁移到涉及识别非名词视觉概念的任务时表现较弱?

为了研究这一点，我们测量并比较了 CLIP 和 ImageNet 模型在多个视频上的性能

动作分类数据集用于衡量模型识别动词的能力。在表 15 中，我们报告了在 UCF-101（Soomro 等，2012）和 Kinetics-700（Carreira 等，2019）上的结果，这两个是该任务常用的数据集。不幸的是，由于训练帧数量非常庞大，我们基于 CPU 的线性分类器在视频数据集上进行评估需要耗费过长时间。为了解决这一问题，我们对每个视频进行了激进的子采样，仅保留单个中心帧，从而有效地将其转化为图像分类数据集。因此，我们在线性评估设置下报告的性能很可能在一定程度上低估了实际性能。

	IN Top-1	IN-V2 Top-1	IN-A Top-1	IN-R Top-1	ObjectNet Top-1	IN-Sketch Top-1	IN-Vid PM0	IN-Vid PM10	YTBB PM0	YTBB PM10
NS EfficientNet-L2[a]	**88.3**	**80.2**	**84.9**	74.7	68.5	47.6	88.0	82.1	67.7	63.5
FixResNeXt101-32x48d V2[b]	86.4	78.0	68.4	80.0	57.8	59.1	85.8	72.2	68.9	57.7
Linear Probe CLIP	85.4	75.9	75.3	84.2	66.2	57.4	89.1	77.2	68.7	63.1
Zero-Shot CLIP	76.2	70.1	77.2	**88.9**	**72.3**	**60.2**	**95.3**	**89.2**	**95.2**	**88.5**

表 16. 详细的 ImageNet 鲁棒性性能。IN 用作 ImageNet 的缩写。[a](Xie 等，2020) [b](Touvron 等，2019)

尽管存在这一缺陷，CLIP 特征迁移到该任务上的效果却出人意料地好。在使用线性探针的评估设置下，CLIP 在 UCF-101 上达到了此前最佳结果，并且在我们的评估套件中也优于所有其他模型。在 Kinetics-700 上，CLIP 也超过了原论文中经过微调的 I3D 基线。由于它不需要训练阶段，我们报告了 CLIP 在对所有帧的预测取平均时的零样本性能。CLIP 在这一设置下同样表现良好，并且在 Kinetics-700 上，其性能与在 545000 个带标签视频上训练的全监督 I3D 基线相差不到 1%。受这些结果鼓舞，我们还测量了 CLIP 在最近提出的 Rare Act 数据集（Miech 等，2020a）上的性能，该数据集旨在衡量对“锤击手机”和“钻鸡蛋”等不寻常动作的零样本识别能力。与此前最先进的方法相比，CLIP 提高了 10 个百分点；该方法是一个 S3D 模型，使用从 1 亿个教学视频中自动提取的字幕进行训练。

尽管 CLIP 在动作识别任务上表现出了令人鼓舞的强劲性能，但我们注意到，被比较的模型之间除了监督形式之外，还存在许多差异，例如模型架构、训练数据分布、数据集规模以及所使用的计算资源。仍需进一步研究，以更精确地确定哪些具体设计决策有助于在该任务上实现高性能。

	1km	25km	200km	750km	2500km
ISNs[a]	**16.9**	**43.0**	**51.9**	**66.7**	**80.2**
CPlaNet[b]	16.5	37.1	46.4	62.0	78.5
CLIP	13.9	32.9	43.0	62.0	79.3
Deep-Ret+[c]	14.4	33.3	47.7	61.6	73.4
PlaNet[d]	8.4	24.5	37.6	53.6	71.3

表17. IM2GPS 测试集上的地理定位性能。指标为定位在给定半径内的图像百分比。模型按平均性能排序。[a](Muller-Budack 等，2018) [b](Hongsuck Seo 等，2018) [c](Vo 等，2017) [c](Weyand 等，2016)

E.4. 地理定位

在 CLIP 的开发过程中，我们注意到的另一种行为是它能够识别许多地点和位置。为了量化这一点，我们创建了 Country211 数据集（如附录 A 所述），并在整篇论文中报告了其上的结果。不过，由于这是一个新的基准，为了与以往的地理定位工作进行比较，我们还在表 17 中报告了 Hays & Efros（2008）的 IM2GPS 测试集上的结果。由于 IM2GPS 是一个回归基准，我们使用 CLIP 的嵌入空间，在一组参考图像中猜测最近图像的 GPS 坐标。这并不是零样本结果，因为它使用了最近邻回归。尽管只查询了 100 万张图像，远少于以往工作，CLIP 的表现仍与若干任务特定模型相近。然而，它并不能与当前最先进的水平相竞争。

E.5. 对分布偏移的鲁棒性

第 3.3 节对与 ImageNet 相关的鲁棒性结果进行了高层次总结和分析。我们在本附录中简要提供一些额外的数值细节。表 16 给出了各数据集的性能结果，并与 Taori 等人（2020）的评估套件中报告的当前最先进结果进行了比较。零样本 CLIP 在 7 个数据集中的 5 个上提升了当前最先进水平，包括 ImageNet-R、ObjectNet、ImageNet-Sketch、ImageNet-Vid 和 Youtube-BB。CLIP 在 ImageNet-Vid 和 Youtube-BB 上的提升最大，这得益于其灵活的零样本能力；在 ImageNet-R 上的提升也很显著，这可能反映了 CLIP 的预训练分布包含大量创意内容。Taori 等人（2020）讨论的基于 Instagram 预训练的 ResNeXt 模型也记录了类似行为。

F. 模型超参数

Hyperparameter	Value
Batch size	32768
Vocabulary size	49408
Training epochs	32
Maximum temperature	100.0
Weight decay	0.2
Warm-up iterations	2000
Adam β_1	0.9
Adam β_2	0.999 (ResNet), 0.98 (ViT)
Adam ϵ	10^{-8} (ResNet), 10^{-6} (ViT)

表 18. 常见的 CLIP 超参数

Model	Learning rate	Embedding dimension	Input resolution	ResNet blocks	ResNet width	Text Transformer layers	Text Transformer width	Text Transformer heads
RN50	5×10^{-4}	1024	224	(3, 4, 6, 3)	2048	12	512	8
RN101	5×10^{-4}	512	224	(3, 4, 23, 3)	2048	12	512	8
RN50x4	5×10^{-4}	640	288	(4, 6, 10, 6)	2560	12	640	10
RN50x16	4×10^{-4}	768	384	(6, 8, 18, 8)	3072	12	768	12
RN50x64	3.6×10^{-4}	1024	448	(3, 15, 36, 10)	4096	12	1024	16

表 19. CLIP-ResNet 超参数

Model	Learning rate	Embedding dimension	Input resolution	Vision Transformer layers	Vision Transformer width	Vision Transformer heads	Text Transformer layers	Text Transformer width	Text Transformer heads
ViT-B/32	5×10^{-4}	512	224	12	768	12	12	512	8
ViT-B/16	5×10^{-4}	512	224	12	768	12	12	512	8
ViT-L/14	4×10^{-4}	768	224	24	1024	16	12	768	12
ViT-L/14-336px	2×10^{-5}	768	336	24	1024	16	12	768	12

表 20. CLIP-ViT 超参数