2202 nuJ 41] VC .sc [2v71910.5022:viXra

CoCa：对比式描述生成器是图像-文本基础模型

于嘉慧† 王子睿†
{jiahuiyu, ziruiw}@google.com
维杰·瓦苏德万 莱格·杨 莫吉塔巴·赛义德侯赛尼 吴永辉
Google 研究

摘要

探索大规模预训练基础模型在计算机视觉中具有重要意义，因为这些模型可以快速迁移到许多下游任务。本文提出了 Contrastive Captioner（CoCa），一种极简设计，用于通过对比损失和图像描述损失联合预训练图像-文本编码器-解码器基础模型，从而兼具 CLIP 等对比方法和 SimVLM 等生成方法的模型能力。不同于所有解码器层都会关注编码器输出的标准编码器-解码器 Transformer，CoCa 在前半部分解码器层中省略交叉注意力，以编码 *unimodal* 文本表示，并级联其余解码器层，使其对图像编码器进行交叉注意力以获得 *multimodal* 图像-文本表示。除了在多模态解码器输出上施加图像描述损失、以自回归方式预测文本标记之外，我们还在单模态图像和文本嵌入之间应用对比损失。通过共享同一计算图，这两个训练目标能够以极小的额外开销高效计算。CoCa 在网络规模的替代文本数据和带标注图像上以端到端方式从零开始预训练，并将所有标签都简单地视为文本，从而无缝统一用于表示学习的自然语言监督。实验表明，CoCa 在广泛的下游任务上通过零样本迁移或极少的任务特定适配取得了最先进的性能，涵盖视觉识别（ImageNet、Kinetics-400/600/700、Moments-in-Time）、跨模态检索（MSCOCO、Flickr30K、MSR-VTT）、多模态理解（VQA、SNLI-VE、NLVR2）以及图像描述（MSCOCO、NoCaps）。值得注意的是，在 ImageNet 分类任务上，CoCa 取得了 86.3% 的 *zero-shot* Top-1 准确率，使用 *frozen encoder* 和学习得到的分类头时达到 90.6%，并在 ImageNet 上使用 *finetuned encoder* 达到新的最先进 91.0% Top-1 准确率。

1 引言

深度学习近来见证了基础语言模型 [1] 的兴起，如 BERT [2]、T5 [3]、GPT-3 [4]，这些模型在网络规模的数据上进行预训练，并通过零样本、少样本或迁移学习展现出通用的多任务能力。与专门的单一模型相比，为海量下游任务预训练基础模型可以摊销训练成本，为推动模型规模 [5] 的极限以实现人类水平的智能提供了机会。

对于视觉和视觉-语言问题，已有若干基础模型候选方案得到探索：(1) 开创性工作 [6, 7, 8] 已经证明了在 ImageNet [9] 等图像分类数据集上使用交叉熵损失预训练的单编码器模型的有效性。图像编码器提供了通用的 *visual representations*，可适配于包括

†Equal contribution.

Preprint.

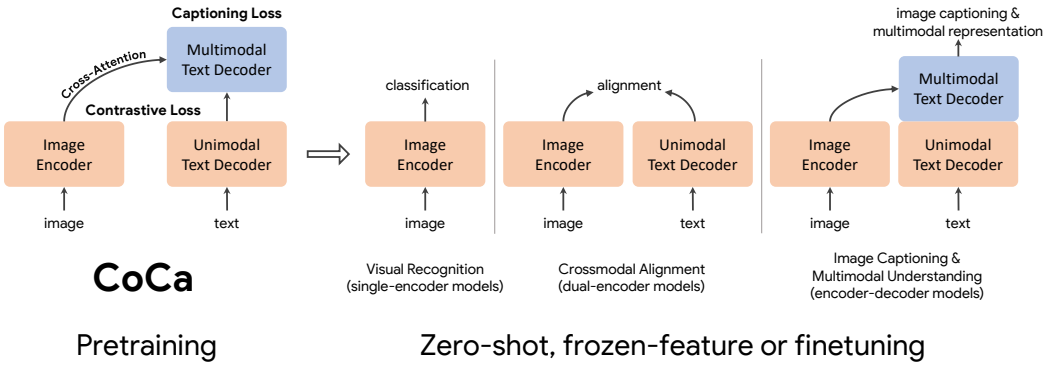


图 1：作为图文基础模型的对比式图像描述器（CoCa）预训练概览。预训练的 CoCa 可用于下游任务，包括视觉识别、视觉-语言对齐、图像描述生成和多模态理解，并支持零样本迁移、冻结特征评估或端到端微调。

图像和视频理解 [10, 11]。然而，这些模型严重依赖作为标注向量的图像注释，并未内化自由形式的人类自然语言知识，从而阻碍了它们在同时涉及视觉和语言模态的下游任务中的应用。(2) 近年来，一系列研究 [12, 13, 14] 通过在网络规模的噪声图文对上使用对比损失预训练两个并行编码器，展示了图文基础模型候选方案的可行性。除了用于纯视觉任务的视觉嵌入外，所得的双编码器模型还可以将文本嵌入编码到同一潜在空间中，从而实现新的 *crossmodal alignment* 能力，例如零样本图像分类和图文检索。尽管如此，由于缺少用于学习融合图像和文本表示的联合组件，这些模型并不能直接应用于视觉问答（VQA）等联合视觉-语言理解任务。(3) 另一条研究路线 [15, 16, 17] 探索了使用编码器-解码器模型进行生成式预训练，以学习通用视觉和多模态表示。在预训练期间，模型在编码器端接收图像，并在解码器输出上应用语言建模（LM）损失（或 PrefixLM [3, 16]）。对于下游任务，解码器输出随后可用作 *multimodal understanding* 任务的联合表示。尽管预训练的编码器-解码器模型已经取得了出色的视觉-语言结果 [16]，但它们不会生成与图像嵌入对齐的纯文本表示，因此对于跨模态对齐任务而言可行性和效率较低。

在这项工作中，我们统一了 *single-encoder*、*dual-encoder* 和 *encoder-decoder* 范式，并训练了一个图文基础模型，涵盖了这三种方法的全部能力。我们提出了一个名为 Contrastive Captioners（CoCa）的简单模型族，其采用改进的编码器-解码器架构，并同时使用对比损失和图像描述（生成式）损失进行训练。如图 1 所示，我们将解码器 Transformer 解耦为两部分：单模态解码器和多模态解码器。我们在单模态解码器层中省略交叉注意力，以编码纯文本表征，并级联多模态解码器层，使其对图像编码器输出进行交叉注意力，从而学习 *multimodal* 图文表征。我们同时在图像编码器与单模态文本解码器的输出之间应用对比目标，并在多模态解码器的输出处应用图像描述目标。此外，CoCa 通过将所有标签简单地视为文本，在图像标注数据和有噪声的图文数据上进行训练。图像标注文本上的生成式损失提供了类似于单编码器交叉熵损失方法的细粒度训练信号，从而有效地将所有三种预训练范式纳入一个统一的方法中。

CoCa 的设计利用对比学习来学习全局表征，并利用图像描述生成来学习细粒度的区域级特征，从而使图 1 所示的三类任务都受益。CoCa 表明，单个预训练模型可以通过零样本迁移或最少的任务特定适配，超越许多专用模型。例如，CoCa 在 ImageNet 上取得了 86.3% 的零样本准确率，并在 MSCOCO 和 Flickr30k 上实现了更好的零样本跨模态检索。使用冻结编码器时，CoCa 在 ImageNet 分类上达到 90.6%，在 Kinetics-40/600/700 上分别达到 88.0%/88.5%/81.1%，在 Moments-in-Time 上达到 47.4%。经过轻量级微调后，CoCa 进一步在 ImageNet 上达到 91.0%，在 VQA 上达到 82.3%，并在 NoCaps 上取得 120.6 的 CIDEr 分数。

2 相关工作

视觉预训练。在大规模标注数据（如 ImageNet [6, 7, 8]、Instagram [20] 或 JFT [21]）上预训练 ConvNets [18] 或 Transformers [19]，已成为解决包括分类、定位、分割、视频识别、跟踪以及许多其他问题在内的视觉识别问题的一种流行策略。近来，自监督预训练方法也得到了探索。BEiT [22] 借鉴自然语言处理中的 BERT [2]，提出了一种掩码图像建模任务，并使用量化的视觉 token id 作为预测目标。MAE [23] 和 SimMIM [24] 则不再需要图像分词器，而是直接使用轻量级解码器或投影层来回归像素值。尽管如此，这些方法仅学习视觉模态的模型，因此不适用于需要对图像和文本输入进行联合推理的任务。

视觉-语言预训练。近年来，视觉-语言预训练（VLP）取得了快速进展，其目标是在融合模型中联合编码视觉和语言。该方向的早期工作（例如 LXMERT [25]、UNITER [26]、VinVL [27]）依赖于预训练的目标检测模块，如 Fast(er) R-CNN [28]，来提取视觉表示。后续工作如 ViLT [29] 和 VLMo [30] 统一了视觉与语言 Transformer，并从头开始训练多模态 Transformer。

图文基础模型。近期研究提出了图文基础模型，能够同时涵盖视觉预训练和视觉-语言预训练。CLIP [12] 和 ALIGN [13] 表明，在有噪声的图文对上使用对比目标进行预训练的双编码器模型，可以为跨模态对齐任务和零样本图像分类学习到强大的图像与文本表征。Florence [14] 通过统一的对比目标 [31] 进一步发展了这一方法，训练出可适配广泛视觉和图文基准的基础模型。为进一步提升零样本图像分类准确率，LiT [32] 和 BASIC [33] 首先在大规模图像标注数据集上使用交叉熵预训练模型，然后在有噪声的替代文本图像数据集上使用对比损失进一步微调。另一条研究路线 [16, 17, 34] 提出了使用生成式损失训练的编码器-解码器模型，并在视觉-语言基准上取得了强劲结果，同时其视觉编码器在图像分类上仍具有竞争力。在本文中，我们专注于在单一预训练阶段从零开始训练图文基础模型，以统一这些方法。尽管近期工作 [35, 36, 37] 也探索了图文统一，但它们需要对单模态和多模态模块进行多个预训练阶段，才能获得良好性能。例如，ALBEF [36] 采用双编码器设计，将对比损失与掩码语言建模（MLM）相结合。然而，我们的方法更简单且训练效率更高，同时还支持更多模型能力：（1）对于一批图文对，CoCa 只执行一次前向和反向传播，而 ALBEF 需要两次（一次使用被破坏的输入，另一次使用未破坏的输入）；（2）CoCa 仅基于两个目标从零开始训练，而 ALBEF 则从预训练的视觉和文本编码器初始化，并使用包括动量模块在内的额外训练信号；（3）带有生成式损失的解码器架构更适合自然语言生成，因此可直接支持图像描述生成和零样本学习 [16]。

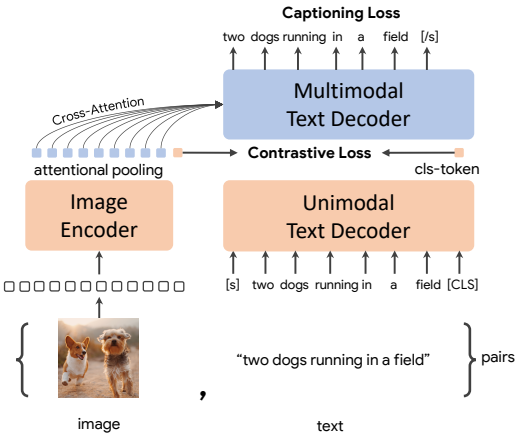
3 方法

我们首先回顾三类以不同方式利用 *natural language supervision* 的基础模型家族：单编码器分类预训练、双编码器对比学习，以及编码器-解码器图像描述生成。随后，我们介绍对比描述器（Contrastive Captioners，CoCa），它在一个简单架构下兼具对比学习和图像到描述生成的优点。我们进一步讨论 CoCa 模型如何通过零样本迁移或最小任务适配快速迁移到下游任务。

3.1 自然语言监督

单编码器分类。经典的单编码器方法通过在大规模众包图像标注数据集（*e.g*，ImageNet [9]、Instagram [20] 或 JFT [21]）上进行图像分类来预训练视觉编码器，其中标注文本的词汇表通常是固定的。这些图像标注通常被映射为离散的类别向量，并通过交叉熵损失进行学习，如下所示：

$$\mathcal{L}_{\text{Cls}} = -p(y) \log q_\theta(x), \tag{1}$$



Algorithm 1 Pseudocode of Contrastive Captioners architecture.

```
# image, text.ids, text.labels, text.mask: paired {image, text} data
# con_query: 1 query token for contrastive embedding
# cap_query: N query tokens for captioning embedding
# cls_token_id: a special cls_token_id in vocabulary

def attentional_pooling(features, query):
  out = multihead_attention(features, query)
  return layer_norm(out)

img_feature = vit_encoder(image) # [batch, seq_len, dim]
con_feature = attentional_pooling(img_feature, con_query) # [batch, 1, dim]
cap_feature = attentional_pooling(img_feature, cap_query) # [batch, N, dim]

ids = concat(text.ids, cls_token_id)
mask = concat(text.mask, zeros_like(cls_token_id)) # unpad cls_token_id
txt_embs = embedding_lookup(ids)
unimodal_out = lm_transformers(txt_embs, mask, cross_attn=None)
multimodal_out = lm_transformers(
    unimodal_out[:, :-1, :], mask, cross_attn=cap_feature)
cls_token_feature = layer_norm(unimodal_out)[:, -1:, :] # [batch, 1, dim]

con_loss = contrastive_loss(con_feature, cls_token_feature)
cap_loss = softmax_cross_entropy_loss(
    multimodal_out, labels=text.labels, mask=text.mask)
```

vit_encoder: vision transformer based encoder; lm_transformer: language-model transformers.

图 2：CoCa 架构和训练目标的详细示意图。

其中，$p(y)$ 是来自真实标签 y 的 one-hot、multi-hot 或平滑标签分布。随后，学习得到的图像编码器被用作下游任务的通用视觉表示提取器。

双编码器对比学习。与需要人工标注标签和数据清洗的单编码器分类预训练相比，双编码器方法利用噪声较大的网络规模文本描述，并引入一个可学习的文本塔来编码自由形式文本。两个编码器通过将配对文本与采样批次中的其他文本进行对比来联合优化：

$$\mathcal{L}_{\text{Con}} = -\frac{1}{N}\Big(\underbrace{\sum_{i}^{N}\log\frac{\exp(x_i^\top y_i/\sigma)}{\sum_{j=1}^{N}\exp(x_i^\top y_j/\sigma)}}_{\text{image-to-text}} + \underbrace{\sum_{i}^{N}\log\frac{\exp(y_i^\top x_i/\sigma)}{\sum_{j=1}^{N}\exp(y_i^\top x_j/\sigma)}}_{\text{text-to-image}}\Big), \tag{2}$$

其中，x_i 和 y_j 分别是第 i 个配对中的图像和第 j 个配对中的文本的归一化嵌入。N 是批量大小，σ 是用于缩放 logits 的温度。除了图像编码器之外，双编码器方法还学习一个对齐的文本编码器，从而支持图像-文本检索和零样本图像分类等跨模态对齐应用。经验证据表明，在损坏或分布外图像上，零样本分类更加鲁棒 [12, 13, 38]。

编码器-解码器式描述生成。双编码器方法将文本作为整体进行编码，而生成式方法（*a.k.a.* captioner）旨在实现细粒度的描述，并要求模型以自回归方式预测 y 的精确分词文本。遵循标准的编码器-解码器架构，图像编码器提供潜在编码特征（*e.g.*，使用视觉 Transformer [39] 或卷积网络 [40]），文本解码器则学习在前向自回归分解下最大化配对文本 y 的条件似然：

$$\mathcal{L}_{\text{Cap}} = -\sum_{t=1}^{T}\log P_\theta(y_t|y_{<t}, x). \tag{3}$$

编码器-解码器采用教师强制 [41] 进行训练，以并行化计算并最大化学习效率。与以往方法不同，图像描述生成器方法能够产生可用于视觉-语言理解的联合图像-文本表征，同时也具备通过自然语言生成进行图像描述的应用能力。

3.2 对比式图注生成器预训练

图 2 展示了所提出的对比式字幕生成器（CoCa）：一种简单的编码器-解码器方法，能够无缝结合三种训练范式。与标准的图像-文本编码器-解码器模型类似，CoCa 通过神经网络编码器将图像编码为潜在表示，例如视觉 Transformer（ViT）[39]（默认使用；也可以是其他图像编码器，如 ConvNets [40]），并使用因果掩码 Transformer 解码器解码文本。不同于标准的

	Image Encoder			Text Decoder				Image / Text		
Model	Layers	MLP	Params	n_{uni}	n_{multi}	MLP	Params	Hidden	Heads	Total Params
CoCa-Base	12	3072	86M	12	12	3072	297M	768	12	383M
CoCa-Large	24	4096	303M	12	12	4096	484M	1024	16	787M
CoCa	40	6144	1B	18	18	5632	1.1B	1408	16	2.1B

表 1：CoCa 的规模变体。图像编码器和文本解码器均为 Transformer [19, 39]。

解码器 Transformer 中，CoCa 在解码器层的前半部分省略交叉注意力，以编码 *unimodal* 文本表示，并级联其余解码器层，通过交叉注意力关注图像编码器以获得 *multimodal* 图像-文本表示。因此，CoCa 解码器同时生成单模态和多模态文本表示，使我们能够同时应用对比式和生成式目标，如下所示：

$$\mathcal{L}_{\text{CoCa}} = \lambda_{\text{Con}} \cdot \mathcal{L}_{\text{Con}} + \lambda_{\text{Cap}} \cdot \mathcal{L}_{\text{Cap}}, \tag{4}$$

其中 λ_{Con} 和 λ_{Cap} 是损失加权超参数。我们注意到，当词汇表为所有标签名称的集合时，单编码器交叉熵分类目标可以解释为应用于图像标注数据的生成式方法的一个特例。

解耦文本解码器与 CoCa 架构。图像描述方法优化文本的条件似然，而对比方法使用无条件文本表示。为了解决这一困境并将这两种方法结合到单一模型中，我们提出了一种简单的 *decoupled decoder* 设计：通过在单模态解码器层中跳过交叉注意力机制，将解码器拆分为单模态组件和多模态组件。也就是说，底部的 n_{uni} 个单模态解码器层使用因果掩码自注意力将输入文本编码为潜在向量，而顶部的 n_{multi} 个多模态层进一步应用因果掩码自注意力，并结合对视觉编码器输出的交叉注意力。所有解码器层都禁止词元关注未来词元，并且可以直接使用多模态文本解码器输出作为图像描述目标 $\mathcal{L}_{\text{Cap}}$。对于对比目标 $\mathcal{L}_{\text{Con}}$，我们在输入句子的末尾附加一个可学习的 [CLS] 词元，并使用其对应的单模态解码器输出作为文本嵌入。我们将解码器对半拆分，使得 $n_{\text{uni}} = n_{\text{multi}}$。遵循 ALIGN [13]，我们使用 288×288 的图像分辨率和 18×18 的补丁大小进行预训练，从而得到总共 256 个图像词元。我们最大的 CoCa 模型（简称“CoCa”）遵循 [21] 中的 ViT-giant 设置，图像编码器包含 10 亿参数，加上文本解码器总共包含 21 亿参数。我们还探索了两个较小的变体：“CoCa-Base”和“CoCa-Large”，详见表 1。

注意力池化器。值得注意的是，对比损失为每张图像使用单个嵌入，而解码器在编码器-解码器图像描述生成器 [16] 中通常会关注一系列图像输出标记。我们的初步实验表明，单个池化后的图像嵌入作为全局表示有助于视觉识别任务，而更多视觉标记（因此更细粒度）则有利于需要区域级特征的多模态理解任务。因此，CoCa 采用任务特定的注意力池化 [42]，以定制用于不同类型训练目标和下游任务的视觉表示。这里，*pooler* 是一个单层多头注意力层，具有 n_{query} 个可学习查询，并将编码器输出同时作为键和值。通过这种方式，模型可以学习为两个训练目标池化不同长度的嵌入，如图 2 所示。使用任务特定池化不仅满足了不同任务的不同需求，还将池化器作为一种自然的任务适配器引入。我们在预训练中为生成损失使用注意力池化器 $n_{\text{query}} = 256$，为对比损失使用注意力池化器 $n_{\text{query}} = 1$。

预训练效率。解耦自回归解码器设计的一个关键优势在于，它可以高效地计算所考虑的两个训练损失。由于单向语言模型是在完整句子上使用因果掩码进行训练的，因此解码器只需一次前向传播即可高效地为对比损失和生成损失生成输出（相比之下，双向方法 [36] 需要两次前向传播）。因此，大部分计算在这两个损失之间共享，与标准编码器-解码器模型相比，CoCa 仅引入极小的额外开销。另一方面，尽管许多现有方法 [30, 32, 33, 35, 36, 37] 在各种数据源和/或模态上通过多个阶段训练模型组件，CoCa 则直接使用各种数据源（*i.e*，带标注图像和嘈杂的替代文本图像），将所有标签视为文本，并针对对比目标和生成目标从零开始进行端到端预训练。

3.3 面向下游任务的对比式描述生成器

零样本迁移。预训练的 CoCa 模型通过同时利用图像和文本输入，以零样本方式执行多种任务，包括零样本图像分类、零样本图像-文本交叉检索、零样本视频-文本交叉检索。遵循以往做法 [12, 32]，这里的“零样本”不同于经典的零样本学习，因为在预训练期间，模型可能会看到相关的监督信息，但在迁移协议中不使用任何监督样本。对于预训练数据，我们遵循 [13, 32] 中提出的严格去重流程，以过滤掉所有与下游任务近域的样本。

冻结特征评估。如上一节所述，CoCa 采用任务特定的注意力池化 [42]（为简洁起见记为 *pooler*），以在共享骨干编码器的同时，为不同类型的下游任务定制视觉表征。这使得模型能够作为 *frozen encoder* 获得强大的性能，其中我们只需学习一个新的池化器来聚合特征。它还可以使多任务问题受益，这些问题共享相同的冻结图像编码器计算，但具有不同的任务特定头。如 [23] 中也讨论的，线性评估难以准确衡量学习到的表征，而我们发现注意力池化器在真实世界应用中更加实用。

用于视频动作识别的 CoCa。我们采用一种简单的方法，使学习到的 CoCa 模型能够用于视频动作识别任务。我们首先从视频中抽取多帧，并将每一帧分别输入到 *shared* 图像编码器中，如图 3 所示。对于冻结特征评估或微调，我们在空间和时间特征 token 之上额外学习一个池化器，并使用 softmax 交叉熵损失。注意，该池化器只有一个查询 token，因此在所有空间和时间 token 上进行池化的计算开销并不大。对于零样本视频-文本检索，我们采用一种更简单的方法，即计算视频中 16 帧的平均嵌入（这些帧从视频中均匀采样）。在计算检索指标时，我们还将每个视频的字幕编码为目标嵌入。

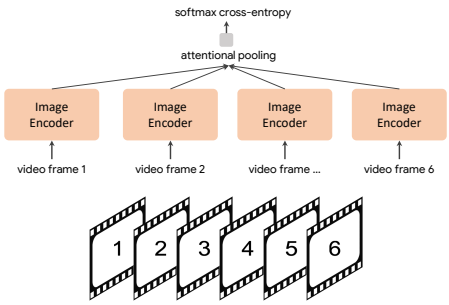


图 3：用于视频识别的 CoCa。

4 实验

在本节中，我们首先描述实验设置的细节。接下来，我们按视觉识别任务、跨模态对齐任务、图像描述生成任务和多模态理解任务来组织并呈现主要结果。我们的主要结果针对下游任务分为三类：零样本迁移、冻结特征评估和微调。我们还展示了包括训练目标和架构设计在内的消融实验。

4.1 训练设置

数据。如第 3.2 节所述，CoCa 通过将所有标签简单地视为文本，在单阶段中从头开始同时在网络规模的替代文本数据和带标注图像上进行预训练。我们使用 JFT-3B 数据集 [21]，将标签名称作为配对文本；并使用 ALIGN 数据集 [13] 及其噪声替代文本。类似于 [33]，我们将 JFT 中每张图像的标签名称随机打乱并拼接，同时加入一个从 [12] 中采样的提示词。由此得到的 JFT 图像文本标签示例如下：“a photo of the cat, animal”。不同于以往同样使用这两个数据集组合的模型 [32, 33]，为简化流程并提高预训练效率，我们同时从头开始训练所有模型参数，而不使用监督交叉熵损失预训练图像编码器。为确保公平评估，我们遵循 [13, 32] 中提出的严格去重流程，过滤掉与下游任务近域的所有样本（总共移除了 360 万张图像）。为对文本输入进行分词，我们使用在采样的预训练数据集上训练的 sentence-piece 模型 [43, 44]，其词表大小为 64k。

优化。我们的模型在 Lingvo 框架 [45] 中实现，并使用 GSPMD [46, 47, 48, 49] 来提升扩展性能。按照 [33]，我们使用 65,536 个图像-文本对的批量大小，

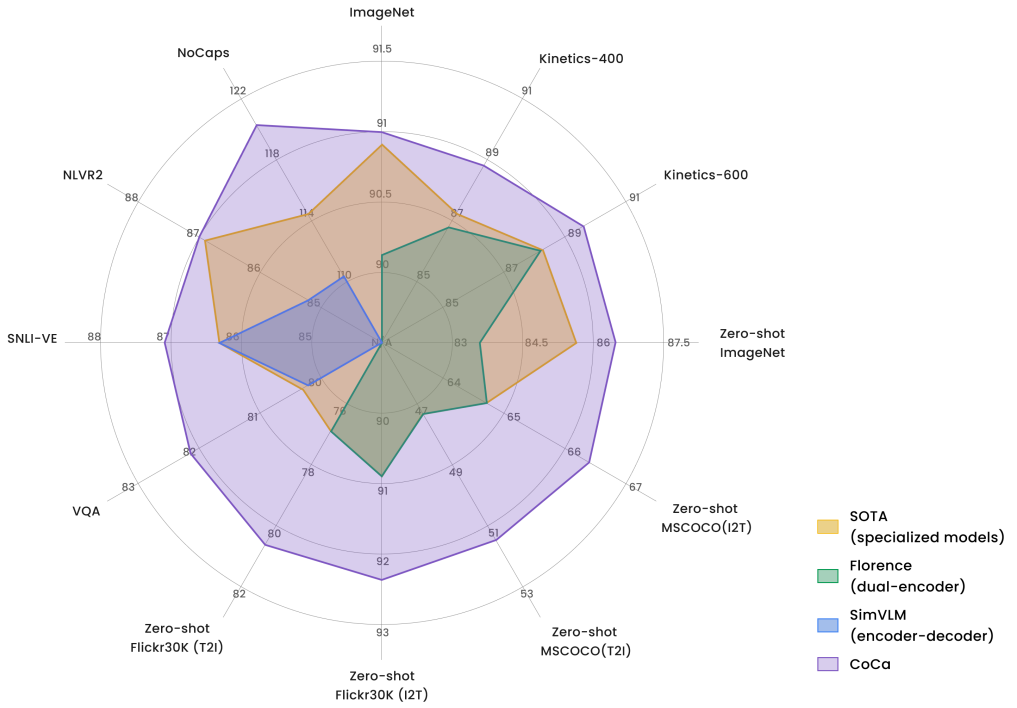


图 4：CoCa 与其他图文基础模型（无任务特定定制）以及多个最先进的任务专用模型的比较。

Model	ImageNet
ALIGN [13]	88.6
Florence [14]	90.1
MetaPseudoLabels [51]	90.2
CoAtNet [10]	90.9
ViT-G [21]	90.5
+ Model Soups [52]	90.9
CoCa (frozen)	90.6
CoCa (finetuned)	**91.0**

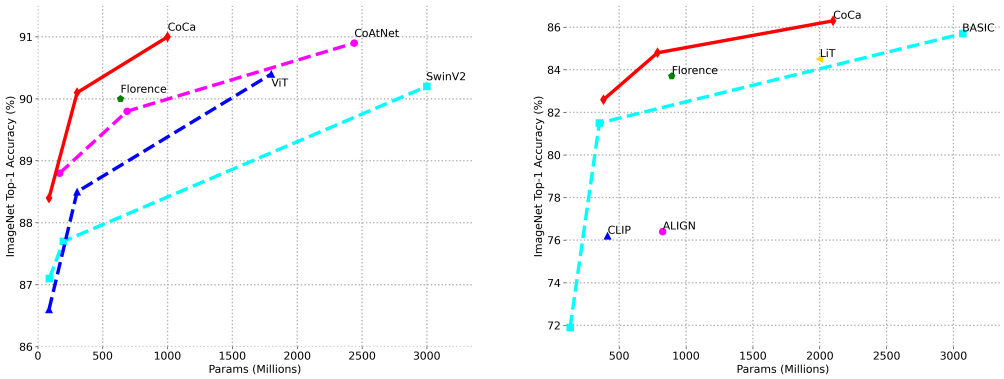
Model	K-400	K-600	K-700	Moments-in-Time
ViViT [53]	84.8	84.3	-	38.0
MoViNet [54]	81.5	84.8	79.4	40.2
VATT [55]	82.1	83.6	-	41.1
Florence [14]	86.8	88.0	-	-
MaskFeat [56]	87.0	88.3	80.4	
CoVeR [11]	87.2	87.9	78.5	46.1
CoCa (frozen)	88.0	88.5	81.1	47.4
CoCa (finetuned)	**88.9**	**89.4**	**82.7**	**49.0**

表 2：使用冻结编码器或微调编码器进行图像分类和视频动作识别。

其中，每个批次的一半分别来自 JFT 和 ALIGN。所有模型都基于式(4)中的组合式对比学习和字幕生成目标训练 500k 步，大致相当于在 JFT 上训练 5 个 epoch、在 ALIGN 上训练 10 个 epoch。正如我们后续研究所示，我们发现更大的字幕生成损失权重效果更好，因此 $\lambda_{\text{Cap}} = 2.0$ 且 $\lambda_{\text{Con}} = 1.0$。遵循 [13]，我们采用带有可训练温度 τ 的对比损失，其初始值为 0.07。为提高内存效率，我们使用 Adafactor [50] 优化器，其中 $\beta_1 = 0.9, \beta_2 = 0.999$，并采用 0.01 的解耦权重衰减比例。我们在训练前 2% 的步数中将学习率预热到峰值 8×10^{-4}，随后进行线性衰减。CoCa 的预训练在 2,048 个 CloudTPUv4 芯片上大约需要 5 天。遵循 [12, 13, 14]，我们继续在更高分辨率 576×576 上预训练一个 epoch。对于微调评估，我们主要遵循简单协议，直接在下游任务上训练 CoCa，而不进行如 CIDEr 分数等进一步的指标特定调优（详见附录 A 和 B）。

4.2 主要结果

我们广泛评估了 CoCa 模型作为预训练基础模型在各种下游任务中的能力。我们主要考虑三类核心任务，以考察（1）



(a) Finetuned ImageNet Top-1 Accuracy.

(b) Zero-Shot ImageNet Top-1 Accuracy.

图 5：不同模型规模的图像分类扩展性能。

视觉识别、(2) 跨模态对齐，以及 (3) 图像字幕生成和多模态理解能力。由于 CoCa 能够同时生成对齐的单模态表示和融合的多模态嵌入，因此只需极少的适配即可轻松迁移到这三类任务。图 4 总结了 CoCa 与其他双编码器和编码器-解码器基础模型以及最先进的任务专用方法在关键基准上的性能对比。CoCa 通过单个预训练检查点，在所有三类任务上都取得了新的最先进结果。

4.2.1 视觉识别任务

我们的视觉识别实验在 ImageNet [9] 上进行，将其作为图像识别基准；同时使用多个视频数据集，包括 Kinetics-400 [57]、Kinetics-600 [58]、Kinetics-700 [59]、Moments-in-Time [60]，作为视频动作识别的测试平台。值得注意的是，CoCa 仅在图像数据上进行预训练，并未访问任何额外的视频数据集。我们将 CoCa 编码器分别应用于视频帧（第 3.3 节），没有对时间信息进行早期融合，但由此得到的 CoCa-for-Video 模型表现优于许多进行时空早期融合的视频模型。

冻结特征。我们将预训练且冻结的 CoCa 模型应用于图像分类和视频动作识别。编码器用于这两项任务，而解码器被丢弃。如第 3.3 节所述，在 CoCa 编码器的嵌入输出之上，同时学习一个注意力池化层和一个 softmax 交叉熵损失层。对于视频分类，学习一个单一的查询 token，用于对所有空间 patch × 时间帧的 token 输出进行加权。我们将注意力池化器和 softmax 的学习率均设置为 5×10^{-4}，批量大小为 128，并采用余弦学习率调度（详见附录 A）。对于视频动作识别，我们在相同设置下将 CoCa 与其他方法进行比较（*i.e.*，不使用额外的有监督视频数据，也不将音频信号作为模型输入）。如表 2 所示，在不微调整个编码器的情况下，与专门的图像方法相比，CoCa 已经取得了具有竞争力的 Top-1 分类准确率，并且在视频任务上优于以往最先进的专门方法。

微调。基于冻结特征评估的架构，我们进一步以较小的学习率 1×10^{-4} 分别在图像和视频数据集上微调 CoCa 编码器。更多实验细节总结在附录 A 中。微调后的 CoCa 在这些任务上的性能均有所提升。值得注意的是，CoCa 在 ImageNet 上取得了新的最先进 91.0% Top-1 准确率，并且相比近期的视频方法获得了更好的视频动作识别结果。更重要的是，如图 5a 所示，CoCa 模型在视觉编码器中使用的参数量远少于其他方法。这些结果表明，所提出的框架能够高效地结合文本训练信号，因此相比经典的单编码器方法，能够更好地学习高质量的视觉表征。

4.2.2 跨模态对齐任务

与其他基于融合的基础方法 [16, 17, 35] 不同，CoCa 天然适用于跨模态对齐任务，因为它会生成对齐的图像和文本单模态嵌入。具体而言，我们

	Flickr30K (1K test set)						MSCOCO (5K test set)					
	Image → Text			Text → Image			Image → Text			Text → Image		
Model	R@1	R@5	R@10	R@1	R@5	R@10	R@1	R@5	R@10	R@1	R@5	R@10
CLIP [12]	88.0	98.7	99.4	68.7	90.6	95.2	58.4	81.5	88.1	37.8	62.4	72.2
ALIGN [13]	88.6	98.7	99.7	75.7	93.8	96.8	58.6	83.0	89.7	45.6	69.8	78.6
FLAVA [35]	67.7	94.0	-	65.2	89.4	-	42.7	76.8	-	38.4	67.5	-
FILIP [61]	89.8	99.2	99.8	75.0	93.4	96.3	61.3	84.3	90.4	45.9	70.6	79.3
Florence [14]	90.9	99.1	-	76.7	93.6	-	64.7	85.9	-	47.2	71.4	-
CoCa-Base	89.8	98.8	99.8	76.8	93.7	96.8	63.8	84.7	90.7	47.5	72.4	80.9
CoCa-Large	91.4	99.2	99.9	79.0	95.1	97.4	65.4	85.6	91.4	50.1	73.8	81.8
CoCa	**92.5**	**99.5**	**99.9**	**80.4**	**95.7**	**97.7**	**66.3**	**86.2**	**91.8**	**51.2**	**74.2**	**82.0**

表3：在 Flickr30K [62] 和 MSCOCO [63] 数据集上的零样本图像-文本检索结果。

Model	ImageNet	ImageNet-A	ImageNet-R	ImageNet-V2	ImageNet-Sketch	ObjectNet	Average
CLIP [12]	76.2	77.2	88.9	70.1	60.2	72.3	74.3
ALIGN [13]	76.4	75.8	92.2	70.1	64.8	72.2	74.5
FILIP [61]	78.3	-	-	-	-	-	-
Florence [14]	83.7	-	-	-	-	-	-
LiT [32]	84.5	79.4	93.9	78.7	-	81.1	-
BASIC [33]	85.7	85.6	95.7	80.6	76.1	78.9	83.7
CoCa-Base	82.6	76.4	93.2	76.5	71.7	71.6	78.7
CoCa-Large	84.8	85.7	95.6	79.6	75.7	78.6	83.3
CoCa	**86.3**	**90.2**	**96.5**	**80.7**	**77.6**	**82.7**	**85.7**

表 4：在 ImageNet [9]、ImageNet-A [64]、ImageNet-R [65]、ImageNet-V2 [66]、ImageNet-Sketch [67] 和 ObjectNet [68] 上的零样本图像分类结果。

我们关注零样本设置，其中所有参数在预训练后被冻结，并直接用于提取嵌入。这里，我们使用与预训练期间用于对比损失相同的嵌入，因此不使用多模态文本解码器。

零样本图像-文本检索。我们在两个标准图像-文本检索基准上评估 CoCa：MSCOCO [63] 和 Flickr30K [62]。遵循 CLIP 设置 [12]，我们首先将每张图像/每段文本分别输入对应的编码器，并获得测试集中所有图像/文本的嵌入。然后，我们基于整个测试集上的余弦相似度分数进行检索。如表 3 所示，在所有指标上，CoCa 在图像到文本和文本到图像检索方面均显著优于以往方法。此外，我们的模型具有参数效率，CoCa-Base 已经优于强基线（CLIP [12] 和 ALIGN [13]），而 CoCa-Large 优于 Florence [14]（其参数量与 ViT-Huge 相当）。这表明 CoCa 学习到了良好的单模态表示 *and* 并使其在不同模态之间很好地对齐。

零样本图像分类。遵循先前工作 [12, 13]，我们使用对齐的图像/文本嵌入，通过将图像与标签名称进行匹配，在不进行微调的情况下执行零样本图像分类。我们遵循 [12] 中完全相同的设置，并应用同一组用于标签类别名称的提示。如表 4 所示，CoCa 在 ImageNet 上取得了新的最先进零样本分类结果。值得注意的是，与此前最佳模型 [33] 相比，CoCa 使用的参数更少，而较小的 CoCa 变体已经优于强基线 [12, 14]，如图 5b 所示。此外，我们的模型在零样本评估下表现出有效的泛化能力，这与先前发现 [12, 13] 一致，CoCa 在所考虑的全部六个数据集上均有所提升。最后，尽管先前模型 [32, 33] 发现，以多个阶段依次采用单编码器和双编码器方法进行预训练对于性能提升至关重要，但我们的结果表明，通过在单阶段框架中统一训练目标和数据集，也可以获得强大的性能。

零样本视频检索。我们在 MSR-VTT [71] 的完整划分上使用 CoCa 评估视频-文本检索。表 5 显示，CoCa 在文本到视频和视频到文本检索中都取得了最高的检索指标。需要注意的是，MSR-VTT 视频来源于 YouTube，而我们需要原始视频来计算嵌入。许多视频已被明确设为不可用 [72]，因此我们在评估时公开可用的数据子集上计算检索结果。使用 Socratic Models [70] 作者提供的 code[3]，我们在可用子集上重新计算了这些方法的指标，并以“(subset)”标注，以便进行最公平的比较。

[3] `https://socraticmodels.github.io`

	MSR-VTT Full					
	Text → Video			Video → Text		
Method	R@1	R@5	R@10	R@1	R@5	R@10
CLIP [69]	21.4	41.1	50.4	40.3	69.7	79.2
Socratic Models [70]	-	-	-	44.7	71.2	80.0
CLIP [69] (subset)	23.3	44.2	53.6	43.3	73.3	**81.8**
Socratic Models [70] (subset)	-	-	-	46.9	**73.5**	81.3
CoCa (subset)	**30.0**	**52.4**	**61.6**	**49.9**	73.4	81.4

Table 5: Zero-shot Video-Text Retrieval on MSR-VTT Full test set.

	VQA		SNLI-VE		NLVR2	
Model	test-dev	test-std	dev	test	dev	test-p
UNITER [26]	73.8	74.0	79.4	79.4	79.1	80.0
VinVL [27]	76.6	76.6	-	-	82.7	84.0
CLIP-ViL [73]	76.5	76.7	80.6	80.2	-	-
ALBEF [36]	75.8	76.0	80.8	80.9	82.6	83.1
BLIP [37]	78.3	78.3	-	-	82.2	82.2
OFA [17]	79.9	80.0	90.3†	90.2†	-	-
VLMo [30]	79.9	80.0	-	-	85.6	86.9
SimVLM [16]	80.0	80.3	86.2	86.3	84.5	85.2
Florence [14]	80.2	80.4	-	-	-	-
METER [74]	80.3	80.5	-	-	-	-
CoCa	**82.3**	**82.3**	**87.0**	**87.1**	**86.1**	**87.0**

表 6：多模态理解结果，对比视觉-语言预训练方法。†OFA 同时使用图像和文本前提作为输入，而其他模型仅使用图像。

4.2.3 图像描述与多模态理解任务

CoCa 的另一个关键优势在于，作为采用生成式目标训练的编码器-解码器模型，它能够处理多模态嵌入。因此，CoCa 无需任何进一步的融合适配，就可以执行图像字幕生成和多模态理解等下游任务 [73, 74]。总体而言，实验结果表明，CoCa 既能作为双编码器方法具备视觉和检索能力，又能受益于编码器-解码器模型，从而获得强大的多模态理解与生成能力。

多模态理解。如 [16] 所示，编码器-解码器模型的输出可以联合编码图像和文本输入，并可用于需要对两种模态进行推理的任务。我们考虑了三个流行的多模态理解基准：视觉问答（VQA v2 [75]）、视觉蕴含（SNLI-VE [76]）和视觉推理（NLVR2 [77]）。我们主要遵循 [16] 中的设置，并在解码器输出之上训练线性分类器来预测答案（更多细节见附录 B）。表 6 中的结果表明，CoCa 优于强大的视觉-语言预训练（VLP）基线，并在所有三个任务上取得了最先进的性能。以往的双编码器模型 [12, 14] 不包含融合层，因此需要额外的视觉-语言（VL）预训练阶段来完成下游多模态理解任务；而 CoCa 涵盖了这三种预训练范式，并通过轻量级微调在视觉-语言任务上获得了更好的性能。

图像描述生成。除了多模态分类任务外，CoCa 作为编码器-解码器模型也可直接应用于图像描述生成任务。我们仅使用描述生成损失 $\mathcal{L}_{\text{Cap}}$ 在 MSCOCO [63] 描述生成任务上对 CoCa 进行微调，并在 MSCOCO Karpathy 测试划分和 NoCaps [78] 在线评测上进行评估。如表 7 的实验所示，CoCa 优于在 MSCOCO 上使用交叉熵损失训练的强基线模型，并取得了与采用 CIDEr 指标特定优化 [79] 的方法相当的结果。值得注意的是，为简化起见，我们没有使用 CIDEr 特定优化 [79]。在具有挑战性的 NoCaps 基准上，CoCa 在验证集和测试集划分上均取得了新的最先进结果（生成示例如图 6 所示）。这些结果展示了 CoCa 作为图像-文本基础模型的生成能力。

	MSCOCO				NoCaps			
					Valid		Test	
	B@4	M	C	S	C	S	C	S
CLIP-ViL [73]	40.2	29.7	134.2	23.8	-	-	-	-
BLIP [37]	40.4	-	136.7	-	113.2	14.8	-	-
VinVL[27]	41.0	31.1	140.9	25.4	105.1	14.4	103.7	14.4
SimVLM [16]	40.6	33.7	143.3	**25.4**	112.2	-	110.3	14.5
LEMON [80]	**41.5**	30.8	139.1	24.1	117.3	15.0	114.3	14.9
$\text{LEMON}_{\text{SCST}}$ [80]†	42.6	31.4	145.5	25.5	-	-	-	-
OFA [17]†	43.5	31.9	149.6	26.1	-	-	-	-
CoCa	40.9	**33.9**	**143.6**	24.7	**122.4**	**15.5**	**120.6**	**15.5**

表 7：在 MSCOCO 和 NoCaps 上的图像描述生成结果（B@4：BLEU@4，M：METEOR，C：CIDEr，S：SPICE）。†表示使用 CIDEr 优化进行微调的模型。



图 6：以 NoCaps 图像作为输入，由 CoCa 生成的文本描述精选样本。

4.3 消融分析

我们在一个较小的模型变体上广泛消融分析了 CoCa 的各项属性。具体而言，我们训练了 CoCa-Base，其解码器层数减少为 12 层，总批大小为 4,096。我们主要使用零样本图像分类和 VQA 进行评估，因为前者同时涵盖视觉表征质量和跨模态对齐，而后者则代表多模态推理。

字幕生成 ***vs***。分类。我们首先考察字幕生成损失在图像标注数据集上的有效性。为此，我们在 JFT-3B 数据集上使用 $\mathcal{L}_{\text{Cap}}$ 训练一个朴素的编码器-解码器模型，并在表 8a 中将其与使用 $\mathcal{L}_{\text{Cls}}$ 训练的标准 ViT-Base 单编码器模型进行比较。我们发现，在轻量评估和微调结果上，编码器-解码器模型的表现与单编码器预训练相当。这表明生成式预训练涵盖了分类预训练，这与我们的直觉一致：当文本词汇表是所有可能类别名称的集合时，$\mathcal{L}_{\text{Cls}}$ 是 $\mathcal{L}_{\text{Cap}}$ 的一个特例。因此，我们的 CoCa 模型可以被解释为对这三种范式的有效统一。这也解释了为什么 CoCa 不需要预训练的视觉编码器也能表现良好。

训练目标。我们研究了两种训练目标的影响，并在表 8b 中将 CoCa 与单目标变体进行了比较。与仅使用对比学习的模型相比，CoCa 在零样本对齐和 VQA 上都有显著提升（请注意，仅使用对比学习的模型需要为 VQA 额外加入融合模块）。CoCa 在 VQA 上的表现与仅使用图像描述生成的模型相当，同时还额外支持零样本分类等检索式任务。表 8c 进一步研究了损失比例，并表明图像描述生成损失不仅提升了 VQA，也改善了模态之间的零样本对齐。我们假设生成式目标能够学习细粒度的文本表示，从而进一步提升文本理解能力。最后，我们在表 8b 中比较了训练成本（以 TPUv3-core-days 衡量；数值越大表示越慢），发现由于两个目标之间共享计算，CoCa 与仅使用图像描述生成的模型（*a.k.a.*朴素编码器-解码器）一样高效。这些结果表明，将两种损失结合起来能够以极小的额外成本带来新的能力和更好的性能。

单模态和多模态解码器。CoCa 引入了一种新颖的解码器设计，我们对其组件进行了消融研究。在表 8d 中，我们改变单模态解码器层的数量（同时保持总层数不变）。直观地说，较少的单模态文本层会导致零样本分类效果变差，因为缺乏良好的单模态文本理解能力；而较少的多模态层会降低模型对 VQA 等多模态输入进行推理的能力。总体而言，我们

loss	LE	FT
$\mathcal{L}_{\text{Cls}}$	81.0	85.1
$\mathcal{L}_{\text{Cap}}$	82.1	84.9

(一个) 编码器-解码器 *vs*。单编码器模型（在 JFT 上训练）。

loss	ZS	VQA	TPU cost
$\mathcal{L}_{\text{Con}}$	70.7	59.2	1×
$\mathcal{L}_{\text{Cap}}$	-	68.9	1.17×
$\mathcal{L}_{\textbf{CoCa}}$	**71.6**	**69.0**	**1.18**×

(b) 训练目标消融。

$\lambda_{\text{Cap}} : \lambda_{\text{Con}}$	ZS	VQA
1:1	71.5	68.6
1:2	71.0	68.1
2:1	**71.6**	**69.0**

(c) 训练目标权重。

n_{uni}	ZS	VQA
3	70.2	69.0
6	**71.6**	**69.0**
9	71.4	68.8

(d) 单模态解码器层。

variant	AE	MSCOCO
1 [CLS]	**80.7**	**41.4**
+ text tokens	80.3	40.2
8 [CLS]	80.3	36.9
+ text tokens	80.4	40.3

(e) 对比式文本嵌入设计消融。

variant	ZS	VQA
parallel	71.2	68.7
cascade	**71.6**	**69.0**
$n_{\text{query}} = 0$	71.5	69.0
$n_{\text{query}} = 1$	69.3	64.4
$n_{\text{query}} = 32$	71.2	68.2

(f) 注意力池化器设计消融。

表 8：CoCa 消融实验。在 ImageNet 分类上，我们报告以下设置的 top-1 准确率：零样本（ZS）、线性评估（LE）、在冻结特征上使用池化器的注意力评估（AE），以及微调（FT）。在 MSCOCO 检索上，我们报告图像到文本和文本到图像 R@1 的平均值。在 VQA 上，我们报告开发集 vqa 分数。默认 CoCa 设置以粗体显示。

我们发现，将解码器解耦为一半可以保持良好的平衡。一种可能的解释是，用于检索的全局文本表示不需要深层模块 [33]，而浅层的早期融合对于多模态理解也可能并非必要。接下来，我们探索提取单模态文本嵌入的各种选项。具体而言，我们实验了可学习 [CLS] 标记的数量以及聚合设计。对于后者，我们仅对 [CLS] 标记进行聚合，或对 [CLS] 与原始输入句子的拼接进行聚合。有趣的是，在表 8e 中，我们发现对于纯视觉和跨模态检索任务，训练单个 [CLS] 标记且不使用原始输入更为理想。这表明，学习一个额外的简单句子表示可以减轻对比损失与字幕生成损失之间的干扰，并且其能力足以实现强泛化。

注意力池化器。CoCa 在其设计中利用注意力池化器，既用于不同的预训练目标，也用于特定目标的下游任务适配。在预训练中，我们比较了几种使用池化器处理对比损失和生成损失的设计变体：（1）“并行”设计，即如图 2 所示，在 Vision Transformer 编码器输出上同时提取对比损失和生成损失；（2）“级联”设计，即将对比池化器应用于生成池化器的输出之上。表 8f 展示了这些变体的结果。经验上，我们发现在小规模设置下，“级联”版本（在生成池化器之上使用对比池化器）表现更好，并在所有 CoCa 模型中默认使用。我们还研究了查询数量的影响，其中 $n_{\text{query}} = 0$ 表示不使用生成池化器（因此所有 ViT 输出 token 都用于解码器的交叉注意力）。结果表明，两个任务都更偏好由详细图像 token 组成的较长序列，代价是计算量和参数量略有增加。因此，我们使用长度为 256 的生成池化器，以提升多模态理解基准表现，同时仍保持强大的冻结特征能力。

5 更广泛的影响

本文提出了一种在网络规模数据集上进行图像-文本预训练的方法，能够以零样本方式或通过轻量级微调迁移到广泛的下游任务。尽管预训练模型能够完成许多视觉和视觉-语言任务，但我们注意到，我们的模型使用了与先前方法 [13, 21, 32, 33] 相同的预训练数据，因此在实际使用这些模型之前，有必要对数据及所得模型进行额外分析。我们表明，CoCa 模型在受损图像上更加鲁棒，但它仍可能容易受到当前评估集或真实场景中尚未涵盖的其他图像损坏的影响。对于两者

对于数据和模型，还需要社区进一步探索，以了解其更广泛的影响，包括但不限于公平性、社会偏见和潜在滥用。

6 结论

在这项工作中，我们提出了对比式字幕生成器（Contrastive Captioners，CoCa），这是一个新的图像-文本基础模型家族，它以自然语言监督涵盖了现有的视觉预训练范式。CoCa 在单阶段中基于来自各种数据源的图像-文本对进行预训练，并在编码器-解码器模型中高效结合了对比学习和字幕生成目标。CoCa 仅凭一个检查点，就在广泛的视觉及视觉-语言问题上取得了一系列最先进的性能。我们的工作弥合了各种预训练方法之间的差距，并希望能够激发图像-文本基础模型的新方向。

致谢

我们感谢 Yi-Ting Chen、Kaifeng Chen、Ye Xia、Zhen Li、Chao Jia、Yinfei Yang、Zhengdong Zhang、Wei Han、Yuan Cao、Tao Zhu、Futang Peng、Soham Ghosh、Zihang Dai、Junnan Li、Ning Wang、Xin Li、Anelia Angelova、Jason Baldridge、Izhak Shafran、Shengyang Dai、Abhijit Ogale、Zhifeng Chen、Claire Cui、Paul Natsev、Tom Duerig 提供的有益讨论，感谢 Andrew Dai 在对比模型方面提供的帮助，感谢 Christopher Fifty 和 Bowen Zhang 在视频模型方面提供的帮助，感谢 Yuanzhong Xu 在模型扩展方面提供的帮助，感谢 Lucas Beyer 在数据准备方面提供的帮助，感谢 Andy Zeng 在 MSR-VTT 评估方面提供的帮助，感谢 Hieu Pham 和 Simon Kornblith 在零样本评估方面提供的帮助，感谢 Erica Moreira 和 Victor Gomes 在资源协调方面提供的帮助，感谢 Tom Small 在可视化插图方面提供的帮助，感谢 Lianglian g Cao 的校对，以及 Google Brain 团队的其他成员在整个项目期间给予的支持。

参考文献

[1] Rishi Bommasani、Drew A Hudson、Ehsan Adeli、Russ Altman、Simran Arora、Sydney von Arx、Michael S Bernstein、Jeannette Bohg、Antoine Bosselut、Emma Brunskill 等。基础模型的机遇与风险。*arXiv preprint arXiv:2108.07258*，2021。 [2] Jacob Devlin、Ming-Wei Chang、Kenton Lee 和 Kristina Toutanova。Bert：用于语言理解的深度双向 Transformer 预训练。*arXiv preprint arXiv:1810.04805*，2018。 [3] Colin Raffel、Noam Shazeer、Adam Roberts、Katherine Lee、Sharan Narang、Michael Matena、Yanqi Zhou、Wei Li 和 Peter J Liu。使用统一的文本到文本 Transformer 探索迁移学习的极限。*arXiv preprint arXiv:1910.10683*，2019。 [4] Tom Brown、Benjamin Mann、Nick Ryder、Melanie Subbiah、Jared D Kaplan、Prafulla Dhariwal、Arvind Neelakantan、Pranav Shyam、Girish Sastry、Amanda Askell 等。语言模型是少样本学习者。*Advances in neural information processing systems*，33:1877–1901，2020。 [5] Paul Barham、Aakanksha Chowdhery、Jeff Dean、Sanjay Ghemawat、Steven Hand、Dan Hurt、Michael Isard、Hyeontaek Lim、Ruoming Pang、Sudip Roy 等。Pathways：用于机器学习的异步分布式数据流。*arXiv preprint arXiv:2203.12533*，2022。 [6] Ross Girshick、Jeff Donahue、Trevor Darrell 和 Jitendra Malik。用于精确目标检测和语义分割的丰富特征层次结构。见 *Proceedings of the IEEE conference on computer vision and pattern recognition*，第 580–587 页，2014。 [7] Jonathan Long、Evan Shelhamer 和 Trevor Darrell。用于语义分割的全卷积网络。见 *Proceedings of the IEEE conference on computer vision and pattern recognition*，第 3431–3440 页，2015。 [8] Karen Simonyan 和 Andrew Zisserman。用于视频动作识别的双流卷积网络。*Advances in neural information processing systems*，27，2014。 [9] Jia Deng、Wei Dong、Richard Socher、Li-Jia Li、Kai Li 和 Li Fei-Fei。Imagenet：一个大规模层次化图像数据库。见 *2009 IEEE conference on computer vision and pattern recognition*，第 248–255 页。Ieee，2009。

[10] Zihang Dai, Hanxiao Liu, Quoc V Le, and Mingxing Tan. Coatnet：将卷积与注意力结合以适应所有数据规模。*Advances in Neural Information Processing Systems*, 34:3965–3977, 2021. [11] Bowen Zhang, Jiahui Yu, Christopher Fifty, Wei Han, Andrew M Dai, Ruoming Pang, and Fei Sha. 使用视频和图像共同训练 Transformer 可提升动作识别性能。*arXiv preprint arXiv:2112.07175*, 2021. [12] Alec Radford, Jong Wook Kim, Chris Hallacy, Aditya Ramesh, Gabriel Goh, Sandhini Agarwal, Girish Sastry, Amanda Askell, Pamela Mishkin, Jack Clark, et al. 从自然语言监督中学习可迁移的视觉模型。载于 *International Conference on Machine Learning*, 第 8748–8763 页。PMLR, 2021. [13] Chao Jia, Yinfei Yang, Ye Xia, Yi-Ting Chen, Zarana Parekh, Hieu Pham, Quoc Le, Yun- Hsuan Sung, Zhen Li, and Tom Duerig. 通过噪声文本监督扩展视觉和视觉-语言表征学习。载于 *International Conference on Machine Learning*, 第 4904–4916 页。PMLR, 2021. [14] Lu Yuan, Dongdong Chen, Yi-Ling Chen, Noel Codella, Xiyang Dai, Jianfeng Gao, Houdong Hu, Xuedong Huang, Boxin Li, Chunyuan Li, et al. Florence：一种新的计算机视觉基础模型。 *arXiv preprint arXiv:2111.11432*, 2021. [15] Oriol Vinyals, Alexander Toshev, Samy Bengio, and Dumitru Erhan. Show and tell：一种神经图像字幕生成器。载于 *Proceedings of the IEEE conference on computer vision and pattern recognition*, 第 3156–3164 页, 2015. [16] Zirui Wang, Jiahui Yu, Adams Wei Yu, Zihang Dai, Yulia Tsvetkov, and Yuan Cao. Simvlm：基于弱监督的简单视觉语言模型预训练。*arXiv preprint arXiv:2108.10904*, 2021. [17] Peng Wang, An Yang, Rui Men, Junyang Lin, Shuai Bai, Zhikang Li, Jianxin Ma, Chang Zhou, Jingren Zhou, and Hongxia Yang. 通过一个简单的序列到序列学习框架统一架构、任务和模态。 *arXiv preprint arXiv:2202.03052*, 2022. [18] Alex Krizhevsky, Ilya Sutskever, and Geoffrey E Hinton. 使用深度卷积神经网络进行 ImageNet 分类。 *Advances in neural information processing systems*, 25, 2012. [19] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N Gomez, ukasz Kaiser, and Illia Polosukhin. 注意力就是你所需要的一切。*Advances in neural information processing systems*, 30, 2017. [20] Dhruv Mahajan, Ross Girshick, Vignesh Ramanathan, Kaiming He, Manohar Paluri, Yixuan Li, Ashwin Bharambe, and Laurens Van Der Maaten. 探索弱监督预训练的极限。载于 *Proceedings of the European conference on computer vision (ECCV)*, 第 181–196 页, 2018. [21] Xiaohua Zhai, Alexander Kolesnikov, Neil Houlsby, and Lucas Beyer. 扩展视觉 Transformer, 2021. [22] Hangbo Bao, Li Dong, and Furu Wei. Beit：图像 Transformer 的 Bert 预训练。*arXiv preprint arXiv:2106.08254*, 2021. [23] Kaiming He, Xinlei Chen, Saining Xie, Yanghao Li, Piotr Dollár, and Ross Girshick. 掩码自编码器是可扩展的视觉学习器。 *arXiv preprint arXiv:2111.06377*, 2021. [24] Zhenda Xie, Zheng Zhang, Yue Cao, Yutong Lin, Jianmin Bao, Zhuliang Yao, Qi Dai, and Han Hu. Simmim：用于掩码图像建模的简单框架。 *arXiv preprint arXiv:2111.09886*, 2021. [25] Hao Tan and Mohit Bansal. Lxmert：从 Transformer 中学习跨模态编码器表征。*arXiv preprint arXiv:1908.07490*, 2019. [26] Yen-Chun Chen, Linjie Li, Licheng Yu, Ahmed El Kholy, Faisal Ahmed, Zhe Gan, Yu Cheng, and Jingjing Liu. Uniter：通用图像-文本表征学习。载于 *ECCV*, 2020. [27] Pengchuan Zhang, Xiujun Li, Xiaowei Hu, Jianwei Yang, Lei Zhang, Lijuan Wang, Yejin Choi, and Jianfeng Gao. Vinvl：重新审视视觉-语言模型中的视觉表征。载于 *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 第 5579–5588 页, 2021 年 6 月.

[28] Shaoqing Ren、Kaiming He、Ross Girshick 和 Jian Sun。Faster r-cnn：利用区域候选网络实现实时目标检测。在 C. Cortes、N. Lawrence、D. Lee、M. Sugiyama 和 R. Garnett 编辑的 *Advances in Neural Information Processing Systems*，第 28 卷。Curran Associates, Inc.，2015。[29] Wonjae Kim、Bokyung Son 和 Ildoo Kim。Vilt：无需卷积或区域监督的视觉-语言 Transformer，2021。[30] Wenhui Wang、Hangbo Bao、Li Dong 和 Furu Wei。Vlmo：采用模态专家混合的统一视觉-语言预训练。*arXiv preprint arXiv:2111.02358*，2021。[31] Jianwei Yang、Chunyuan Li、Pengchuan Zhang、Bin Xiao、Ce Liu、Lu Yuan 和 Jianfeng Gao。图像-文本-标签空间中的统一对比学习，2022。[32] Xiaohua Zhai、Xiao Wang、Basil Mustafa、Andreas Steiner、Daniel Keysers、Alexander Kolesnikov 和 Lucas Beyer。Lit：通过锁定图像的文本调优实现零样本迁移。*arXiv preprint arXiv:2111.07991*，2021。[33] Hieu Pham、Zihang Dai、Golnaz Ghiasi、Kenji Kawaguchi、Hanxiao Liu、Adams Wei Yu、Jiahui Yu、Yi-Ting Chen、Minh-Thang Luong、Yonghui Wu、Mingxing Tan 和 Quoc V. Le。用于开放词汇图像分类的联合缩放，2021。[34] AJ Piergiovanni、Wei Li、Weicheng Kuo、Mohammad Saffar、Fred Bertsch 和 Anelia Angelova。Answer-me：多任务开放词汇视觉问答。*arXiv preprint arXiv:2205.00949*，2022。[35] Amanpreet Singh、Ronghang Hu、Vedanuj Goswami、Guillaume Couairon、Wojciech Galuba、Marcus Rohrbach 和 Douwe Kiela。Flava：基础性语言与视觉对齐模型。*arXiv preprint arXiv:2112.04482*，2021。[36] Junnan Li、Ramprasaath Selvaraju、Akhilesh Gotmare、Shafiq Joty、Caiming Xiong 和 Steven Chu Hong Hoi。先对齐后融合：基于动量蒸馏的视觉和语言表示学习。*Advances in Neural Information Processing Systems*，34，2021。[37] Junnan Li、Dongxu Li、Caiming Xiong 和 Steven Hoi。Blip：用于统一视觉-语言理解与生成的语言-图像预训练引导。*arXiv preprint arXiv:2201.12086*，2022。[38] Anders Andreassen、Yasaman Bahri、Behnam Neyshabur 和 Rebecca Roelofs。微调过程中分布外鲁棒性的演化。*arXiv preprint arXiv:2106.15831*，2021。[39] Alexey Dosovitskiy、Lucas Beyer、Alexander Kolesnikov、Dirk Weissenborn、Xiaohua Zhai、Thomas Unterthiner、Mostafa Dehghani、Matthias Minderer、Georg Heigold、Sylvain Gelly、Jakob Uszkoreit 和 Neil Houlsby。一张图像相当于 16x16 个词：用于大规模图像识别的 Transformer。在 *International Conference on Learning Representations*，2021。[40] Kaiming He、Xiangyu Zhang、Shaoqing Ren 和 Jian Sun。用于图像识别的深度残差学习。在 *Proceedings of the IEEE conference on computer vision and pattern recognition*，第 770–778 页，2016。[41] Ronald J Williams 和 David Zipser。用于连续运行的全递归神经网络的学习算法。*Neural computation*，1(2):270–280，1989。[42] Juho Lee、Yoonho Lee、Jungtaek Kim、Adam Kosiorek、Seungjin Choi 和 Yee Whye Teh。集合 Transformer：一种基于注意力的置换不变神经网络框架。在 *International Conference on Machine Learning*，第 3744–3753 页。PMLR，2019。[43] Rico Sennrich、Barry Haddow 和 Alexandra Birch。使用子词单元处理稀有词的神经机器翻译。*arXiv preprint arXiv:1508.07909*，2015。[44] Taku Kudo。子词正则化：通过多个子词候选改进神经网络翻译模型。*arXiv preprint arXiv:1804.10959*，2018。[45] Jonathan Shen、Patrick Nguyen、Yonghui Wu、Zhifeng Chen 等。Lingvo：一个用于序列到序列建模的模块化且可扩展框架，2019。[46] Yanping Huang、Youlong Cheng、Ankur Bapna、Orhan Firat、Dehao Chen、Mia Chen、HyoukJoong Lee、Jiquan Ngiam、Quoc V Le、Yonghui Wu 等。Gpipe：使用流水线并行高效训练巨大神经网络。*Advances in neural information processing systems*，32，2019。

[47] Yuanzhong Xu、HyoukJoong Lee、Dehao Chen、Hongjun Choi、Blake Hechtman 和 Shibo Wang。数据并行训练中权重更新的自动跨副本分片。*arXiv preprint arXiv:2004.13336*，2020。 [48] Dmitry Lepikhin、HyoukJoong Lee、Yuanzhong Xu、Dehao Chen、Orhan Firat、Yanping Huang、Maxim Krikun、Noam Shazeer 和 Zhifeng Chen。Gshard：通过条件计算和自动分片扩展巨型模型。*arXiv preprint arXiv:2006.16668*，2020。 [49] Yuanzhong Xu、HyoukJoong Lee、Dehao Chen、Blake Hechtman、Yanping Huang、Rahul Joshi、Maxim Krikun、Dmitry Lepikhin、Andy Ly、Marcello Maggioni 等。Gspmd：用于机器学习计算图的通用且可扩展的并行化。*arXiv preprint arXiv:2105.04663*，2021。 [50] Noam Shazeer 和 Mitchell Stern。Adafactor：具有次线性内存成本的自适应学习率。收录于 *International Conference on Machine Learning*，第 4596–4604 页。PMLR，2018。 [51] Hieu Pham、Zihang Dai、Qizhe Xie 和 Quoc V Le。元伪标签。收录于 *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*，第 11557–11568 页，2021。 [52] Mitchell Wortsman、Gabriel Ilharco、Samir Yitzhak Gadre、Rebecca Roelofs、Raphael Gontijo-Lopes、Ari S Morcos、Hongseok Namkoong、Ali Farhadi、Yair Carmon、Simon Kornblith 等。模型汤：对多个微调模型的权重取平均可在不增加推理时间的情况下提高准确率。*arXiv preprint arXiv:2203.05482*，2022。

[53] Anurag Arnab、Mostafa Dehghani、Georg Heigold、Chen Sun、Mario Lučić 和 Cordelia Schmid。Vivit：一种视频视觉 Transformer。载于 *Proceedings of the IEEE/CVF International Conference on Computer Vision*，第 6836–6846 页，2021 年。

[54] Dan Kondratyuk、Liangzhe Yuan、Yandong Li、Li Zhang、Mingxing Tan、Matthew Brown 和 Boqing Gong。Movinets：用于高效视频识别的移动视频网络。发表于 *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*，第 16020–16030 页，2021 年。

[55] Hassan Akbari, Liangzhe Yuan, Rui Qian, Wei-Hong Chuang, Shih-Fu Chang, Yin Cui, and Boqing Gong. Vatt：用于从原始视频、音频和文本进行多模态自监督学习的 Transformer。*Advances in Neural Information Processing Systems*, 34, 2021.

[56] 陈伟、Haoqi Fan、Saining Xie、Chao-Yuan Wu、Alan Yuille 和 Christoph Feichtenhofer。用于自监督视觉预训练的掩码特征预测。*arXiv preprint arXiv:2112.09133*，2021。

[57] Will Kay, Joao Carreira, Karen Simonyan, Brian Zhang, Chloe Hillier, Sudheendra Vijaya- narasimhan, Fabio Viola, Tim Green, Trevor Back, Paul Natsev 等。Kinetics 人类动作视频数据集。*arXiv preprint arXiv:1705.06950*，2017。

[58] Joao Carreira, Eric Noland, Andras Banki-Horvath, Chloe Hillier, and Andrew Zisserman. 关于 Kinetics-600 的简短说明。*arXiv preprint arXiv:1808.01340*, 2018.

[59] Joao Carreira、Eric Noland、Chloe Hillier 和 Andrew Zisserman。关于 Kinetics-700 人类动作数据集的简短说明。*arXiv preprint arXiv:1907.06987*，2019。

[60] Mathew Monfort, Alex Andonian, Bolei Zhou, Kandan Ramakrishnan, Sarah Adel Bargal, Tom Yan, Lisa Brown, Quanfu Fan, Dan Gutfreund, Carl Vondrick 等。Moments in Time 数据集：用于事件理解的一百万个视频。*IEEE transactions on pattern analysis and machine intelligence*, 42(2):502–508, 2019.

[61] Lewei Yao, Runhui Huang, Lu Hou, Guansong Lu, Minzhe Niu, Hang Xu, Xiaodan Liang, Zhenguo Li, Xin Jiang, and Chunjing Xu. Filip：细粒度交互式语言-图像预训练。*arXiv preprint arXiv:2111.07783*, 2021.

[62] Bryan A Plummer、Liwei Wang、Chris M Cervantes、Juan C Caicedo、Julia Hockenmaier 和 Svetlana Lazebnik。Flickr30k 实体：为更丰富的图像到句子模型收集区域到短语的对应关系。收录于 *Proceedings of the IEEE international conference on computer vision*，第 2641–2649 页，2015 年。

[63] Xinlei Chen、Hao Fang、Tsung-Yi Lin、Ramakrishna Vedantam、Saurabh Gupta、Piotr Dollár 和 C Lawrence Zitnick。Microsoft COCO 图像描述：数据收集与评估服务器。*arXiv preprint arXiv:1504.00325*，2015。

[64] Dan Hendrycks、Kevin Zhao、Steven Basart、Jacob Steinhardt 和 Dawn Song。自然对抗样本。发表于 *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*，第 15262–15271 页，2021 年。[65] Dan Hendrycks、Steven Basart、Norman Mu、Saurav Kadavath、Frank Wang、Evan Dorundo、Rahul Desai、Tyler Zhu、Samyak Parajuli、Mike Guo 等。鲁棒性的多面性：对分布外泛化的批判性分析。发表于 *Proceedings of the IEEE/CVF International Conference on Computer Vision*，第 8340–8349 页，2021 年。[66] Benjamin Recht、Rebecca Roelofs、Ludwig Schmidt 和 Vaishaal Shankar。ImageNet 分类器能否泛化到 ImageNet？发表于 *International Conference on Machine Learning*，第 5389–5400 页。PMLR，2019 年。[67] Haohan Wang、Songwei Ge、Zachary Lipton 和 Eric P Xing。通过惩罚局部预测能力学习鲁棒的全局表征。*Advances in Neural Information Processing Systems*，32，2019 年。[68] Andrei Barbu、David Mayo、Julian Alverio、William Luo、Christopher Wang、Dan Gutfreund、Josh Tenenbaum 和 Boris Katz。ObjectNet：一个用于推动目标识别模型极限的大规模偏差控制数据集。*Advances in neural information processing systems*，32，2019 年。[69] Jesús Andrés Portillo-Quintero、José Carlos Ortiz-Bayliss 和 Hugo Terashima-Marín。一个使用 CLIP 进行视频检索的简单框架。*arXiv preprint arXiv:2102.12443*，2021 年。[70] Andy Zeng、Adrian Wong、Stefan Welker、Krzysztof Choromanski、Federico Tombari、Aveek Purohit、Michael Ryoo、Vikas Sindhwani、Johnny Lee、Vincent Vanhoucke 和 Pete Florence。苏格拉底模型：用语言组合零样本多模态推理。*arXiv preprint arXiv:2204.00598*，2022 年。[71] Jun Xu、Tao Mei、Ting Yao 和 Yong Rui。MSR-VTT：一个用于连接视频与语言的大型视频描述数据集。发表于 *Proceedings of the IEEE conference on computer vision and pattern recognition*，第 5288–5296 页，2016 年。[72] Lucas Smaira、João Carreira、Eric Noland、Ellen Clancy、Amy Wu 和 Andrew Zisserman。关于 Kinetics-700-2020 人类动作数据集的简短说明。*arXiv preprint arXiv:2010.10864*，2020 年。[73] Sheng Shen、Liunian Harold Li、Hao Tan、Mohit Bansal、Anna Rohrbach、Kai-Wei Chang、Zhewei Yao 和 Kurt Keutzer。CLIP 能在多大程度上有益于视觉语言任务？*arXiv preprint arXiv:2107.06383*，2021 年。[74] Zi-Yi Dou、Yichong Xu、Zhe Gan、Jianfeng Wang、Shuohang Wang、Lijuan Wang、Chenguang Zhu、Zicheng Liu、Michael Zeng 等。端到端视觉语言 Transformer 训练的实证研究。*arXiv preprint arXiv:2111.02387*，2021 年。[75] Yash Goyal、Tejas Khot、Douglas Summers-Stay、Dhruv Batra 和 Devi Parikh。让 VQA 中的 V 变得重要：提升图像理解在视觉问答中的作用。发表于 *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*，第 6904–6913 页，2017 年。[76] Ning Xie、Farley Lai、Derek Doran 和 Asim Kadav。视觉蕴含：一种用于细粒度图像理解的新任务。*arXiv preprint arXiv:1901.06706*，2019 年。[77] Alane Suhr、Stephanie Zhou、Ally Zhang、Iris Zhang、Huajun Bai 和 Yoav Artzi。一个用于推理基于照片的自然语言的语料库。*arXiv preprint arXiv:1811.00491*，2018 年。[78] Harsh Agrawal、Karan Desai、Yufei Wang、Xinlei Chen、Rishabh Jain、Mark Johnson、Dhruv Batra、Devi Parikh、Stefan Lee 和 Peter Anderson。nocaps：大规模新颖目标图像描述。发表于 *Proceedings of the IEEE/CVF International Conference on Computer Vision*，第 8948–8957 页，2019 年。[79] Steven J Rennie、Etienne Marcheret、Youssef Mroueh、Jerret Ross 和 Vaibhava Goel。用于图像描述的自我批判序列训练。发表于 *Proceedings of the IEEE conference on computer vision and pattern recognition*，第 7008–7024 页，2017 年。[80] Xiaowei Hu、Zhe Gan、Jianfeng Wang、Zhengyuan Yang、Zicheng Liu、Yumao Lu 和 Li- juan Wang。扩展用于图像描述的视觉语言预训练。*arXiv preprint arXiv:2111.12233*，2021 年。

视觉识别微调细节

Hyper-parameter	ImageNet		Kinetics-400/600/700		Moments-in-Time	
	Frozen-feature	Finetuning	Frozen-feature	Finetuning	Frozen-feature	Finetuning
Optimizer	Adafacter with Decoupled Weight Decay					
Gradient clip	1.0					
EMA decay rate	0.9999					
LR decay schedule	Cosine Schedule Decaying to Zero					
Loss	Softmax					
MixUp	None					
CutMix	None					
AutoAugment	None					
RepeatedAugment	None					
RandAugment	2, 20	2, 20	None	None	None	None
Label smoothing	0.2	0.5	0.1	0.1	0.0	0.0
Train steps	200k	200k	120k	120k	120k	120k
Train batch size	512	512	128	128	128	128
Pooler LR	5e-4	5e-4	5e-4	5e-4	5e-4	5e-4
Encoder LR	0.0	5e-4	0.0	5e-4	0.0	5e-4
Warm-up steps	0	0	1000	1000	1000	1000
Weight decay rate	0.01	0.01	0.0	0.0	0.0	0.0

表9：视觉识别实验中使用的超参数。

除了零样本迁移外，我们还评估了 CoCa 在视觉识别任务上的冻结特征和微调性能。对于冻结特征评估，我们在视觉特征输出序列之上添加一个注意力池化层（pooler），并额外添加一个 softmax 交叉熵损失层，用于学习图像和视频分类。对于微调，我们采用与冻结特征评估相同的架构（因此也包含 pooler），并同时微调编码器和 pooler。所有学习超参数列于表 9。

B 多模态理解微调细节

Hyper-parameter	VQA	SNLI-VE	NLVR2	MSCOCO	NoCaps
Optimizer	Adafacter with Decoupled Weight Decay				
Gradient clip	1.0				
LR decay schedule	Cosine Schedule Decaying to Zero				
RandAugment	1, 10	1, 10	None	None	None
Train steps	100k	50k	50k	50k	10k
Train batch size	64	128	64	128	128
Pooler LR	5e-4	1e-3	5e-4	NA	NA
Encoder LR	2e-5	5e-5	2e-5	1e-5	1e-5
Warm-up steps	1000	1000	1000	1000	1000
Weight decay rate	0.1	0.1	0.1	0.1	0.1

表 10：多模态实验中使用的超参数。

CoCa 是一种编码器-解码器模型，其最终解码器输出可用于多模态理解/生成。因此，我们在流行的视觉-语言基准上进行评估。我们主要遵循 [16] 中介绍的相同设置。所有超参数列于表 10。

对于多模态分类，我们将图像输入编码器，并将相应文本输入解码器。然后，我们应用另一个带有单个查询的注意力池化器，从解码器输出中提取嵌入，并在池化后的嵌入之上训练一个线性分类器。对于 VQA v2 [75]，我们遵循先前工作，将该任务表述为在训练集中 3,129 个最常见答案上的分类问题。我们还在文本问题与答案的拼接对上启用生成损失的联合训练，以提高模型鲁棒性。类似地，对于 SNLI-VE，图像和文本假设分别输入编码器和解码器，并训练分类器来预测它们之间的关系为蕴含、中立或矛盾。对于 NLVR2，我们

为每张图像和文本描述创建两个输入对，并将它们拼接后作为分类器的输入。我们不对 NLVR2 使用图像增强。

对于图像字幕生成，我们采用简单的交叉熵损失（与预训练中使用的字幕生成损失相同），并在 MSCOCO 的训练集上微调模型，以对 MSCOCO 测试集和 NoCaps 在线评估进行预测。