PALI-3 视觉语言模型：更小、更快、更强

陈曦[⋆]1 王晓[⋆]2 卢卡斯·拜尔[⋆]2 亚历山大·科列斯尼科夫2 吴佳霖1 保罗·福伊特伦德1 巴西尔·穆斯塔法2 塞巴斯蒂安·古德曼1 易卜拉欣·阿卜杜勒穆赫辛2 彼得·帕德莱夫斯基2 丹尼尔·萨尔茨1 熊曦3 丹尼尔·弗拉西奇3 菲利普·帕韦蒂奇2 荣可然2 于天立3 丹尼尔·凯泽斯2 翟晓华[⋆†]2 拉杜·索里库特[†]1

1Google 研究院 2Google DeepMind 3Google Cloud

摘要

本文介绍了 PaLI-3，这是一个更小、更快且更强的视觉语言模型（VLM），其性能优于参数规模大 10 倍的同类模型。为了实现这一强劲性能，我们比较了使用分类目标预训练的视觉 Transformer（ViT）模型与使用对比学习（SigLIP）预训练的模型。我们发现，尽管基于 SigLIP 的 PaLI 在标准图像分类基准上表现略逊一筹，但它在各种多模态基准上展现出更优的性能，尤其是在定位和视觉情境中的文本理解方面。我们将 SigLIP 图像编码器扩展到 20 亿参数，并在多语言跨模态检索上取得了新的最先进水平。我们希望仅有 50 亿参数的 PaLI-3 能够重新激发对复杂 VLM 基础组成部分的研究，并推动新一代扩展模型的发展。

3202 tcO 71]VC.sc[2v99190.0132:viXra

1 引言

视觉-语言模型（VLM）扩展到数百亿甚至数千亿参数规模（Chen et al., 2023b; Alayrac et al., 2022; Chen et al., 2023a; Driess et al., 2023）后，性能不断提升。与此同时，较小规模的模型仍然至关重要，因为它们在训练和部署上更具实用性，更环保，并且支持更快的模型设计研究周期。

本着专注于较小规模建模的理念，我们提出了 PaLI-3，即第三代 PaLI（Chen 等，2023b）模型系列。我们使用一个总参数量仅为 5B 的预训练骨干网络，优化了训练方案，并在各种 VLM 基准测试上取得了具有竞争力且新的最先进（SOTA）结果。我们的新方案包含三个主要组成部分：在网络规模的图像-文本数据上对图像编码器进行对比式预训练（Zhai 等，2023）、用于 PaLI 多模态训练的改进数据集混合，以及在更高分辨率下进行训练。

PaLI-3 在需要视觉情境文本理解和目标定位的任务上取得了新的 SOTA 成果，包括八项视觉情境文本理解任务以及 RefCOCO（Yu et al., 2016）上的指代表达式分割任务，同时在广泛的经典视觉任务上也表现强劲。作为这项工作的一部分，我们还引入了一个扩展到 20 亿参数的 SOTA 多语言对比视觉模型，该模型使用最近提出的 SigLIP 方法（Zhai et al., 2023）获得。此外，我们还进行了有针对性的消融研究，以比较分类预训练的视觉 Transformer（ViT）主干网络（Dosovitskiy et al., 2021）与对比预训练的主干网络（SigLIP）。这进一步证实了在嘈杂的网络规模图像-文本数据上预训练视觉编码器的可行性，并表明相较于在分类式数据上训练，这是一种更可取的替代方案。

我们的贡献总结如下：

[⋆]Core contributors, [†]Project leads

1. 我们使用 PaLI 框架（Chen et al., 2023b），将分类预训练的 ViT 模型（Dosovitskiy et al., 2021）与对比式预训练的 SigLIP 模型进行比较。我们发现，对比式预训练模型在视觉情境文本理解任务和定位任务上表现显著更好。2. 与当前 SOTA 模型 Chen et al. (2023a) 相比，我们的模型规模小 10 倍，同时在 10+ 个多样化的视觉-语言基准上实现了 SOTA 性能。对于视觉情境文本理解，其提升幅度尤其显著。3. 尽管没有在任何视频数据上进行预训练，我们的模型仍在多个视频问答基准上取得新的 SOTA，显示出强大的泛化能力。4. 我们推出了在 We-bLI（Chen et al., 2023b）上训练的 20 亿参数（ViT-G）多语言 SigLIP 模型，该模型在涵盖 36 种语言的多语言跨模态检索基准 Thapliyal et al. (2022) 上创下了新的最先进水平。

2 相关工作

近期的大型视觉语言模型（VLM）将预训练图像编码器作为更大模型的一部分：有些通过有监督分类对其进行预训练（PaLI（Chen et al., 2023b）、PaLI-X（Chen et al., 2023a）、PaLM-E（Driess et al., 2023）），有些使用预训练的 CLIP 编码器（BLIPv2（Li et al., 2023）、CrossTVR（Dai et al., 2023）、ChatBridge（Zhao et al., 2023）），还有一些采用定制的多模态预训练（Flamingo（Alayrac et al., 2022）、BEiT3（Wang et al., 2022b）、CoCa（Yu et al., 2022）、SimVLM（Wang et al., 2021b））。在本文中，我们使用 PaLI 框架比较了两种主流的图像编码器预训练方式：基于大规模弱标注数据集的分类预训练（JFT，如 Kolesnikov et al., 2020；Zhai et al., 2022a；Dehghani et al., 2023）以及基于网络规模噪声数据的对比预训练（WebLI，如 Zhai et al., 2023）。

PaLI（Chen 等，2023b）和 PaLI-X（Chen 等，2023a）的一项近期发现是，扩大经过分类预训练的图像编码器规模似乎比此前认为的更有前景（Alayrac 等，2022）。具体而言，虽然 ImageNet 等经典的仅图像基准似乎表明，仅图像模型的预训练规模扩展会出现性能饱和（Zhai 等，2022a），但 PaLI 表明，通过将视觉编码器从 ViT-G（2B）扩大到 ViT-e（4B），在视觉-语言（VL）任务上的提升比在 ImageNet 上更为显著。PaLI-X 进一步扩大了视觉和语言组件的规模，表明这些更大的图像编码器在接入大型视觉-语言模型（VLM）时仍能持续带来收益。这一发现表明，在 VLM 语境下，关于图像编码器的预训练还有更多值得探索的内容；与考察“纯”视觉任务相比，在考察 VLM 任务时可能会得出不同结论。本文深入研究图像编码器对 VLM 的影响，直接比较经过分类预训练的视觉模型与经过对比预训练的视觉模型，并揭示后者在多种任务上具有显著优势，尤其是在定位和视觉情境文本理解方面。

可以将多模态理解能力大致分为两类：自然场景理解（图像描述、VQA、目标检测/定位）和视觉情境中的文本理解（文档和信息图表问答）。这两类任务需要不同粒度的理解，而以往的 VLM 大多专注于其中一种任务类型，导致其训练方案也针对该类任务进行了调优。例如，PaLI-17B（Chen et al., 2023b）和 Pix2struct（Lee et al., 2022）分别只在这两类任务中的一类上表现出强劲性能。近期的 PaLI-X（Chen et al., 2023a）基于改进的 OCR 相关训练方案以及规模显著更大的 55B 参数模型，在这两类任务上都取得了 SOTA 性能。在本工作中，我们将对比预训练 ViT 的优势与进一步改进且更加均衡的训练方案结合到 PaLI-3 中，并证明即使在 5B 参数规模下，也可以在上述两类多模态理解任务上达到 SOTA 水平的性能。

3 模型

3.1 架构

从高层次来看，该架构遵循 Chen 等人（2023b；a）：ViT 将图像编码为标记，这些标记与文本输入（问题、提示、指令）一起传递给编码器-解码器 Transformer（Vaswani 等人，2017），从而生成文本输出。

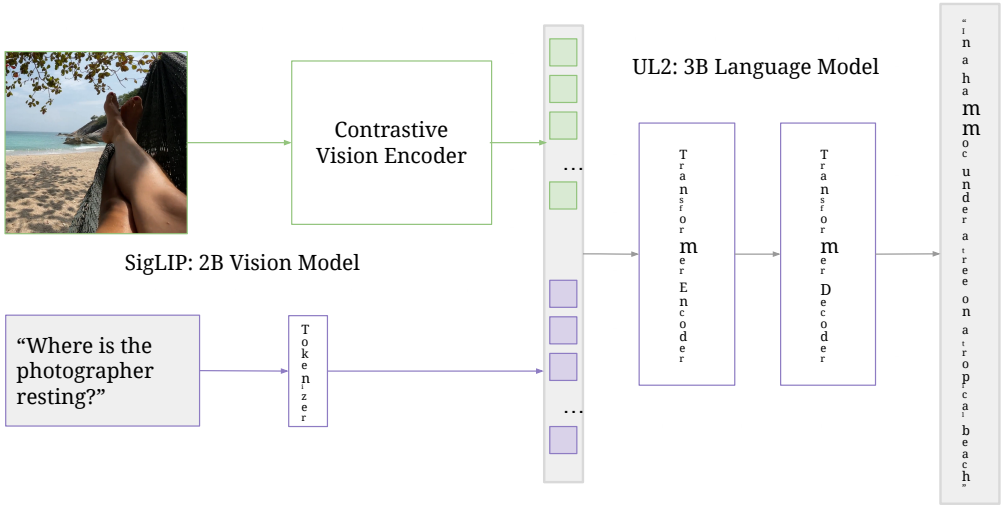


图 1：PaLI-3（5B）模型概览：图像由经过对比预训练的 2B SigLIP 视觉模型分别编码为视觉标记。这些视觉标记连同查询一起传入一个 3B 编码器-解码器 UL2 Transformer，从而生成所需答案。在这种设置下，与先前 PaLI 模型中使用的分类预训练模型相比，经过对比预训练的模型能够提供显著更有用的标记。

视觉组件 PaLI-3 的视觉骨干网络使用 SigLIP（Zhai et al., 2023）训练方案，从一个经过对比预训练的 ViT-G/14[2] (Zhai et al., 2022a) 模型（约 20 亿参数）初始化。简而言之，训练一个图像嵌入 ViT-G/14 和一个文本嵌入 Transformer，使其分别对图像和文本进行嵌入，从而让一个使用图像与文本嵌入点积的 sigmoid 交叉熵的二元分类器，能够正确判断相应的图像和文本是否彼此对应。这类似于 CLIP（Radford et al., 2021）和 ALIGN（Jia et al., 2021），但已被证明更高效、更具可扩展性且更鲁棒（Zhai et al., 2023）。这样做是为了预训练 ViT 图像嵌入组件，因此在将 ViT 插入 PaLI 时会丢弃文本嵌入 Transformer。

完整的 PaLI 模型 ViT 图像编码器在池化之前的输出形成视觉 tokens，这些 tokens 经过线性投影后被前置到嵌入的输入文本 tokens 之前。这些 tokens 一起被输入到一个预训练的 30 亿参数 UL2 编码器-解码器语言模型（Tay 等，2023）中，该模型生成文本输出。模型的文本输入通常由一个描述任务类型的提示组成（例如，用于图像描述任务的“*Generate the alt_text in* ⟨lang⟩ *at* ⟨pos⟩”），并编码该任务所需的文本输入（例如，用于 VQA 任务的“*Answer in* ⟨lang⟩*: {question}*”）。

3.2 训练阶段

训练流程与 PaLI 和 PaLI-X 类似，由多个阶段组成：

阶段 0：单模态预训练。图像编码器按照 SigLIP 训练协议（Zhai 等，2023），在来自网络的图像-文本对上进行对比式预训练。这不同于 PaLI 和 PaLI-X，后两者使用的是经过 JFT 分类预训练的编码器。我们采用了类似于 Schuhmann 等（2021）中的基于模型的过滤方法，保留了约 40% 的配对。图像编码器以 224×224 的分辨率进行训练。文本编码器-解码器是一个 3B UL2 模型，按照 Tay 等（2023）描述的去噪器混合流程进行训练。

阶段 1：多模态训练。在此阶段，图像编码器按照前文及图 1 所述与文本编码器-解码器结合。随后，这个组合后的 PaLI 模型在多模态任务和数据混合上进行训练，但会保持图像编码器冻结并使用其原生

[2]为了更好地利用硬件，嵌入维度从1664改为1536。

表 1：在相同的 PaLI 设置下，对比预训练（“SigLIP”）模型与分类预训练（“Classif”）ViT 图像编码器在广泛任务上的性能比较。虽然线性分类少样本探测（第一列）表明 SigLIP 编码器在许多任务上表现更差，但当它们接入 PaLI 并进行迁移时，显示出明显提升。在最复杂且细粒度的图像理解任务上，SigLIP 模型大幅优于 Classif 模型。图像描述生成的数值为 CIDEr 分数，其中 XM3600 第一列显示英语性能，第二列显示其他语言的平均性能。RefCOCO 数值为 mIoU 分数（详见第 4.3 节）。

		Probe	**Captioning**			**VQA**			**RefCOCO**		
		8 tasks	COCO	XM3600		v2	OK	Text	val	+	g
4l/G	Classif	88.1	139.9	94.5	44.7	76.7	57.2	31.9	51.6	43.5	43.4
	SigLIP	**-2.5**	**+0.4**	**+1.6**	**+0.7**	**+0.8**	**+1.4**	**+18.7**	**+15.1**	**+19.1**	**+17.7**
6l/L	Classif	86.2	132.6	93.0	42.3	73.7	55.6	24.9	46.9	38.8	38.8
	SigLIP	**-2.8**	**+3.2**	**+1.4**	**+1.4**	**+1.9**	**+1.9**	**+16.2**	**+17.4**	**+20.9**	**+20.1**
6l/B	Classif	83.7	127.7	91.7	40.7	72.3	54.7	22.5	46.3	38.1	38.4
	SigLIP	**-2.6**	**+3.6**	**-2.0**	**-0.2**	**+1.4**	**+0.9**	**+13.3**	**+16.8**	**+19.6**	**+19.3**

(224×224) 分辨率。主要混合组件同样源自 WebLI 数据集，通过对文本质量进行启发式过滤，并使用 SplitCap 训练目标（Chen et al., 2023b）。继承自（Chen et al., 2023b）的其他组成部分包括 CC3M-35L 和 WebLI OCR 上的多语言图像描述生成、使用 VQ^2A-CC3M-35L 的跨语言 VQA 和 VQG、目标感知 VQA，以及目标检测。值得注意的是，我们没有纳入源自视频的任务或数据（这在 PaLI-X 中已完成），但得益于其强大的图像编码器，PaLI-3 在这些基准上仍保持了有竞争力的性能。不过，我们通过用包含密集文本的 PDF 文档以及被描述为海报或文档的网页图像来丰富 WebLI，进一步提升了文档和文本理解能力，覆盖超过 100 种语言。

阶段 2：提高分辨率。高分辨率输入是一种被广泛接受的提升性能的方法，这既是因为它能让图像中的更多细节变得可感知，也是因为通过增加序列长度提升了模型能力。我们通过使用逐步提高分辨率的短课程对整个模型进行微调（解冻图像编码器），来提高 PaLI-3 的分辨率，并在 812×812 和 1064×1064 分辨率下保留检查点。数据混合侧重于涉及视觉情境文本和目标检测的部分。

任务专门化（迁移）。最后，对于每个单独任务（基准），我们按照相应章节中的描述，在该任务的训练数据上对冻结了 ViT 图像编码器的 PaLI-3 模型进行微调。对于大多数任务，我们微调 812×812 分辨率的检查点，但对于两个文档理解任务，我们将分辨率提高到 1064×1064。

4 实验

4.1 分类预训练还是对比式预训练的 ViT?

我们首先在 PaLI 框架内对不同的 ViT 模型进行受控比较。我们考虑两种类型的 ViT 模型：在 JFT 数据集上进行分类预训练（“Classif”）的模型，以及在 WebLI 数据集上进行对比预训练（“SigLIP”）的模型。为节省计算量，我们使用固定的 224×224 分辨率（即仅包含阶段 1）进行这些实验。我们还将阶段 1 缩短为本文其余部分所用完整 PaLI-3 训练计划的 20%。

表 1 的结果总体上呈现出清晰的图景：尽管 SigLIP 模型的少样本线性分类（Doso- vitskiy 等，2021）表现落后，但当用于 PaLI-3 时，SigLIP 模型在图像描述和问答等“较简单”任务上带来了中等幅度的提升，并在 TextVQA 和 RefCOCO 等更“复杂”的场景文本与空间理解任务上带来了显著提升。

表 2：在更侧重于理解视觉场景中文本的基准上的结果。TextCaps、TextVQA、STVQA、InfographicVQA 和 DocVQA 均使用相应的官方评测服务器进行评估。标记为“†”的方法在目标基准上微调之前，使用了与目标基准类似的额外 VQA 数据进行训练。对于 ChartQA，我们通过在不使用思维链或类似提示技术的情况下进行微调，与类似设置进行比较。SOTA 模型包括 (a) Chen 等人（2023a），(b) Powalski 等人（2021），(c) Peng 等人（2022）。

Model	Text Caps	Text VQA	ST VQA	OCR VQA	Info VQA	Doc VQA	AI2D	Chart QA	Screen2 Words	Widget Cap	Avg. of first 8
***with** OCR pipeline input*											
SOTA	163.7 (a)	**80.78** (a)	84.5 (a)	77.3 (a)	61.2 (b)†	88.4 (c)†	**81.4** (a)	**72.3** (a)	-	-	88.7
PaLI-3	**164.3**	**80.78**	**85.7**	**77.8**	**62.4**	**88.6**	75.2	69.5	-	-	88.0 (-0.7)
***without** OCR pipeline input*											
SOTA	147.0 (a)	71.44 (a)	79.9 (a)	75.0 (a)	49.2 (a)	80.0 (a)	**81.2** (a)	**70.9** (a)	127.9 (a)	153.0 (a)	81.8
PaLI-3	**158.8**	**79.51**	**84.1**	**76.7**	**57.8**	**87.6**	75.2	70.0	**130.7**	**159.8**	86.2 (+4.4)

变体。这促使我们不再采用经过分类预训练的图像编码器，转而改用经过 sigmoid 对比式预训练的图像编码器来构建 PaLI-3。

4.2 视觉情境下的文本理解

我们在视觉情境文本理解任务上评估 PaLI-3：TextCaps（Sidorov 等，2020）、TextVQA（Singh 等，2019）、STVQA（Biten 等，2019）、OCRVQA（Mishra 等，2019）、Info- graphicVQA（Mathew 等，2022）、DocVQA（Mathew 等，2021）、ChartQA（Masry 等，2022）、Scree2Words（Wang 等，2021a）和 WidgetCap（Li 等，2020）。这些数据集中的图像涵盖了广泛的领域，例如自然图像、插图、文档和用户界面。

对于 InfographicVQA 和 DocVQA 基准，我们微调 1064×1064 分辨率模型，其他所有基准均使用 812×812 分辨率模型。我们报告每个基准的标准指标，即：所有图像描述基准使用 CIDEr 分数；VQAv2、OKVQA 和 TextVQA 使用 VQA 准确率；ST-VQA、DocVQA 和 InfographicsVQA 使用平均归一化 Levenshtein 相似度（ANLS）；TallyQA、OCR-VQA 和 AI2D 使用精确匹配（EM）；ChartQA 使用宽松准确率（RA）。对于视觉场景中的文本理解，通常会利用外部 OCR 系统提供图像的 OCR 标注，作为模型的额外输入以提升性能。这里我们遵循（Chen et al., 2023a），并报告在有无 OCR 输入两种情况下微调 PaLI-3 的结果。OCR 标注使用与训练集相同的服务获得。如表 2 所示，无论是否使用外部 OCR 输入，PaLI-3 在绝大多数图像描述和 VQA 基准上都达到了 SOTA 性能。例外是 AI2D 和 ChartQA，它们分别要求模型不仅理解图表和图形，还需要具备强大的推理能力。在这两个基准上，PaLI-3 略逊于 PaLI-X（Chen et al., 2023a），这可能是因为后者显著更大的 32B LLM 更擅长推理。

对表 2 中在所有设置下都有结果的 8 个基准进行平均后，PaLI-3 在使用外部 OCR 系统的设置下，仅比所有 SOTA 方法的综合结果低 0.7 分。然而，在没有此类外部系统的设置下，PaLI-3 相比所有 SOTA 方法的综合结果具有显著的 4.4 分优势。对于 TextCaps、TextVQA、InfographicVQA 和 DocVQA，这一优势达到 8 分或更多。最后，我们可以看到，不使用任何外部 OCR 系统的 PaLI-3 仅比依赖外部 OCR 系统低 1.8 分，这表明图像编码器学习到了强大的内在 OCR 能力。

4.3 指代表达式分割

我们扩展了 PaLI-3，使其具备通过类似语言的输出预测分割掩码的能力。为此，我们使用了 Ning 等人（2023）的向量量化变分自编码器（VQ-VAE）。该 VQ-VAE 经过训练，用于学习一个包含 128 个掩码词元的离散码本。其编码器可以

表 3：PaLI 在 RefCOCO（Yu 等，2016）变体上的指代表达式分割结果。所有结果均为验证集上的 mIoU。

Model	RefCOCO	RefCOCO+	G-Ref
RefTr (Li & Sigal, 2021)	74.34	66.75	66.63
PolyFormer (Liu et al., 2023)	76.94	72.15	71.15
PaLI-3 (Ours)	**77.33**	**73.53**	**72.72**

将一个 64 × 64 像素的分割掩码标记化为 16 个掩码标记，其解码器可以将其转换回来。我们训练 PaLI-3 来预测单个分割掩码。首先，PaLI-3 以文本形式输出 4 个坐标，表示一个边界框。随后输出 16 个掩码标记，表示边界框内的掩码。

我们在 RefCOCO、RefCOCO+ 和 RefCOCOg（Yu 等，2016）[3] 的组合训练集上，以 812×812 分辨率对 PaLI-3 进行微调。每个训练样本由一个指代表达（例如“左边那只棕色的大狗”）和一个带分割掩码的框组成。我们使用提示“*detect: the large brown dog on the left* ⟨extra_id_0⟩”来提示 PaLI，目标是类似“*348 543 684 664* ⟨mask_token_81⟩ . . . ⟨mask_token_10⟩”的序列。目标序列包含 16 个介于 0 到 127 之间的掩码标记，这些标记由 VQ-VAE 编码器生成，其输入是裁剪并调整大小到 64 × 64 的分割掩码。

表 1 的结果表明，对于此类定位任务，对比预训练比分类预训练有效得多。表 3 显示，完整的 PaLI-3 模型在指代表达式分割任务上能够略微优于当前最先进水平。

4.4 自然图像理解

在本节中，我们在通用视觉-语言理解任务上评估 PaLI-3，包括面向通用视觉理解的 COCO captions（Karpathy & Fei-Fei, 2015）和 VQAv2（Goyal et al., 2017）、侧重于基于知识的理解的 OKVQA（Marino et al., 2019），以及衡量在文本指导下进行计数表现的 TallyQA（Acharya et al., 2019）。表 4 中给出的各项基准测试结果均使用 812×812 分辨率。与以往工作一样，它们未采用外部 OCR 模块，因为这些基准测试很少涉及图像中的文本。

总体而言，尽管 PaLI-3 的规模明显小于近期的 SOTA 模型，但它在这些基准测试上表现非常强劲。在 COCO 上，PaLI-3 的表现优于除 BEiT-3 以及 17B 和 55B PaLI 之外的所有模型。在 VQAv2 和 TallyQA 上，PaLI-3 超过了除 PaLI-X 之外的所有先前模型，并且在 VQAv2 上的差距不到 1 分。对于通常受益于大型语言组件的知识密集型 OKVQA 任务，PaLI-3 仅落后于 PaLM-E（562B）和 PaLI-X（55B），但仍优于 32-shot Flamingo（80B）模型。

4.5 视频字幕生成与问答

我们在 4 个视频字幕生成基准上微调并评估 PaLI-3 模型：MSR-VTT（Xu 等，2016）、VATEX（Wang 等，2019）、ActivityNet Captions（Krishna 等，2017）以及 Spoken Moments in Time（Monfort 等，2021）。我们也在 3 个视频问答基准上进行了同样的操作：NExT-QA（Xiao 等，2021）、MSR-VTT-QA（Xu 等，2017）以及 ActivityNet-QA（Yu 等，2019）。附录 A 中提供了每个基准及其用法的简要说明。

沿用 PaLI-X（Chen et al., 2023a）的设置，我们使用 Stage 1 检查点，以 224×224 分辨率分别针对每个任务对模型进行微调。对于每个基准，我们以固定的时间步幅最多采样 16 帧。每一帧都由 ViT 图像编码器独立处理，得到的视觉 token 被简单拼接，最多可产生 4096 个视觉 token。与 PaLI-X 设置的一个关键区别在于，PaLI-3 的预训练中没有视频数据，这意味着 PaLI-3 在预训练期间从未见过多帧输入。

[3] 我们从PaLI和VQ-VAE的训练集中移除了所有验证图像和测试图像。

表 4：在 COCO Captions（Karpathy 划分）、VQAv2、OKVQA 和 TallyQA 上的结果。（*Flamingo 报告的是 32-shot 结果）。带下划线的数字表示 PaLI-3 仅次于 55B PaLI-X，并且优于列表中的所有其他模型。

	COCO	VQAv2		OKVQA	TallyQA	
Model	Karp.-test	test-dev	test-std	val	Simple	Complex
SimVLM	143.3	80.03	80.34	-	-	-
CoCa (2.1B)	143.6	82.3	82.3	-	-	-
GIT (0.7B)	144.8	78.56	78.81	-	-	-
GIT2 (5.1B)	145.0	81.74	81.92	-	-	-
OFA (0.9B)	145.3	82.0	82.0	-	-	-
Flamingo (80B)	138.1	82.0	82.1	57.8*	-	-
BEiT-3 (1.9B)	147.6	84.2	84.0	-	-	-
PaLM-E (562B)	138.7	80.0	-	**66.1**	-	-
MoVie	-	69.26	-	-	74.9	56.8
PaLI-17B	149.1	84.3	84.3	64.5	81.7	70.9
PaLI-X (55B)	**149.2**	**86.0**	**86.1**	**66.1**	**86.0**	**75.6**
PaLI-3 (5B)	145.9	<u>85.0</u>	<u>85.2</u>	60.1	<u>83.3</u>	70.5

表 5：使用最多 16 帧进行视频字幕生成和视频问答的结果。†GIT2 直接优化 CIDEr 指标。mPLUG-2 为 Xu 等人（2023），PaLI-X 为 Chen 等人（2023a），GIT2 为 Wang 等人（2022a），Flamingo-32 为 Alayrac 等人（2022）的 32-shot 变体。

	MSR-VTT		Activity-Net		VATEX	SMIT	NExT-QA
Method	Caption	QA	Caption	QA	Caption	Caption	QA
Prior SOTA	**80.3** mPLUG-2	48.0 mPLUG-2	**54.9** PaLI-X	49.4 PaLI-X	94.0† GIT2	**43.5** PaLI-X	**38.3** Flamingo-32
PaLI-3	78.3	**49.3**	50.8	**51.2**	66.9	39.6	37.7

尽管未使用视频数据进行预训练，PaLI-3 仍以较小的模型规模取得了出色的视频问答结果：在 MSR-VTT-QA 和 ActivityNet-QA 上达到新的最先进性能，并在 NextQA 上取得具有竞争力的结果。图像和视频问答上的持续提升凸显了采用对比式 ViT 的优势。PaLI-3 还取得了相当不错的视频字幕生成结果，平均仅比 SOTA 低 3 个 CIDEr 分。考虑到模型规模，PaLI-3 在性能和实用性方面似乎都是一个出色的选择。

表 6：对视觉组件进行单独评估（不包含语言模型）。我们报告了在 ImageNet、ImageNet-ReaL 和 ImageNet-V2 上的微调分类准确率；在 XM3600 上跨 36 种语言的平均零样本跨模态检索 recall@1；以及跨 8 个任务的平均 10-shot 线性探针分类准确率。

Model	**Encoder**	**ImageNet (fine-tuning)**				**XM3600 (retrieval)**		**Probe**
		Res.	Val	ReaL	v2	I→T	T→I	8 tasks
PaLI-3	SigLIP ViT-G	518px	89.6	90.9	82.3	56.9	44.0	85.6
PaLI-15B	Classif ViT-G	518px	90.5	90.8	83.3	-	-	88.1
PaLI-17B	Classif ViT-e	644px	90.9	91.1	84.3	36.0	28.5	89.5
PaLI-X	Classif ViT-22B	756px	89.2	91.0	83.7	-	-	89.9

表 7：PaLI-3 在 FairFace（Karkkainen & Joo，2021）上生成的标题的 RAI 统计数据。

	Perceived Gender		Ethnicity			Age Bucket			
	Lowest	Highest	Lowest	Median	Highest	Lowest	Median	Highest	**Overall**
Toxicity	0.02%	0.05%	0.00%	0.00%	0.10%	0.00%	0.00%	0.07%	**0.04%**
Profanity	0.00%	0.00%	0.00%	0.00%	0.00%	0.00%	0.00%	0.00%	**0.00%**
Insult	0.04%	0.10%	0.00%	0.07%	0.14%	0.00%	0.06%	0.17%	**0.07%**
Threat	0.10%	0.12%	0.00%	0.14%	0.20%	0.00%	0.00%	0.21%	**0.11%**
Attack	0.00%	0.00%	0.00%	0.00%	0.00%	0.00%	0.00%	0.00%	**0.00%**

表 8：PaLI-3 在 MIAP（Schumann 等，2021）上生成的说明文字中的 RAI 分数统计。

	Perceived Gender		Age Bucket			Skin Tone			
	Lowest	Highest	Lowest	Median	Highest	Lowest	Median	Highest	**Overall**
Toxicity	0.05%	0.10%	0.05%	0.24%	0.48%	0.00%	0.00%	0.26%	**0.07%**
Profanity	0.10%	0.10%	0.00%	0.12%	0.24%	0.00%	0.00%	0.10%	**0.10%**
Insult	0.10%	0.14%	0.00%	0.13%	0.17%	0.00%	0.00%	0.38%	**0.13%**
Threat	0.34%	0.80%	0.30%	0.54%	1.68%	0.00%	0.59%	0.94%	**0.65%**
Identity Attack	0.00%	0.00%	0.00%	0.00%	0.00%	0.00%	0.00%	0.00%	**0.00%**

4.6 直接图像编码器评估

在这里，我们旨在直接评估学习到的图像编码器（ViT-G 模型），而不包括外围的语言模型，也就是说不是完整的 PaLI-3。所有结果汇总在表 6 中。

首先，我们使用标准的 ImageNet（Russakovsky 等，2014）基准及其两个最受欢迎的变体（Beyer 等，2020；Recht 等，2019）来测试图像分类能力。我们在 ImageNet 上对阶段 0 的单模态图像编码器进行微调，并将其与先前 PaLI 模型中使用的分类预训练 ViT 的微调结果进行比较。主要比较对象是 Zhai 等（2022a）提出的分类（Classif）预训练 ViT-G/14 模型。SigLIP 在 top-1 和 v2 准确率方面略微落后，但在 ReaL 准确率（Beyer 等，2020）方面持平；该指标可避免衡量对 ImageNet 特有性质的“过拟合”。

其次，我们报告了在 Crossmodal-3600 基准（Thapliyal 等，2022）上的多语言图文检索结果。由于分类预训练的图像编码器不具备这种能力，我们在多语言 WebLI 数据集上为其对文本编码器进行 LiT 微调（Zhai 等，2022b）。我们还在完全相同的设置下为 SigLIP 图像编码器对一个新的文本编码器进行 LiT 微调，以消除比较中的任何混杂因素。SigLIP ViT-G 模型明显优于经过分类预训练且规模更大的 ViT-e 模型。

最后，我们按照 Dosovitskiy 等人（2021）；Zhai 等人（2022a）的方法，在少样本设置下，对表征进行线性探测，涵盖 Zhai 等人（2022a）中也使用的 8 个不同分类任务，并报告平均性能。在这里，我们看到 SigLIP 表现落后，这可能是因为其表征并未以支持线性可分性的方式进行预训练，正如 Tschannen 等人（2023）最近所揭示的那样。

综上所述，这些结果勾勒出一幅清晰的图景：在标准分类任务上评估时，最好且最大的经过分类预训练的图像编码器似乎（略微）更好；然而，在视觉-语言任务上，它们明显不如经过 SigLIP 预训练的图像编码器。

5 模型公平性、偏见和其他潜在问题

我们遵循 Chen 等人（2023a）的评估协议来评估模型公平性、偏见以及其他潜在问题。首先，我们使用 MIAP（Schumann 等人，2021）和 FairFace（Karkkainen & Joo，2021）数据集生成字幕，并使用 Perspective API（Lees 等人，2022）（阈值 > 0.8）来衡量毒性、亵渎性语言以及其他潜在问题。表 7（FairFace）和表 8（MIAP）总结了结果。包含 < 20 个示例的切片会从分析中剔除。总体而言，我们观察到在所有切片中，毒性和亵渎性语言等问题的水平都较低。结果与 PaLI-X（Chen 等人，2023a）中的结果相当。

表 9：在 MIAP 数据集（Schumann 等，2021）中图像恰好包含单个个体的子集上，PaLI-3 对“person”的检测错误率。PaLI-3 在所有子群体中均保持较低的错误率。肤色遵循 Monk 肤色量表（Monk，2019）。方括号内的数字对应于每个分桶的大小。

Skin Tone	**1** [2]	**2** [871]	**3** [3008]	**4** [522]	**5** [184]	**6** [85]	**7** [54]	**8** [49]	**9** [6]	**10** [1]
	0.00%	0.00%	0.17%	0.39%	0.00%	0.00%	0.00%	0.00%	0.00%	0.00%
Gender	**Predominantly Feminine** [2437]					**Predominantly Masculine** [3544]				
	0.41%					1.78%				
Age Bucket	**0-2 yrs** [17]		**3-19 yrs** [568]		**20-59 yrs** [4925]		**> 60 yrs** [247]			
	0.00%		0.18%		1.30%		0.82%			

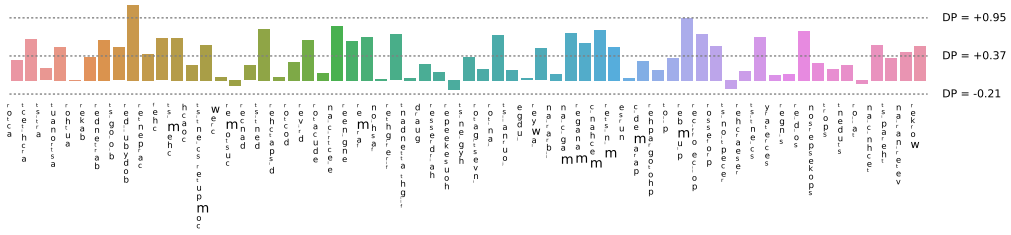


图 2：PaLI-3 对 CelebA 图像输出中的人口统计均等性（DP）水平，比较女性与男性之间的平均对数困惑度。接近零的值表示不存在偏差。虚线对应于 μ 和 $\mu \pm 2\sigma$。除“健美运动员”和“水管工”外，所有职业的 DP 都落在 95% 置信区间内；模型往往将这两个职业强烈地与男性相关联。

其次，我们考察模型本身的人口统计均等性（Dwork et al., 2012）水平。按照（Chen et al., 2023a）的方法，我们将 CelebA 数据集（Liu et al., 2015）中的一张图像输入 PaLI-3，并将所选职业作为前缀，记录模型生成结果的平均对数困惑度分数。人口统计均等性是人口统计群体内平均对数困惑度之间的差异。图 2 总结了结果：与 PaLI-X 类似，在大多数职业中，PaLI-3 倾向于给女性分配比男性*higher*的对数困惑度分数，平均差异为 $\mu = 0.37$。然而，与 PaLI-X 相比，PaLI-3 中落在区间 $\mu \pm 2\sigma$ 之外的职业更少。

第三，我们再次遵循（Chen et al., 2023a），使用 MIAP 数据集比较所有子群体在检测任务上的表现。对于只包含一个人的图像，我们向 PaLI-3 提问：“这张图像中有人吗？”并评估其回答的准确性。表 9 总结了结果。所有子群体的错误率（假阴性）都非常低。

关于 WebLI 数据集本身的分析，例如感知性别与职业之间的相关性，参见 Chen 等人（2023a）。

局限性。本工作的局限性与文献中已提出的局限性非常相似。我们参考（Chen et al., 2023a），其中提出了所有适用于我们工作的局限性。

6 结论

在本文中，我们更深入地研究了大型 VLM 中图像编码器的预训练，具体来说是 PaLI 类型的模型。通过对该部分进行受控实验，我们首次明确比较了分类预训练和图像-文本（对比）预训练这两大阵营，发现后者能够带来更好且更高效的 VLM，尤其是在定位和文本理解任务上。这只是 VLM 的 *one small aspect*，我们希望这项研究及其结果能够推动对训练 VLM 的 *many other aspects* 进行进一步的详细研究。

7 致谢

我们感谢 Bo Pang、Michael Tschannen、Soravit Changpinyo、AJ Piergiovanni、Marvin Ritter、Yi Tay、Paulina Pietrzyk、Matthias Minderer、André Susano Pinto、Mojtaba Seyedhosseini、Anelia Angelova、Neil Houlsby、Yiming Gu、Daniel Hernandez Diaz、Chun-Liang Li、Guo long Su、Hao Zhang、Chenxia Wu、Rui Lin、Ting Yu、Weina Ge、Shengyang Dai、Tania Bedrax-Weiss、Rob Fergus、Jeremiah Harmsen 和 Joelle Barral 所提供的有益讨论、反馈和支持。我们感谢 Google Research 和 Google DeepMind 团队为开展研究提供了富有成效的环境。

参考文献

Manoj Acharya、Kushal Kafle 和 Christopher Kanan。TallyQA：回答复杂计数问题。载于 *The Thirty-Third AAAI Conference on Artificial Intelligence, AAAI 2019, The Thirty-First Innovative Applications of Artificial Intelligence Conference, IAAI 2019, The Ninth AAAI Symposium on Educational Advances in Artificial Intelligence, EAAI 2019, Honolulu, Hawaii, USA, January 27 - February 1, 2019*，第 8076–8084 页。AAAI Press，2019。doi: 10.1609/aaai. v33i01.33018076。URL https://doi.org/10.1609/aaai.v33i01.33018076。

Jean-Baptiste Alayrac、Jeff Donahue、Pauline Luc、Antoine Miech、Iain Barr、Yana Hasson、Karel Lenc、Arthur Mensch、Katie Millican、Malcolm Reynolds 等。Flamingo：用于少样本学习的视觉语言模型。*arXiv preprint arXiv:2204.14198*，2022。

Lucas Beyer、Olivier J Hénaff、Alexander Kolesnikov、Xiaohua Zhai 和 Aäron van den Oord。我们已经完成 ImageNet 了吗？*arXiv preprint arXiv:2006.07159*，2020。

Ali Furkan Biten、Ruben Tito、Andres Mafla、Lluis Gomez、Marçal Rusinol、Ernest Valveny、CV Jawahar 和 Dimosthenis Karatzas。场景文本视觉问答。载于 *Proceedings of the IEEE/CVF international conference on computer vision*，第 4291–4301 页，2019 年。

Xi Chen、Josip Djolonga、Piotr Padlewski、Basil Mustafa、Soravit Changpinyo、Jialin Wu、Carlos Riquelme Ruiz、Sebastian Goodman、Xiao Wang、Yi Tay、Siamak Shakeri、Mostafa Dehghani、Daniel Salz、Mario Lucic、Michael Tschannen、Arsha Nagrani、Hexiang Hu、Mandar Joshi、Bo Pang、Ceslee Montgomery、Paulina Pietrzyk、Marvin Ritter、AJ Piergiovanni、Matthias Minderer、Filip Pavetic、Austin Waters、Gang Li、Ibrahim Alabdulmohsin、Lucas Beyer、Julien Amelot、Kenton Lee、Andreas Peter Steiner、Yang Li、Daniel Keysers、Anurag Arnab、Yuanzhong Xu、Keran Rong、Alexander Kolesnikov、Mojtaba Seyedhosseini、Anelia Angelova、Xiaohua Zhai、Neil Houlsby 和 Radu Soricut。Pali-x：关于扩展多语言视觉与语言模型，2023a。

Xi Chen、Xiao Wang、Soravit Changpinyo、AJ Piergiovanni、Piotr Padlewski、Daniel Salz、Sebastian Alexander Goodman、Adam Grycner、Basil Mustafa、Lucas Beyer、Alexander Kolesnikov、Joan Puigcerver、Nan Ding、Keran Rong、Hassan Akbari、Gaurav Mishra、Linting Xue、Ashish Thapliyal、James Bradbury、Weicheng Kuo、Mojtaba Seyedhosseini、Chao Jia、Burcu Karagol Ayan、Carlos Riquelme、Andreas Steiner、Anelia Angelova、Xiaohua Zhai、Neil Houlsby 和 Radu Soricut。PaLI：一种联合扩展的多语言语言-图像模型。收录于 *ICLR*，2023b。

Zuozhuo Dai、Fangtao Shao、Qingkun Su、Zilong Dong 和 Siyu Zhu。使用冻结图像编码器的细粒度文本-视频检索。*CoRR*，abs/2307.09972，2023。doi: 10.48550/arXiv.2307. 09972。URL https://doi.org/10.48550/arXiv.2307.09972.

Mostafa Dehghani、Josip Djolonga、Basil Mustafa、Piotr Padlewski、Jonathan Heek、Justin Gilmer、Andreas Steiner、Mathilde Caron、Robert Geirhos、Ibrahim Alabdulmohsin、Rodolphe Jenatton、Lucas Beyer、Michael Tschannen、Anurag Arnab、Xiao Wang、Carlos Riquelme、Matthias Min- derer、Joan Puigcerver、Utku Evci、Manoj Kumar、Sjoerd van Steenkiste、Gamaleldin F. Elsayed、Aravindh Mahendran、Fisher Yu、Avital Oliver、Fantine Huot、Jasmijn Bastings、Mark Patrick Collier、Alexey Gritsenko、Vighnesh Birodkar、Cristina Vasconcelos、Yi Tay、Thomas Mensink、Alexander Kolesnikov、Filip Pavetić、Dustin Tran、Thomas Kipf、Mario Lučić、Xiaohua Zhai、Daniel Keysers、Jeremiah Harmsen 和 Neil Houlsby。将视觉 Transformer 扩展到 220 亿参数，2023。URL https://arxiv.org/abs/2302.05442。

Alexey Dosovitskiy、Lucas Beyer、Alexander Kolesnikov、Dirk Weissenborn、Xiaohua Zhai、Thomas Unterthiner、Mostafa Dehghani、Matthias Minderer、Georg Heigold、Sylvain Gelly、Jakob Uszkoreit 和 Neil Houlsby。一张图像胜过 16x16 个词：用于大规模图像识别的 Transformer。载于 *9th International Conference on Learning Representations, ICLR 2021, Virtual Event, Austria, May 3-7, 2021*。OpenReview.net，2021。URL https://openreview.net/forum? id=YicbFdNTTy。

Danny Driess、Fei Xia、Mehdi S. M. Sajjadi、Corey Lynch、Aakanksha Chowdhery、Brian Ichter、Ayzaan Wahid、Jonathan Tompson、Quan Vuong、Tianhe Yu、Wenlong Huang、Yevgen Chebotar、Pierre Sermanet、Daniel Duckworth、Sergey Levine、Vincent Vanhoucke、Karol Hausman、Marc Toussaint、Klaus Greff、Andy Zeng、Igor Mordatch 和 Pete Florence。Palm-e：一种具身多模态语言模型。收录于 Andreas Krause、Emma Brunskill、Kyunghyun Cho、Barbara Engelhardt、Sivan Sabato 和 Jonathan Scarlett（编），*International Conference on Machine Learning, ICML 2023, 23-29 July 2023, Honolulu, Hawaii, USA*，*Proceedings of Machine Learning Research* 第 202 卷，第 8469–8488 页。PMLR，2023。URL https://proceedings. mlr.press/v202/driess23a.html.

Cynthia Dwork、Moritz Hardt、Toniann Pitassi、Omer Reingold 和 Richard S. Zemel。通过感知实现公平性。载于 Shafi Goldwasser（编），*Innovations in Theoretical Computer Science 2012, Cambridge, MA, USA, January 8-10, 2012*，第 214–226 页。ACM，2012。doi: 10.1145/ 2090236.2090255。URL https://doi.org/10.1145/2090236.2090255。

Yash Goyal、Tejas Khot、Douglas Summers-Stay、Dhruv Batra 和 Devi Parikh。让 VQA 中的 V 发挥作用：提升图像理解在视觉问答中的作用。载于 *Proceedings of the IEEE conference on computer vision and pattern recognition*，第 6904–6913 页，2017 年。

Chao Jia, Yinfei Yang, Ye Xia, Yi-Ting Chen, Zarana Parekh, Hieu Pham, Quoc V. Le, Yun-Hsuan Sung, Zhen Li, and Tom Duerig. 利用噪声文本监督扩展视觉和视觉-语言表征学习。载于 Marina Meila and Tong Zhang（编），*Proceedings of the 38th International Conference on Machine Learning, ICML 2021, 18-24 July 2021, Virtual Event*，*Proceedings of Machine Learning Research* 第 139 卷，第 4904–4916 页。PMLR，2021。URL http://proceedings.mlr.press/v139/jia21b.html.

Kimmo Karkkainen 和 Jungseock Joo。Fairface：用于偏差测量与缓解的平衡种族、性别和年龄的人脸属性数据集。载于 *Proceedings of the IEEE/CVF Winter Conference on Applications of Computer Vision*，第 1548–1558 页，2021 年。

Andrej Karpathy 和 Li Fei-Fei。用于生成图像描述的深度视觉-语义对齐。发表于 *CVPR*，2015。

Alexander Kolesnikov、Lucas Beyer、Xiaohua Zhai、Joan Puigcerver、Jessica Yung、Sylvain Gelly 和 Neil Houlsby。大迁移（bit）：通用视觉表征学习。载于 Andrea Vedaldi、Horst Bischof、Thomas Brox 和 Jan-Michael Frahm（主编），*Computer Vision - ECCV 2020 - 16th European Conference, Glasgow, UK, August 23-28, 2020, Proceedings, Part V*，*Lecture Notes in Computer Science* 第 12350 卷，第 491–507 页。Springer，2020。doi: 10.1007/ 978-3-030-58558-7_29。URL https://doi.org/10.1007/978-3-030-58558-7_ 29.

Ranjay Krishna、Kenji Hata、Frederic Ren、Li Fei-Fei 和 Juan Carlos Niebles。视频中的事件密集描述。载于 *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*，2017。

Kenton Lee、Mandar Joshi、Iulia Turc、Hexiang Hu、Fangyu Liu、Julian Eisenschlos、Urvashi Khan- delwal、Peter Shaw、Ming-Wei Chang 和 Kristina Toutanova。Pix2struct：将截图解析作为视觉语言理解的预训练。*arXiv preprint arXiv:2210.03347*，2022。

Alyssa Lees、Vinh Q Tran、Yi Tay、Jeffrey Sorensen、Jai Gupta、Donald Metzler 和 Lucy Vasser-man。新一代 Perspective API：高效的多语言字符级 Transformer。*arXiv preprint arXiv:2202.11176*，2022。

Junnan Li、Dongxu Li、Silvio Savarese 和 Steven C. H. Hoi。BLIP-2：使用冻结的图像编码器和大型语言模型自举式语言-图像预训练。载于 Andreas Krause、Emma Brunskill、Kyunghyun Cho、Barbara Engelhardt、Sivan Sabato 和 Jonathan Scarlett（编），*International Conference on Machine Learning, ICML 2023, 23-29 July 2023, Honolulu, Hawaii, USA*，*Proceedings of Machine Learning Research* 第 202 卷，页 19730–19742。PMLR，2023。URL https://proceedings.mlr.press/v202/li23q.html。Muchen Li 和 Leonid Sigal。Referring transformer：一种用于多任务视觉定位的一步式方法。载于 Marc'Aurelio Ranzato、Alina Beygelzimer、Yann N. Dauphin、Percy Liang 和 Jennifer Wortman Vaughan（编），*Advances in Neural Information Processing Systems 34: Annual Conference on Neural Information Processing Systems 2021, NeurIPS 2021, December 6-14, 2021, virtual*，页 19652–19664，2021。URL https://proceedings.neurips.cc/ paper/2021/hash/a376802c0811f1b9088828288eb0d3f0-Abstract.html。Yang Li、Gang Li、Luheng He、Jingjie Zheng、Hong Li 和 Zhiwei Guan。Widget captioning：为移动用户界面元素生成自然语言描述。载于 *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP)*，页 5495–5510，在线，2020 年 11 月。计算语言学协会。doi：10.18653/v1/ 2020.emnlp-main.443。URL https://aclanthology.org/2020.emnlp-main.443。Jiang Liu、Hui Ding、Zhaowei Cai、Yuting Zhang、Ravi Kumar Satzoda、Vijay Mahadevan 和 R Manmatha。Polyformer：将指代表达图像分割视为顺序多边形生成。载于 *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*，页 18653–18663，2023。Ziwei Liu、Ping Luo、Xiaogang Wang 和 Xiaoou Tang。野外环境中的深度学习人脸属性。载于 *International Conference on Computer Vision*，2015。Kenneth Marino、Mohammad Rastegari、Ali Farhadi 和 Roozbeh Mottaghi。OK-VQA：一个需要外部知识的视觉问答基准。载于 *Proceedings of the IEEE/cvf conference on computer vision and pattern recognition*，页 3195–3204，2019。Ahmed Masry、Do Long、Jia Qing Tan、Shafiq Joty 和 Enamul Hoque。ChartQA：一个关于图表的、具有视觉和逻辑推理的问题回答基准。载于 *Findings of ACL*，2022。Minesh Mathew、Dimosthenis Karatzas 和 CV Jawahar。Docvqa：用于文档图像 VQA 的数据集。载于 *Proceedings of the IEEE/CVF winter conference on applications of computer vision*，页 2200–2209，2021。Minesh Mathew、Viraj Bagal、Rubèn Tito、Dimosthenis Karatzas、Ernest Valveny 和 CV Jawahar。Infographicvqa。载于 *Proceedings of the IEEE/CVF Winter Conference on Applications of Computer Vision*，页 1697–1706，2022。Anand Mishra、Shashank Shekhar、Ajeet Kumar Singh 和 Anirban Chakraborty。Ocr-vqa：通过读取图像中的文本进行视觉问答。载于 *ICDAR*，2019。Mathew Monfort、Sou Young Jin、Alexander Liu、David Harwath、Rogerio Feris、James Glass 和 Aude Oliva。Spoken moments：从视频描述中学习联合音频-视觉表示。载于 *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*，页 14871–14881，2021。Ellis Monk。Monk 肤色量表，2019。URL https://skintone.google。Jia Ning、Chen Li、Zheng Zhang、Zigang Geng、Qi Dai、Kun He 和 Han Hu。All in tokens：通过软标记统一视觉任务的输出空间。*arXiv preprint arXiv:2301.02229*，2023。Qiming Peng、Yinxu Pan、Wenjin Wang、Bin Luo、Zhenyu Zhang、Zhengjie Huang、Teng Hu、Weichong Yin、Yongfeng Chen、Yin Zhang 等。Ernie-layout：用于视觉丰富文档理解的布局知识增强预训练。*arXiv preprint arXiv:2210.06155*，2022。Rafa Powalski、 ukasz Borchmann、Dawid Jurkiewicz、Tomasz Dwojak、Micha Pietruszka 和 Gabriela Pa ka。借助文本-图像-布局 Transformer 全力推进文档理解。载于 *Document Analysis and Recognition–ICDAR 2021: 16th International Conference, Lausanne, Switzerland, September 5–10, 2021, Proceedings, Part II 16*，页 732–747。Springer，2021。

Alec Radford, Jong Wook Kim, Chris Hallacy, Aditya Ramesh, Gabriel Goh, Sandhini Agarwal, Girish Sastry, Amanda Askell, Pamela Mishkin, Jack Clark, Gretchen Krueger, and Ilya Sutskever. 从自然语言监督中学习可迁移的视觉模型。载于 Marina Meila and Tong Zhang（编），*Proceedings of the 38th International Conference on Machine Learning, ICML 2021, 18-24 July 2021, Virtual Event*，*Proceedings of Machine Learning Research* 第 139 卷，pp. 8748–8763。PMLR，2021。URL http://proceedings.mlr.press/v139/radford21a.html。Benjamin Recht, Rebecca Roelofs, Ludwig Schmidt, and Vaishaal Shankar. ImageNet 分类器能泛化到 ImageNet 吗？载于 *International Conference on Machine Learning*，pp. 5389–5400，2019。Olga Russakovsky, Jia Deng, Hao Su, Jonathan Krause, Sanjeev Satheesh, Sean Ma, Zhiheng Huang, Andrej Karpathy, Aditya Khosla, Michael S. Bernstein, Alexander C. Berg, and Li Fei-Fei. Imagenet 大规模视觉识别挑战赛。*CoRR*，abs/1409.0575，2014。URL http://arxiv.org/abs/1409.0575。Christoph Schuhmann, Richard Vencu, Romain Beaumont, Robert Kaczmarczyk, Clayton Mullis, Aarush Katta, Theo Coombes, Jenia Jitsev, and Aran Komatsuzaki. LAION-400M：开放的经 CLIP 过滤的 4 亿图像-文本对数据集。*CoRR*，abs/2111.02114，2021。URL https://arxiv.org/abs/2111.02114。Candice Schumann, Susanna Ricco, Utsav Prabhu, Vittorio Ferrari, and Caroline Rebecca Pantofaru. 迈向更具包容性的公平性人物标注的一步。载于 *Proceedings of the AAAI/ACM Conference on AI, Ethics, and Society (AIES)*，2021。Oleksii Sidorov, Ronghang Hu, Marcus Rohrbach, and Amanpreet Singh. TextCaps：用于具有阅读理解能力的图像描述的数据集。载于 *European conference on computer vision*，pp. 742–758，2020。Amanpreet Singh, Vivek Natarajan, Meet Shah, Yu Jiang, Xinlei Chen, Dhruv Batra, Devi Parikh, and Marcus Rohrbach. 迈向能够阅读的 VQA 模型。载于 *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*，pp. 8317–8326，2019。Yi Tay, Mostafa Dehghani, Vinh Q. Tran, Xavier Garcia, Jason Wei, Xuezhi Wang, Hyung Won Chung, Siamak Shakeri, Dara Bahri, Tal Schuster, Huaixiu Steven Zheng, Denny Zhou, Neil Houlsby, and Donald Metzler. Ul2：统一语言学习范式，2023。Ashish V. Thapliyal, Jordi Pont-Tuset, Xi Chen, and Radu Soricut. Crossmodal-3600：一个大规模多语言多模态评估数据集。载于 *Conference on Empirical Methods in Natural Language Processing*，2022。Michael Tschannen, Manoj Kumar, Andreas Steiner, Xiaohua Zhai, Neil Houlsby, and Lucas Beyer. 图像描述器也是可扩展的视觉学习器。*CoRR*，abs/2306.07915，2023。doi: 10.48550/arXiv.2306.07915。URL https://doi.org/10.48550/arXiv.2306.07915。Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Lukasz Kaiser, and Illia Polosukhin. 注意力就是你所需要的一切。*CoRR*，abs/1706.03762，2017。URL http://arxiv.org/abs/1706.03762。Bryan Wang, Gang Li, Xin Zhou, Zhourong Chen, Tovi Grossman, and Yang Li. Screen2words：通过多模态学习实现自动移动 UI 摘要。载于 *The 34th Annual ACM Symposium on User Interface Software and Technology*，UIST ’21，pp. 498–510，New York, NY, USA，2021a。Association for Computing Machinery。ISBN 9781450386357。doi: 10.1145/3472749.3474765。URL https://doi.org/10.1145/3472749.3474765。Jianfeng Wang, Zhengyuan Yang, Xiaowei Hu, Linjie Li, Kevin Lin, Zhe Gan, Zicheng Liu, Ce Liu, and Lijuan Wang. Git：用于视觉与语言的生成式图像到文本 Transformer。*arXiv preprint arXiv:2205.14100*，2022a。Wenhui Wang, Hangbo Bao, Li Dong, Johan Bjorck, Zhiliang Peng, Qiang Liu, Kriti Aggarwal, Owais Khan Mohammed, Saksham Singhal, Subhojit Som, and Furu Wei. 将图像视为外语：用于所有视觉和视觉-语言任务的 Beit 预训练。*CoRR*，abs/2208.10442,

2022b。doi: 10.48550/arXiv.2208.10442。URL https://doi.org/10.48550/arXiv. 2208.10442。Xin Wang、Jiawei Wu、Junkun Chen、Lei Li、Yuan-Fang Wang 和 William Yang Wang。Vatex：用于视频与语言研究的大规模、高质量多语言数据集。载于 *Proceedings of the IEEE/CVF International Conference on Computer Vision*，第 4581–4591 页，2019。Zirui Wang、Jiahui Yu、Adams Wei Yu、Zihang Dai、Yulia Tsvetkov 和 Yuan Cao。Simvlm：使用弱监督的简单视觉语言模型预训练。*arXiv preprint arXiv:2108.10904*，2021b。Junbin Xiao、Xindi Shang、Angela Yao 和 Tat-Seng Chua。Next-qa：面向解释时序动作的下一阶段问答。载于 *Proceedings of the IEEE/CVF Conference on Com- puter Vision and Pattern Recognition*，第 9777–9786 页，2021。Dejing Xu、Zhou Zhao、Jun Xiao、Fei Wu、Hanwang Zhang、Xiangnan He 和 Yueting Zhuang。通过在外观和运动上逐步细化注意力进行视频问答。载于 *Proceedings of the 25th ACM international conference on Multimedia*，第 1645–1653 页，2017。Haiyang Xu、Qinghao Ye、Ming Yan、Yaya Shi、Jiabo Ye、Yuanhong Xu、Chenliang Li、Bin Bi、Qi Qian、Wei Wang、Guohai Xu、Ji Zhang、Songfang Huang、Fei Huang 和 Jingren Zhou。mplug-2：跨文本、图像和视频的模块化多模态基础模型。载于 Andreas Krause、Emma Brunskill、Kyunghyun Cho、Barbara Engelhardt、Sivan Sabato 和 Jonathan Scarlett（编），*International Conference on Machine Learning, ICML 2023, 23-29 July 2023, Honolulu, Hawaii, USA*，*Proceedings of Machine Learning Research* 第 202 卷，第 38728–38748 页。PMLR，2023。URL https://proceedings.mlr.press/v202/xu23s.html。Jun Xu、Tao Mei、Ting Yao 和 Yong Rui。Msr-vtt：用于连接视频与语言的大型视频描述数据集。载于 *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*，2016。Jiahui Yu、Zirui Wang、Vijay Vasudevan、Legg Yeung、Mojtaba Seyedhosseini 和 Yonghui Wu。Coca：对比式字幕生成器是图像-文本基础模型。*arXiv preprint arXiv:2205.01917*，2022。Licheng Yu、Patrick Poirson、Shan Yang、Alexander C Berg 和 Tamara L Berg。指代表达中的语境建模。载于 *Computer Vision–ECCV 2016: 14th European Conference, Amsterdam, The Netherlands, October 11-14, 2016, Proceedings, Part II 14*，第 69–85 页。Springer，2016。Zhou Yu、Dejing Xu、Jun Yu、Ting Yu、Zhou Zhao、Yueting Zhuang 和 Dacheng Tao。Activitynet-qa：通过问答理解复杂网络视频的数据集。载于 *Proceedings of the AAAI Conference on Artificial Intelligence*，第 33 卷，第 9127–9134 页，2019。Xiaohua Zhai、Alexander Kolesnikov、Neil Houlsby 和 Lucas Beyer。扩展视觉 Transformer。载于 *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*，第 12104–12113 页，2022a。Xiaohua Zhai、Xiao Wang、Basil Mustafa、Andreas Steiner、Daniel Keysers、Alexander Kolesnikov 和 Lucas Beyer。Lit：通过锁定图像文本调优实现零样本迁移。载于 *IEEE/CVF Conference on Computer Vision and Pattern Recognition, CVPR 2022, New Orleans, LA, USA, June 18-24, 2022*，第 18102–18112 页。IEEE，2022b。doi: 10.1109/CVPR52688.2022.01759。URL https://doi.org/10.1109/CVPR52688.2022.01759。Xiaohua Zhai、Basil Mustafa、Alexander Kolesnikov 和 Lucas Beyer。用于语言图像预训练的 Sigmoid 损失。载于 *International Conference on Computer Vision*，2023。Zijia Zhao、Longteng Guo、Tongtian Yue、Sihan Chen、Shuai Shao、Xinxin Zhu、Zehuan Yuan 和 Jing Liu。Chatbridge：以大型语言模型作为语言催化剂来桥接模态。*CoRR*，abs/2305.16103，2023。doi: 10.48550/arXiv.2305.16103。URL https://doi.org/ 10.48550/arXiv.2305.16103。

A 附加结果：视频字幕生成和问答

A.1 数据集与基准

由于在实验时新收集数据时，基准测试中的并非所有视频都可在线获取，因此在某些情况下，有效视频数量少于公开的官方划分数量。表 10 报告了我们在训练和评估中使用的子集的详细数量。我们遵循与 PaLI-X（Chen et al., 2023a）相同的实验设置，包括数据集划分配置和评估指标。更多与数据相关的细节请参阅 PaLI-X（Chen et al., 2023a）。

		MSR-VTT	VATEX	ANet-Cap	SMIT	M-V-QA	. ANet-QA	NExT-QA
Original size	valid.	497	3000	17505	14604	12278	18000	5343
	test	2990	6000	17031	3513	72821	8000	9178
Dataset size	valid.	325	2646	14566	8096	8160	10000	5343
	test	2135	5242	14197	3513	52623	7040	9178
% Remaining	valid.	65.39	88.20	83.21	100.00	66.46	-	100.00
	test	71.40	87.37	83.36	100.00	72.26	88.00	100.00

表10：由于我们新近收集了这些数据集，实际训练数据量小于公开基准，使任务更具挑战性。除 NextQA 和 SMIT 外，训练和评估中均有超过 10% 的视频缺失。

B A 附加结果：CROSSMODAL-3600 检索 评估

本节中，我们展示了在 Crossmodal-3600（Thapliyal 等，2022）上零样本图文检索结果（recall@1）的更多结果。SigLIP ViT-G 和 Classif ViT-e 在 36 种语言上的详细结果见图 3、图 4 和表 11。

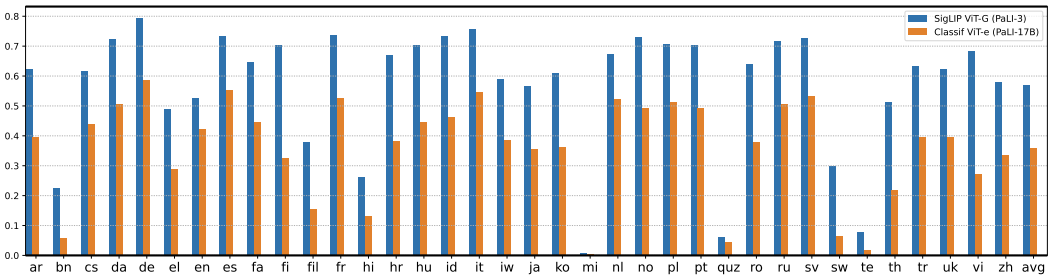


图 3：SigLIP ViT-G 和 Classif ViT-e 在 Crossmodal-3600 上的图像到文本零样本检索 recall@1。

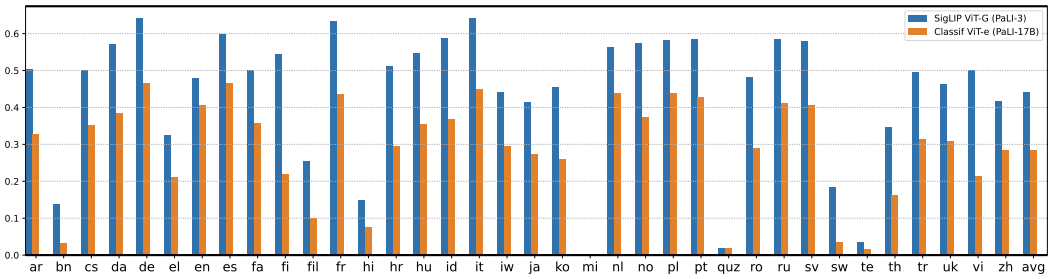


图 4：SigLIP ViT-G 和 Classif ViT-e 在 crossmodal-3600 上的文本到图像零样本检索召回率@1。

Language	Image-to-text		Text-to-image	
	SigLIP ViT-G	Classif ViT-e	SigLIP ViT-G	Classif ViT-e
ar	62.22	39.69	50.33	32.60
bn	22.67	5.67	13.61	3.31
cs	61.69	44.03	50.10	35.24
da	72.47	50.75	57.16	38.48
de	79.28	58.53	64.20	46.50
el	49.11	29.03	32.36	20.92
en	52.64	42.11	47.89	40.63
es	73.31	55.22	59.77	46.55
fa	64.56	44.50	50.09	35.58
fi	70.39	32.64	54.34	21.80
fil	37.89	15.53	25.40	10.04
fr	73.81	52.61	63.28	43.47
hi	26.22	13.14	14.94	7.42
hr	66.89	38.31	51.03	29.55
hu	70.22	44.67	54.63	35.49
id	73.53	46.33	58.62	36.75
it	75.56	54.53	64.14	44.76
iw	59.14	38.67	44.10	29.39
ja	56.69	35.47	41.31	27.24
ko	61.03	36.11	45.50	25.95
mi	0.64	0.33	0.30	0.22
nl	67.25	52.14	56.23	43.79
no	73.03	49.17	57.40	37.35
pl	70.69	51.42	58.24	43.72
pt	70.22	49.19	58.47	42.73
quz	6.28	4.31	1.89	1.90
ro	63.92	37.75	48.20	28.82
ru	71.69	50.64	58.51	41.11
sv	72.69	53.22	57.76	40.66
sw	29.86	6.42	18.31	3.41
te	7.81	1.92	3.39	1.42
th	51.14	22.00	34.65	16.06
tr	63.36	39.50	49.41	31.47
uk	62.19	39.53	46.15	30.81
vi	68.50	27.08	50.14	21.28
zh	57.92	33.61	41.51	28.24
avg	56.85	35.99	43.98	28.46

表 11：SigLIP ViT-G（20 亿参数）和 Classif ViT-e（40 亿参数）在 Crossmodal-3600 零样本检索中的 recall@1（%）。SigLIP ViT-G 在所有语言上均显著优于 Classif ViT-e。在文本到图像检索任务中，SigLIP 的平均表现从 28.5% 提升到 44.0%。