3202 yaM 92]VC.sc[1v56581.5032:viXra

PaLI-X：扩展多语言视觉与语言模型

Xi Chen、Josip Djolonga、Piotr Padlewski、Basil Mustafa、Soravit Changpinyo、Jialin Wu、Carlos Riquelme Ruiz、Sebastian Goodman、Xiao Wang、Yi Tay、Siamak Shakeri、Mostafa Dehghani、Daniel Salz、Mario Lucic、Michael Tschannen、Arsha Nagrani、Hexiang Hu、Mandar Joshi、Bo Pang、Ceslee Montgomery、Paulina Pietrzyk、Marvin Ritter、AJ Piergiovanni、Matthias Minderer、Filip Pavetic、Austin Waters、Gang Li、Ibrahim Alabdulmohsin、Lucas Beyer、Julien Amelot、Kenton Lee、Andreas Peter Steiner、Yang Li、Daniel Keysers、Anurag Arnab、Yuanzhong Xu、Keran Rong、Alexander Kolesnikov、Mojtaba Seyedhosseini、Anelia Angelova、Xiaohua Zhai、Neil Houlsby、Radu Soricut

Google 研究 pali-communications@google.com

摘要

我们介绍了 PaLI-X 的训练方案与结果，该模型是一个多语言视觉与语言模型，在组件规模以及训练任务组合的广度上都进行了扩展。我们的模型在各种复杂任务上达到了新的性能水平，包括多种基于图像的图像描述和问答任务、基于图像的文档理解和少样本（上下文内）学习，以及目标检测、视频问答和视频描述。PaLI-X 在所考察的大多数视觉与语言基准（其中 25+ 个）上推进了最先进水平。最后，我们观察到了涌现能力，例如复杂计数和多语言目标检测，这些任务并未明确包含在训练组合中。

1 引言

语言模型扩展的成功 [1, 2, 3, 4] 使得以类似方式扩展视觉-语言（V&L）模型颇具吸引力，并可研究此类模型的改进、能力和涌现特性。受 [5] 中工作的启发，我们提出了 PaLI-X，这是一个多语言视觉与语言模型，具有可复用的扩展组件，由一个预训练的大容量视觉编码器（以 [6] 作为起点）和一个预训练的纯语言编码器-解码器（以 [7] 作为起点）组成，并进一步在视觉与语言数据混合集上，结合自监督和全监督信号进行大规模训练。

从 PaLI [5] 的结果与本文所呈现工作的结合中浮现出的一个清晰模式是，同时扩展 *both* V&L 组件会在广泛任务上带来性能提升。我们通过与 PaLI 所使用的相同基准进行比较（图 1，左）来展示这一点，也通过与用于评估 PaLI-X 新能力的新基准进行比较来展示这一点（例如 ChartQA、AI2D、DocVQA、InfographicVQA，以及视频理解任务）。我们观察到，扩展不仅相较于 PaLI 模型的结果带来了大幅改进，也优于那些专门为解决特定任务而训练的专用大规模模型；这些模型通常借助（往往大得多的）纯文本 LLM [8]。特别是，我们发现，同时提高视觉组件（[9] 更偏向单方面这样做）的有效容量和语言组件的有效容量

Preprint. Under review.

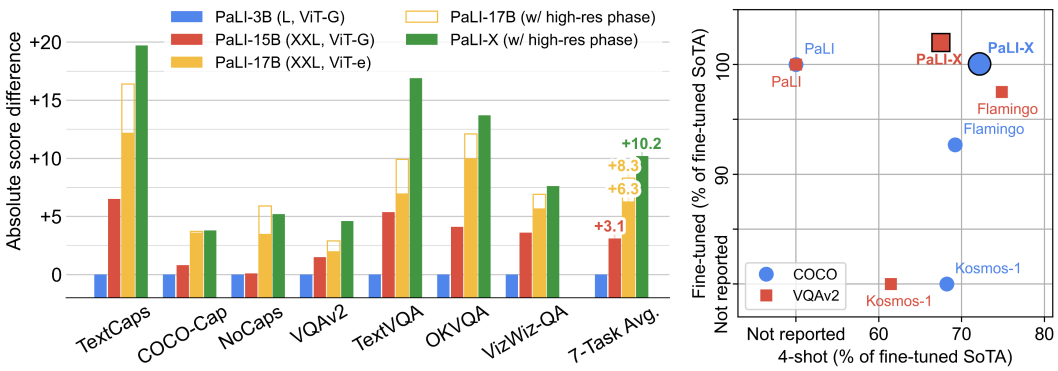


图 1：[左] 在图像字幕生成和 VQA 基准上比较 PaLI-X 与 PaLI。[右] 少样本性能与微调性能之间的帕累托前沿，比较 PaLI-X 与 PaLI [5]、Flamingo [10] 和 Kosmos-1 [11]。

（[10] 也以单方面方式这样做）是有益的；新的 PaLI-X 模型相比任何以往工作都提供了更均衡的参数分配（总容量大约按 40%-60% 划分）。

除了确认规模的影响之外，PaLI-X 的原创贡献在于利用 [7] 中提出的目标混合方法进行视觉-语言建模，并表明由此得到的模型在微调和少样本配置下均提升了当前最先进结果和帕累托前沿（图 1，右）。

我们还观察到，基于 PaLI-X 的结果，与架构相似但规模更小的先前模型相比，出现了一些涌现特性。例如，我们报告了其在计数能力上的显著性能提升（见表 1 和附录 B），包括简单类型（计算某一类别的所有实例）和复杂类型（根据自然语言描述计算实例），这些提升不能归因于训练设计[1]。此外，我们还对模型性能提供了定性见解（附录 A），重点关注多语言迁移学习，例如使用非英语标签检测物体的能力（图 2），以及在图像中出现的文本语言（例如英语）与生成的图像标题语言（例如罗马尼亚语）之间进行切换的能力。

我们的技术贡献包括以下内容：

1. 我们扩展了一个视觉-语言模型，使其在多种基准测试上实现了卓越性能。我们观察到，同时扩展*both*视觉与语言组件是有益的，并报告在这一规模下性能仍未饱和。2. 我们表明，在这一规模下，使用结合前缀补全和掩码词元补全的混合目标来训练此类模型，可以改善微调性能与少样本性能之间的帕累托前沿。3. 我们表明，高容量视觉编码器（ViT-22B）可以有效地联合训练图像分类和 OCR 标签分类[2]，从而在那些理解图像中文字至关重要的 V&L 任务上取得显著提升。4. 总体而言，PaLI-X 通过在 15+ 个基准测试上进行微调提升了 SoTA 结果，并且我们表明，它是首个能够通过多任务微调同时适应一组多样化基准测试且不出现显著性能下降的同类模型。

2 相关工作

与 GPT4 [12] 和 PaLM [1] 等大型语言模型类似，规模带来的益处也在近期的视觉和视觉-语言模型中得到了观察。Flamingo [10] 使用了一个冻结的语言

[1]Plain counting is usually achievable via good object detection, while complex counting requires a fine-grained understanding of the alignment between language-based specifications and visually-based occurrences.

[2]We use OCR tokens produced by the GCP Vision API over the training images as targets.

组件，并展示了将这一部分扩展到 700 亿参数对少样本多模态能力的益处，而视觉编码器则固定为 4.35 亿参数。另一方面，GIT [9] 探索了将视觉组件扩展到 48 亿参数，并使用 3 亿参数的语言解码器。PaLI [5] 探索了对视觉和语言组件进行联合扩展，分别达到 40 亿和 170 亿参数，并表明同时扩展这两个组件有益于广泛的视觉-语言任务。所有这些模型都利用了视觉和语言单模态预训练模型作为骨干网络来开始多模态训练。最近，在视觉模型方面，已推出了一个拥有 220 亿参数的视觉 Transformer [6]。在这项工作中，我们使用了一个专门针对 OCR 能力进行调优的 ViT-22B 模型，以探索将视觉-语言模型扩展到更大的参数规模。

正如 [13] 首次所示，只要提供少量示例——或 *shots*——作为输入，*large* 语言模型有时能够在推理时解决新的未见任务。这通常被称为上下文学习 [14]。后续工作提出了改进的样本拆分和提示方式，例如思维链 [15] 或 Least-to-Most 提示 [16]。到目前为止，这方面的绝大多数工作都是在语言输入的背景下完成的 [17]。在这项工作中，我们探索了基于图像和标题配对的多模态上下文学习。我们的工作在精神上与 Flamingo [10] 一致，后者在预训练期间使用同一网页中的交错图像-文本对以及上下文调优 [18]。我们首先按 url 对图像-文本对进行分组，并将每组拆分为“shots”集合和“target”集合。然后，我们使用“shots”集合中的少量示例作为输入特征，来预测目标集合中的示例。

除了在多个领域解决视觉-语言任务外，近期的 VLM 还尝试一次性解决这些任务，而不是在每个单独的基准上进行微调。Unified-IO [19] 进行了多任务微调，并报告了在 16 个基准上的稳健结果。Spotlight [20] 报告称，在 UI 领域内，多任务微调可以达到接近任务特定微调的性能。在这项工作中，我们表明 PaLI-X 可以同时在多个领域的一组多样化基准上进行微调，而不会导致性能下降。

3 模型

3.1 架构

PaLI-X 模型架构遵循编码器-解码器架构：图像由 ViT 编码器处理，生成的视觉嵌入会与额外文本输入（例如问题/前缀/提示）的嵌入一起输入到编码器-解码器主干网络中。更多细节见附录 A。

视觉组件 我们的视觉骨干网络扩展到 22B 参数，如 [6] 所介绍，这是迄今为止最大的密集型 ViT 模型。为了使模型能够处理各种复杂的视觉-语言任务，我们特别关注其 OCR 能力。为此，我们引入了如下基于 OCR 的预训练：使用 GCP Vision API 检测到的 OCR 文本对 WebLI 数据集 [5] 中的图像进行标注；随后，编码器通过原始基于 JFT 的分类任务与新的基于 OCR 的分类任务（根据 OCR 结果判断给定 token 是否出现在图像中）的混合任务进行进一步预训练。有关视觉组件的更多细节，请参见附录 A。PaLI-X 被设计为以 $n >= 1$ 张图像作为输入（用于少样本和视频理解），涉及单张图像的任务则作为 $n = 1$ 的情况。对于 $n > 1$，每张图像都由 ViT 模块独立处理，从 ViT 输出的 patch 级嵌入会被展平并拼接，以形成视觉输入（见附录 A）。请注意，与单图像情况类似，在视觉嵌入沿时间维度聚合之前，不会在空间维度上进行池化。也就是说，对于一个包含 n 帧、每帧有 k 个 patch 的输入，得到的视觉输入具有 $n * k$ 个 token。

整体模型 编码器-解码器骨干网络初始化自 UL2 [7] 编码器-解码器模型的一个变体，该变体使用 32B 参数。该变体的架构在编码器和解码器中均有 50 层（高于 [7] 中的 32 层），并在与 [7] 类似的文本数据混合集上进行预训练。视觉嵌入在经过一个投影层后，与文本输入的词元嵌入拼接在一起，并输入到编码器-解码器骨干网络中。大多数预训练任务（掩码图像词元任务除外）都从这种多模态输入中预测纯文本输出。模型的文本输入通常由一个提示组成，用于标记任务类型（例如，用于图像描述任务的“*Generate caption in* ⟨lang⟩”），并编码该任务所需的文本输入（例如，用于 VQA 任务的“*Answer in* ⟨lang⟩*: {question}*”）。对于需要 OCR 能力的任务，我们尝试要么仅依赖视觉编码器的文本编码能力，要么可选地将上游 OCR 系统提取的词元作为额外文本输入加入。

小样本设定 在小样本设置中，对于给定的 *target example*，模型会接收若干“带标签”的示例（以额外的 ⟨图像、文本⟩ 对的形式），我们将其称为 *shots*/*exemplars*。其假设是，这些样例中包含的信息能够为模型提供有用的上下文，以生成目标示例的预测。形式上，包含 N 个样本的输入是一个序列（$t_1, \ldots, t_N, t_T, i_1, \ldots, i_N, i_T$），其中 $t_1 : t_N$ 和 $i_1 : i_N$ 分别是 N 个样本的文本和图像，而 t_T 和 i_T 是目标示例的文本（提示）和图像。PaLI-X 按如下方式处理该输入：所有图像（包括目标图像）首先由视觉编码器独立处理，所得的补丁级嵌入被展平并拼接，以形成视觉输入序列。经过一个投影层后，它们与文本嵌入拼接，形成编码器使用的多模态输入序列。我们实现了额外的优化，包括在编码器和解码器之间分配样例，以及一种注意力重加权机制（见附录 B）。

3.2 预训练数据和混合

我们模型的主要预训练数据基于 WebLI [5]，包含约十亿张来自网络且带有替代文本的图像以及 OCR 注释（使用 GCP Vision API），覆盖 100 多种语言。除了 WebLI ⟨图像、文本⟩对之外，我们在此引入 *Episodic WebLI* 数据，其中每个 episode 对应于一组这样的配对。我们的目标是让每个 episode 包含松散相关的图像（即根据其 URL 字段进行聚类），从而鼓励在一个“episode”中的样例之间进行注意力交互。我们发现这个新数据集（包含 7500 万个 episode，总计约 4 亿张图像）对于发展模型的少样本能力非常重要。

预训练混合数据由以下数据和目标组成：(i) 仅文本数据上的片段损坏（15% 的 token）；(ii) WebLI alt-text 数据上的分割式描述生成 [21, 5]；(iii) CC3M [22] 上基于原生和翻译后的 alt-text 数据的描述生成（覆盖 XM3600 [23] 所涵盖的相同 35 种语言）；(iv) WebLI OCR 标注上的 split-ocr [24]；(v) 在 CC3M 训练划分上，使用 VQ^{2}A 方法 [25] 生成的 ⟨image, question, answer⟩ 三元组上的视觉问答目标，涵盖原生和翻译文本（相同的 35 个语言对）；(vi) 使用上述相同三元组的视觉问题生成目标；(vii) 使用 Object-Aware 方法 [26]（仅英语）生成的 ⟨image, question, answer⟩ 三元组上的视觉问答目标；(viii) Episodic WebLI 示例上的描述生成（根据其余 alt-text 和图像预测目标 alt-text）；(ix) 4 对示例上的视觉问答（类似于 Episodic WebLI，并使用 VQ^{2}A-CC3M 三元组），其中答案目标以其他 ⟨image, question, answer⟩ 数据对为条件；(x) [27] 中引入的 pix2struct 目标，使用与 html 页面 DOM 树表示配对的截图图像来针对页面布局和结构进行建模；(xi) 短视频数据上的描述生成，使用 VTP 数据 [10]（每个视频使用四帧）；(xii) WebLI 数据上的目标检测目标，其中使用 OWL-ViT 模型 [28]（L/14）对 WebLI 图像进行标注，从而为每张图像生成数百个伪对象标签和边界框；(xiii) 图像 token 预测目标，其中我们使用 patch 大小为 16×16 的 ViT-VQGAN [29] 模型对 WebLI 图像（256×256 分辨率）进行 token 化（每张图像 256 个 token）；该目标被设定为 2D 掩码 token 任务（即填补缺失的网格块，同时对应的图像像素也被掩码）。请注意，加入图像 token 预测目标主要是作为一种条件，用于检查它是否会对语言输出任务的性能产生对抗性影响；我们的消融实验表明它不会。

3.3 训练阶段

我们的模型分两个阶段进行训练。在第 1 阶段，视觉编码器（经过混合目标训练后）保持冻结，其余参数则使用完整混合数据，在基础分辨率 224×224（ViT-22B 的原生分辨率）下，总共训练 2.2B 个样本。在第 2 阶段，模型继续仅使用 OCR 相关目标（pix2struct 和 split-ocr）以及目标检测目标进行训练；该阶段分为若干子阶段，在此期间图像分辨率逐步提高到 448×448、672×672，最终达到 756×756。

4 实验

4.1 图像描述与视觉问答

我们的结果表明，PaLI-X 更大的容量在其视觉和语言组件上都具有良好的扩展性，并且对更具挑战性的场景文本和文档理解任务尤其有益。我们的模型在多种视觉-语言任务上超越了当前最佳水平（SOTA），在某些情况下具有显著优势。

基准数据集 用于评估的图像描述和 VQA 基准汇总见附录 B，其中包括 6 个图像描述基准（COCO（Karpathy 划分 [30]）、NoCaps [31]、TextCaps [32]、VizWiz-Cap [33]、Screen2Words [34]、Widget-Cap [35]）和 13 个 VQA 基准（VQAv2 [36]、OKVQA [37]、TallyQA [38]、TextVQA [39]、VizWiz-VQA [40]、STVQA [41]、OCRVQA [42]、InfographicVQA [43]、DocVQA [44]、AI2D [45]、ChartQA [46]、OVEN [47]、InfoSeek [48]）。这些任务涵盖了广泛的视觉领域，从自然图像、插图到文档和用户界面（UI）。我们还在附录 B 中包含了 XM3600 上多语言图像描述的结果。

4.1.1 按任务微调结果

实验设置 我们使用冻结的 ViT-22B 对 PaLI-X 进行微调；在所有微调实验中，学习率都从初始值 1e-4 线性衰减。更多详细信息见附录 B。

	COCO	NoCaps		VQAv2		OKVQA	TallyQA	
Model	Karp.-test	val	test	test-dev	test-std	val	simple	complex
GIT2 [9] (5.1B)	145.0	126.9	**124.8**	81.74	81.92	-	-	-
Flamingo [10] (80B)	138.1	-	-	82.0	82.1	57.8*	-	-
BEiT-3 [49] (1.9B)	147.6	-	-	84.2	84.0	-	-	-
PaLM-E [50] (562B)	138.7	-	-	80.0	-	**66.1**	-	-
MoVie [51]	-	-	-	69.26	-	-	74.9	56.8
PaLI [5](17B)	149.1	**127.0**	124.4	84.3	84.3	64.5	81.7	70.9
PaLI-X (55B)	**149.2**	126.3	124.3	**86.0**	**86.1**	**66.1**	**86.0**	**75.6**

表 1：在 COCO Captions（Karpathy 划分）、NoCaps、VQAv2 [36]、OKVQA [37] 和 TallyQA [38] 上的结果，采用无 OCR 流水线输入的端到端建模（“simple”和“complex”为测试子划分）。

Model	Text Caps	VizWiz Cap	Text VQA	VizWiz VQA	ST VQA	OCR VQA	Info VQA	Doc VQA	AI2D	Chart QA	Screen2 Words	Widget Cap	OVEN	Info Seek
***with** OCR pipeline input*														
SoTA	160.4 [5]	124.7 [5]	73.67 [52]	73.3 [5]	79.9 [5]	67.5 [53]	47.4 [54]	84.7 [54]	38.5 [45]	45.5 [46]	- -	- -	- -	- -
PaLI-X	**163.7**	**125.7**	**80.78**	**74.6**	**84.5**	**77.3**	**54.8**	**86.8**	**81.4**	**72.3**	-	-	-	-
***without** OCR pipeline input*														
SoTA	145.0 [9]	120.8 [9]	67.27 [9]	70.7 [5]	75.8 [9]	71.3 [27]	40.0 [27]	76.6 [27]	42.1 [27]	70.5 [8]	109.4 [27]	141.8 [20]	20.0 [47]	17.7 [48]
PaLI-X	**147.0**	**122.7**	**71.44**	**70.9**	**79.9**	**75.0**	**49.2**	**80.0**	**81.2**	**70.9**	**127.9**	**153.0**	**23.1**	**21.8**

表 2：在更侧重文本理解能力的基准测试上的结果。对于 OVEN [47] 和 InfoSeek [48]，我们遵循所提出的 224×224 分辨率设置，以进行公平比较。

首先，我们展示了未使用外部 OCR 系统条件下的基准测试结果（表 1，扩展表见附录 B）。总体趋势是，PaLI-X 在这些基准上达到或超越了 SoTA 结果，尤其是在 TallyQA 基准上相较于 MoVie [51]（专门的计数模型）有显著提升：对于简单计数问题（例如“有多少只长颈鹿”）提升了 +11.1，对于复杂计数问题（例如“有多少只长颈鹿在喝水”）提升了 +18.8；相较于 PaLI [5] 也有显著提升，这表明规模在此类模型执行计数任务的能力中起着重要作用。我们还注意到，在 VQAv2 上达到了 86.1 准确率的最先进结果，这是通过开放词汇生成式

方法，并且在 OKVQA 上达到 66.1 的准确率，与规模大得多的 PaLM-E [50] 模型性能相当。

接下来，我们考察文本密集型 V&L 基准，在这些基准中，可以使用上游 OCR 系统来提升性能。如表 2 所示，无论是否使用额外的 OCR 输入（使用 GCP Vision API），PaLI-X 都在所有图像描述和 VQA 基准上全面提升了 SoTA。例如，在 AI2D[3] 上观察到 +42.9 分的显著提升；AI2D 是一个多项选择基准，每个问题都会同时提供选项。能够将文本选项作为输入，相比此前的 SoTA Pix2Struct [27] 为 PaLI-X 带来了优势，因为 Pix2Struct 必须将文本渲染到图像上，但这并不能解释全部提升。在仅问题配置（不提供答案选项）下，PaLI-X 在 AI2D 上取得了 46.3 的成绩，比 Pix2Struct 的结果高出 4 分以上。

一般来说，使用由外部 OCR 流水线提取的 OCR 文本可以提升性能。不过，在若干基准测试（例如 AI2D、ChartQA、OCRVQA 和 Widget-Cap）中，PaLI-X 利用其内置 OCR 能力时的端到端性能，接近于使用额外 OCR 输入时的性能。这些基准测试的一个共同特征是文本方向规整——包括图表、统计图、书籍封面或用户界面，并且在 756×756 分辨率下字体大小较为合理。对于涉及自然图像中场景文本的任务（TextCaps、TextVQA、STVQA）或小文本密度非常高的任务（DocVQA、InfoVQA），结果仍然清楚表明，使用外部 OCR 模型能带来明显收益。

4.1.2 多任务微调

我们同时在属于同一类别的多个基准上对预训练检查点进行微调和评估。我们针对混合中每个任务的测试集，对每个训练集进行了去重，以防止任何测试集样本泄漏到混合训练集中。这很有用，因为它会得到一个能够执行所有任务的单一微调模型，而无需分别对每个任务进行微调。我们分别在所有图像描述基准和大多数 VQA 基准上进行了这种多任务微调。

表 3 展示了字幕生成任务的多任务微调结果。在多任务设置下，COCO 上的性能略有下降，这可能是因为该任务需要更长的训练时间才能收敛。对于 Screen2Words，其训练集和开发/测试集规模最小，可能是性能波动的原因。值得注意的是，VizWiz-Cap 和 Widget-Cap 通过多任务微调取得了性能提升。总体而言，多任务微调使平均性能下降了 1.4 个百分点（不包括 Screen2Words 时为 0.2 个百分点），同时带来了一个明显优势：只需单个检查点即可执行所有这些任务。附录 B 展示了 VQA 任务的类似结果。我们认为这一结果是积极的，它证明了在多样化基准上，多任务微调与单任务微调具有相当的性能；这与先前的工作形成对比，后者认为单任务与多任务微调之间存在差距 [19]，或仅在同一领域的基准上显示出很小的差距 [20]。

Method	COCO	NoCaps	Text Caps	VizWiz Cap	Screen2 Words	Widget Cap	Avg.
Split	Karp.-test	val	val	test-dev	test	test	-
SOTA (Single-task FT)	149.1	**127.0**	148.6	119.4	109.4	136.7	
PaLI-X Single-task FT	**149.2**	126.3	150.8	123.1	**127.9**	153.2	-
PaLI-X Multitask FT	147.3	125.6	**154.6**	**124.2**	120.6	**153.7**	-
Multitask (+/-)	-1.9	-0.7	+3.8	+1.1	-7.3*	+0.5	-1.4 (-0.2 w/o "*")

表 3：图像描述任务中，多任务微调得分与单任务微调得分的比较。部分任务报告的是验证集或 test-dev 集的结果。

4.1.3 少样本评估

我们在少样本任务的混合数据上对 PaLI-X 模型进行了微调。该少样本混合数据包含 Episodic 混合数据、（非 Episodic）Webli 和（非 Episodic）CC3M 数据。请注意，所有这些数据集在之前的训练阶段中已经使用过，但混合比例较低。在

[3]As with all the other benchmarks, our training examples are carefully deduped to exclude images occurring in these benchmarks, including AI2D. Such results, therefore, are *not* attributable to train-test data leakage.

预训练时，我们最多只使用 4 个样本，同时使用编码器和解码器样本（见附录 B）。微调时，我们最多使用 8 个编码器样本，并且不使用解码器样本。

我们在 COCO caption（Karpathy 测试划分 [30]）和 XM3600 [23] 数据集上评估少样本性能。对于每个任务，我们首先创建一个包含 256 个样例的“样本池”，这些样例从该任务的训练集中随机选取。由于 XM3600 基准没有提供训练集，我们使用 Google Translate API 为 COCO Karpathy 训练集增强了 XM3600 所涵盖的 35 种语言的字幕。然后，对于每个测试数据点，我们从样本池中随机选取 N 个样本作为实际的少样本示例。遵循 [10]，我们还在 2 个纯文本样本设置上进行评估，其中仅使用 2 个随机采样的少样本示例的文本部分。

表 4 报告了英语和多语言图像描述任务上的少样本图像描述性能，以及在 VQAv2 上的少样本 VQA 性能。PaLI-X 在 COCO 上以 4-shot 和 32-shot 均取得了 SOTA 少样本结果；在 4-shot 设置下，它比此前的 SOTA 高出 +4.4 个 CIDEr 点，表明其具有从少量示例中高效获取提示的强大能力。我们还报告了使用 XM3600 在 35 种语言上平均得到的少样本 CIDEr 分数，展示了 PaLI-X 的多语言能力。与此同时，尽管 PaLI-X 在 VQAv2 上的表现也相当不错，但其与 SOTA Flamingo 模型 [10]（该模型冻结了语言主干）之间的差距，可能是由于对语言主干进行微调而损失了部分少样本文本问答能力，这支持了关于少样本能力与微调能力之间存在张力的假设。

	COCO Captions		XM3600 Cap. (35-lang avg.)		VQAv2	
Method	4 shots	32 shots	4 shots	32 shots	4 shots	32 shots
Prev. SoTA [10]	103.2	113.8	N/A (53.6 w/ fine-tune [5])		**63.1**	**67.6**
PaLI-X	**107.6**	**114.5**	45.1	47.1	56.9	57.1

表 4：PaLI-X 模型的少样本性能（XM3600 的多语言图像描述）。

4.2 视频字幕生成与问答

我们在 4 个视频字幕生成基准（MSR-VTT [55]、VATEX [56]、ActivityNet Captions [57]、Spoken Moments in Time [58]）和 3 个视频问答基准（NExT-QA [59]、MSR-VTT-QA [60]、ActivityNet-QA [61]）上对 PaLI-X 模型进行微调和评估。附录 C 提供了每个基准的简要描述以及关于其使用方式的说明。

实验设置 我们针对每个任务分别微调模型（基础分辨率为 224×224），使用验证集划分进行早停，并在测试集划分上报告性能。我们对所有任务使用 10^{-4} 的学习率，并且不针对特定任务调整任何超参数。帧采样对每个数据集使用固定的时间步长（根据该数据集中视频长度分布确定，使得对于一半的视频，帧数与步长的乘积大于总帧数），并且我们实验了每个视频最多包含 8 帧或 16 帧。我们没有在空间维度上进行池化；每帧 16×16 个图像块的嵌入作为视觉输入提供给多模态编码器。

结果 我们报告视频字幕生成任务的 CIDEr 分数。视频问答任务被视为开放式生成任务；我们报告 [65, 59] 中的全字符串准确率（用于 MSR-VTT-QA 和 ActivityNet-QA）以及 WUPS 指标（用于 NExT-QA）。如表 5 所示，16 帧版本优于 8 帧版本，有时优势显著（例如，在 ActivityNet-Captions 上 CIDEr 分数提升接近 6 分）。更重要的是，尽管 PaLI-X 的预训练主要由图像-文本任务主导，我们仍在 7 个任务中的 5 个任务上取得了新的 SOTA 性能[4]，并且在 MSR-VTT-QA 上的表现非常接近此前的 SOTA（47.1 对 47.4）。

4.3 图像分类

为了测试图像分类能力，我们在 ImageNet [66] 上对 PaLI-X 和来自 [5] 的模型进行了微调，并在 ImageNet-REAL [67] 和分布外数据上评估了所得模型。

[4]As noted in Table 5, current SOTA on NExT-QA for the open-ended QA task was achieved by Flamingo 32-shot, which had outperformed prior fine-tuning SOTA. To the best of our knowledge, PaLI-X performance on this task does outperform existing published fine-tuning performances, with the caveat that we do not have information on what Flamingo fine-tuning would have achieved on this task.

Method	MSR-VTT		Activity-Net		VATEX	SMIT	NExT-QA
	Cap. [55]	QA [60]	Cap. [57]	QA [61]	Cap. [56]	Cap. [58]	QA [59]
Prior SOTA	75.9 GIT2 [9]	**47.4** Flamingo [10]	52.5 PDVC [62]	44.7 VINDLU [63]	94.0† GIT2 [9]	28.1‡ MV-GPT [64]	33.5§ Flamingo 32shot [10]
PaLI-X (8fr)	74.6	46.9	49.0	48.4	66.0	42.5	37.0
PaLI-X (16fr)	**76.8**	**47.1**	**54.9**	**49.4**	69.3	**43.5**	**38.3**

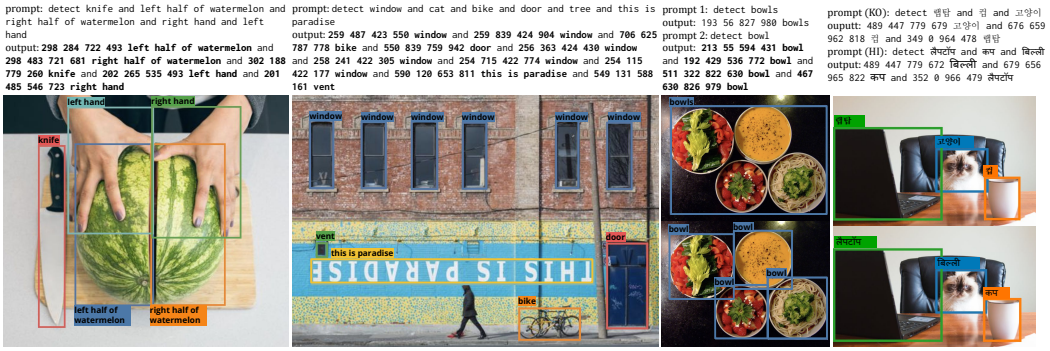
表5：使用8帧（8fr）或16帧（16fr）进行视频字幕生成和视频问答（Video-QA）的结果。† GIT2 使用自我批判序列训练（Self-Critical Sequence Training）来直接优化 VATEX 上的 CIDEr 指标。‡SMIT 此前尚未用于视频字幕生成，我们应用 MV-GPT [64] 并报告测试集上的结果。§这些数值是使用 32-shot 获得的；由于 Flamingo 32-shot 在该开放式问答任务上优于微调的 SOTA，因此他们没有针对此任务进行进一步的微调实验。

数据集：ImageNet-R [68]、ImageNet-A [69]、ImageNet-Sketch [70]、ImageNet-v2 [71]。我们使用了第一训练阶段的模型（分辨率为 224）以及最后训练阶段的模型（分辨率为 756）。我们对所有运行都使用了相同的训练超参数（未进行任何超参数调优；更多细节见附录 D）。

结果见表 6。我们将结果与开放词汇的生成式模型 GIT2 [9]（使用 384 图像分辨率）进行比较，该模型是目前在 ImageNet 上进行全量微调的 SOTA。PaLI-X 在 ImageNet 以及其他数据集上实现了生成式模型的 SOTA 结果。我们还对 PaLI-X 进行了零样本评估，结果见附录 D。

Model (resolution)	INet [66]	REAL [67]	INet-R [68]	INet-A [69]	INet-Sketch [70]	INet-v2 [71]
GIT2 [9] (384)	**89.22**	-	-	-	-	-
PaLI-17B [5] (224)	86.13	88.84	78.21	50.00	71.21	78.91
PaLI-X (224)	88.22	90.36	77.66	55.97	72.56	81.42
PaLI-X (756)	**89.19**	**90.98**	**80.06**	**72.57**	**73.37**	**83.66**

表 6：在 ImageNet [66] 上微调后的分类准确率（top-1）。



Credits: Watermelon/Cat; Sarah Pflug (burst), Bowls; ariesandrea (flickr), Wall; Matthew Henry (burst)

图 2：展示多语言、OCR 及其他能力迁移到检测任务中的示例。

4.4 目标检测

目标检测可以很容易地在我们的模型中表述，如 pix2seq [72] 所示。用于预训练的数据集混合在第 3 节中介绍；检测数据一直被纳入到使用 672 分辨率的阶段（含该阶段），之后在检测数据上对一个单独的检测专用模型进行了微调。在进行检测专用调优之前，已从所有检测训练数据集中移除了 LVIS [73] 和 COCO 标签，从而允许在 LVIS 上进行零样本评估。

LVIS 上的边界框平均 AP 如表 7 所示，包括零样本性能；经过检测调优的模型总体 AP 达到 31，在稀有类别上达到 31.4，而在零样本情况下两者均约为 12。稀有类别上的性能与常见类别上的性能相当，这是一项困难的

这一成果传统上需要通过复杂的采样计划和数据增强来实现。在我们的设置中，它由 PaLI-X 多样化的训练混合直接促成。通过投入微调，例如使用 pix2seq [72] 中的噪声增强方法，或进一步进行仅针对高分辨率 LVIS 的训练阶段，这一结果很可能还能进一步提升。从定性角度看，我们观察到与非检测任务共同训练带来了许多有趣现象；例如，多语言检测、OCR 边界框和更长的描述，这些都未包含在检测训练中，但 PaLI-X 通常都能很好地处理。更多结果和信息见附录 E.3。

	LVIS AP	LVIS AP_{Rare}
ViLD [74] (tuned on non-rare LVIS)	29.3	26.3
Region-CLIP [75] (tuned on non-rare LVIS)	32.3	22.0
OwLViT-L/16 [28] (tuned on non-rare LVIS)	34.7	25.6
OwLViT-L/16 [28] (with Object365 and VG datasets)	34.6	31.2
PaLI-X (Zeroshot)	12.36	12.16
PaLI-X (Detection-tuned)	30.64	31.42

表 7：PaLI-X 在 LVIS 上的目标检测结果。多样化的预训练组合使 LVIS 稀有类别和常见类别之间达到相当的性能。其他相关方法仅作为背景展示，但不能直接比较。

5 模型公平性、偏见及其他潜在问题

大型模型如果不加以约束，可能会对社会造成伤害——例如放大偏见 [76, 77, 78, 79]、造成差异 [78, 80, 81]，或编码狭隘的文化视角 [82, 83]。因此，评估 PaLI-X 是否存在此类潜在问题十分重要。我们将 RAI 评估重点放在三个方面：(1) 有害关联，例如毒性和亵渎性语言；(2) 模型输出中的人口统计公平性，例如编码社会刻板印象/偏见；以及 (3) 各子群体之间的性能差异。这一划分遵循了文献中的早期工作，例如 [84]。

毒性/脏话。我们估计生成字幕中的毒性和脏话水平，包括按子群体拆分后的情况。我们使用 FairFace 数据集 [85]，该数据集包含带有真实属性标注的人物图像：性别呈现、年龄和族裔。我们生成字幕，并使用 Perspective API [86]（阈值 > 0.8）来衡量毒性和脏话。表 8 总结了结果；我们观察到所有切片中的毒性/脏话水平均较低。表 9 和表 10 提供了 FairFace 数据集中所有子群体的毒性/脏话结果的详细分解。在表 11 和表 12 中，我们报告了 MIAP [87] 数据集上的类似结果，并按感知性别和年龄进行了拆分。

	Gender		Ethnicity			Age			
	Lowest	Highest	Lowest	Median	Highest	Lowest	Median	Highest	**Overall**
Toxicity	0.14%	0.19%	0.00%	0.13%	0.39%	0.00%	0.17%	0.31%	**0.01%**
Profanity	0.00%	0.02%	0.00%	0.00%	0.05%	0.00%	0.00%	0.03%	**0.00%**

表 8：PaLI-X 在 FairFace 数据集上生成的字幕中的平均毒性/脏话程度。

偏见 / 人口统计均等性。我们评估 PaLI-X 在性别和职业方面的人口统计均等性（DP）[88] 水平。为估计模型输出中的人口统计均等性（DP）水平，我们将一张图像输入 PaLI-X，并以所选职业名称作为前缀，记录模型生成字幕的平均对数困惑度分数。为确保任何观察到的均等性更可能反映模型本身的非预期偏见，而不是评估数据集的偏差，我们使用 CelebA [89]，该数据集包含带有性别呈现标注的名人图像。我们的假设是，许多反映社会刻板印象的职业，例如秘书和水管工，在 CelebA 数据集中相当罕见，因此输出中的差异可能反映的是模型自身编码的内容。职业列表基于 [90] 以及 [91] 中的美国就业统计报告编制。

图 3（顶部）总结了总体结果。首先，在大多数职业中，PaLI-X 倾向于给女性分配比男性更高的对数困惑度分数；也就是说，模型预测男性更有可能从事这些职业。其次，PaLI-X 认为女性成为（“秘书” &

Ethnicity	Toxicity			Profanity		
	< 0.2	$0.2 - 0.8$	> 0.8	< 0.2	$0.2 - 0.8$	> 0.8
Middle Eastern	64.24%	35.76%	0.00%	94.87%	5.13%	0.00%
Black	59.47%	40.40%	0.13%	92.67%	7.33%	0.00%
Indian	63.86%	36.07%	0.07%	94.39%	5.61%	0.00%
Hispanic	61.09%	38.79%	0.12%	94.45%	5.55%	0.00%
White	62.45%	37.16%	0.39%	92.85%	7.10%	0.05%
Southeast Asian	63.18%	36.61%	0.21%	93.57%	6.43%	0.00%
East Asian	63.15%	36.72%	0.13%	91.55%	8.45%	0.00%

表 9：PaLI-X 在 FairFace 数据集上生成的图像说明按族裔细分后的预测毒性/粗俗语言分布。

Age	Toxicity			Profanity		
	< 0.2	$0.2 - 0.8$	> 0.8	< 0.2	$0.2 - 0.8$	> 0.8
< 19	58.78%	40.00%	0.22%	89.71%	10.29%	0.00%
20 - 29	63.01%	36.86%	0.12%	93.24%	6.73%	0.03%
30 - 39	63.13%	36.70%	0.17%	95.41%	4.59%	0.00%
40 - 49	63.62%	36.31%	0.07%	95.27%	4.73%	0.00%
50 - 59	65.87%	33.88%	0.25%	96.48%	3.52%	0.00%
60 - 69	65.31%	34.38%	0.31%	95.95%	4.05%	0.00%
> 70	66.10%	33.90%	0.00%	92.37%	7.63%	0.00%

表10：PaLI-X 在 FairFace 数据集上生成的字幕按年龄分组后的预测毒性/亵渎性分布。

Perceived Gender	Toxicity			Profanity		
	< 0.2	$0.2 - 0.8$	> 0.8	< 0.2	$0.2 - 0.8$	> 0.8
Predominantly Feminine	53.98%	45.93%	0.09%	90.55%	9.39%	0.07%
Predominantly Masculine	70.76%	29.17%	0.06%	94.97%	5.01%	0.01%

表 11：PaLI-X 在 MIAP 数据集上生成的字幕中，按感知性别细分的预测毒性/亵渎性分布。

Age Bucket	Toxicity			Profanity		
	< 0.2	$0.2 - 0.8$	> 0.8	< 0.2	$0.2 - 0.8$	> 0.8
0-2 yrs	28.00%	72.00%	0.00%	69.90%	30.10%	0.00%
3-19 yrs	49.96%	49.96%	0.07%	91.46%	8.54%	0.00%
20-59 yrs	66.27%	33.68%	0.05%	93.42%	6.55%	0.03%
> 60 yrs	65.46%	34.54%	0.00%	96.39%	3.61%	0.00%

表 12：按年龄段细分的 MIAP 数据集上 PaLI-X 生成字幕的预测毒性/亵渎性分布。

“演员”），而男性更有可能是（“警卫”和“水管工”），置信水平为 95%。图 3（底部）展示了 WebLI 数据集中感知性别呈现与职业之间的相应相关性，其中我们通过将每个标签视为二元随机变量来使用皮尔逊相关系数，并注意到对于二元随机变量，零相关意味着完全独立。数据中所有相关系数的绝对值均为 < 0.2，其中 99% 为 < 0.1。

性能差异。我们在此使用 MIAP [87] 数据集评估 PaLI-X 在不同子群体上的表现。对于仅包含一个人的图像，我们向 PaLI-X 提问：“这张图像中有人吗？”并评估其回答的准确率。请注意，在此评估中不存在误报。表 13 总结了结果。我们观察到，PaLI-X 在所有子群体上都保持了较高的准确率。

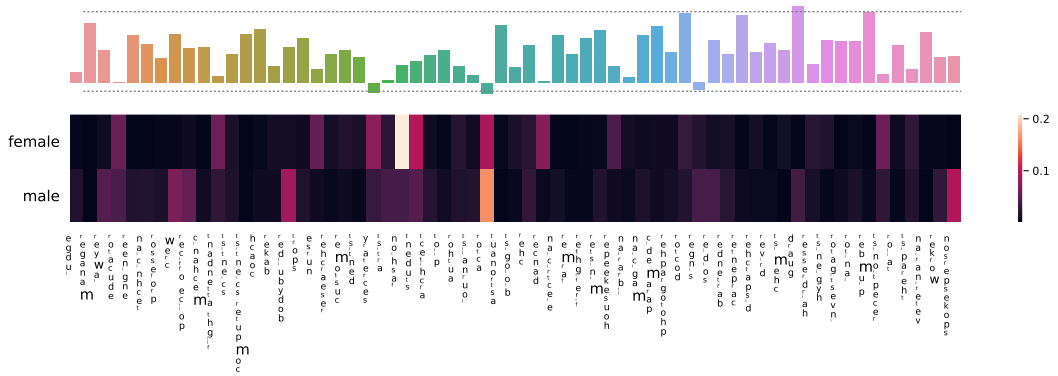


图 3：上图：PaLI-X 对 CelebA 图像的输出中女性与男性之间的人口统计均等性（DP）水平。数值接近零表示不存在偏见。下图：WebLI 中性别呈现与职业之间的 *Absolute* Pearson 相关系数。

Skin Tone	**1** [2]	**2** [871]	**3** [3008]	**4** [522]	**5** [184]	**6** [85]	**7** [54]	**8** [49]	**9** [6]	**10** [1]
	0.00%	0.11%	0.47%	1.53%	0.54%	1.18%	0.00%	0.00%	0.00%	0.00%

Gender	**Predominantly Feminine** [2437]	**Predominantly Masculine** [3544]
	0.53%	0.85%

Age Bucket	**0-2 yrs** [17]	**3-19 yrs** [568]	**20-59 yrs** [4925]	**> 60 yrs** [247]
	0.00%	0.00%	0.77%	0.81%

表 13：PaLI-X 在 MIAP 数据集 [87] 子集上针对“person”的检测错误率，该子集中的图像恰好只包含一个个体。PaLI-X 在所有子群体中均保持较低错误率。肤色遵循 Monk 肤色量表 [92]。方括号内的数字对应每个桶的大小。

局限性。本节所进行的分析必然是有限的，因为公平性是一个社会概念，无法被简化为统计指标。我们预计，随着文献中发现并报告新的问题以及更多数据集的可用，RAI 评估将随着时间的推移而演进。统计分析只是其中的一个步骤，不能替代对已部署模型所产生的广泛且滞后影响的研究。

此外，我们在某些部分依赖自动化工具来推断属性，而这些工具并非完全准确，可能会导致对人群进行宽泛分类，从而错误识别真实身份。我们不支持基于视觉指标创建或应用用于敏感属性（如性别或族裔）的分类器，并鼓励读者深入阅读阐述其潜在风险的综合性工作，如 [93, 94]，以获得进一步了解。此外，尽管我们在分析中使用了由数据提供的感知性别呈现（即 CelebA 和 FairFace 中的数据），但我们承认，人们可能以许多其他方式表达其性别身份。

在我们的评估中，毒性仅基于生成的字幕进行预测。然而，如果不了解图像的上下文，这可能会导致误报。

6 结论

在这项工作中，我们通过进一步扩展视觉和语言模型获得了更多见解。我们表明，规模扩展和改进的训练方案带来了一个显著超越以往最先进模型的模型，产生了涌现行为，并指出了进一步改进的空间。具体而言，我们报告该模型在文档、图表和信息图理解、图像描述、视觉问答、计数方面取得了显著提升，并且在少样本（上下文内）图像描述、视频描述和问答以及目标检测方面表现良好。

致谢

我们感谢 Sarah Laszlo、Kathy Meier-Hellstern、Caroline Pantofaru、Susanna Ricco、Candice Schumann、Ken Burke、Simon Wang、Rachel Hornung、Yichang Chen、Utsav Prabhu、Abhijit Ogale、Kristina Toutanova、Weicheng Kuo、Jihyung Kil、Xiangning Chen、Liang Chen、Rich Lee、Elizabeth Adkison、James Cockerille、Eric Ni、Erica Moreira、Victor Gomes、Jeremiah Harmsen、Claire Cui、Slav Petrov、Tania Bedrax-Weiss、Joelle Barral、Tom Duerig、Paul Natsev、Fernando Pereira、Jeff Dean 和 Zoubin Ghahramani 提供的有益讨论、反馈和支持。

A 额外的模型细节和示例

A.1 PaLI-X 架构示意图

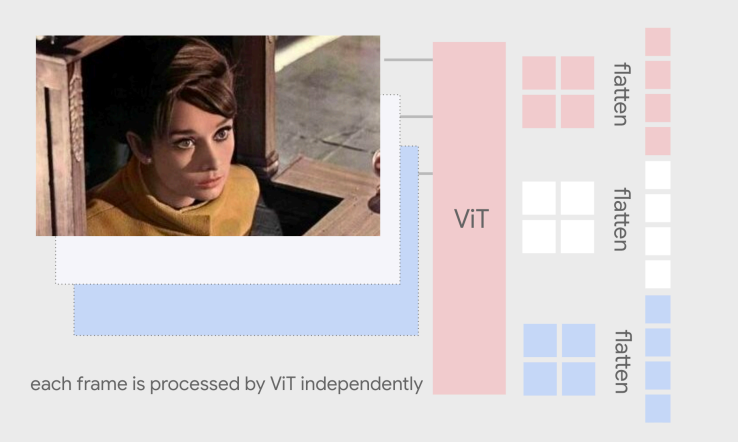


图 4：视频的视觉输入：每一帧都由 ViT 独立处理；图像块嵌入被展平并拼接在一起，以形成视觉表示。（示例输入图像属于公有领域）。

A.2 调优 ViT-22B 以获得更好的 OCR 能力

视觉编码器理解文本的能力对于多个下游任务和整体可用性至关重要。基于 JFT 的预训练不足以覆盖这一能力，因此我们在 WebLI-OCR 数据上对 ViT-22B 进行了调优。为了保持与 ViT-22B 最初使用的基于判别式分类的目标一致，我们将 OCR 转化为词袋预测任务。OCR 文本使用 mT5 分词器 [95] 对所有语言进行分词，并训练模型预测给定的词元是否出现在图像中。这被视为多标签分类，并使用扩展的分类头。

在表 22 所示的消融研究中，我们确认这一额外的调优步骤确实显著提升了场景文本理解能力，这一点由 ST-VQA 和 TextVQA 上的表现所证明。与此同时，在 VQAv2 基准等常规 VQA 任务上的表现也有所提升。

A.3 PaLI-X 示例说明

表14展示了 PaLI-X 的代表性示例，说明其在计数（包括简单和复杂类型）、上下文文本阅读能力以及空间感知方面的能力有所提升。



Image Credit: Wikimedia Commons [CC BY-SA 4.0]

Q: how many coins are there?
A: 12

Q: how many one-dollar coins are there?
A: 2

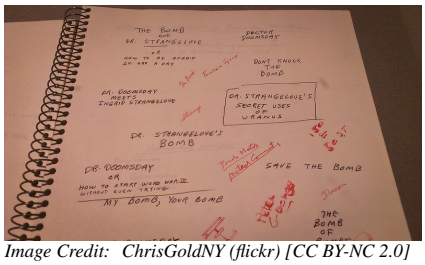


Image Credit: ChrisGoldNY (flickr) [CC BY-NC 2.0]

Q: what is written inside the box?
A: dr. strangelove's secret uses of uranus

Q: what is written on the top-left corner of the page?
A: the bomb and dr. strangelove

Q: what is written on the top-right corner of the page?
A: doctor doomsday



Public Domain Image

Captioning:
a movie poster for rebecca starring laurence olivier and joan fontaine.

Q: who directed this movie?
A: alfred hitchcock

Q: who produced this movie?
A: david o. seznick

表14：具有上下文和空间感知能力的计数、文本阅读能力示例。结果由多任务微调模型利用模型自身固有的 OCR 能力生成（即未使用外部 OCR 系统）。

B 附加结果：图像描述和 VQA

B.1 下游图像基准测试信息

表15总结了图像描述和VQA基准。对于仅以端到端方式建模且不输入OCR流水线的基准（表1和表16），微调采用672×672的分辨率进行。对于表2中呈现的场景文本和文档理解任务，微调采用756×756的分辨率进行。

B.2 图像基准测试的扩展表格

表 16 展示了一些图像基准测试的扩展结果表。

Benchmark	Visual Domain	Description	Metric
COCO Captions	Natural Images	Captioning of natural images	CIDEr
NoCaps		Captioning of natural images	CIDEr
TextCaps		Captioning of natural images containing text	CIDEr
VizWiz-Cap		Captioning of photos taken by people who are blind	CIDEr
VQAv2		VQA on natural images	VQA accu.
OKVQA		VQA on natural images requiring outside knowledge	VQA accu.
TextVQA		VQA on natural images containing text	VQA accu.
VizWiz-QA		VQA on photos taken by people who are blind	VQA accu.
ST-VQA		VQA on natural images containing text	ANLS
TallyQA		VQA with counting questions	EM
OVEN		VQA on natural images for visual entity recognition	EM
InfoSeek		VQA on natural images for visual info-seeking questions	Relaxed EM
OCR-VQA	Illustrations	VQA on images of book covers	EM
ChartQA		VQA on images of charts	RA
AI2D		VQA on images of scientific diagrams	EM
DocVQA	Documents	VQA on images of scanned documents	ANLS
InfographicsVQA		VQA on images of infographics	ANLS
Screen2Words	UIs	Captioning a UI screen to describe functionality	CIDEr
Widget Captioning		Captioning a UI component on a screen	CIDEr

表 15：用于评估 PaLI-X 的图像描述和 VQA 基准汇总

	COCO	NoCaps		VQAv2		OKVQA	TallyQA	
Model	Karp.-test	val	test	test-dev	test-std	val	simple	complex
SimVLM	143.3	112.2	110.3	80.03	80.34	-	-	-
CoCa (2.1B)	143.6	122.4	120.6	82.3	82.3	-	-	-
GIT (0.7B)	144.8	125.5	123.4	78.56	78.81	-	-	-
GIT2 (5.1B)	145.0	126.9	**124.8**	81.74	81.92	-	-	-
OFA (0.9B)	145.3	-	-	82.0	82.0	-	-	-
Flamingo (80B)	138.1	-	-	82.0	82.1	57.8*	-	-
BEiT-3 (1.9B)	147.6	-	-	84.2	84.0	-	-	-
PaLM-E (562B)	138.7	-	-	80.0	-	**66.1**	-	-
MoVie	-	-	-	69.26	-	-	74.9	56.8
PaLI (17B)	149.1	**127.0**	124.4	84.3	84.3	64.5	81.7	70.9
PaLI-X (55B)	**149.2**	126.3	124.3	**86.0**	**86.1**	**66.1**	**86.0**	**75.6**

表 16：在不使用 OCR 流水线输入的端到端建模下，COCO Captions（Karpathy 划分）、NoCaps、VQAv2、OKVQA 和 TallyQA 上的结果。“simple”和“complex”是测试子划分。

B.3 多语言字幕生成

XM-3600 上的多语言图像描述 Crossmodal-3600（XM3600）基准包含一组地理分布多样的 3600 张图像，并配有 36 种语言的人工标注参考描述 [23]。表 17 展示了 PaLI（当前 XM-3600 上的 SoTA）和 PaLI-X 的多语言结果，二者均以 224×224 分辨率进行微调。总体而言，在我们此处报告的 7 种语言中，PaLI-X 在其中 5 种语言上提升了 SoTA 性能（在所考虑的全部 35 种语言中有 14 种也是如此）；值得注意的是，英语上的性能相比 PaLI 低了 4 个 CIDEr 点。PaLI 和 PaLI-X 的 35 种语言平均 CIDEr 分数处于相近水平，PaLI 略有 +0.5 的优势。

Model	en	fr	hi	iw	ro	th	zh	35-lang avg.
PaLI	**98.1**	75.5	31.3	46.8	35.8	72.1	**36.5**	**53.6**
PaLI-X	94.2	**78.7**	**32.0**	**46.9**	**36.9**	**75.3**	36.1	53.1

表17：在 Crossmodal-3600 基准上，七种不同语言（英语、法语、印地语、希伯来语、罗马尼亚语、泰语和中文）的图像描述 CIDEr 分数，以及该基准涵盖的 35 种语言的平均分。两个模型均以 224×224 分辨率进行微调。

B.4 TallyQA 与复杂计数能力的涌现

我们在表 18 中展示了类似模型在广泛容量范围内的性能——从 700M 参数到 PaLI-X 的 55B 参数。图 5 中的图表说明，随着参数规模增加，简单计数似乎呈现出更线性的进展，而复杂计数似乎在 PaLI 17B 的性能所提供的数据点之前的某个位置表现出涌现。这与我们的直觉相符：复杂计数是一项真正的多模态任务，需要模型具备额外能力，即视觉信息与提示规范之间所需的对齐能力。

Model	TallyQA simple	TallyQA complex	Weighted average
PaLI (700M)	66.9	55.6	62.4
PaLI (3B)	72.0	56.7	65.9
PaLI (17B)	76.2	65.5	71.9
PaLI-X (55B)	81.3	71.0	77.2

表18：在 TallyQA 简单问题和复杂问题划分上的性能。所有模型均使用 224×224 的图像分辨率。

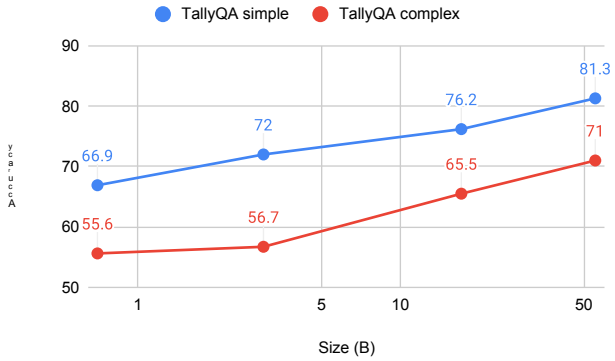


图 5：使用 PaLI 变体和 PaLI-X 在 TallyQA 简单与复杂划分上的性能。所有模型均使用 224×224 的图像分辨率。PaLI-X 清楚地展现了超过 3B 规模后在复杂计数上的涌现行为。

B.5 少样本建模细节

B.5.1 少样本形式化

图 6 展示了少样本模型的网络流程。每个样本的文本和提示部分被嵌入并拼接为 PaLI-X 模型的文本特征。每个样本的图像和目标图像由 ViT 组件独立编码，并且 ViT 特征沿序列轴拼接为视觉特征。在该序列的条件下，PaLI-X 解码器以自回归方式对目标图像进行预测。

编码器样本和解码器样本 虽然所有少样本示例和目标示例的图像都会作为输入提供给模型，但文本信息可以通过不同方式提供。在推理时，与少样本示例相关的所有文本信息都会提供给编码器；例如，在多答案 VQA 任务中，这包括包含问题的提示以及预期答案。目标示例的提示也会提供给编码器，而解码器的任务是为目标示例生成答案。然而，在训练期间，我们通过让模型同时预测目标示例和所选样本（*decoder shots*）的答案来提高训练效率。也就是说，我们将 N 个样本划分为两组：编码器样本（$N_e > 0$）和解码器样本（$N_d \geq 0$），使得 $N_e + N_d \leq N$。我们在预训练期间总共最多使用 4 个样本（即 $N = 4$），并从 1 到 N 中均匀随机采样 N_e。编码器样本的文本输入包含

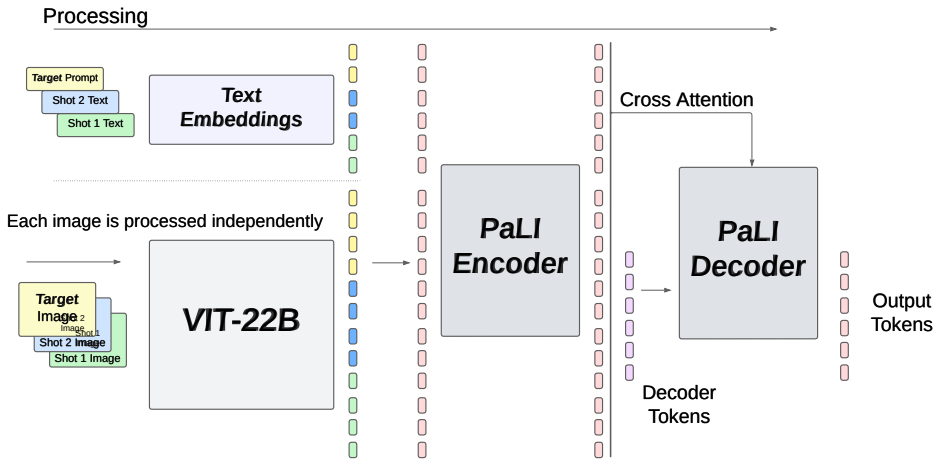


图 6：少样本示例如何被输入到模型组件中的详细视图。

同时包含提示和答案。然而，解码器示例的行为就像目标样例一样：它们输入到编码器的文本只包含提示，而解码器除了需要预测目标样例的答案外，还需要预测解码器示例的答案。

注意力重加权 增加 shots 的数量被证明具有挑战性，这可能是由于对目标示例输入 token 的交叉注意力被大量 shots 稀释了。为了解决这一问题，我们引入了一种注意力重加权机制。如图 7 所示，我们显式提升了解码器 token 与来自目标示例的编码 token（即目标图像和目标文本提示）之间的交叉注意力权重。

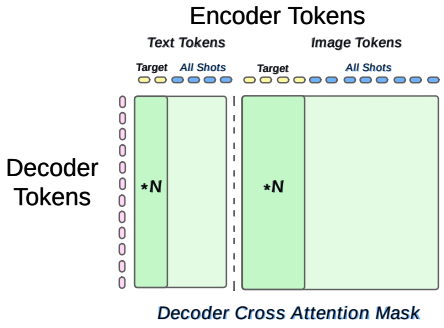


图 7：少样本下的重加权注意力。

具体而言，如果总共有 N 个 shots，那么在解码每个 token 时，我们会将来自编码器输出的目标图像和文本 token 的交叉注意力权重乘以 N。我们观察到，当我们为模型提供大量 shots（例如 32 shots）时，这种注意力重新加权技术尤其有帮助。[96] 引入了一种类似思路的技术，用于在推理时从不同的编码镜头线程中收集注意力权重时对其进行操控。

B.5.2 额外的小样本结果

多语言图像描述结果 表19报告了7种语言的CIDEr分数以及35种语言的平均分，以展示PaLI在XM3600基准上少样本设置下的多语言图像描述能力。预训练模型（未进行少样本微调）的平均分为22.7。PaLI-X模型在4-shot时的平均分为45.1，在32-shot时为47.1。请注意，32-shot PaLI-X的平均CIDEr分数仅比完全微调模型低6分，而完全微调模型每种语言大约使用60万个训练样本（而少样本方法不会更新模型参数）。

定性结果 图8展示了少样本图像描述和VQA任务中用于定性分析的3个示例。第一行展示了使用图像原始语言生成的图像描述，

[5]Equivalent with the Flamingo “0-shot” setting.

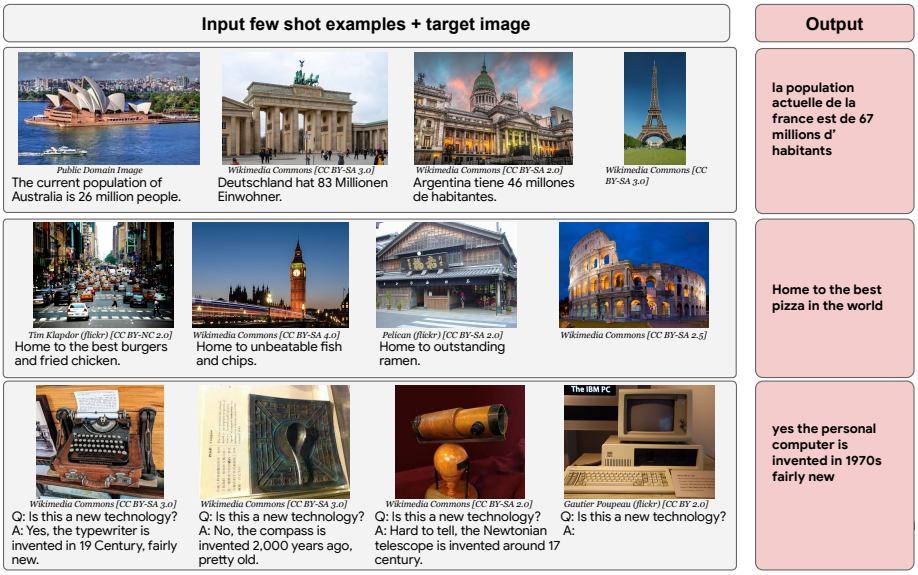


图 8：少样本图像描述（前两行）和 VQA（最后一行）任务的定性结果。

	Crossmodal-3600 Captioning							
	en	fr	hi	iw	ro	th	zh	35-lang avg.
PaLI-X 0-shot	48.8	25.0	10.5	20.1	13.0	33.3	18.4	22.7
PaLI-X (2 text-only shots[5])	54.5	46.7	12.0	22.2	9.4	40.3	23.7	25.8
PaLI-X 4 shots	77.8	62.5	22.2	38.7	30.2	56.0	27.7	45.1
PaLI-X 32 shots	81.4	66.1	25.6	40.6	32.4	59.4	29.7	47.1
PaLI-X (finetuned)	94.2	78.7	32.0	46.9	36.9	75.3	36.1	53.1

表 19：PaLI-X 模型在多语言图像描述任务上的少样本性能。

展示了少样本能力的跨多语言迁移。第二行用一个国家的流行美食为图像添加说明，表明少样本方法可以访问模型的世界知识。最后一行展示了一个带有类似解释场景的 VQA，我们询问图像中的技术是否“新”。一般来说，图中所示的个人电脑生产于 40 多年前，考虑到当前高科技发展的快速步伐，可以被视为旧技术。然而，3 个输入示例为“新”这一概念提供了详细校准，少样本模型成功理解了上下文，并针对这台非常老旧的 PC 输出“新”，同时给出了合理的解释。

B.5.3 少样本消融结果

在本节中，我们展示并讨论了我们为少样本设置所探索的一些消融结果，以指导我们对 PaLI-X 的最终设计选择。除非另有说明，我们使用一个具有相同编码器-解码器架构的 7 亿参数模型，该模型由 ViT-B/16 视觉编码器和 mT5-base 编码器-解码器语言模型组成。

池化与不池化图像 token 为了减轻多样本带来的计算负担，我们可以在拼接所有输入 token 之前，对每张图像的 token 进行池化（例如取平均）。这种池化图像 token 的模型在 4-shot COCO 图像描述任务中取得了 56.3 的 CIDEr 分数，显著低于完整模型 61.7 的 CIDEr 分数。这凸显了保留 ViT 编码器输出的所有 token 的重要性，尽管这会带来计算开销。

有限范围编码注意力。我们探索了按样本的图像-文本注意力，如 [10] 中所提出并应用的。在这种方法下，每个样本的图像查询标记只能关注

对应的文本标记，而文本查询标记可以关注所有标记。通过使用这种逐样本注意力模型，我们在 4-shot COCO 图像描述任务中取得了 59.6 的 CIDEr 分数，比全注意力模型 61.7 的 CIDEr 分数低 2.1 分。

大量样本下的注意力重加权。我们报告了早停的 PaLI-2 3B 模型在 COCO 图像描述任务上的少样本结果；在这种情况下，我们没有在训练中应用归一化注意力。我们提供了在 *inference* 期间针对不同数量的编码器样本、使用和不使用注意力重加权的测试结果。使用注意力重加权时，4、8 和 16 个样本分别取得了 82.1、84.3 和 84.5 的 CIDEr 分数提升。另一方面，不使用注意力重加权时，模型分别取得了 83.4、76.5 和 66.3。性能下降可能表明模型无法在大量样本中定位目标图像和文本提示，而注意力重加权有助于模型聚焦于目标特征。因此，我们决定在 PaLI-X 的微调过程中加入注意力重加权。

在编码器和解码器之间分配示例。我们在预训练期间探索同时使用编码器示例和解码器示例。我们在 PaLI-2 混合数据上预训练 PaLI-2 700M 模型，并改变编码器示例的数量（介于 1 到 4 之间）。剩余的示例（总数恰好达到 4）用作解码器示例。在 COCO 图像描述任务中，仅使用编码器示例时，4 个示例的 CIDEr 得分为 64.0。编码器和解码器示例的最佳组合达到 65.2 的 CIDEr 得分。这表明拆分示例会带来更具挑战性的预训练任务，有助于模型更高效地学习。

B.6 微调超参数

下游微调实验的超参数选择总结见表 20。如正文所述，对于所有下游微调实验，我们使用了一组精简的超参数，而没有进行繁重的逐任务优化。

Benchmark	learning rate schedule	Steps before LR decay to 0	batch size
COCO	linear decay from 1e-4	10k	256
VQAv2		20k	256
OCRVQA		20k	256
Multitask-VQA		20k	256
Multitask-Captioning		20k	256
All other		5k	128

表 20：用于微调 PaLI-X 的超参数。

B.7 多任务微调

我们对每个任务的测试集上的所有训练集混合数据进行了去重，以防止任何测试集样本泄漏到训练集中。该混合数据通过将每个子任务的训练样本合并在一起形成，并通过启发式调整实现更好的平衡。沿用单任务微调的分辨率设置，多任务图像描述和 VQA 微调分别使用 672 和 756 的图像分辨率。多任务微调总共涵盖约 500 万个样本，即在批量大小为 256 的情况下训练 2 万步。对于场景文本和文档理解任务，多任务微调采用端到端设置，不输入 OCR 流水线结果。

以下几个方面使多任务微调尤其具有挑战性：(i) 所有任务都使用相同的提示词，没有任务特定的指示符；因此，模型需要同时适应多个基准的风格。2) 我们不进行按任务划分的验证集优化。所有子任务都使用同一个检查点进行评估，但各任务以不同的速度收敛到其最优值。

B.8 消融实验

我们首先在表 22 中展示 ViT-22B 的 OCR 联合训练阶段所带来的优势。我们将原始 ViT-22B 以及经过额外 OCR 联合训练的 ViT-22B 与小型语言模型 mT5-base 配对，并在 4000 万 WebLI-OCR 数据上使用 splitOCR 目标对这些模型进行预训练，然后在 ST-VQA 上进行微调。图像和 OCR 分类的联合训练在以下方面具有显著优势

Model	VQA v2	OK VQA	Text VQA	VizWiz VQA	ST VQA	OCR VQA	Info VQA	Doc VQA	Chart QA	Avg.
Split	test-dev	val	val	test-dev	val	test	test	test	test	-
Previous Multi-task SOTA	84.3	64.5	68.4	71.6	75.1	71.3	40.0	76.6	70.5	-
Single-task FT	**86.0**	**66.1**	**71.9**	**72.6**	**80.2**	**75.9**	49.2	80.0	**70.9**	-
Multi-task FT	84.3	63.5	71.4	71.4	79.0	73.4	**50.7**	**80.9**	70.6	-
Multi-task (+/-)	-1.7	-2.6	-0.5	-1.2	-1.2	-2.4	+1.5	+0.9	-0.3	-0.8

表21：VQA中多任务微调与单任务微调的得分对比。部分任务报告的是验证集或test-dev集上的数值。

ST-VQA 和 TextVQA。与此同时，在场景文本占比并不高的 VQAv2 上，性能也有所提升。此外，我们发现，将左上角图像块设为白色曾有助于在 ViT-22B 上进行图像分类和 OCR 分类的协同训练，但对于 PaLI-X 的后续训练并不是必需的。

对于 PaLI-X 训练流程的消融实验，我们使用了一个 5B 模型，其中包含 3B 参数的 UL2-3B 和 2B 参数的 ViT-G，这大约是 PaLI-X 55B 模型按 10:1 缩小后的规模。

Model	OCR-task Indicator	ST-VQA	TextVQA	VQAv2	3-task avg.
mT5-base + Vanilla ViT-22B	No	42.6	36.1	68.9	49.2
mT5-base + ViT-22B-OCR	No	**47.0**	38.9	69.8	**51.9**
mT5-base + ViT-22B-OCR	Yes	46.2	**39.4**	**70.2**	**51.9**

表 22：ViT-22B 的 OCR 协同训练阶段的优势。预训练使用 224×224 分辨率进行，微调使用 448×448。报告的数值基于验证集。

对于第一阶段训练，我们在表23中表明，加入图像标记生成不会损害主要图像+语言理解任务上的性能。

Mixture	COCO	VQAv2
without ViT-VQGAN	139.3	77.3
with 10% ViT-VQGAN	139.7	77.1

表 23：消融实验表明，添加 ViT-VQGAN 标记不会损害理解性能（图像描述和 VQA 任务）。

C 附加结果：视频字幕生成和问答

下面我们简要描述用于评估的每个视频数据集。请注意，我们在进行实验时重新收集了数据，这导致在某些情况下不同划分中的有效视频数量有所不同，见表 24。

这些描述指的是原始数据集大小，但我们训练所用的视频数量（有时显著）更少——确切数量见表 24。这是因为在撰写本文时，并非数据集中的所有视频都可在线获取（例如，由于用户删除）。

C.1 数据集与基准测试

MSR-VTT [55]：该数据集包含 1 万个用于视频字幕生成的开放域视频片段，每个片段配有 20 条字幕。每个视频片段的时长在 10 到 30 秒之间。我们遵循 [55] 提出的标准划分，并在测试集上报告结果。

VATEX [56]：VATEX 包含从 Kinetics-600 数据集中采样的 4.1 万个视频的描述，每个视频有 10 条英文描述。我们在英文公开测试集上报告结果。

ActivityNet Captions [57]：该数据集包含针对 2 万个视频的 10 万个时间定位句子。我们遵循标准划分，将数据集的 50/25/25% 分别用于训练、验证和测试，并在评估时按照 [57] 使用真实时间提案。请注意，按照其他工作 [62]，我们使用 val_1 划分进行验证，使用 val_2 划分进行测试。

时间中的口语瞬间（SMIT）[58]：该数据集由通过音频录制为 50 万个短视频片段获取的长字幕组成。虽然该数据集传统上仅用于文本到视频检索，但我们发现它也是一个强大的字幕生成基准，因为它是规模最大的人工标注视频文本字幕数据集。

ActivityNet-QA [61]：该数据集包含 ActivityNet 数据集 [97] 中视频的 58,000 个问答对。我们报告测试集上的准确率（使用精确字符串匹配）。请注意，我们对所有 VideoQA 数据集都采用开放式生成。

MSR-VTT-QA [60]：该数据集是在 MSR-VTT 数据集基础上使用半自动流程创建的。我们在测试集划分上报告准确率（使用精确字符串匹配）。

NExT-QA [59]：我们关注开放式问答任务，该任务包含 52,044 个问答对，覆盖总计 5,440 个视频（从 VidOr 数据集 [98] 中采样）。严格遵循 NExT-QA [59] 和 Flamingo [10]，我们在测试集上报告 Wu-Palmer 相似度（WUPS）。

		MSR-VTT	VATEX	ANet-Cap	SMIT	M-V-QA	ANet-QA	NExT-QA
Original size	train	6513	25991	37421	481094	158581	32000	37523
	valid.	497	3000	17505	14604	12278	18000	5343
	test	2990	6000	17031	3513	72821	8000	9178
Dataset size	train	4768	22902	30982	481094	116943	28020	37523
	valid.	327	2657	14604	8096	8215	15890	5343
	test	2144	5276	14234	3513	53014	7050	9178
% Remaining	train	73.21	88.12	82.79	100.00	73.74	87.56	100.00
	valid.	65.79	88.57	83.43	100.00	66.91	88.28	100.00
	test	71.71	87.93	83.58	100.00	72.80	88.13	100.00

表24：我们从相应的数据源重新收集了这些数据集。对于每个视频包含多个问答对的情况，我们报告问答对的数量。类似地，对于 ActivityNet Captions，我们报告字幕的数量。由于在原始数据集定义之后有些视频被移除而缺失，我们的大多数数据集缺少了10%或更多的视频。

D 附加结果：图像分类

零样本和微调评估设置 此处实验所使用的设置采用 PaLI-X 模型通过字幕生成提示直接生成（英文）类别名称。如果输出与类别名称完全匹配，则认为输出正确（ImageNet-REAL 除外，在该数据集中我们会检查输出对应的类别是否在正确标签集合中）。

零样本评估结果 我们使用与 PaLI [5] 中相同的评分技术，在零样本设置下评估 PaLI-X（未在任何 Imagenet 数据上进行训练）。我们使用第一阶段训练后获得的 PaLI-X 模型（使用基础的 224 图像分辨率）。

结果见表 25。我们将结果与 PaLI [5]（此前的零样本生成式 SOTA）以及 Flamingo [10]（另一种架构相似的生成式模型，其 1-shot 和 5-shot 结果具有可比性）进行了比较。总体而言，我们报告 PaLI 和 PaLI-X 在 0-shot 设置下的结果相近。

Model (ImageNet data)	INet	REAL	INet-R	INet-A	INet-Sketch	INet-v2	ObjNet
Flamingo-80B (1-shot)	71.9	-	-	-	-	-	-
Flamingo-80B (5-shot)	77.3	-	-	-	-	-	-
PaLI (17B) (0-shot)	**72.11**	**76.43**	81.97	44.70	**63.83**	**64.46**	42.62
PaLI-X (0-shot)	71.16	75.75	**82.96**	**46.13**	61.58	63.91	**44.58**

表 25：在 ImageNet [66]、ImageNet-REAL [67]、ImageNet-R [68]、ImageNet-A [69]、ImageNet-Sketch [70]、Imagenet-v2 [71] 和 ObjectNet [99] 上的 0-shot 图像分类 Top 1 准确率结果。

微调 为了测试图像分类能力，我们在 ImageNet [66] 上对 PaLI-X 进行微调，并在 ImageNet-REAL [67] 以及分布外数据集 ImageNet-R [68]、ImageNet-A [69]、ImageNet-Sketch [70]、ImageNet-v2 [71] 上评估所得模型。

我们使用第一训练阶段的模型（分辨率为 224）以及最后训练阶段的模型（分辨率为 756）。我们在所有运行中使用相同的训练超参数（未进行任何超参数调优而选定）。

结果见表 26。我们将结果与开放词汇生成模型 GiT2 [9]（使用 384 图像分辨率）进行比较，后者是当前在 ImageNet 上进行全量微调的 SOTA。PaLI-X 在 ImageNet 以及其他数据集上取得了接近生成模型 SOTA 的结果。

Model (resolution)	INet	REAL	INet-R	INet-A	INet-Sketch	INet-v2
GIT2 (384)	**89.22**	-	-	-	-	-
PaLI 3B (224)	85.11	88.71	**81.11**	45.71	70.00	78.23
PaLI 17B (224)	86.13	88.84	78.21	50.00	71.21	78.91
PaLI-X (224)	88.22	90.36	77.66	55.97	72.56	81.42
PaLI-X (756)	88.82	90.80	79.97	**73.47**	**73.39**	83.48
PaLI-X † (756)	89.19	**90.98**	80.06	72.57	73.37	**83.66**

表26：在以下数据集上使用 ImageNet [66] 微调的分类（top-1）准确率：ImageNet、ImageNet-REAL [67]、ImageNet-R [68]、ImageNet-A [69]、ImageNet-Sketch [70]、ImageNet-v2 [71]（括号内为分辨率）。PaLI-X † 微调步数增加了 2.2 倍。

E 目标检测

E.1 将目标检测作为 VLM 任务

目标检测的表述方式与 Pix2seq [72] 类似，但有两个关键区别：使用自然语言词汇表，以及类别条件化。提示类别会以 detect class1 and class2 and class3 的格式输入到 PaLI-X 的文本编码器中。模型被训练为只输出与该提示中的类别对应的边界框。我们以与 pix2seq [72] 相同的风格表示边界框坐标；也就是说，使用 4 个整数 y_{min} x_{min} y_{max} x_{max}，取值范围为 0 到 999。图 9 展示了一个输入示例。

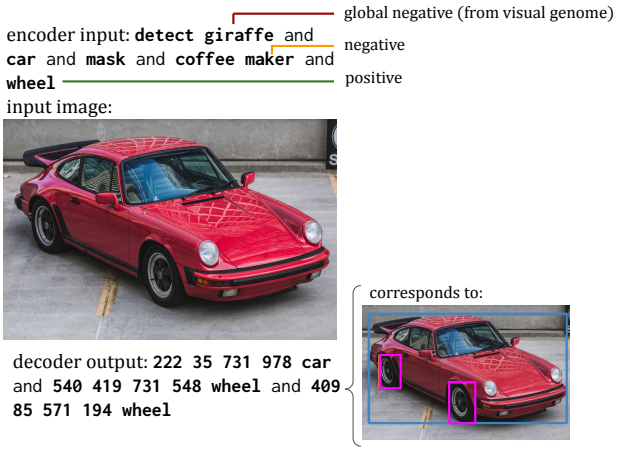


Image credits: Matthew Henry, burst, https://burst.shopify.com/photos/vintage-red-porsche

图 9：一个训练样本对示例，包括文本提示、图像和预期输出。该提示包含多个类别；我们展示了一个假设的 Open Images V4 示例，其中正类为“汽车”和“车轮”，负类为“长颈鹿”，全局负类为“面具”和“咖啡机”（从 Visual Genome 标签空间中采样）。

提示采样超参数 在训练期间，会为每个示例采样一个提示。我们根据三部分信息构建提示：

- *Positives*：这些是图像中确定存在的对象的边界框。在训练期间，对于每个样本，我们采样 $p^+ \sim \mathcal{U}(0, P^+_{\max})$，并保留该比例的正样本。
- *Negatives*：这些是已知的实例负类，即明确不存在对象的边界框。对于像 COCO 这样穷尽标注的数据集，这就是未标注为正类的类别。对于像 LVIS 这样非穷尽标注的数据集，这些是未标注为正类、但已呈现给标注者的类别。在训练期间采样 $f^- \sim \mathcal{U}(0, 5.0)$，并最多使用 $f^- \times n^+$，其中 n^+ 是采样 p^+ 后的正类数量。
- *Global negatives*：这些是未被明确标注为负类的负样本。它们来自结合了多个检测数据集的更广泛标签空间。对于给定示例，有效的全局负类由更广泛标签空间中未被明确标注为正类或负类的类别组成。在训练期间，我们采样 $f^{GN} \sim \mathcal{U}(0, 5.0)$ 并追加 $f \times n^+$ 个全局负类，其中 n_+ 是在采样 p^+ 后的正类数量。默认情况下，将 Visual Genome、Objects365 和 OpenImagesV4 的组合标签空间用作全局标签空间，但检测微调除外，在该情况下还会加入 LVIS 和 COCO 标签空间。

我们将总类别数截断为 $n_{\max}$。$n_{\max}$ 和 $P^+_{\max}$) 会针对每个数据集进行调优，以满足序列长度要求。截断后，我们会在提示中打乱类别顺序。

E.2 预处理

在预训练期间，按照 OwlViT [28] 的协议，对数据进行预处理以移除所有 LVIS-rare 标签。检测微调时不进行此操作。图像会被随机水平翻转，并随机缩放到其原始尺寸的 0.3 到 2.0 × 之间，随后在当前训练分辨率下随机选择一个正方形裁剪区域。如果图像被缩放到小于当前分辨率，则保持不变。最后将图像填充为正方形。

E.3 正文图 2 中所用图像的许可和署名

- 西瓜：图片来源：Sarah Pflug https://burst.shopify.com/photos/cutting-watermelon.
- 碗：https://www.flickr.com/photos/ariesandrea/502826051/ CC-BY-NC-ND 2.0
- 商务猫 图片来源：Sarah Pflug，https://burst.shopify.com/photos/business-cat-in-office
- 墙面图片来源：Matthew Henry
  https://burst.shopify.com/photos/man-walking-in-front-of-this-is-paradise-wall?c=urban-life

参考文献

[1] Aakanksha Chowdhery, Sharan Narang, Jacob Devlin, Maarten Bosma, Gaurav Mishra, Adam Roberts, Paul Barham, Hyung Won Chung, Charles Sutton, Sebastian Gehrmann 等。PaLM：使用 Pathways 扩展语言建模。*arXiv preprint arXiv:2204.02311*，2022。[2] Tom B. Brown, Benjamin Mann, Nick Ryder, Jared Kaplan Melanie Subbiah, Prafulla Dhariwal, Arvind Neelakantan, Pranav Shyam, Girish Sastry, Amanda Askell, Sandhini Agarwal, Ariel Herbert-Voss, Gretchen Krueger, Tom Henighan, Rewon Child, Aditya Ramesh, Daniel M. Ziegler, Jeffrey Wu, Christopher Hesse Clemens Winter, Mark Chen, Eric Sigler, Mateusz Litwin, Scott Gray, Benjamin Chess, Jack Clark, Christopher Berner, Sam McCandlish, Alec Radford, Ilya Sutskever, and Dario Amodei。语言模型是少样本学习者。*NeurIPS*，2020。[3] Nan Du, Yanping Huang, Andrew M Dai, Simon Tong, Dmitry Lepikhin, Yuanzhong Xu, Maxim Krikun, Yanqi Zhou, Adams Wei Yu, Orhan Firat, Barret Zoph, Liam Fedus, Maarten P Bosma, Zongwei Zhou, Tao Wang, Emma Wang, Kellie Webster, Marie Pellat, Kevin Robinson, Kathleen Meier-Hellstern, Toju Duke, Lucas Dixon, Kun Zhang, Quoc Le, Yonghui Wu, Zhifeng Chen, and Claire Cui。GLaM：使用专家混合高效扩展语言模型。载于 *ICML*，2022。[4] Rohan Anil, Andrew M. Dai, Orhan Firat, Melvin Johnson, Dmitry Lepikhin, Alexandre Passos, Siamak Shakeri, Emanuel Taropa, Paige Bailey, Zhifeng Chen, Eric Chu, Jonathan H. Clark, Laurent El Shafey, Yanping Huang, Kathy Meier-Hellstern, Gaurav Mishra, Erica Moreira, Mark Omernick, Kevin Robinson, Sebastian Ruder, Yi Tay, Kefan Xiao, Yuanzhong Xu, Yujing Zhang, Gustavo Hernandez Abrego, Junwhan Ahn, Jacob Austin, Paul Barham, Jan Botha, James Bradbury, Siddhartha Brahma, Kevin Brooks, Michele Catasta, Yong Cheng, Colin Cherry, Christopher A. Choquette-Choo, Aakanksha Chowdhery, Clément Crepy, Shachi Dave, Mostafa Dehghani, Sunipa Dev, Jacob Devlin, Mark Díaz, Nan Du, Ethan Dyer, Vlad Feinberg, Fangxiaoyu Feng, Vlad Fienber, Markus Freitag, Xavier Garcia, Sebastian Gehrmann, Lucas Gonzalez, Guy Gur-Ari, Steven Hand, Hadi Hashemi, Le Hou, Joshua Howland, Andrea Hu, Jeffrey Hui, Jeremy Hurwitz, Michael Isard, Abe Ittycheriah, Matthew Jagielski, Wenhao Jia, Kathleen Kenealy, Maxim Krikun, Sneha Kudugunta, Chang Lan, Katherine Lee, Benjamin Lee, Eric Li, Music Li, Wei Li, YaGuang Li, Jian Li, Hyeontaek Lim, Hanzhao Lin, Zhongtao Liu, Frederick Liu, Marcello Maggioni, Aroma Mahendru, Joshua Maynez, Vedant Misra, Maysam Moussalem, Zachary Nado, John Nham, Eric Ni, Andrew Nystrom, Alicia Parrish, Marie Pellat, Martin Polacek, Alex Polozov, Reiner Pope, Siyuan Qiao, Emily Reif, Bryan Richter, Parker Riley, Alex Castro Ros, Aurko Roy, Brennan Saeta, Rajkumar Samuel, Renee Shelby, Ambrose Slone, Daniel Smilkov, David R. So, Daniel Sohn, Simon Tokumine, Dasha Valter, Vijay Vasudevan, Kiran Vodrahalli, Xuezhi Wang, Pidong Wang, Zirui Wang, Tao Wang, John Wieting, Yuhuai Wu, Kelvin Xu, Yunhan Xu, Linting Xue, Pengcheng Yin, Jiahui Yu,

Qiao Zhang、Steven Zheng、Ce Zheng、Weikang Zhou、Denny Zhou、Slav Petrov 和 Yonghui Wu。Palm 2 技术报告，2023 年。

[5] Xi Chen, Xiao Wang, Soravit Changpinyo, AJ Piergiovanni, Piotr Padlewski, Daniel Salz, Sebas- tian Alexander Goodman, Adam Grycner, Basil Mustafa, Lucas Beyer, Alexander Kolesnikov, Joan Puigcerver, Nan Ding, Keran Rong, Hassan Akbari, Gaurav Mishra, Linting Xue, Ashish Thapliyal, James Bradbury, Weicheng Kuo, Mojtaba Seyedhosseini, Chao Jia, Burcu Karagol Ayan, Carlos Riquelme, Andreas Steiner, Anelia Angelova, Xiaohua Zhai, Neil Houlsby, and Radu Soricut. PaLI：一种联合扩展的多语言语言-图像模型。收录于 *ICLR*，2023。

[6] Mostafa Dehghani、Josip Djolonga、Basil Mustafa、Piotr Padlewski、Jonathan Heek、Justin Gilmer、Andreas Steiner、Mathilde Caron、Robert Geirhos、Ibrahim Alabdulmohsin、Rodolphe Je- natton、Lucas Beyer、Michael Tschannen、Anurag Arnab、Xiao Wang、Carlos Riquelme、Matthias Minderer、Joan Puigcerver、Utku Evci、Manoj Kumar、Sjoerd van Steenkiste、Gamaleldin F. Elsayed、Aravindh Mahendran、Fisher Yu、Avital Oliver、Fantine Huot、Jasmijn Bastings、Mark Patrick Collier、Alexey Gritsenko、Vighnesh Birodkar、Cristina Vasconcelos、Yi Tay、Thomas Mensink、Alexander Kolesnikov、Filip Pavetić、Dustin Tran、Thomas Kipf、Mario Lučić、Xiaohua Zhai、Daniel Keysers、Jeremiah Harmsen 和 Neil Houlsby。将视觉 Transformer 扩展到 220 亿参数。发表于 *ICML*，2023 年。

[7] Yi Tay、Mostafa Dehghani、Vinh Q. Tran、Xavier Garcia、Jason Wei、Xuezhi Wang、Hyung Won Chung、Siamak Shakeri、Dara Bahri、Tal Schuster、Huaixiu Steven Zheng、Denny Zhou、Neil Houlsby 和 Donald Metzler。UL2：统一语言学习范式。载于 *ICLR*，2023。

[8] Fangyu Liu、Julian Martin Eisenschlos、Francesco Piccinno、Syrine Krichene、Chenxi Pang、Kenton Lee、Mandar Joshi、Wenhu Chen、Nigel Collier 和 Yasemin Altun。DePlot：通过图表到表格翻译实现的一次性视觉语言推理。*arXiv preprint arXiv:2212.10505*，2022。

[9] Jianfeng Wang、Zhengyuan Yang、Xiaowei Hu、Linjie Li、Kevin Lin、Zhe Gan、Zicheng Liu、Ce Liu 和 Lijuan Wang。GIT：用于视觉和语言的生成式图像到文本 Transformer。*TMLR*，2022。

[10] Jean-Baptiste Alayrac、Jeff Donahue、Pauline Luc、Antoine Miech、Iain Barr、Yana Hasson、Karel Lenc、Arthur Mensch、Katie Millican、Malcolm Reynolds 等。Flamingo：用于小样本学习的视觉语言模型。载于 *NeurIPS*，2022。

[11] Shaohan Huang、Li Dong、Wenhui Wang、Yaru Hao、Saksham Singhal、Shuming Ma、Tengchao Lv、Lei Cui、Owais Khan Mohammed、Qiang Liu 等。语言并非你所需要的一切：将感知与语言模型对齐。*arXiv preprint arXiv:2302.14045*，2023。

[12] OpenAI. Gpt-4 技术报告，2023。

[13] Tom Brown, Benjamin Mann, Nick Ryder, Melanie Subbiah, Jared D Kaplan, Prafulla Dhariwal, Arvind Neelakantan, Pranav Shyam, Girish Sastry, Amanda Askell 等。语言模型是少样本学习者。*Advances in neural information processing systems*, 33:1877–1901, 2020.

[14] 董庆修、李磊、戴大麦、郑策、吴志勇、常宝宝、孙旭、徐晶晶、隋智芳。关于上下文学习的综述。*arXiv preprint arXiv:2301.00234*，2022。

[15] Jason Wei、Xuezhi Wang、Dale Schuurmans、Maarten Bosma、brian ichter、Fei Xia、Ed Chi、Quoc V Le 和 Denny Zhou。思维链提示激发大型语言模型中的推理能力。载于 *Advances in Neural Information Processing Systems*，2022 年。

[16] Denny Zhou、Nathanael Schärli、Le Hou、Jason Wei、Nathan Scales、Xuezhi Wang、Dale Schuurmans、Claire Cui、Olivier Bousquet、Quoc Le 和 Ed Chi。Least-to-most prompting enables complex reasoning in large language models。发表于 *ICLR*，2023。

[17] Jerry Wei、Jason Wei、Yi Tay、Dustin Tran、Albert Webson、Yifeng Lu、Xinyun Chen、Hanxiao Liu、Da Huang、Denny Zhou 等。更大的语言模型以不同方式进行上下文学习。*arXiv preprint arXiv:2303.03846*，2023。[18] Yanda Chen、Ruiqi Zhong、Sheng Zha、George Karypis 和 He He。通过语言模型上下文调优进行元学习。见 *ACL*，2022。[19] Jiasen Lu、Christopher Clark、Rowan Zellers、Roozbeh Mottaghi 和 Aniruddha Kembhavi。Unified-IO：用于视觉、语言和多模态任务的统一模型。见 *ICLR*，2023。[20] Gang Li 和 Yang Li。Spotlight：使用具有焦点的视觉-语言模型理解移动 UI。见 *ICLR*，2023。

[21] Zirui Wang、Jiahui Yu、Adams Wei Yu、Zihang Dai、Yulia Tsvetkov 和 Yuan Cao。SimVLM：使用弱监督进行简单视觉语言模型预训练。收录于 *ICLR*，2022。 [22] Piyush Sharma、Nan Ding、Sebastian Goodman 和 Radu Soricut。Conceptual Captions：用于自动图像字幕生成的经过清洗、上位词化的图像替代文本数据集。收录于 *ACL*，2018。 [23] Ashish V. Thapliyal、Jordi Pont-Tuset、Xi Chen 和 Radu Soricut。Crossmodal-3600：一个大规模多语言多模态评估数据集。收录于 *EMNLP*，2022。 [24] Jihyung Kil、Soravit Changpinyo、Xi Chen、Hexiang Hu、Sebastian Goodman、Wei-Lun Chao 和 Radu Soricut。PreSTU：用于场景文本理解的预训练。*arXiv preprint arXiv:2209.05534*，2022。 [25] Soravit Changpinyo、Doron Kuklinsky、Idan Szpektor、Xi Chen、Nan Ding 和 Radu Soricut。VQA 所需的可能只是图像字幕。收录于 *NAACL*，2022。 [26] AJ Piergiovanni、Weicheng Kuo 和 Anelia Angelova。为开放词汇任务预训练图像-语言 Transformer。收录于
T4V: Transformers for Vision Workshop, Conference on Computer Vision and Pattern Recognition，2022。 [27] Kenton Lee、Mandar Joshi、Iulia Turc、Hexiang Hu、Fangyu Liu、Julian Eisenschlos、Urvashi Khandelwal、Peter Shaw、Ming-Wei Chang 和 Kristina Toutanova。Pix2Struct：将截图解析作为视觉语言理解的预训练。收录于 *ICML*，2023。 [28] Matthias Minderer、Alexey Gritsenko、Austin Stone、Maxim Neumann、Dirk Weissenborn、Alexey Dosovitskiy、Aravindh Mahendran、Anurag Arnab、Mostafa Dehghani、Zhuoran Shen 等。使用视觉 Transformer 进行简单的开放词汇目标检测。收录于 *ECCV*，2022。 [29] Jiahui Yu、Xin Li、Jing Yu Koh、Han Zhang、Ruoming Pang、James Qin、Alexander Ku、Yuanzhong Xu、Jason Baldridge 和 Yonghui Wu。使用改进的 VQGAN 进行向量量化图像建模。收录于 *ICLR*，2022。 [30] Andrej Karpathy 和 Li Fei-Fei。用于生成图像描述的深度视觉-语义对齐。收录于 *CVPR*，2015。 [31] Harsh Agrawal、Karan Desai、Yufei Wang、Xinlei Chen、Rishabh Jain、Mark Johnson、Dhruv Batra、Devi Parikh、Stefan Lee 和 Peter Anderson。nocaps：大规模新颖对象字幕生成。收录于 *Proceedings of the IEEE/CVF International Conference on Computer Vision*，第 8948–8957 页，2019。

[32] Oleksii Sidorov、Ronghang Hu、Marcus Rohrbach 和 Amanpreet Singh。TextCaps：一个用于具备阅读理解的图像描述的数据集。见 *European conference on computer vision*，第 742–758 页，2020 年。

[33] Danna Gurari、Yinan Zhao、Meng Zhang 和 Nilavra Bhattacharya。为盲人拍摄的图像生成说明。在 *Computer Vision–ECCV 2020: 16th European Conference, Glasgow, UK, August 23–28, 2020, Proceedings, Part XVII 16* 中，第 417–434 页。Springer，2020。[34] Bryan Wang、Gang Li、Xin Zhou、Zhourong Chen、Tovi Grossman 和 Yang Li。Screen2Words：通过多模态学习实现自动移动 UI 摘要。在 *The 34th Annual ACM Symposium on User Interface Software and Technology* 中，UIST ’21，第 498–510 页，美国纽约州纽约，2021。Association for Computing Machinery。[35] Yang Li、Gang Li、Luheng He、Jingjie Zheng、Hong Li 和 Zhiwei Guan。Widget Captioning：为移动用户界面元素生成自然语言描述。在 *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP)* 中，第 5495–5510 页，线上，2020 年 11 月。Association for Computational Linguistics。[36] Yash Goyal、Tejas Khot、Douglas Summers-Stay、Dhruv Batra 和 Devi Parikh。让 VQA 中的 V 发挥作用：提升图像理解在视觉问答中的作用。在 *Proceedings of the IEEE conference on computer vision and pattern recognition* 中，第 6904–6913 页，2017。[37] Kenneth Marino、Mohammad Rastegari、Ali Farhadi 和 Roozbeh Mottaghi。OK-VQA：一个需要外部知识的视觉问答基准。在 *Proceedings of the IEEE/cvf conference on computer vision and pattern recognition* 中，第 3195–3204 页，2019。[38] Manoj Acharya、Kushal Kafle 和 Christopher Kanan。Tallyqa：回答复杂计数问题。在 *Proceedings of the AAAI conference on artificial intelligence* 中，第 33 卷，第 8076–8084 页，2019。

[39] Amanpreet Singh、Vivek Natarajan、Meet Shah、Yu Jiang、Xinlei Chen、Dhruv Batra、Devi Parikh 和 Marcus Rohrbach。迈向能够阅读的 VQA 模型。见 *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*，第 8317–8326 页，2019 年。[40] Danna Gurari、Qing Li、Abigale J Stangl、Anhong Guo、Chi Lin、Kristen Grauman、Jiebo Luo 和 Jeffrey P Bigham。VizWiz 大挑战：回答盲人提出的视觉问题。见 *Proceedings of the IEEE conference on computer vision and pattern recognition*，第 3608–3617 页，2018 年。[41] Ali Furkan Biten、Rubèn Tito、Andrés Mafla、Lluis Gomez、Marçal Rusiñol、C.V. Jawahar、Ernest Valveny 和 Dimosthenis Karatzas。场景文本视觉问答。见 *2019 IEEE/CVF International Conference on Computer Vision (ICCV)*，第 4290–4300 页，2019 年。[42] Anand Mishra、Shashank Shekhar、Ajeet Kumar Singh 和 Anirban Chakraborty。Ocr-vqa：通过阅读图像中的文本进行视觉问答。见 *ICDAR*，2019 年。[43] Minesh Mathew、Viraj Bagal、Rubèn Tito、Dimosthenis Karatzas、Ernest Valveny 和 CV Jawahar。Infographicvqa。见 *Proceedings of the IEEE/CVF Winter Conference on Applications of Computer Vision*，第 1697–1706 页，2022 年。

[44] Minesh Mathew、Dimosthenis Karatzas 和 CV Jawahar。Docvqa：用于文档图像 VQA 的数据集。载于 *Proceedings of the IEEE/CVF winter conference on applications of computer vision*，第 2200–2209 页，2021 年。

[45] Aniruddha Kembhavi、Mike Salvato、Eric Kolve、Minjoon Seo、Hannaneh Hajishirzi 和 Ali Farhadi。一张图表胜过十二张图像。载于 *ECCV*，2016。

[46] Ahmed Masry、Do Long、Jia Qing Tan、Shafiq Joty 和 Enamul Hoque。ChartQA：一个通过视觉和逻辑推理回答图表相关问题的基准。在 *Findings of ACL*，2022。

[47] Hexiang Hu、Yi Luan、Yang Chen、Urvashi Khandelwal、Mandar Joshi、Kenton Lee、Kristina Toutanova 和 Ming-Wei Chang。开放域视觉实体识别：迈向识别数百万维基百科实体。*arXiv preprint arXiv:2302.11154*，2023。

[48] Yang Chen, Hexiang Hu, Yi Luan, Haitian Sun, Soravit Changpinyo, Alan Ritter, and Ming-Wei Chang. 预训练的视觉与语言模型能回答视觉信息寻求型问题吗? *arXiv preprint arXiv:2302.11713*, 2023.

[49] Wenhui Wang、Hangbo Bao、Li Dong、Johan Bjorck、Zhiliang Peng、Qiang Liu、Kriti Aggarwal、Owais Khan Mohammed、Saksham Singhal、Subhojit Som 等。图像作为一门外语：用于所有视觉和视觉-语言任务的 BEiT 预训练。*arXiv preprint arXiv:2208.10442*，2022。

[50] Danny Driess、Fei Xia、Mehdi S. M. Sajjadi、Corey Lynch、Aakanksha Chowdhery、Brian Ichter、Ayzaan Wahid、Jonathan Tompson、Quan Vuong、Tianhe Yu、Wenlong Huang、Yevgen Chebotar、Pierre Sermanet、Daniel Duckworth、Sergey Levine、Vincent Vanhoucke、Karol Hausman、Marc Toussaint、Klaus Greff、Andy Zeng、Igor Mordatch 和 Pete Florence。PaLM-E：一种具身多模态语言模型。载于 *arXiv*，2023。

[51] Duy-Kien Nguyen、Vedanuj Goswami 和 Xinlei Chen。重新审视用于视觉计数及更广泛任务的调制卷积。*ICLR*，2021。

[52] Yixuan Qiao, Hao Chen, Jun Wang, Yihao Chen, Xianbin Ye, Ziliang Li, Xianbiao Qi, Peng Gao, and Guotong Xie. 2021 年 TextVQA 挑战赛冠军团队 Mia：使用预训练序列到序列模型进行视觉与语言表征学习。*arXiv preprint arXiv:2106.15332*, 2021.

[53] Ali Furkan Biten、Ron Litman、Yusheng Xie、Srikar Appalaraju 和 R. Manmatha。LaTr：用于场景文本 VQA 的布局感知 Transformer。发表于 *CVPR*，2022。[54] Zineng Tang、Ziyi Yang、Guoxin Wang、Yuwei Fang、Yang Liu、Chenguang Zhu、Michael Zeng、Cha Zhang 和 Mohit Bansal。统一视觉、文本和布局以实现通用文档处理。发表于 *CVPR*，2023。[55] Jun Xu、Tao Mei、Ting Yao 和 Yong Rui。MSR-VTT：用于连接视频与语言的大规模视频描述数据集。发表于 *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*，2016。

[56] Xin Wang, Jiawei Wu, Junkun Chen, Lei Li, Yuan-Fang Wang, and William Yang Wang. VATEX：用于视频与语言研究的大规模高质量多语言数据集。见 *ICCV*，2019。 [57] Ranjay Krishna, Kenji Hata, Frederic Ren, Li Fei-Fei, and Juan Carlos Niebles. 视频中的密集字幕事件。见 *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*，2017。 [58] Mathew Monfort, SouYoung Jin, Alexander Liu, David Harwath, Rogerio Feris, James Glass, and Aude Oliva. Spoken Moments：从视频描述中学习联合音频-视觉表示。见 *CVPR*，2021。 [59] Junbin Xiao, Xindi Shang, Angela Yao, and Tat-Seng Chua. NExT-QA：从问答到解释时序动作的下一阶段。见 *CVPR*，2021。 [60] Dejing Xu, Zhou Zhao, Jun Xiao, Fei Wu, Hanwang Zhang, Xiangnan He, and Yueting Zhuang. 通过对外观和运动逐步细化注意力进行视频问答。见 *MM*，2017。 [61] Zhou Yu, Dejing Xu, Jun Yu, Ting Yu, Zhou Zhao, Yueting Zhuang, and Dacheng Tao. ActivityNet-QA：一个通过问答理解复杂网络视频的数据集。见 *AAAI*，2019。 [62] Teng Wang, Ruimao Zhang, Zhichao Lu, Feng Zheng, Ran Cheng, and Ping Luo. 基于并行解码的端到端密集视频字幕生成。见 *Proceedings of the IEEE/CVF International Conference on Computer Vision*，第 6847–6857 页，2021。

[63] 程峰、王希子、雷杰、David Crandall、Mohit Bansal 和 Gedas Bertasius。VindLU：有效视频-语言预训练的方法。收录于 *CVPR*，2023。

[64] Paul Hongsuck Seo、Arsha Nagrani、Anurag Arnab 和 Cordelia Schmid。用于多模态视频字幕生成的端到端生成式预训练。载于 *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*，第 17959–17968 页，2022。 [65] Mario Fritz Mateusz Malinowski。基于不确定输入的真实世界场景问答的多世界方法。载于 *NeurIPS*，2014。 [66] Jia Deng、Wei Dong、Richard Socher、Li-Jia Li、Kai Li 和 Li Fei-Fei。ImageNet：一个大规模层次化图像数据库。载于 *2009 IEEE conference on computer vision and pattern recognition*，第 248–255 页，2009。 [67] Lucas Beyer、Olivier J Hénaff、Alexander Kolesnikov、Xiaohua Zhai 和 Aäron van den Oord。我们完成 ImageNet 了吗? *arXiv preprint arXiv:2006.07159*，2020。 [68] Dan Hendrycks、Steven Basart、Norman Mu、Saurav Kadavath、Frank Wang、Evan Dorundo、Rahul Desai、Tyler Zhu、Samyak Parajuli、Mike Guo 等。鲁棒性的多重面貌：对分布外泛化的批判性分析。载于 *Proceedings of the IEEE/CVF International Conference on Computer Vision*，第 8340–8349 页，2021。 [69] Dan Hendrycks、Kevin Zhao、Steven Basart、Jacob Steinhardt 和 Dawn Song。自然对抗样本。载于 *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*，第 15262–15271 页，2021。 [70] Haohan Wang、Songwei Ge、Zachary Lipton 和 Eric P Xing。通过惩罚局部预测能力来学习鲁棒的全局表示。载于 *Advances in Neural Information Processing Systems*，第 10506–10518 页，2019。 [71] Benjamin Recht、Rebecca Roelofs、Ludwig Schmidt 和 Vaishaal Shankar。ImageNet 分类器能泛化到 ImageNet 吗? 载于 *International Conference on Machine Learning*，第 5389–5400 页，2019。 [72] Ting Chen、Saurabh Saxena、Lala Li、David J. Fleet 和 Geoffrey E. Hinton。Pix2Seq：用于目标检测的语言建模框架。载于 *The Tenth International Conference on Learning Representations, ICLR*，2022。 [73] Agrim Gupta、Piotr Dollár 和 Ross B. Girshick。LVIS：用于大词汇量实例分割的数据集。载于 *IEEE Conference on Computer Vision and Pattern Recognition, CVPR 2019, Long Beach, CA, USA, June 16-20, 2019*，第 5356–5364 页。Computer Vision Foundation / IEEE，2019。

[74] Xiuye Gu、Tsung-Yi Lin、Weicheng Kuo 和 Yin Cui。通过视觉与语言知识蒸馏进行开放词汇目标检测。见 *ICLR*，2022。 [75] Yiwu Zhong、Jianwei Yang、Pengchuan Zhang、Chunyuan Li、Noel Codella、Liunian Harold Li、Luowei Zhou、Xiyang Dai、Lu Yuan、Yin Li 和 Jianfeng Gao。Regionclip：基于区域的语言-图像预训练。见 *CVPR*，2022。 [76] Lisa Anne Hendricks、Kaylee Burns、Kate Saenko、Trevor Darrell 和 Anna Rohrbach。女性也会单板滑雪：克服图像描述模型中的偏见。见 *ECCV*，2018。 [77] Aylin Caliskan、Joanna J Bryson 和 Arvind Narayanan。从语言语料库中自动推导出的语义包含类人偏见。*Science*，356(6334)，2017。 [78] Jieyu Zhao、Tianlu Wang、Mark Yatskar、Vicente Ordonez 和 Kai-Wei Chang。男性也喜欢购物：使用语料库级约束减少性别偏见放大。见 *EMNLP*，2017。 [79] Zeyu Wang、Klint Qinami、Ioannis Christos Karakozis、Kyle Genova、Prem Nair、Kenji Hata 和 Olga Russakovsky。迈向视觉识别中的公平性：缓解偏见的有效策略。见 *CVPR*，2020。 [80] Joy Buolamwini 和 Timnit Gebru。性别阴影：商业性别分类中的交叉性准确率差异。见 *FAccT*，2018。 [81] Jessica Deuschel、Bettina Finzel 和 Ines Rieger。揭示面部表情中的偏见。*arXiv preprint arXiv:2011.11311*，2020。 [82] Ben Hutchinson、Jason Baldridge 和 Vinodkumar Prabhakaran。场景描述到描绘任务中的欠规范化。见 *AACL / IJCNLP*，2022。 [83] Terrance De Vries、Ishan Misra、Changhan Wang 和 Laurens Van der Maaten。目标识别适用于所有人吗？见 *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition workshops*，第 52–59 页，2019。 [84] Priya Goyal、Adriana Romero Soriano、Caner Hazirbas、Levent Sagun 和 Nicolas Usunier。用于系统评估视觉特征提取器的公平性指标。见 *2022 ACM Conference on Fairness, Accountability, and Transparency*，第 70–88 页，2022。 [85] Kimmo Karkkainen 和 Jungseock Joo。Fairface：用于偏见测量和缓解的平衡种族、性别和年龄的人脸属性数据集。见 *Proceedings of the IEEE/CVF Winter Conference on Applications of Computer Vision*，第 1548–1558 页，2021。 [86] Alyssa Lees、Vinh Q Tran、Yi Tay、Jeffrey Sorensen、Jai Gupta、Donald Metzler 和 Lucy Vasser-man。新一代 Perspective API：高效的多语言字符级 Transformer。见 *KDD*，2022。 [87] Candice Schumann、Susanna Ricco、Utsav Prabhu、Vittorio Ferrari 和 Caroline Rebecca Pantofaru。朝着更具包容性的人物标注迈出的一步，以促进公平性。见 *Proceedings of the AAAI/ACM Conference on AI, Ethics, and Society (AIES)*，2021。 [88] Cynthia Dwork、Moritz Hardt、Toniann Pitassi、Omer Reingold 和 Richard Zemel。通过意识实现公平性。见 *Innovations in Theoretical Computer Science*，2012。 [89] Ziwei Liu、Ping Luo、Xiaogang Wang 和 Xiaoou Tang。自然环境中的深度学习人脸属性。见 *ICCV*，2015。 [90] Jack W Rae、Sebastian Borgeaud、Trevor Cai、Katie Millican、Jordan Hoffmann、Francis Song、John Aslanides、Sarah Henderson、Roman Ring、Susannah Young 等。扩展语言模型：训练 Gopher 的方法、分析与洞见。*arXiv preprint arXiv:2112.11446*，2021。 [91] Rachel Rudinger、Jason Naradowsky、Brian Leonard 和 Benjamin Van Durme。共指消解中的性别偏见。见 *Proceedings of the 2018 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies*，路易斯安那州新奥尔良，2018 年 6 月。计算语言学协会。 [92] Ellis Monk。Monk 肤色量表，2019。 [93] Foad Hamidi、Morgan Klaus Scheuerman 和 Stacy M Branham。性别识别还是性别还原主义？嵌入式性别识别系统的社会影响。见 *Proceedings of the 2018 chi conference on human factors in computing systems*，第 1–13 页，2018。 [94] Os Keyes。错误性别机器：自动性别识别对跨性别者/人机交互的影响。*Proceedings of the ACM on human-computer interaction*，2(CSCW):1–22，2018。

[95] Linting Xue、Noah Constant、Adam Roberts、Mihir Kale、Rami Al-Rfou、Aditya Siddhant、Aditya Barua 和 Colin Raffel。mT5：一种大规模多语言预训练文本到文本 Transformer。载于 *Proceedings of the 2021 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies*，第 483–498 页，2021 年 6 月。[96] Yaru Hao、Yutao Sun、Li Dong、Zhixiong Han、Yuxian Gu 和 Furu Wei。结构化提示：将上下文学习扩展到 1,000 个示例。*arXiv preprint arXiv:2212.06713*，2022 年。[97] Fabian Caba Heilbron、Victor Escorcia、Bernard Ghanem 和 Juan Carlos Niebles。Activitynet：用于人类活动理解的大规模视频基准。载于 *Proceedings of the ieee conference on computer vision and pattern recognition*，第 961–970 页，2015 年。[98] Xindi Shang、Donglin Di、Junbin Xiao、Yu Cao、Xun Yang 和 Tat-Seng Chua。标注用户生成视频中的对象和关系。载于 *Proceedings of the 2019 on International Conference on Multimedia Retrieval*，第 279–287 页，2019 年。[99] Andrei Barbu、David Mayo、Julian Alverio、William Luo、Christopher Wang、Dan Gutfreund、Joshua Tenenbaum 和 Boris Katz。ObjectNet：用于推动对象识别模型极限的大规模偏差控制数据集。载于 *Proceedings of the 33rd International Conference on Neural Information Processing Systems*，第 9453–9463 页，2019 年。