2022 Jul 5]VC .sc[2v47640.6022:viXra

Uni-Perceiver-MoE：使用条件 MoE 学习稀疏通用模型

朱金国[1*†]，朱曦洲[2*]，王文海[3]，王晓华[1]，李鸿升[4]，王小刚[4]，戴继锋[2,3✉]
[1]西安交通大学 [2]商汤研究院 [3]上海人工智能实验室 [4]香港中文大学 lechatelia@stu.xjtu.edu.cn, zhuwalter@sensetime.com, xhw@mail.xjtu.edu.cn, {wangwenhai, daijifeng}@pjlab.org.cn, {hsli, xgwang}@ee.cuhk.edu.hk

摘要

为了构建类似生物智能系统的人工神经网络，近期工作已将众多任务统一到一个通用模型中，该模型可以使用共享参数处理各种任务，并且不包含任何任务特定模块。尽管通用模型在各种基准上取得了有前景的结果，但与任务专用模型相比，它们在某些任务上的性能有所下降。在这项工作中，我们发现不同任务和模态之间的干扰是导致这一现象的主要因素。为缓解这种干扰，我们将条件混合专家（Conditional Mixture-of-Experts，Conditional MoEs）引入通用模型。我们提出了不同条件层级下的路由策略，以同时兼顾训练/推理成本和泛化能力。通过结合所提出的 Conditional MoEs，近期提出的通用模型 Uni-Perceiver 能够有效缓解跨任务和跨模态的干扰，并通过在 1% 下游数据上进行提示调优，在一系列下游任务上取得最先进的结果。此外，引入 Conditional MoEs 仍然保持了通用模型在新任务上进行零样本推理的泛化能力，*e.g.,* 视频-文本检索和视频字幕生成。代码和预训练通用模型将在 https://github.com/fundamentalvision/Uni-Perceiver 发布。

1 引言

长期以来，机器学习领域一直在追求能够处理多种模态和众多任务的通用模型。然而，以往的研究 [65, 89, 71] 侧重于开发带有任务特定模块的专用模型。当这些模型应用于新任务时，需要按需重新设计这些专门设计的组件，并在足够的下游数据上进行微调。因此，它们的模型规模会随着多样化下游任务数量的增加而增长，这与通用模型的目标相冲突。

最近，一些先驱研究 [93, 79, 3, 84, 86, 62] 已经初步尝试通过将各种任务建模为统一形式来构建通用模型。借助统一建模，在各种数据集上进行大规模预训练使通用模型能够使用共享参数处理不同的下游任务。这些通用模型不仅在预训练任务上取得了具有竞争力的性能 [79, 3, 84, 86]，还能够在不引入额外参数的情况下对新任务进行零样本推理 [93, 62]。

然而，与为每个任务配备特定参数的专用模型相比，使用共享参数的通用模型会受到任务干扰问题的影响——不同任务共享

*Equal contribution. †This work is done when Jinguo Zhu is an intern at SenseTime Research. ✉Corresponding author.

Preprint.

参数之间可能会相互冲突 [88]。在多语言 NLP 模型中也观察到了同样的问题 [4, 81, 83]。我们认为，任务干扰问题主要是由多任务学习中的优化不一致导致的。如表 1 所示，在通用模型的训练阶段，不同任务的梯度方向可能不一致，甚至相反。因此，如果多个任务共享参数，共享参数的最优更新方向将变得不确定，从而导致次优性能。

允许存在冲突的模态和任务使用独立参数，应能有效缓解通用模型中的干扰问题。专家混合（Mixture of Experts, MoEs）[43, 23] 提供了一种潜在解决方案，其能够在不引入任何任务特定模块的情况下动态激活子网络。然而，原始 MoEs [67] 根据 token 表示来选择专家，这不仅会带来较高的训练/推理成本，还会忽略不同任务和模态的信息。在本文中，我们认为，当 MoEs 应用于通用模型以缓解任务干扰问题时，其路由策略需要进行专门设计。

为了解决通用模型中的任务干扰问题，我们提出了条件混合专家（Conditional Mixture-of-Experts，Conditional MoEs），通过引入不同条件层级的信息来改进普通 MoEs，包括词元级、上下文级、模态级、任务级以及预定义词元属性。在这种情况下，普通 MoEs 是我们 Conditional MoEs 的一种词元级变体，可以由其他层级的变体替代，以实现更强大的通用模型。我们仔细讨论了不同变体的训练/推理成本和泛化能力，并通过消融实验评估了它们在缓解通用模型干扰问题方面的性能。值得注意的是，带有预定义词元属性的 Conditional MoEs 引入了 8 位属性嵌入，用于描述当前处理任务和模态的信息，展现出优异的计算和内存效率以及良好的泛化能力。

为了验证条件 MoE 的有效性，我们将其与近期提出的通用感知模型 Uni-Perceiver [93] 相结合，将自注意力和 FFN 模块中的线性投影替换为条件 MoE 层。实验表明，通过使用我们提出的条件 MoE 缓解任务干扰，Uni-Perceiver 可以在不降低性能的情况下对多种任务进行联合预训练，同时还能保持其对其他任务的泛化能力。我们的主要贡献如下：

- 我们仔细分析了通用模型中的任务干扰问题，并从梯度方向的角度提供了解释，同时提出了一个用于量化该问题的指标。
- 我们提出条件 MoE，以解决通用模型中的任务干扰问题。通过引入当前处理任务和模态的信息，条件 MoE 能够有效缓解干扰问题，同时保持较低的计算和内存成本。
- 与以往的 SOTA 相比，我们的通用模型仅使用 1% 的下游数据进行提示调优，便取得了有竞争力的性能，同时仅使用了 <5% 的训练数据和 <10% 的训练成本。我们希望这项工作能够作为通用模型的坚实基线，并推动进一步研究。

2 相关工作

专用模型。以往研究专注于为特定任务构建专用模型。CNN [47, 26, 70] 和 ViT [20, 53, 76, 80] 被开发用于图像分类。后续工作对它们进行重新设计，以适应多样化的下游视觉任务，*e.g.,* 如目标检测 [63] 和分割 [15, 48]。在自然语言处理领域，不同架构被专门设计用于神经机器翻译 [77]、自然语言理解 [19] 和自然语言生成 [51]。至于视觉-语言任务，以往工作通常将特定模态的编码器与表示融合模块结合起来 [13, 54]。近期，[89, 65, 71] 将多个专用模型整合为一个模型，以处理多样化任务。这类集成式专用模型配备了多个任务特定模块，以尽可能适应更多下游任务。然而，这些方法仍然遵循任务特定范式，这与通用模型的目标相冲突。

原生通用模型。原生通用模型使用共享参数处理不同任务和模态。Uni-Perceiver [93] 将各种感知任务表述为：通过表示之间的相似性，为每个输入寻找最大似然目标。OFA [79]、Flamingo [3] 和 SimVLM [84] 试图将不同任务统一为序列到序列生成。UniCORN [86] 和 Gato [62] 分别进一步将边界框和强化学习任务纳入统一表述中。这些通用模型不仅取得了具有竞争力的

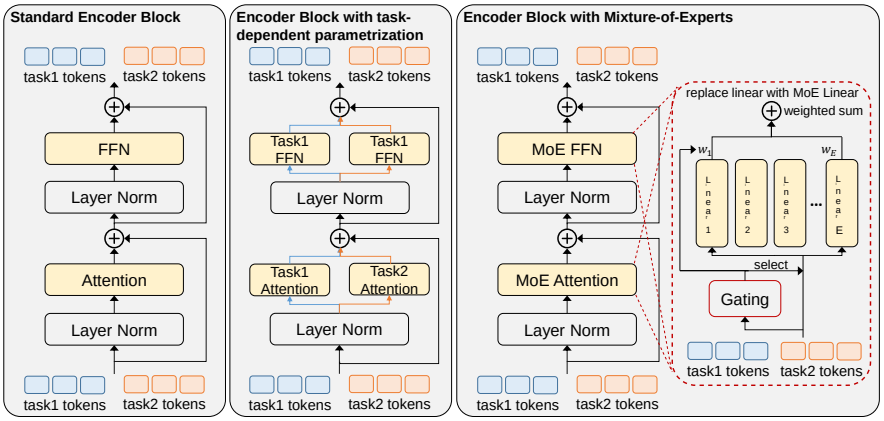


图 1：全共享标准编码器块、具有任务专用参数的任务特定编码器块以及采用高效 MoE 参数化的编码器块的比较。

在使用共享参数进行预训练任务时的性能，而且还可以在新任务上进行零样本推理 [62, 93]。然而，这些方法很少研究不同模态和任务之间潜在的干扰，而这种干扰可能导致通用模型的性能下降。

多任务学习。多任务学习 [8, 17] 已在视觉 [27, 74, 72]、语言 [25, 16, 50] 以及视觉-语言学习 [10, 55, 29] 领域得到广泛研究。尽管多任务训练能够促进任务之间的协作，但也可能引入任务干扰问题 [81, 83, 28, 36, 72]。为缓解任务干扰问题，一些工作 [14, 24, 38] 提出动态调整每个任务的损失权重，而另一些工作 [90, 49, 36] 则使用任务专用参数。然而，采用任务特定参数的方法难以泛化到新任务，也不符合通用模型的要求。

专家混合（MoEs）。MoEs 已展现出其扩展神经网络的卓越能力 [67, 43, 23, 64, 21]。[67] 首次通过在 LSTM 模型中堆叠 MoE 层证明了 MoEs 的有效性。[68, 43] 进一步将这一方法引入 Transformer 架构。[23, 40] 通过采用简化的 MoE 路由策略和高效训练技术，成功训练了具有万亿参数的语言模型。也有一些工作将 MoEs 应用于 CNN，以完成计算机视觉任务 [1, 85, 82]。最近，V-MoE [64] 成功地将 MoEs 应用于 ViTs，在许多视觉任务上展现出有前景的性能。Task-MoE [42] 专注于将 MoEs 应用于多语言翻译，以缓解不同语言之间的干扰。在本工作中，我们旨在探索通用模型在不同条件下的 MoEs。

3 方法

在本节中，我们首先从梯度方向的角度分析任务干扰问题。基于该分析，我们提出了面向通用模型的条件混合专家（Conditional MoEs），其引入由不同层级信息条件化的参数，以在几乎不增加额外开销的情况下缓解任务干扰问题。

3.1 任务干扰

为了量化第 j 个任务对第 i 个任务的干扰，我们估计当根据第 j 个任务 L_j 优化共享参数 θ 时，第 i 个任务的损失 L_i 的变化，如下所示：

$$\Delta_j L_i(x_i) \doteq \mathbb{E}_{x_j}\left(L_i(x_i;\theta) - L_i(x_i;\theta - \lambda\frac{\nabla_\theta L_j(x_j)}{\|\nabla_\theta L_j(x_j)\|})\right) \approx \lambda\mathbb{E}_{x_j}\left(\frac{\nabla_\theta L_j(x_j)}{\|\nabla_\theta L_j(x_j)\|}^T \nabla_\theta L_i(x_i)\right), \quad (1)$$

其中，x_i 和 x_j 分别是第 i 个任务和第 j 个任务的采样训练批次。不失一般性，我们仅考虑更新方向，而忽略更新范数。那么，第 j 个任务对第 i 个任务的干扰可以量化为：

$$\mathcal{I}_{i,j} = \mathbb{E}_{x_i}\left(\frac{\Delta_j L_i(x_i)}{\Delta_i L_i(x_i)}\right), \quad (2)$$

表 1：任务 j 对任务 i 在第 4/12 个 FFN 块处的平均干扰指标 $\mathcal{I}_{i,j}$。为计算干扰指标，我们为每个任务采样 100 个批次，并基于预训练的 Uni-Perceriver-Ti 记录梯度。红色数值表示任务 j 对任务 i 产生负面影响，绿色数值表示产生正面影响。

(a) The 4-th FFN Block

Task i \ Task j	ImgCLS (Img)	MLM (Text)	Caption (Img-Text)
ImgCLS (Img)	1.00	-0.57	1.29
MLM (Text)	0.07	1.00	0.68
Caption (Img-Text)	0.01	0.01	1.00

(b) The 12-nd FFN Block

Task i \ Task j	ImgCLS (Img)	MLM (Text)	Caption (Img-Text)
ImgCLS (Img)	1.00	-2.91	-2.45
MLM (Text)	-1.65	1.00	-1.05
Caption (Img-Text)	-0.11	0.19	1.00

其中，分母用于归一化损失变化的尺度。如表 1 所示，我们为每个任务采样 100 个批次，并记录梯度，以计算第 j 个任务在第 4/第 12 个 FFN 块处对第 i 个任务的平均干扰指标 $\mathcal{I}_{i,j}$。可以看到，在浅层中，图像描述任务对图像分类和掩码语言建模具有正向影响，表明不同任务之间存在协作。而在深层中，具有不同优化目标的任务几乎无法相互增强，梯度方向甚至可能相反。

图 1 总结了多任务模型的三种主流架构。第一种是标准架构 [93, 31, 32]，不同任务完全共享参数，如上文分析所示，这种架构存在任务干扰问题。第二种是任务特定参数化架构 [89, 65, 29, 71]，为每个任务配备专用参数。尽管该架构通过任务特定参数解决了干扰问题，但它难以泛化到训练阶段未出现的新任务。不同于上述两种架构，混合专家（Mixture-of-Experts，MoE）架构 [67, 43, 23, 40, 64] 会根据不同给定输入，通过选择性地利用模型参数的不同子集来稀疏地激活模型。稀疏路由机制使训练超大规模通用模型成为可能，从而最大化协作，同时缓解干扰问题。在本文中，我们重点探索用于通用模型的条件 MoE，其专家由来自不同层级的条件进行门控。

3.2 条件混合专家（Conditional MoEs）

我们首先描述条件式 MoE 的原型，然后给出其在不同条件下的具体实例化方式，以及其在通用模型中的应用。

原型。给定输入序列 $X = \{x_i\}_{i=1}^{L}$ 中的任意 token x_i，具有 E 个专家的条件式 MoE 首先引入一个门控决策向量 $\mathcal{G} \in \mathbb{R}^E$，用于将不同的输入 token 分派给不同的专家，其计算方式如下：

$$\mathcal{G} = \text{top}_k\left(\text{softmax}\left(\mathbf{W}_g \cdot R(x_i) + \epsilon\right)\right). \tag{3}$$

其中，$R(\cdot)$ 定义了一种用于门控决策的通用路由策略，该策略在不同条件下具有不同选择。$\mathbf{W}_g$ 是门控决策中的可训练权重，ϵ 是噪声项。$\text{top}_k(\cdot)$ 算子将除最大的 k 个值之外的所有值置为零。由于 $\mathcal{G}$ 只有 $k \ll E$ 个非零值，令牌 x_i 仅被路由到少数专家。在得到门控决策向量 $\mathcal{G}$ 后，相应的输出 y_i 是每个专家在 x_i 上计算结果的加权组合，如下所示：

$$y_i = \sum_{e=1}^{E} \mathcal{G}_e \cdot \mathbf{W}_e \cdot x_i, \tag{4}$$

其中，$\mathbf{W_e}$ 是第 e 个专家的线性投影权重，门控决策 $\mathcal{G}_e$ 决定第 e 个专家对输出 y_i 的贡献程度。注意，$\mathcal{G}_e =$ 为 0 的专家无需计算，以节省计算量。

在条件式 MoE 中，路由策略 $R(\cdot)$ 在通用模型的多模态和多任务训练中发挥着重要作用。通过根据不同条件稀疏激活专家，条件式 MoE 可以在保持预训练模型通用性的同时缓解干扰问题。接下来，我们介绍在不同条件下采用特定路由策略的变体，如图 2 所示。

词元级路由。与普通 MoE [67, 43, 23, 40, 64] 类似，词元级 MoE 直接使用词元表示来制定路由策略，可写为：

$$R_{\text{token}}(x_i) = x_i. \tag{5}$$

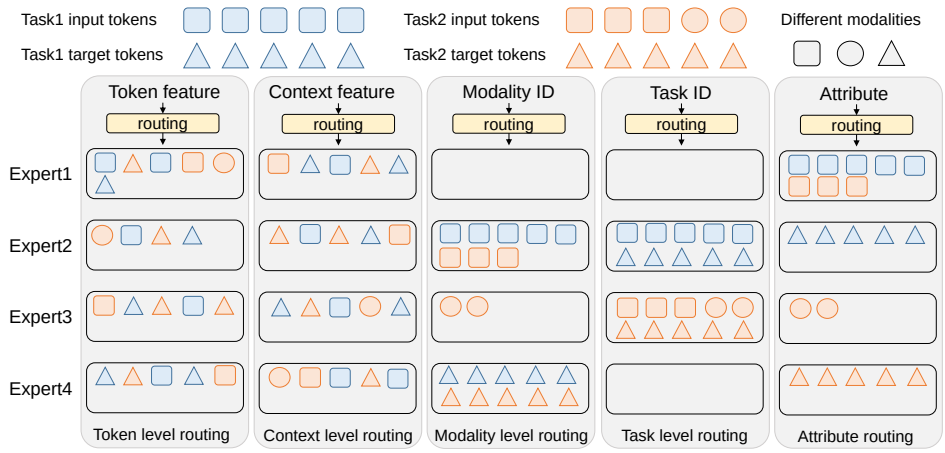


图 2：在双任务训练下，采用 top-1 门控决策的路由策略比较。

词元级 MoE 的路由策略是一个恒等函数，其中门控决策仅取决于每个词元自身的表示。

上下文级路由。具有相似表示的词元可能出现在相互冲突的任务中，其最优专家决策应当有所不同，以缓解任务干扰。因此，为了帮助门控函数做出更可靠的决策，我们探索全局上下文与局部词元表示的结合。利用全局上下文的路由策略可以表示为：

$$R_{\text{context}}(x_i) = \text{concat}(x_i, \text{attnpool}(X)), \tag{6}$$

其中 concat(·) 表示拼接操作，$X = \{x_i\}_{i=1}^{L}$ 是当前样本中所有词元的序列，attnpool(·) 表示注意力池化算子 [61]。

模态级路由。当前大多数实践针对不同模态输入使用具有独立参数的模态特定编码器。受此启发，我们也探索利用当前 token 的模态作为一种路由策略：

$$R_{\text{modal}}(x_i) = \text{embed}(\text{id}_{\text{modal}}(x_i)) \tag{7}$$

这里，embed(·) 表示嵌入层，$\text{id}_{\text{modal}}(\cdot)$ 表示当前令牌 x_i 的模态索引。路由函数将根据该令牌的模态嵌入将其分配给专家。

任务级路由。除了模态信息外，任务信息也可用于引导门控函数做出可靠决策，以缓解任务干扰。与公式（7）类似，路由策略可表示为：

$$R_{\text{task}}(x_i) = \text{embed}(\text{id}_{\text{task}}(x_i)), \tag{8}$$

其中 $\text{id}_{\text{task}}(\cdot)$ 是当前 token x_i 的任务索引。该任务的任务嵌入将用于计算门控决策。由于来自同一任务的所有 token 都具有相同的任务嵌入，因此对应于该任务的所有 token 都将被路由到同一组专家。

属性路由。在上述变体中，词元级、上下文级和模态级路由策略仅关注输入词元，而忽略了当前所处理任务的信息。尽管任务级路由策略依赖于特定任务的 ID，但这会限制其对新的下游任务的泛化能力。为在不损害通用模型泛化能力的情况下引入当前所处理任务和模态的信息，我们提出引入词元属性来辅助门控决策。

如表 2 所述，当前 token 的属性被表示为一个 8 维二进制嵌入，其属性包括当前任务和 token 的模态（索引 0~5）、模型的因果类型（索引 6）以及 token 来源（索引 7）。因此，所设计的 token 属性在保持任务泛化能力的同时，为当前处理的任务提供了全面的信息。基于属性嵌入，路由策略表示为：

$$R_{\text{attr}}(x_i) = \text{layernorm}\left(\mathbf{W}_{\text{attr}} \cdot \text{attr}(x_i)\right). \tag{9}$$

表2：用于属性级路由策略的8维二进制嵌入。通过检查八个描述的陈述是否与当前标记匹配，将属性嵌入分配给一个标记。例如，图像分类任务输入序列中任意标记的属性嵌入应为 [1, 0, 0, 1, 1, 0, 0, 1]。有关我们工作中所有任务的属性嵌入的详细查找表，请参见附录。

Index	Descriptions	Yes	No
0	Visual modality exists in the inputs of the current task.	1	0
1	Text modality exists in the inputs of the current task.	1	0
2	Visual modality exists in the targets of the current task.	1	0
3	Text modality exists in the targets of the current task.	1	0
4	The modality of current token is visual.	1	0
5	The modality of current token is text.	1	0
6	The attention mask of the current token is causal.	1	0
7	The current token comes from the inputs, not the targets.	1	0

这里，attr(x_i) 是当前标记 x_i 的 8 维二进制属性嵌入，如表 2 所述。$\mathbf{W}_{\text{attr}}$ 是用于将属性嵌入转换为潜在表示的可学习权重，而 layernorm(·) 表示用于稳定训练的层归一化 [6]。

应用于通用模型。在不失一般性的情况下，我们探索了条件 MoE 在通用模型 Uni-Perceiver [93] 中的应用，该模型使用 Transformer 通过共享参数处理各种模态和任务。我们将自注意力和 FFN 模块中的线性投影层替换为条件 MoE 层（见图 1）。

3.3 Conditional-MoE 变体的比较

如图 2 所示，在条件 MoE 的各种变体中，token 级和上下文级 MoE 是数据依赖的，而模态级、任务级和属性 MoE 是数据无关的。

训练和推理成本。与参数数量相同的稠密模型相比，所有条件 MoE 变体都能受益于稀疏路由机制，从而显著降低计算成本。由于对输入数据的依赖，token 级和上下文级 MoE 在模型训练期间的内存消耗相对较高，需要通过将专家划分到多个设备上来进行模型并行，以缓解内存成本，但这会导致沉重的设备间通信开销。在使用预训练模型进行特定任务推理时，这一问题依然存在，因为所有专家都需要加载到内存中，并且可能被任意 token 激活。

不同于数据依赖的条件 MoE，模态级、任务级和属性 MoE 等数据无关变体具有出色的内存效率，因为对于具有相同模态/任务/属性的所有 token，只需激活 top-k 个专家。此外，在训练和推理阶段，数据无关 MoE 层中的专家都可以通过重参数化技术合并为单个线性投影。在这种情况下，带有数据无关条件 MoE 的网络的计算成本将等同于不含 MoE 的稠密模型。

泛化能力。我们希望在保持通用模型对新的下游任务的泛化能力的同时，缓解任务干扰问题。尽管没有任务特定设计的词元级、上下文级和模态级 MoE 不会损害泛化能力，但它们忽略了对解决任务干扰至关重要的任务级信息。相反，任务级路由策略与特定的任务 ID 绑定，难以泛化到新的下游任务。属性 MoE 引入预定义的词元属性，以全面描述当前处理任务和模态的信息，并且无需任何任务特定的修改即可迁移到新的下游任务。这使得属性 MoE 有潜力在不丧失泛化能力的情况下缓解任务干扰。

4 实验

在本节中，我们首先描述实验设置。然后，我们确认通用模型 Uni-Perceiver [93] 中存在的任务干扰问题，并对不同 Conditional MoE 缓解任务干扰的能力进行消融分析。最后，我们进行大规模训练，以验证我们提出的 Conditional-MoEs 的有效性及其对新任务的泛化能力。

表 3：条件 MoE 不同路由策略的性能。基础模型为采用 $\text{BERT}_{\text{tiny}}$ 的 Uni-Perceiver。我们还展示了任务特定变体，其中每个任务都有自己的专用参数。报告了三个任务上的训练和验证性能：ImageNet-1K [18] 上的图像分类、COCO Caption [12] 上的图像描述，以及 Books&Wiki 上的掩码语言建模（MLM）。在 1% 容差范围内的最佳结果以粗体显示。

model	task-specific parameterization	training time	inference time	ImageNet-1k		COCO Caption		MLM	
				$\uparrow\text{acc}_{\text{train}}$	$\uparrow\text{acc}_{\text{val}}$	$\uparrow\text{acc}_{\text{train}}$	$\uparrow\text{B@4}_{\text{val}}$	$\uparrow\text{acc}_{\text{train}}$	$\downarrow\text{ppl}_{\text{val}}$
Uni-Perceiver-Ti [93]		1.0×	1.0×	47.3	68.3	49.2	18.2	54.5	5.86
	✓	1.1×	1.0×	**53.3**	**73.5**	**52.6**	20.4	**60.5**	**4.48**
+ Conditional MoEs $_{\text{token}}$		1.8×	2.2×	**53.1**	72.7	**52.9**	20.9	58.3	4.96
+ Conditional MoEs $_{\text{context}}$		2.2×	2.6×	52.5	**73.1**	**52.8**	21.5	58.6	4.86
+ Conditional MoEs $_{\text{modality}}$		1.4×	1.0×	51.7	72.6	52.1	21.8	57.5	5.06
+ Conditional MoEs $_{\text{task}}$		1.4×	1.0×	**52.9**	**73.2**	**52.7**	21.2	**59.9**	**4.56**
+ Conditional MoEs $_{\text{attribute}}$		1.4×	1.0×	**52.8**	**73.3**	**53.1**	**23.0**	**60.0**	**4.56**

4.1 数据集

我们使用 Uni-Perceiver [93] 中相同的数据集来预训练我们的模型。具体而言，ImageNet-21k [18] 用于图像分类预训练。Kinetics-700 [37] 和 Moments in Time [57] 用于视频分类预训练。语言建模任务在 BookCorpus [94] 和英文维基百科（Books&Wiki）上训练。对于带有图像线索的语言建模和图像-文本检索，我们使用多个图像-文本配对数据集的组合：SBU Captions（SBU）[58]、Visual Genome [41]、COCO Caption [12]、CC3M [66]、CC12M [9] 和 YFCC [35]。遵循 Uni-Perceiver，我们利用 ImageNet1K [18]、Kinetics-400 [37]、COCO Caption [12] 和 Flickr30k [59] 来评估通用模型在下游任务上的性能。我们还使用两个用于评估对新任务泛化能力的数据集：MSVD [11] 和 GLUE [78]。此外，所有数据集许可证均包含在附录中。

4.2 实现细节

我们将普通的通用模型 Uni-Perceiver 与 Conditional MoEs 结合，用于三种不同变体的实验：Uni-Perceiver-Ti（Tiny）、Uni-Perceiver-B（Base）和 Uni-Perceiver-L（Large）。架构超参数请参见附录。若未特别说明，输入图像分辨率设置为 224×224。在每次训练迭代中，每个 GPU 独立采样一个任务和数据集。不同 GPU 的梯度在梯度反向传播后进行同步。我们使用 AdamW 优化器，基础学习率为 0.0005，权重衰减为 0.05。与 [52, 61] 类似，我们发现设置 $\beta_2 = 0.98$ 和 $\epsilon = 10^{-6}$ 有助于提高大规模训练时的稳定性。此外，使用 0.5 的梯度裁剪来稳定训练。

Uni-Perceiver-B 和 Uni-Perceiver-L 每隔一层配备 Conditional-MoEs 层，而 Uni-Perception-Ti 在所有层中使用 Conditional MoEs。按照 [64]，还在门控 logits 上使用了正态噪声，以便更好地探索新的潜在专家。如果没有特别说明，则使用 top-2 门控函数。关于 MoE 层的其他超参数，请参见附录。

4.3 消融实验

本部分探讨条件 MoE 是否能够有效缓解通用模型中的任务干扰，并比较不同的路由策略。表 3 总结了 Uni-Perceiver 及其变体在三个典型任务上的性能。与任务特定参数化相比，Uni-Perceiver 的性能下降证实了任务干扰的存在。采用任意路由策略引入条件 MoE 都可以缓解任务干扰问题，并显著提升性能。在这五种路由策略中，token 级、上下文级和模态级 MoE 的性能略差。我们认为，缺失的任务信息对于解决任务干扰至关重要。此外，数据依赖型 MoE，即 *i.e.,* token 级和上下文级 MoE，具有相对更高的训练和推理成本，而其他三种 MoE 通过使用重参数化技术具有出色的效率。尽管任务级 MoE 和属性 MoE 都取得了良好性能，但任务级 MoE 中专门的 task-id 设计使其难以泛化到新任务。因此，将使用采用属性路由策略的条件 MoE。

表4：在图像分类、视频分类和图文检索任务中，将条件 MoE 与 Uni-Perceiver 结合的性能。“#param”表示模型部署期间所需的参数量。“#data”表示涉及的视觉训练样本数量。“WT”、“PT”和“FT”分别表示不调优、提示调优和微调。“1%”和“100%”表示用于调优的下游数据比例。“$\text{FT}_{100\%}\uparrow$”表示使用更大图像尺寸进行微调。分数旁的下标数字表示使用了不同于 224 的图像分辨率。† 这些方法使用了比我们多 $>20\times$ 的训练数据规模和多 $>10\times$ 的训练成本。

(a) 在 ImageNet-1k 上的图像分类准确率。

Method	#param	#data	WT	$\text{PT}_{1\%}$	$\text{FT}_{100\%}$	$\text{FT}_{100\%}\uparrow$
DeiT-B [76]	86M	1.28M	-	-	81.8	83.1_{384}
ViT-B [73]	86M	15.5M	-	-	84.0	85.5_{384}
ViT-L [73]	307M	15.5M	-	-	84.0	85.6_{384}
OFA [79]	472M	60.6M	-	-	-	84.9_{480}
CLIP [61]	307M	400M	76.2_{336}	-	-	-
†ALIGN [33]	480M	1.8B	76.4_{289}	-	-	88.6_{289}
†Florence [89]	637M	900M	83.7_{384}	-	-	$90.0_{\geq 384}$
†CoCa-B [87]	86M	4.8B	82.6_{576}	-	-	88.3_{576}
†CoCa-L [87]	303M	4.8B	84.8_{576}	-	-	90.2_{576}
†Flamingo-3B [3]	3.2B	2.3B	-	71.0_{320}	-	-
Uni-Perceiver-B	86M	44.1M	79.2	80.9	84.0	85.2_{384}
+ Conditional MoEs	86M	44.1M	80.3	82.0	84.5	85.8_{384}
Uni-Perceiver-L	303M	44.1M	82.7	84.2	86.2	87.0_{384}
+ Conditional MoEs	303M	44.1M	83.4	84.9	86.4	87.0_{384}

(b) Kinetics-400 上的视频分类准确率。

Method	#param	#data	WT	$\text{PT}_{1\%}$	$\text{FT}_{100\%}$
TimeSformer-B [7]	121.4M	14.2M	-	-	80.7
VATT-B [2]	87.9M	238M	-	-	79.6_{320}
VATT-L [2]	306.1M	238M	-	-	82.1_{320}
ViViT-L [5]	>307M	14.2M	-	-	81.7
ViViT-L [5]	>307M	300M	-	-	84.9
†Florence [89]	647M	900M	-	-	86.5_{384}
†CoCa [87]	2.1B	4.8B	-	-	88.9_{576}
Uni-Perceiver-B	86M	44.1M	74.5	74.8	77.7
+ Conditional MoEs	86M	44.1M	76.8	77.2	79.3
Uni-Perceiver-L	303M	44.1M	79.5	80.0	81.9
+ Conditional MoEs	303M	44.1M	82.1	83.0	84.2

(c) 图文检索 R@1 性能。

Method			Flickr30K						MSCOCO Caption					
			Image → Text			Text → Image			Image → Text			Text → Image		
	#param	#data	WT	$\text{PT}_{1\%}$	$\text{FT}_{100\%}$	WT	$\text{PT}_{1\%}$	$\text{FT}_{100\%}$	WT	$\text{PT}_{1\%}$	$\text{FT}_{100\%}$	WT	$\text{PT}_{1\%}$	$\text{FT}_{100\%}$
ImageBERT [60]	170M	10M	70.7	-	87.0	54.3	-	73.1	44.0	-	66.4	32.3	-	50.5
UNITER-B [13]	146M	9.6M	80.7	-	85.9	66.2		72.5	-	-	64.4	-	-	50.3
UNITER-L [13]	363M	9.6M	83.6	-	87.3	68.7	-	75.6	-	-	65.7	-	-	52.9
ViLT [39]	87M	9.7M	73.2	-	74.8	56.5	-	61.5	55.0	-	64.4	40.4	-	42.7
FLAVA [71]	215M	70M	67.7	-	-	65.2	-	-	42.7	-	-	38.4	-	-
CLIP [61]	417M	400M	88.0_{336}	-	-	68.7_{336}	-	-	58.4_{336}	-	-	37.8_{336}	-	-
†ALIGN	820M	1.8B	88.6_{289}	-	95.3_{289}	75.7_{289}	-	84.9_{289}	58.6_{289}	-	77.0_{289}	45.6_{289}	-	59.9_{289}
†Florence [89]	893M	900M	90.9_{384}	-	97.2_{384}	76.7_{384}	-	87.9_{384}	64.7_{384}	-	-	47.2_{384}	-	-
†CoCa-B [87]	383M	4.8B	89.8_{576}	-	-	76.8_{576}	-	-	63.8_{576}	-	-	47.5_{576}	-	-
†CoCa-L [87]	787M	4.8B	92.5_{576}	-	-	80.4_{576}	-	-	66.3_{576}	-	-	51.2_{576}	-	-
†Flamingo-3B [3]	3.2B	2.3B	89.3_{320}	-	-	79.5_{320}	-	-	65.9_{320}	-	-	48.0_{320}	-	-
Uni-Perceiver-B	124M	44.1M	82.3	91.0	92.7	71.1	76.0	77.5	64.9	68.4	69.8	50.7	51.9	53.9
+ Conditional MoEs	167M	44.1M	82.1	91.3	93.6	72.4	78.5	79.8	64.6	68.9	70.5	51.6	52.6	54.1
Uni-Perceiver-L	354M	44.1M	83.7	92.1	94.7	74.2	80.0	82.1	67.8	73.3	74.4	54.1	56.2	57.9
+ Conditional MoEs	505M	44.1M	83.6	92.4	94.1	75.9	80.6	83.7	67.9	73.3	74.7	55.3	57.1	58.3

4.4 预训练任务评估

为了验证我们方法的有效性，我们进行了大规模训练，并首先在预训练所涉及的任务上对其进行评估。具体而言，我们使用广泛采用的 ImageNet-1k [18] 和 Kinetics-400 [37] 分别评估图像分类和视频分类，并使用常用的 Flickr30k [59] 和 COCO Caption [12] 评估图像描述生成和图文检索。

表4和表5a展示了四个预训练任务的结果。可以看到，采用我们的条件 MoE 的 Uni-perceiver 始终以较大优势优于原始 Uni-perceiver。在不进行任何调优的情况下，我们的模型在性能上与使用相似模型规模和训练数据规模训练的任务特定 SOTA 方法相当。需要注意的是，我们的方法是在统一任务形式上预训练的通用模型，而任务特定方法则是专门针对目标任务进行训练的。

当仅在 1% 的下游数据上进行提示调优时，我们模型的性能提升到了接近使用 $>50\times$ 训练数据规模和 $>10\times$ 训练成本的对应模型的水平。对于我们模型的提示调优，仅需调优少量参数，编码器仍然保持固定并在不同任务之间共享，这表明具有条件 MoE 的通用模型能够以比对应模型显著更低的成本处理不同任务。

我们进一步使用 100% 的下游数据对模型进行微调。在这种情况下，我们的模型在所有这些任务上的性能均达到或超过了使用相似数据规模训练的 SOTA，这证明了采用 Conditional MoEs 的通用模型已经学习到了高质量的表示。

表5：在图像描述、自然语言理解、视频-文本检索和视频描述任务中，将条件 MoE 与 Uni-Perceiver 结合的性能表现，其中后三个任务未参与预训练。

(a) 图像描述 BLEU@4 性能。* 表示方法使用区域特征作为网络输入。‡ 表示使用了 Cider 优化。

Method	#param	data	MSCOCO Caption			Flickr30k		
			WT	$PT_{1\%}$	$FT_{100\%}$	WT	$PT_{1\%}$	$FT_{100\%}$
*Unified VLP [92]	86M	3.0M	-	-	36.5	-	-	30.1
*OSCAR-B [46]	154M	6.5M	-	-	36.5	-	-	-
*OSCAR-L [46]	384M	6.5M	-	-	37.4	-	-	-
UNICORN [86]	198M	200k	-	-	35.8	-	-	-
BLIP-B [44]	252M	129M	-	-	39.7_{384}	-	-	-
BLIP-L [44]	473M	129M	-	-	40.4_{384}	-	-	-
CLIP-VIL [69]	> 459M	400M	-	-	40.2	-	-	-
SimVLM [84]	632M	1.8B	11.2_{480}	-	40.6_{480}	-	-	-
*‡OSCAR-L [46]	384M	6.5M	-	-	41.7	-	-	-
‡OFA [79]	472M	60.6M	-	-	43.5_{480}	-	-	-
†CoCa [87]	2.1B	4.8B			40.9_{576}	-	-	-
Uni-Perceiver-B	124M	44.1M	32.0	35.5	36.4	14.7	30.2	31.2
+ Conditional MoEs	167M	44.1M	33.2	36.8	37.3	15.9	30.7	32.4
Uni-Perceiver-L	354M	44.1M	35.3	38.6	39.2	15.1	32.9	35.5
+ Conditional MoEs	505M	44.1M	35.5	39.3	40.5	15.8	33.7	36.2

(b) 在 GLUE 上微调的自然语言理解（新任务）。$BERT_{BASE}$ 记录来自 [34]。VisualBERT 和 LXMERT 记录来自 [30]。*RoBERTa 使用的训练文本标记比我们多 10×。

Method	MNLI (Acc)	QNLI (Acc)	QQP (F1)	RTE (Acc)	SST-2 (Acc)	MRPC (F1)	CoLA (Mcc)
LXMERT [75]	80.4	84.2	75.3	57.2	90.2	80.4	39.0
VisualBERT [45]	81.6	87.0	86.0	56.6	89.4	82.1	38.6
SimVLM-B [84]	83.4	88.6	87.2	63.9	90.9	84.4	46.7
BERT-B [78]	84.5	88.4	88.3	63.5	92.9	89.0	54.7
BERT-L [78]	86.6	92.3	91.3	70.4	93.2	88.0	60.6
OFA-B [79]	84.3	91.1	88.4	70.8	92.7	90.6	52.3
OFA-L [79]	86.6	92.8	88.9	73.6	94.7	91.4	53.1
*RoBERTa-B [52]	87.6	92.8	91.9	78.7	94.8	90.2	63.6
*RoBERTa-L [52]	90.2	94.7	92.2	86.6	96.4	90.9	68.0
Uni-Perceiver-B	79.7	87.3	86.7	71.1	89.3	86.0	43.1
+ Conditional MoEs	81.5	88.2	87.8	75.8	90.9	87.1	52.2
Uni-Perceiver-L	82.5	89.2	87.7	73.7	91.2	90.2	52.0
+ Conditional MoEs	85.7	91.9	89.5	78.4	93.4	91.2	57.4

(c) MSVD 上视频-文本检索（新任务）的 Recall@1 和视频描述生成（新任务）的 BLEU@4 性能。

Method	#param	#data	Video → Text			Text → Video			Video Caption		
			WT	$PT_{1\%}$	$FT_{100\%}$	WT	$PT_{1\%}$	$FT_{100\%}$	WT	$PT_{1\%}$	$FT_{100\%}$
CLIP2video [22]	132M	400M	-	-	58.7	-	-	47.0	-	-	-
HunYuan_tvr [56]	364M	400M	-	-	68.0	-	-	52.7	-	-	-
ORG-TRL [91]	86M	2.0M	-	-	-	-	-	-	-	-	54.3
Uni-Perceiver-B	124M	44.1M	50.3	62.7	62.8	38.7	43.8	45.8	22.6	59.5	63.3
+ Conditional MoEs	167M	44.1M	52.8	65.6	65.0	40.0	45.3	47.8	23.4	60.0	65.4
Uni-Perceiver-L	354M	44.1M	45.4	65.5	65.2	34.2	48.6	50.8	24.7	67.2	68.3
+ Conditional MoEs	505M	44.1M	45.7	66.4	67.6	41.9	50.3	52.3	24.6	67.6	68.9

4.5 泛化到新任务

泛化能力是通用模型最具吸引力的方面，而条件 MoE 的动态子网络激活应在缓解任务干扰的同时保持这种能力。为验证这一点，我们在视频字幕、视频-文本检索和自然语言理解任务上进行了实验，这些任务并未出现在预训练中。如表 5c 所示，我们配备条件 MoE 的 Uni-Perceiver 能够很好地泛化到视频相关任务。它们可以在这些任务上获得合理的零样本性能，并且相比普通 Uni-Perceiver 也有大幅提升。此外，Uni-Perceiver-MoEs 仅使用 1% 的数据进一步进行提示调优，即可在相近训练成本下取得与 SOTA 方法相当的结果。除此之外，条件 MoE 还可以显著提升 Uni-Perceiver 在 GLUE 基准上的性能（表 5b），这得益于其在通用模型中解决任务干扰的出色能力。

5 结论

在本文中，我们提出了条件 MoE，以解决通用模型中的任务干扰问题。通过稀疏地激活子网络且不引入任何任务特定设计，通用模型可以在多个任务上联合预训练而不会出现性能下降，同时保持对新任务的泛化能力。我们将条件 MoE 与近期提出的通用模型 Uni-Perceiver 相结合。通过在 1% 下游数据上进行提示调优，所提出的稀疏通用模型仅使用 <5% 的训练数据和 <10% 的训练成本，就取得了与以往 SOTA 相竞争的性能。我们希望这项工作能够激励对通用模型的进一步研究。

致谢。本工作得到了中国国家重点研发计划（2020AAA0105200）和北京智源人工智能研究院的支持。

参考文献

[1] A. Abbas 和 Y. Andreopoulos。有偏专家混合：在数据传输受限的情况下实现计算机视觉推理。*TIP*，2020。

[2] H. Akbari、L. Yuan、R. Qian、W.-H. Chuang、S.-F. Chang、Y. Cui 和 B. Gong。Vatt：用于从原始视频、音频和文本进行多模态自监督学习的 Transformer。*NIPS*，2021。[3] J.-B. Alayrac、J. Donahue、P. Luc、A. Miech、I. Barr、Y. Hasson、K. Lenc、A. Mensch、K. Milli-can、M. Reynolds 等。Flamingo：用于少样本学习的视觉语言模型。*arXiv preprint arXiv:2204.14198*，2022。[4] N. Arivazhagan、A. Bapna、O. Firat、D. Lepikhin、M. Johnson、M. Krikun、M. X. Chen、Y. Cao、G. Foster、C. Cherry 等。大规模多语言神经机器翻译在真实环境中的应用：发现与挑战。*arXiv preprint arXiv:1907.05019*，2019。[5] A. Arnab、M. Dehghani、G. Heigold、C. Sun、M. Lučić 和 C. Schmid。Vivit：一种视频视觉 Transformer。*arXiv preprint arXiv:2103.15691*，2021。[6] J. L. Ba、J. R. Kiros 和 G. E. Hinton。层归一化。*arXiv preprint arXiv:1607.06450*，2016。[7] G. Bertasius、H. Wang 和 L. Torresani。时空注意力就是视频理解所需的一切吗？*arXiv preprint arXiv:2102.05095*，2021。

[8] R. Caruana. 多任务学习。*Machine learning*, 1997.

[9] S. Changpinyo、P. Sharma、N. Ding 和 R. Soricut。Conceptual 12M：推动网络规模图像-文本预训练以识别长尾视觉概念。收录于 *CVPR*，2021。

[10] D. S. Chaplot、L. Lee、R. Salakhutdinov、D. Parikh 和 D. Batra。具身多模态多任务学习。*arXiv preprint arXiv:1902.01385*，2019。

[11] D. Chen 和 W. B. Dolan。收集高度平行数据用于释义评估。发表于 *ACL*，2011 年。

[12] X. Chen、H. Fang、T.-Y. Lin、R. Vedantam、S. Gupta、P. Dollár 和 C. L. Zitnick。Microsoft COCO Captions：数据收集与评估服务器。*arXiv preprint arXiv:1504.00325*，2015。

[13] Y.-C. Chen、L. Li、L. Yu、A. El Kholy、F. Ahmed、Z. Gan、Y. Cheng 和 J. Liu。Uniter：通用图像-文本表示学习。2020。

[14] Z. Chen、V. Badrinarayanan、C.-Y. Lee 和 A. Rabinovich。Gradnorm：深度多任务网络中用于自适应损失平衡的梯度归一化。载于 *ICML*，2018。

[15] B. Cheng、I. Misra、A. G. Schwing、A. Kirillov 和 R. Girdhar。用于通用图像分割的掩码注意力掩码 Transformer。2022。

[16] K. Clark、M.-T. Luong、U. Khandelwal、C. D. Manning 和 Q. V. Le。Bam！用于自然语言理解的重生多任务网络。*arXiv preprint arXiv:1907.04829*，2019。

[17] M. Crawshaw. 使用深度神经网络的多任务学习：综述。*arXiv preprint arXiv:2009.09796*，2020。 [18] J. Deng、W. Dong、R. Socher、L.-J. Li、K. Li 和 L. Fei-Fei。Imagenet：大规模层次化图像数据库。发表于 *CVPR*，2009。

[19] J. Devlin、M.-W. Chang、K. Lee 和 K. Toutanova。Bert：用于语言理解的深度双向 Transformer 预训练。*arXiv preprint arXiv:1810.04805*，2018。

[20] A. Dosovitskiy, L. Beyer, A. Kolesnikov, D. Weissenborn, X. Zhai, T. Unterthiner, M. Dehghani, M. Minderer, G. Heigold, S. Gelly 等。一张图像胜过 16x16 个词：用于大规模图像识别的 Transformer。*arXiv preprint arXiv:2010.11929*，2020。

[21] N. Du, Y. Huang, A. M. Dai, S. Tong, D. Lepikhin, Y. Xu, M. Krikun, Y. Zhou, A. W. Yu, O. Firat 等。Glam：使用专家混合高效扩展语言模型。*arXiv preprint arXiv:2112.06905*，2021。

[22] H. Fang、P. Xiong、L. Xu 和 Y. Chen。Clip2video：通过图像 CLIP 掌握视频-文本检索。*arXiv preprint arXiv:2106.11097*，2021。 [23] W. Fedus、B. Zoph 和 N. Shazeer。Switch transformers：通过简单高效的稀疏性扩展到万亿参数模型。*arXiv preprint arXiv:2101.03961*，2021。 [24] M. Guo、A. Haque、D.-A. Huang、S. Yeung 和 L. Fei-Fei。用于多任务学习的动态任务优先级排序。见 *ECCV*，2018。

[25] K. Hashimoto、C. Xiong、Y. Tsuruoka 和 R. Socher。联合多任务模型：为多个 NLP 任务增长神经网络。*arXiv preprint arXiv:1611.01587*，2016。

[26] K. He、X. Zhang、S. Ren 和 J. Sun。用于图像识别的深度残差学习。见 *CVPR*，2016。[27] K. He、G. Gkioxari、P. Dollár 和 R. Girshick。Mask R-CNN。见 *ICCV*，2017。

[28] C. Hokamp、J. Glover 和 D. Gholipour。评估多语言翻译模型的监督和零样本性能。*arXiv preprint arXiv:1906.09675*，2019。

[29] R. Hu 和 A. Singh。Unit：使用统一 Transformer 的多模态多任务学习。*arXiv preprint arXiv:2102.10772*，2021。[30] T. Iki 和 A. Aizawa。视觉扩展对视觉-语言模型中自然语言理解的影响。*arXiv preprint arXiv:2104.08066*，2021。[31] A. Jaegle、S. Borgeaud、J.-B. Alayrac、C. Doersch、C. Ionescu、D. Ding、S. Koppula、A. Brock、E. Shelhamer、O. Hénaff、M. M. Botvinick、A. Zisserman、O. Vinyals 和 J. Carreira。Perceiver IO：一种用于结构化输入与输出的通用架构，2021。[32] A. Jaegle、F. Gimeno、A. Brock、O. Vinyals、A. Zisserman 和 J. Carreira。Perceiver：通过迭代注意力实现通用感知。见 *ICML*，2021。

[33] C. Jia、Y. Yang、Y. Xia、Y.-T. Chen、Z. Parekh、H. Pham、Q. Le、Y.-H. Sung、Z. Li 和 T. Duerig。利用噪声文本监督扩展视觉和视觉-语言表征学习。发表于 *International Conference on Machine Learning*，第 4904–4916 页。PMLR，2021。

[34] H. Jiang、P. He、W. Chen、X. Liu、J. Gao 和 T. Zhao。Smart：通过有原则的正则化优化对预训练自然语言模型进行鲁棒且高效的微调。*arXiv preprint arXiv:1911.03437*，2019。

[35] S. Kalkowski、C. Schulze、A. Dengel 和 D. Borth。yfcc100m 数据集的实时分析与可视化。载于 *Proceedings of the 2015 workshop on community-organized multimodal mining: opportunities for novel solutions*，第 25–30 页，2015 年。

[36] M. Kanakis, D. Bruggemann, S. Saha, S. Georgoulis, A. Obukhov, and L. V. Gool. 在无任务干扰的增量多任务学习中重参数化卷积。2020.

[37] W. Kay, J. Carreira, K. Simonyan, B. Zhang, C. Hillier, S. Vijayanarasimhan, F. Viola, T. Green, T. Back, P. Natsev 等。Kinetics 人类动作视频数据集。*arXiv preprint arXiv:1705.06950*，2017。

[38] A. Kendall、Y. Gal 和 R. Cipolla。利用不确定性为场景几何与语义的损失加权的多任务学习。载于 *CVPR*，2018。

[39] W. Kim、B. Son 和 I. Kim。Vilt：无需卷积或区域监督的视觉-语言 Transformer。*arXiv preprint arXiv:2102.03334*，2021。

[40] Y. J. Kim、A. A. Awan、A. Muzio、A. F. C. Salinas、L. Lu、A. Hendy、S. Rajbhandari、Y. He 和 H. H. Awadalla。用于多任务多语言模型的可扩展且高效的 MoE 训练。*arXiv preprint arXiv:2109.10465*，2021。

[41] R. Krishna, Y. Zhu, O. Groth, J. Johnson, K. Hata, J. Kravitz, S. Chen, Y. Kalantidis, L.-J. Li, D. A. Shamma 等。Visual genome：使用众包密集图像标注连接语言与视觉。*IJCV*, 123(1):32–73, 2017.

[42] S. Kudugunta、Y. Huang、A. Bapna、M. Krikun、D. Lepikhin、M.-T. Luong 和 O. Firat。超越蒸馏：用于高效推理的任务级专家混合。*arXiv preprint arXiv:2110.03742*，2021。

[43] D. Lepikhin、H. Lee、Y. Xu、D. Chen、O. Firat、Y. Huang、M. Krikun、N. Shazeer 和 Z. Chen。Gshard：通过条件计算和自动分片扩展巨型模型。*arXiv preprint arXiv:2006.16668*，2020。

[44] J. Li、D. Li、C. Xiong 和 S. Hoi。Blip：用于统一视觉-语言理解与生成的语言-图像预训练自举。*arXiv preprint arXiv:2201.12086*，2022。

[45] L. H. Li、M. Yatskar、D. Yin、C.-J. Hsieh 和 K.-W. Chang。Visualbert：一种用于视觉和语言的简单且高性能的基线。*arXiv preprint arXiv:1908.03557*，2019。[46] X. Li、X. Yin、C. Li、P. Zhang、X. Hu、L. Zhang、L. Wang、H. Hu、L. Dong、F. Wei 等。Oscar：用于视觉-语言任务的对象语义对齐预训练。在 *ECCV* 中，2020。

[47] Z. Li、F. Liu、W. Yang、S. Peng 和 J. Zhou。卷积神经网络综述：分析、应用与前景。*IEEE Transactions on Neural Networks and Learning Systems*，第 1–21 页，2021。doi: 10.1109/TNNLS.2021.3084827。[48] Z. Li、W. Wang、E. Xie、Z. Yu、A. Anandkumar、J. Alvarez、T. Lu 和 P. Luo。Panoptic segformer：用 transformer 深入探究全景分割。2022。[49] Z. Lin、L. Wu、M. Wang 和 L. Li。为多语言机器翻译学习语言特定子网络。*arXiv preprint arXiv:2105.09259*，2021。[50] P. Liu、X. Qiu 和 X. Huang。用于文本分类的对抗式多任务学习。*arXiv preprint arXiv:1704.05742*，2017。[51] X. Liu、Y. Zheng、Z. Du、M. Ding、Y. Qian、Z. Yang 和 J. Tang。GPT 也能理解。*arXiv preprint arXiv:2103.10385*，2021。[52] Y. Liu、M. Ott、N. Goyal、J. Du、M. Joshi、D. Chen、O. Levy、M. Lewis、L. Zettlemoyer 和 V. Stoyanov。Roberta：一种经过稳健优化的 BERT 预训练方法。*arXiv preprint arXiv:1907.11692*，2019。[53] Z. Liu、Y. Lin、Y. Cao、H. Hu、Y. Wei、Z. Zhang、S. Lin 和 B. Guo。Swin transformer：使用移位窗口的层次化视觉 transformer。*ICCV*，2021。

[54] J. Lu、D. Batra、D. Parikh 和 S. Lee。Vilbert：为视觉与语言任务预训练任务无关的视觉语言表示。*arXiv preprint arXiv:1908.02265*，2019。

[55] J. Lu、V. Goswami、M. Rohrbach、D. Parikh 和 S. Lee。12 合 1：多任务视觉与语言表示学习。载于 *CVPR*，2020。

[56] S. Min, W. Kong, R.-C. Tu, D. Gong, C. Cai, W. Zhao, C. Liu, S. Zheng, H. Wang, Z. Li, 等。用于文本-视频检索的 Hunyuan_tvr。*arXiv preprint arXiv:2204.03382*，2022。

[57] M. Monfort, A. Andonian, B. Zhou, K. Ramakrishnan, S. A. Bargal, T. Yan, L. Brown, Q. Fan, D. Gutfreund, C. Vondrick 等。Moments in Time 数据集：用于事件理解的一百万个视频。*TPAMI*，2019。

[58] V. Ordonez、G. Kulkarni 和 T. Berg。Im2text：使用 100 万张带标题的照片描述图像。*NeurIPS*，2011。

[59] B. A. Plummer、L. Wang、C. M. Cervantes、J. C. Caicedo、J. Hockenmaier 和 S. Lazebnik。Flickr30k 实体：为更丰富的图像到句子模型收集区域到短语的对应关系。发表于 *ICCV*，2015。

[60] D. Qi、L. Su、J. Song、E. Cui、T. Bharti 和 A. Sacheti。ImageBERT：使用大规模弱监督图文数据进行跨模态预训练。*arXiv preprint arXiv:2001.07966*，2020。

[61] A. Radford, J. W. Kim, C. Hallacy, A. Ramesh, G. Goh, S. Agarwal, G. Sastry, A. Askell, P. Mishkin, J. Clark, 等。通过自然语言监督学习可迁移的视觉模型。*arXiv preprint arXiv:2103.00020*，2021。

[62] S. Reed、K. Zolna、E. Parisotto、S. G. Colmenarejo、A. Novikov、G. Barth-Maron、M. Gimenez、Y. Sulsky、J. Kay、J. T. Springenberg、T. Eccles、J. Bruce、A. Razavi、A. Edwards、N. Heess、Y. Chen、R. Hadsell、O. Vinyals、M. Bordbar 和 N. de Freitas。通用智能体，2022。

[63] S. Ren、K. He、R. Girshick 和 J. Sun。Faster r-cnn：基于区域建议网络的实时目标检测。*NeurIPS*，2015。

[64] C. Riquelme、J. Puigcerver、B. Mustafa、M. Neumann、R. Jenatton、A. Susano Pinto、D. Keysers 和 N. Houlsby。使用稀疏专家混合扩展视觉。*NIPS*，2021。 [65] J. Shao、S. Chen、Y. Li、K. Wang、Z. Yin、Y. He、J. Teng、Q. Sun、M. Gao、J. Liu 等。Intern：面向通用视觉的新学习范式。*arXiv preprint arXiv:2111.08687*，2021。 [66] P. Sharma、N. Ding、S. Goodman 和 R. Soricut。概念字幕：一个经过清理并进行上位词化处理的图像替代文本数据集，用于自动图像描述生成。见 *ACL*，2018。 [67] N. Shazeer、A. Mirhoseini、K. Maziarz、A. Davis、Q. Le、G. Hinton 和 J. Dean。超大规模神经网络：稀疏门控专家混合层。*arXiv preprint arXiv:1701.06538*，2017。 [68] N. Shazeer、Y. Cheng、N. Parmar、D. Tran、A. Vaswani、P. Koanantakool、P. Hawkins、H. Lee、M. Hong、C. Young 等。Mesh-tensorflow：用于超级计算机的深度学习。*NIPS*，31，2018。

[69] S. Shen、L. H. Li、H. Tan、M. Bansal、A. Rohrbach、K.-W. Chang、Z. Yao 和 K. Keutzer。CLIP 能在多大程度上惠及视觉与语言任务？*arXiv preprint arXiv:2107.06383*，2021。 [70] K. Simonyan 和 A. Zisserman。用于大规模图像识别的甚深卷积网络。*arXiv preprint arXiv:1409.1556*，2014。 [71] A. Sing h、R. Hu、V. Goswami、G. Couairon、W. Galuba、M. Rohrbach 和 D. Kiela。Flava：一种基础性的语言与视觉对齐模型。*arXiv preprint arXiv:2112.04482*，2021。 [72] T. Standley、A. Zamir、D. Chen、L. Guibas、J. Malik 和 S. Savarese。多任务学习中哪些任务应当共同学习？载于 *ICML*，2020。 [73] A. St einer、A. Kolesnikov、X. Zhai、R. Wightman、J. Uszkoreit 和 L. Beyer。如何训练你的 ViT？视觉 Trans former 中的数据、增强与正则化。*arXiv preprint arXiv:2106.10270*，2021。 [74] G. Strezoski、N. v. Noo rd 和 M. Worring。采用任务路由的多任务学习。载于 *ICCV*，2019。 [75] H. Tan 和 M. Bansal。Lxmert ：从 Transformer 中学习跨模态编码器表示。*arXiv preprint arXiv:1908.07490*，2019。 [76] H. Touvron 、M. Cord、M. Douze、F. Massa、A. Sablayrolles 和 H. Jégou。通过注意力训练数据高效的图像 Transf ormer 与蒸馏。载于 *ICML*，2021。 [77] A. Vaswani、N. Shazeer、N. Parmar、J. Uszkoreit、L. Jones、A. N. Gomez、 . Kaiser 和 I. Polosukhin。注意力就是你所需要的一切。载于 *NeurIPS*，2017。 [78] A. Wang、A. Singh、J. Michael、F. Hill、O. Levy 和 S. R. Bowman。GLUE：用于自然语言理解的多任务基准与分析平台。*arXiv preprint arXiv:1804.07461*，2018。

[79] P. Wang、A. Yang、R. Men、J. Lin、S. Bai、Z. Li、J. Ma、C. Zhou、J. Zhou 和 H. Yang。通过简单的序列到序列学习框架统一架构、任务和模态。*arXiv preprint arXiv:2202.03052*，2022。

[80] W. Wang、E. Xie、X. Li、D.-P. Fan、K. Song、D. Liang、T. Lu、P. Luo 和 L. Shao。金字塔视觉 Transformer：一种无需卷积、适用于密集预测的通用骨干网络。发表于 *ICCV*，2021。

[81] X. Wang、Y. Tsvetkov 和 G. Neubig。多语言神经机器翻译的平衡训练。
arXiv preprint arXiv:2004.06748，2020。

[82] X. Wang、F. Yu、L. Dunlap、Y.-A. Ma、R. Wang、A. Mirhoseini、T. Darrell 和 J. E. Gonzalez。通过浅层嵌入实现深度专家混合。载于 *Uncertainty in artificial intelligence*。PMLR，2020。

[83] Z. Wang、Z. C. Lipton 和 Y. Tsvetkov。关于多语言模型中的负干扰：发现与一种元学习处理方法 。*arXiv preprint arXiv:2010.03017*，2020。

[84] Z. Wang、J. Yu、A. W. Yu、Z. Dai、Y. Tsvetkov 和 Y. Cao。Simvlm：基于弱监督的简单视觉语言模型预训练。*arXiv preprint arXiv:2108.10904*，2021。

[85] B. Yang、G. Bender、Q. V. Le 和 J. Ngiam。Condconv：用于高效推理的条件参数化卷积。*NIPS*，32，2019。

[86] Z. Yang、Z. Gan、J. Wang、X. Hu、F. Ahmed、Z. Liu、Y. Lu 和 L. Wang。跨越文本与框的格式边界：迈向统一的视觉-语言建模。*arXiv preprint arXiv:2111.12085*，2021。[87] J. Yu、Z. Wang、V. V asudevan、L. Yeung、M. Seyedhosseini 和 Y. Wu。Coca：对比式字幕生成器是图像-文本基础模型。*arXiv preprint arXiv:2205.01917*，2022。[88] T. Yu、S. Kumar、A. Gupta、S. Levine、K. Hausman 和 C. Finn。用于多任务学习的梯度手术。*NIPS*，33:5824–5836，2020。[89] L. Yuan、D. Chen、Y.-L. Chen 、N. Codella、X. Dai、J. Gao、H. Hu、X. Huang、B. Li、C. Li 等。Florence：一种新的计算机视觉基础模型。*arXiv preprint arXiv:2111.11432*，2021。[90] B. Zhang、A. Bapna、R. Sennrich 和 O. Firat。共享还是不共享？学习为多语言翻译调度语言特定容量。见 *ICLR*，2020。[91] Z. Zhang、Y. Shi、C. Yua n、B. Li、P. Wang、W. Hu 和 Z.-J. Zha。用于视频字幕生成的带教师推荐学习的对象关系图。见 *CVPR*，第 13278–13288 页，2020。

[92] L. Zhou、H. Palangi、L. Zhang、H. Hu、J. Corso 和 J. Gao。用于图像描述和视觉问答的统一视觉-语言预训练。收录于 *AAAI*，2020。 [93] X. Zhu、J. Zhu、H. Li、X. Wu、X. Wang、H. Li、X. Wang 和 J. Dai。Uni-perceiver：面向零样本和少样本任务的通用感知统一架构预训练。
arXiv preprint arXiv:2112.01522，2021。 [94] Y. Zhu、R. Kiros、R. Zemel、R. Salakhutdinov、R. Urtasun、A. Torralba 和 S. Fidler。对齐书籍与电影：通过观看电影和阅读书籍实现类故事的视觉解释。收录于 *ICCV*，第 19–27 页，2015。

表6：本文中使用的 Uni-Perceiver 模型变体。“#vocab params”和“#encoder params”分别表示词表参数数量和编码器网络参数数量。

	base model	embedding dimension	#heads	#layers	#vocab params	#encoder params	#total params
Uni-Perceiver-Ti	DeiT-Ti [76]	192	3	12	9.5M	5.3M	14.8M
Uni-Perceiver-B	ViT-B [20]	768	12	12	38M	86M	124M
Uni-Perceiver-L	ViT-L [20]	1024	16	24	51M	303M	354M

表 7：我们预训练所用的任务和数据集。

task	dataset	batch size/GPU	sampling weight	loss weight
Image Classification	ImageNet-21k [18]	220	0.2486	1.0
Video Classification	Kinetics-700 [37]	6	0.01	0.1
	Moments in Time [57]	24	0.02	0.1
Masked Language Modeling	Books&Wiki [94]	256	0.275	0.5
Image Caption	YFCC [35]	100	0.0584	1.0
	CC12M [9]	100	0.05057	1.0
	CC3M [66]	100	0.026295	1.0
	Visual Genome [41]	100	0.01766	1.0
	COCO Caption [12]	100	0.01144	1.0
	SBU [58]	100	0.01383	1.0
Image-Text Retrieval	YFCC [35]	160	0.0584	0.5
	CC12M [9]	160	05057	0.5
	CC3M [66]	160	0.026295	0.5
	Visual Genome [41]	160	0.01766	0.5
	COCO Caption [12]	160	0.01144	0.5
	SBU [58]	160	0.01383	0.5

6 附录

6.1 实验细节

预训练细节。我们的工作中使用了三种变体的 Uni-Perceiver，如表 6 所总结。Uni-Perceiver-Ti 在消融实验中采用与 DeiT-Ti [76] 相同的设置。Uni-Perceiver-B 和 Uni-Perceiver-L 分别与其对应的 ViT 变体具有相同的架构。我们遵循 Uni-Perceiver [93] 中的大部分设置：所有任务均采用标签平滑为 0.1 的交叉熵损失，检索任务的负样本仅来自当前 GPU 上的本地批次。我们还将与 Uni-Perceiver [93] 相同的数据增强技术应用于图像和视频模态，以避免过拟合。Uni-Perceiver 和 Uni-Perceiver-MoE 模型在 32 块 NVIDIA-A100 GPU（80GB 显存）上进行了 400k 次迭代的预训练。

为了提升原始 Uni-Perceiver 的训练稳定性，我们进行了一些设置调整。按照 [102]，在所有编码器层中使用统一的随机深度丢弃率，并根据模型规模进行调整。此外，使用 LayerScale [101] 来促进 Transformer 训练的收敛，并且为简化起见，所有模型都设置相同的 10^{-3} 初始化。除此之外，表 7 列出了预训练阶段每个任务和数据集的批大小、采样权重和损失权重。通过短 epoch 实验观察早期训练损失，对损失权重进行调整，以满足所有任务的合理优化需求。每个任务和数据集的采样权重与数据集大小的平方根成正比，这已被证明是一种有效的启发式方法，可缓解不同数据集之间的数据不平衡 [4]。按照 [102]，我们首先使用 160×160 的图像分辨率和 16×16 的 patch 大小进行预训练，然后在更高的 224×224 分辨率上继续进行总迭代次数 10% 的预训练。此外，还采用了 [100] 中的混合精度训练实现，以便使用更大的批大小训练 Uni-Perceiver。基于上述设置，我们可以更高效地训练 Uni-Perceiver。如表 8 所示，我们重新实现的 Uni-Perceiver 在各种任务上也取得了更好的性能。

每个 Conditional-MoE 层中的专家数量默认设置为 8。对于采用数据依赖路由策略的 Conditional MoE，即 *i.e.,* token 级和上下文级，我们在训练阶段使用 1.0 的容量因子，在评估阶段使用 2.0 的容量因子 [23, 40]。此外，[23] 中的均衡损失也用于数据依赖 MoE，以实现专家利用率的负载均衡，并以 10^{-2} 的乘法系数加入总损失中。

表 8：原始 Uni-Perceiver-B [93] 与我们重新实现的 Uni-Perceiver-B* 之间的比较。结果分别报告了 ImageNet-1K 上的图像分类准确率、Kinetics-400 上的视频分类准确率、Flickr30K 上的图文检索 R@1，以及 COCO Caption 上的图像描述 BLEU@4。’TR’ 和 ’IR’ 分别表示文本检索和图像检索。

	ImageNet-1k			Kinetics-400			Flickr30K		COCO Caption	pre-training time
	WT	$PT_{1\%}$	$FT_{100\%}$	WT	$PT_{1\%}$	$FT_{100\%}$	$TR(FT_{100\%})$	$IR(FT_{100\%})$	$FT_{100\%}$	TPU-v3-core-days
Uni-Perceiver-B [93]	78.0	80.2	83.8	73.5	73.6	75.8	87.9	74.9	35.6	$\sim$ 3.4k
Uni-Perceiver-B*	79.2	80.9	84.0	74.5	74.8	77.7	92.7	77.5	36.4	$\sim$ 1.0k

表9：下游任务调优的超参数。“*param1/param2*”分别表示用于微调和提示调优的相应参数。

	ImageNet-1k	Kinetics-400	COCO Caption	Flickr30K Caption	COCO Retrieval	Flickr30K Retrieval
Gradient clip	1.0/1.0					
Stoch. Depth	0.2/0.2					
Weight decay rate	1×10^{-4}/0.0					
LR decay schedule	Cosine Schedule Decaying to Zero/Constant Learning Rate					
Train steps	20k/5k	20k/2k	10k/1k	4k/200	10k/500	5k/100
Train batch size	2048/1024	64/32	512/512	512/512	2048/2048	2048/2048
Warm-up steps	2k/500	2k/200	1k/100	400/20	1k/50	500/10
Learning rate	$2\times10^{-5}/1\times10^{-3}$	$5\times10^{-6}/5\times10^{-4}$	$2\times10^{-5}/1\times10^{-3}$	$2\times10^{-5}/1\times10^{-3}$	$5\times10^{-6}/1\times10^{-3}$	$5\times10^{-6}/1\times10^{-3}$

微调与提示调优。除了在不进行任何参数调优的情况下进行评估外，还进行了使用 100% 数据的微调和使用 1% 数据的提示调优，以评估模型性能。我们主要遵循 Uni-Perceiver 中的实践。具体而言，对于提示调优，遵循 P-Tuning v2 [97]，在每个编码器层添加随机初始化的可学习提示 token，并为分类任务添加带有线性头的类别标签。<SPE> token 和层归一化参数也会被调优。微调和提示调优的所有训练配置均列于表 9。

去除重叠。按照 [93]，我们仔细移除了 Kinetics-700 训练集中与 Kinetics-400 验证集重叠的那些视频。

6.2 条件式 MoE 的放置

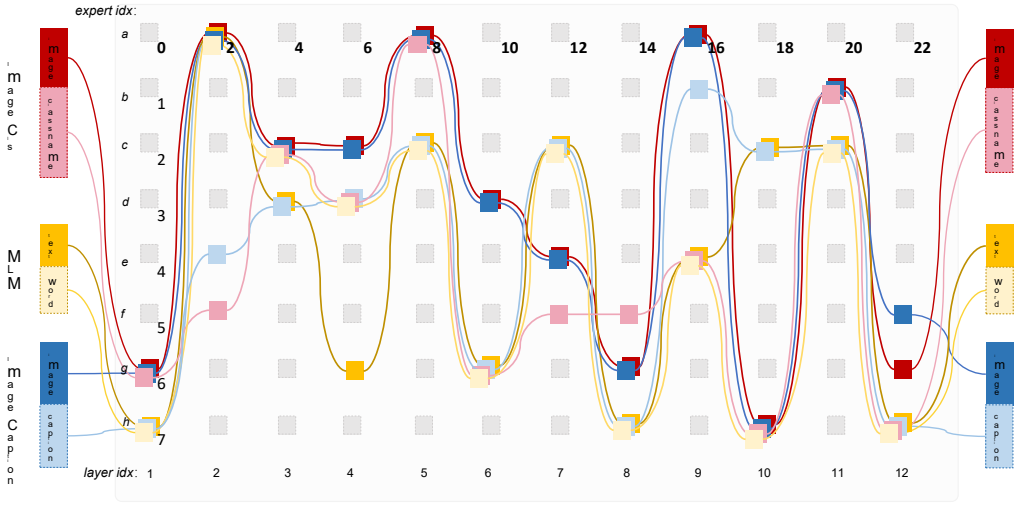
以往方法通常只在每隔一个密集前馈网络（FFN）层中引入 MoE 层 [23, 40]。相反，我们更倾向于在 Transformer 的每一层中使用 Conditional-MoE 层，这有助于更彻底地缓解任务干扰。表 11 展示了在间隔应用 Conditional-MoE 层，或仅在某一类型的层（*i.e.,* FFN 层或自注意力层）上应用时的结果。我们可以观察到，被属性级 MoE 替换的层越多，任务干扰就越能得到缓解，各项任务的性能也越高。此外，在自注意力层和 FFN 层中同时应用 Conditional MoE 能更好地缓解任务干扰。然而，仅为自注意力层配备 Conditional MoE 在解决任务干扰方面能力有限。

6.3 属性级 MoE 的门控决策可视化

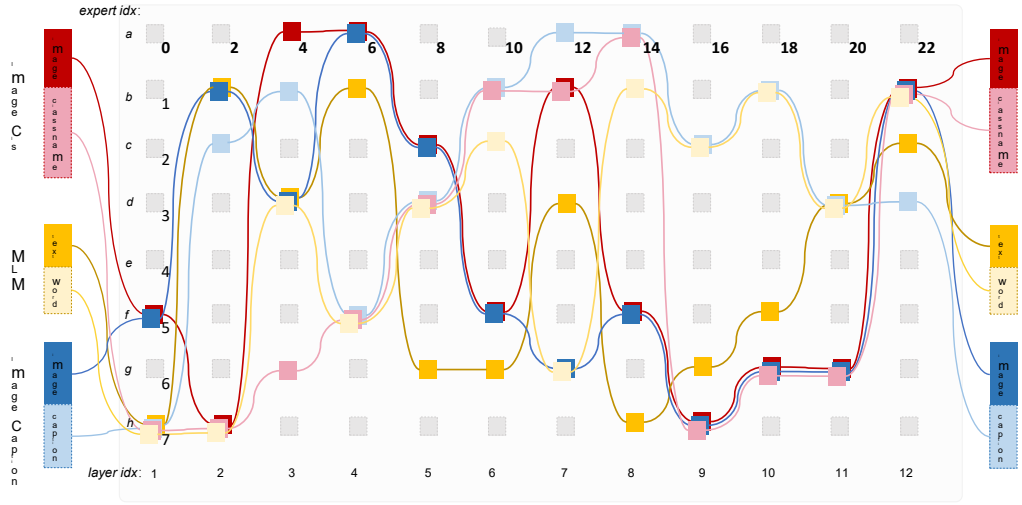
我们在图 3 中展示了训练后的 Uni-Perceiver-MoE 模型不同层的专家分布。自注意力层中的条件 MoE（图 3a）和 FFN 层中的条件 MoE（图 3b）都已学会根据词元属性稀疏地激活专家。一些专家会被具有相同模态的词元共享。例如，用于图像分类和图像描述任务的“图像”通常会被路由到相同的专家。此外，同一任务中的输入和目标也会共享一些专家，*e.g.,* 第 7*th* 个 FFN 层中的专家 *b*。有趣的是，因果注意力掩码这一属性也被条件 MoE 所利用，*e.g.,* 第 2*nd* 和第 9*th* 个自注意力层，这表明自编码任务和自回归任务之间可能存在潜在干扰。

6.4 相关方法的训练统计

表 10 列出了与我们工作相关的一些方法的训练统计数据。如第 2 节所述，这些方法分为三类：专用模型、集成式专用模型和通用模型。为了公平比较，我们记录了从零开始训练每种方法所使用的全部数据，包括现成预训练模型所使用的数据。可以看到，Uni-Perceiver-MoE 的训练数据规模相较于大多数通用模型要小得多，并且与一些专用模型相当。



(a) Gating decisions of the self-attention layers for Uni-Perceiver-MoE-Ti.



(b) Uni-Perceiver-MoE-Ti 的 FFN 层的门控决策。

图 3：带有属性级 MoE 的训练后 Uni-Perceiver-Ti 的门控决策。我们展示了三个任务中每个自注意力层和 FFN 层的专家 top-1 激活：ImageNet-1k 上的图像分类（Image Cls）、Books &Wiki 上的掩码语言建模（MLM）以及 COCO Caption 上的图像描述。来自不同任务的输入和目标对应激活用不同颜色突出显示。灰色阴影方块表示未被激活的专家。

表 10：相关方法的训练统计信息，这些方法分为专用模型、集成式专用模型和通用模型。* 表示纯文本的存储空间。† 表示 RL 任务中的 token 数量。¶ 表示现成预训练模型中使用的数据。§ 数据集为私有数据集。

methods	training data			total visual data size	training time TPU-v3-core-days[1]
	dataset	data type	data size		
► *Specialized Models*					
BERT [19]	Books&Wiki	plain texts	16GB	-	1.4K
ORG-TRL [91]	ImageNet-1K	images	1.28M¶	1.6M	-
	Kinetics-400	videos	300K¶		
	MSCOCO	image-bounding boxes	118K¶		
	Books&Wiki	plain texts	16GB*¶		
Unified VLP [92]	CC3M	image-text pairs	3.0M	3.1M	-
	VG	image-bounding boxes	108K¶		
	Books&Wiki	plain texts	16GB*¶		
OSCAR [46]	COCO, CC3M, SBU, Flickr30K, VQA, GQA, VG-QA	image-text pair	6.5M	6.6M	-
	VG	image-bounding boxes+attributes	108K¶		
UNITER[13]	CC3M, SBU, COCO, VG	image-text pairs	9.6M	9.7M	0.5K
	VG	image-bounding boxes+attributes	108K¶		
ImageBERT [60]	CC3M, SBU, LAIT§	image-text pairs	13.7M	13.8M	-
	VG	image-bounding boxes	108K¶		
	Books&Wiki	plain texts	16GB¶		
TimeSformer [7]	ImageNet-21K	images	14.2M¶	14.5M	-
	Kinetics-400	videos	300K		
ViT-L [73]	ImageNet-21K, ImageNet-1K	images	15.5M	15.5M	0.23K
ViLT [39]	COCO, VG, CC3M, SBU	image-text pairs	9.7M	25.2M	-
	ImageNet-21K, ImageNet-1K	images	15.5M¶		
VATT [2]	AudioSet	audios	2.1M	138M	1.5K
	HowTo100M	video-audio-text triplets	136M		
BLIP [44]	COCO, VG, SBU CC3M, CC12M, LAION	image-text pairs	130M	144M	-
	ImageNet-21k	images	14.2M¶		
	Books&Wiki	plain texts	16GB*¶		
ViViT [5]	JFT-300M§, ImageNet-21K	images	300M¶	300.3M	-
	Kinetics-400	videos	300k		
CLIP [61]	CLIP data§	image-text pairs	400M	400M	18K
HunYuan_tvr [56]	CLIP data§	image-text pairs	400M	400M	-
CLIP2video [22]	CLIP data§	image-text pairs	400M	400M	-
CLIP-VIL [69]	CLIP data§	image-text pairs	400M	400M	-
ALIGN [33]	ALIGN data§	image-text pairs	1.8B	1.8B	-
► *Integrated Specialized Models*					
FLAVA [71]	COCO, SBU, Localized Narratives, CC3M, VG, Wikipedia Image Text, CC12M, Red Caps, YFCC	image-text pairs	70M	71.3M	-
	ImageNet-1K	images	1.28M		
	CCNews, BookCorpus	plain texts	970GB*		
Florence [89]	FLB-900M§	image-text pairs	900M	909M	44K
	FLOD-9M§	image-bounding boxes	9M		
► *Generalist Models*					
UNICORN [86]	COCO, VG, CC3M, SBU	image-text pairs	9.8M	25.3M	-
	ImageNet-21K, ImageNet-1K	images	15.5M¶		
	BooksCorpus, CC-News, OpenwebText, Stories	plain texts	160GB¶		
OFA [79]	CC12M, CC3M, SBU, COCO, VG-Cap	image-text pairs	15.25M	60.6M	-
	VQAv2, VG-QA, GQA	visual question answering	2.92M		
	RefCOCO, RefCOCO+, RefCOCOg, VG-Cap	image-instance-text triplets	3.2M		
	OpenImages, Object365, VG, COCO	image-bounding boxes	3.0M		
	YFCC100M, ImageNet-21K	Images	36.27M		
	Pile	plain texts	140GB*		
SimVLM [84]	ALIGN data§	image-text pairs	1.8B	1.8B	-
	Colossal Clean Crawled Corpus	plain texts	800GB*		
Gato [62]	DM Lab, ALE Atari, ALE Atari Extended, Sokoban, BabyAI, DM Control Suite, Procgen Benchmark, RGB Stacking simulator, RGB Stacking real robot, Meta-World, DM Manipulation Playground, Playroom	simulated data for RL tasks	1.5T†	2.16B	2K
	M3W§, ALIGN data§, CC3M, COCO LTIP§, QKVQA, VQAV2	image-text pairs	2.16B		
	MassiveWeb§	plain texts	1.9TB*		
Flamingo [3]	M3W§, ALIGN data§, LTIP§	image-text pairs	2.3B	2.3B	126K
	VTP§	video-text pair	27M		
CoCa [87]	JFT-3B§, ALIGN data§	image-text pairs	4.8B	4.8B	56K
Uni-Perceiver [93] & Uni-Perceiver-MoE	CC3M, CC12M, SBU, COCO, VG, YFCC	image-text pairs	28.6M	44.1M	4.2K
	ImageNet-21K	images	14.2M		
	Kinetics-700, Moments in Time	videos	1.33M		
	Books&Wiki	plain texts	16GB*		

1我们根据加速器的 TFLOPS 将训练时间转换为 TPU-v3-core-days，*i.e.,* 1.0 TPU-v3-core-days ≈ 0.364 TPU-v4-core-days ≈ 0.151 NVIDIA-A100-days ≈ 0.302 NVIDIA-V100-days..

表 11：不同属性级路由设置的性能。FFN MoE 和 SA MoE 分别表示是否在 FFN 层和自注意力层中应用 Conditional MoE。every-*n* 表示在 Transformer 编码器中每隔 *n* 层放置一个 Conditional-MoE 层。

model	FFN MoE	SA MoE	every-*n*	ImageNet-1k		COCO Caption		MLM	
				$\uparrow \text{acc}_{\text{train}}$	$\uparrow \text{acc}_{\text{val}}$	$\uparrow \text{acc}_{\text{train}}$	$\uparrow \text{B@4}_{\text{val}}$	$\uparrow \text{acc}_{\text{train}}$	$\downarrow \text{ppl}_{\text{val}}$
Uni-Perceiver-Ti	-	-	-	47.3	68.3	49.2	18.2	54.5	5.86
+ Conditional MoEs $_{\text{attribute}}$	✓	✓	4	51.7	71.6	51.3	20.9	56.1	5.47
+ Conditional MoEs $_{\text{attribute}}$	✓	✓	2	52.2	72.3	51.8	21.1	57.3	5.13
+ Conditional MoEs $_{\text{attribute}}$	✓	✗	1	51.5	71.3	52.2	21.0	58.5	4.86
+ Conditional MoEs $_{\text{attribute}}$	✗	✓	1	49.2	69.7	51.0	20.6	55.8	5.50
+ Conditional MoEs $_{\text{attribute}}$	✓	✓	1	52.8	73.3	53.1	23.0	60.0	4.56

6.5 数据集许可证

ImageNet-21K [18] 受 ImageNet 使用条款 [103] 约束。

Kinetics-700 和 Kinetics-400 [37] Kinetics 数据集由 Google Inc. 根据知识共享署名 4.0 国际许可协议授权。

BooksCorpus [94] 复刻版 Toronto BookCorpus 是开源的，并采用 GNU GPL 第 3 版授权。

维基百科 维基百科的大部分文本均依据知识共享署名-相同方式共享 3.0 未本地化许可证（CC BY-SA）和 GNU 自由文档许可证（GFDL）（无版本号，无固定章节、封面文本或封底文本）共同授权。部分文本仅依据 CC BY-SA 及与 CC BY-SA 兼容的许可证导入，不能依据 GFDL 重复使用。

YFCC [35] YFCC 数据集中提供的所有照片和视频均采用知识共享版权许可之一进行授权。

CC12M [9] 根据 Conceptual 12M [98] 的使用条款授权。

CC3M [66] 根据 Conceptual Captions 使用条款 [99] 获得许可。

Visual Genome [41] 采用知识共享署名 4.0 国际许可证 [96] 授权。

COCO Caption [12] 图像受 Flickr 使用条款 [95] 约束。

SBU Caption [58] 这些图像受 Flickr 使用条款 [95] 约束。

附录参考文献

[95] I. Flickr。Flickr 使用条款与条件。https://www.flickr.com/help/terms.

[96] R. Krishna. Visual Genome 使用条款与条件。https://visualgenome.org/about。 [97] X. Liu、K. Ji、Y. Fu、Z. Du、Z. Yang 和 J. Tang。P-tuning v2：提示调优在各种规模和任务上都可以与微调相媲美。*arXiv preprint arXiv:2110.07602*，2021。 [98] G. LLC。Conceptual 12M 使用条款与条件。https://github.com/ google-research-datasets/conceptual-12m/blob/main/LICENSE，。 [99] G. LLC。Conceptual Captions 使用条款与条件。https://github.com/ google-research-datasets/conceptual-captions/blob/master/LICENSE，。 [100] J. Rasley、S. Rajbhandari、O. Ruwase 和 Y. He。DeepSpeed：系统优化使得训练超过 1000 亿参数的深度学习模型成为可能。发表于 *Proceedings of the 26th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining*，2020。 [101] H. Touvron、M. Cord、A. Sablayrolles、G. Synnaeve 和 H. Jégou。使用图像 Transformer 向更深层推进。*arXiv preprint arXiv:2103.17239*，2021。 [102] H. Touvron、M. Cord 和 H. Jégou。DeiT III：ViT 的复仇。*arXiv preprint arXiv:2204.07118*，2022。 [103] P. University 和 S. University。ImageNet 使用条款与条件。https://image-net.org/ download。