2202 voN 71]VC.sc[1v80890.1122:viXra

Uni-Perceiver v2：面向大规模视觉和视觉-语言任务的通用模型

Hao Li[1*]，Jinguo Zhu[2*]，Xiaohu Jiang[3*]，Xizhou Zhu[4,6✉]，Hongsheng Li[1]，Chun Yuan[3]，Xiaohua Wang[2]，Yu Qiao[6]，Xiaogang Wang[1]，Wenhai Wang[6]，Jifeng Dai[5,6]
[1]香港中文大学—商汤科技联合实验室，香港中文大学 [2]西安交通大学 [3]清华大学深圳国际研究生院 [4]商汤研究院 [5]清华大学 [6]上海人工智能实验室

haoli@link.cuhk.edu.hk, lechatelia@stu.xjtu.edu.cn,
jiangxh21@mails.tsinghua.edu.cn, zhuwalter@sensetime.com
daijifeng@tsinghua.edu.cn, {hsli, xgwang}@ee.cuhk.edu.hk,
yuanc@sz.tsinghua.edu.cn, xhw@mail.xjtu.edu.cn, {qiaoyu, wangwenhai}@pjlab.org.cn

摘要

尽管基础模型取得了显著成功，但其面向特定任务的微调范式使其与通用感知建模的目标不一致。消除这种不一致性的关键在于使用通才模型进行通用任务建模。然而，现有关于通才模型的尝试在多功能性和性能方面都仍显不足。本文提出 Uni-Perceiver v2，这是首个能够以具有竞争力的性能处理主要大规模视觉和视觉-语言任务的通才模型。具体而言，图像被编码为通用区域提议，而文本则通过基于 Transformer 的语言模型进行编码。编码后的表示由一个任务无关的解码器进行转换。不同任务被表述为统一的最大似然估计问题。我们进一步提出了一种改进的优化器，通过非混合采样策略确保稳定的多任务学习，这对于需要大批量训练的任务很有帮助。在经过多种任务的联合训练后，Uni-Perceiver v2 能够在无需任何特定任务适配的情况下直接处理下游任务。结果表明，Uni-Perceiver v2 在多功能性和性能方面均优于所有现有通才模型。同时，与通常被认可的、需要特定任务微调的强基线相比，Uni-Perceiver v2 在广泛的视觉和视觉-语言任务上取得了具有竞争力的性能。

1. 引言

学习一个能够处理多种模态和任务的通用感知模型，被广泛认为是迈向通用人工智能的重要一步。由于其难度较大，许多工作（例如 Florence [45]、CoCa [44]、BEiT-3 [40]），也被称为基础模型 [3]，转而关注一种折中方案：学习一个通用表示编码器，使其能够适配（例如微调）到各种下游任务。通过在大规模、多模态、任务无关的数据上进行大规模预训练，这些工作已通过在广泛任务上推动最先进结果的发展而展示出其优越性，这些任务包括单模态任务（例如图像分类和目标检测）以及跨模态任务（例如图像描述生成和图像检索）。

尽管取得了成功，基础模型与通用感知建模的目标之间仍存在相当大的差距。基础模型仅关注通用表征学习，而忽略了任务建模。传统的特定任务微调范式仍在被采用（见图 1）。这显著增加了将预训练模型适配到各种下游任务的边际成本，使其难以满足多样化下游任务和场景快速增长的需求。基础模型这种特定任务微调范式与通用感知建模的目标并不一致。

通用模型并不执行特定任务的微调，而是使用共享的架构和参数处理不同任务，这与通用感知建模的目标一致。它不仅降低了处理多样化任务的成本，还能实现任务协作。现有大多数关于通用模型的尝试都是基于序列的-

*Equal contribution. This work is done when Hao Li, Jinguo, and Xiaohu are interns at Shanghai Artificial Intelligence Laboratory. Code shall be released at https://github.com/fundamentalvision/Uni-Perceiver. ✉Corresponding author.

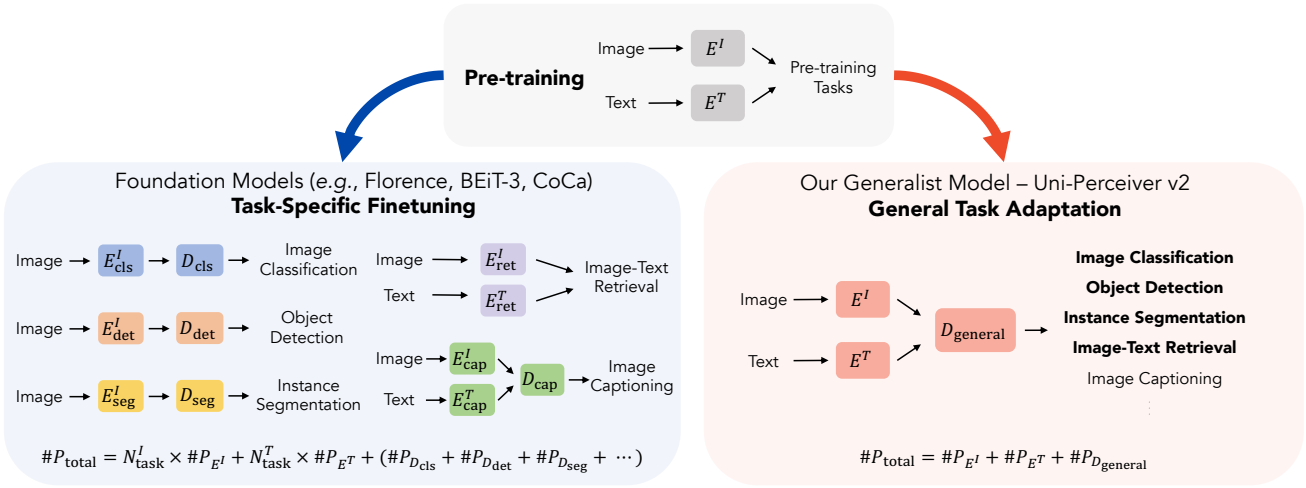


图 1. 基础模型与 Uni-Perceiver v2 的比较。E^I 和 E^T 分别表示图像编码器和文本编码器。在现有基础模型中，采用任务特定解码器 D_{cls}、$D_{\text{det}}, \ldots$ 在不同的任务特定微调中对 E^I 和 E^T 进行调优。自适应中的参数总数 $\#P_{\text{total}}$ 会随着视觉/语言任务数量的增加而增长，分别记为 N^I_{task} 和 N^T_{task}。相比之下，我们的 Uni-Perceiver v2 通过通用解码器 D_{general} 在各种下游任务之间共享所有参数，其中不包含任务特定的微调。优于以往的通才模型，我们的方法还能够有效处理图像分类、目标检测、实例分割和图像-文本检索等支柱任务。

到序列（seq2seq）模型 [2, 6, 11, 15, 23, 29, 39, 43]。然而，这些尝试在通用性和性能方面都存在不足：（1）如表 1 所列，一些核心的视觉和视觉-语言任务无法处理，例如图文检索、目标检测和实例分割；（2）其准确率和推理速度仍显著落后于最先进的任务专用方法。另一条名为 Uni-Perceivers [1, 48] 的研究路线构建了支持生成和非生成任务的通用模型。尽管如此，它们仍然无法处理许多重要任务，例如检测和分割。

为了开发具有更好通用性和性能的通用模型，我们的核心思想是将图像编码为通用区域提议，这些提议由语义、边界框和分割掩码表示组成。与以往将图像表示为不重叠图块的方法相比，这种设计使我们的定位建模更具表达能力和灵活性。对定位线索的这种显式利用，不仅大大降低了处理图像检测和分割等定位任务的难度，还为非定位任务提供了更丰富的特征，从而实现更通用的任务建模和更好的性能。

在本文中，我们提出 Uni-Perceiver v2，作为一种通才模型，能够处理表 1 中列出的主要大规模视觉和视觉-语言任务。具体而言，图像通过区域提议网络被编码为全局表示和区域表示的拼接，而文本则通过基于 Transformer 的语言模型进行编码。图像和文本编码器都可以受益于 off-

现成的预训练模型，这降低了对训练数据和资源的需求，并确保了性能。编码后的表示由一个共享的、模态无关的 Transformer [36] 网络进行转换，以获得解码后的表示。遵循 Uni-Perceivers [1, 48]，不同任务被表述为统一的最大似然估计问题，并进行联合学习，以实现通用的任务适配。我们进一步提出了一种改进的优化器，名为 MT-AdamW，以确保在未混合采样策略下进行稳定的多任务学习；该策略在每次迭代中仅为所有 GPU 采样一个任务。这对于需要大批量训练的任务非常有帮助。

Uni-Perceiver v2 是首个在主要大规模视觉及视觉-语言任务上取得有竞争力结果的通用模型，这些任务包括目标检测、实例分割、图像分类、图像描述生成以及图像-文本检索；但由于计算资源有限，图像生成尚未得到验证。在各种任务上进行联合训练后，它无需任何特定任务的适配即可直接处理广泛的任务，并在现有通用模型中达到最先进的性能。我们的贡献总结如下：

- 我们提出了 Uni-Perceiver v2，这是首个能够以具有竞争力的性能同时处理定位任务和非定位任务的通用模型。图像的通用区域提议编码带来了更灵活且更具表现力的定位建模。
- 为了提高多任务学习的有效性，我们采用了一种非混合采样策略，以实现大批量训练，并开发了一种改进的优化器，名为

Categories	Specific Tasks
Retrieval	**Image-text retrieval**
Classification	**Image classification** Region categorization Situation recognition
Localization	**Object detection** Key point detection Pose estimation Referring expression grounding Human object interaction Relation detection Optical character recognition Object localization
Mask Predication	**Instance segmentation** Semantic segmentation Panoptic segmentation
Image Generation	**Image synthesis** Image inpainting Segment-based image generation Style transferring Depth estimation Surface normal estimation Image infilling Image super resolution
Image to Text	**Image captioning** Visual question answering Region captioning Grounded VQA Grounded captioning Visual commonsense reasoning

表 1. 主流视觉和视觉-语言任务的类别。不同下游任务类别的支柱任务以粗体显示。这些支柱任务是各类别中最具代表性的任务，其他任务可由它们衍生而来。Uni-Perceiver v2 能够有效处理带下划线的支柱任务，但图像合成除外，由于计算资源有限，该任务尚未得到验证。

MT-AdamW 用于缓解梯度的不稳定性。

- Uni-Perceiver v2 在通用性和性能方面均优于所有现有的通用模型。无需任何特定任务的适配，Uni-Perceiver v2 在广泛的下游任务上取得了具有竞争力的性能，可与通常被认为强大的、需要特定任务微调的基线方法相媲美，展现出其强大的通用任务建模能力。

2. 相关工作

基础视觉模型被“设计为通过在大规模广泛数据上进行预训练，以适应（例如，微调）各种下游任务”[3]。这类大规模预训练视觉模型已被证明能够有效增强数据编码能力、缓解数据饥渴问题，并提升下游任务的性能。

在很长一段时间里，ImageNet-1k [9] 上的图像分类一直是主流的预训练范式。然而，随着模型规模的增长，需要更大的标注数据集来避免预训练中的过拟合，例如 ImageNet-21k [9]、Instagram-1B [24]、JFT-300M [35] 和 JFT-3B [46]。受大规模网络爬取文本上的语言预训练成功启发，CLIP [27] 和 ALIGN [13] 开始关注在网络规模的噪声图文对上进行多模态对比预训练，以学习对齐的图像和文本表示。SimVLM [41] 采用多模态序列生成任务进行预训练。FLAVA [34] 结合对比式和生成式预训练，以同时处理单模态和多模态任务。UniCL [42] 和 CoCa [44] 联合使用人工标注数据和网络爬取数据。Florence [45] 和 INTERN [31] 扩大预训练数据的规模和多样性，以增强表示能力。OmniVL [37] 提出在其预训练中同时融入图像-语言和视频-语言任务。BEiT-3 [40] 将不同模态的预训练目标统一为单一的掩码数据建模任务，并在广泛的下游任务上取得了最先进的结果。

这些关于基础模型的工作仅关注通用表征学习，而忽视了任务建模。在将它们适配到下游任务时，仍然采用传统的任务特定微调范式，这与通用感知建模的目标并不一致。同时，随着多样化任务和场景需求的快速增长，任务特定微调范式将导致数据收集、数据标注、模型训练和模型存储方面难以承受的边际成本。

通用模型使用共享的架构和参数来处理各种任务，这一直是机器学习社区长期追求的目标。最近，受 NLP 领域中序列到序列（seq2seq）模型成功的启发 [28]，OFA [39]、Flamingo [2] 和 GIT [38] 提出将各种任务建模为序列生成任务。Unified-IO [23]、Pix2Seq v2 [6] 和 UniTab [43] 通过引入离散坐标标记进一步发展了这一方法，以支持更多任务，从而使位置信息能够由统一模型进行编码或解码。除此之外，Gato [29] 成功地将强化学习任务统一到 seq2seq 框架中。GPV [11] 也通过在基于 DETR [4] 的视觉编码器上添加一个 seq2seq 模块，构建了一个通用视觉系统。

然而，这些采用 seq2seq 形式的方法在通用性和性能方面仍然不足：（1）它们无法处理一些核心视觉任务，例如图文检索、目标检测和实例分割。尽管 Pix2Seq v2 [6] 包含了检测和实例分割任务，但其性能和推理速度仍显著落后于最先进的任务专用方法。

ods [17, 47]；（2）非并行的自回归解码导致推理速度缓慢。例如，图像分类需要在给定图像条件下计算并比较所有类别名称的累积概率；（3）它们在多任务学习中还存在任务干扰问题，导致与任务特定模型相比性能下降。

或者，Uni-Perceivers [1, 48] 将不同任务表述为通过表示相似性为每个输入寻找最大似然目标，而不考虑其模态，从而能够同时支持生成任务和非生成任务。然而，它们仍然无法处理图像检测和分割任务。

3. 重新审视 Uni-Perceivers

感知任务的统一建模。Uni-Perceiver [1] 提出将不同任务重新表述为一个统一的最大似然估计问题。具体而言，每个任务都由一组输入和一组候选目标定义，这些输入和目标可以来自任意模态组合。输入和目标首先通过具有线性投影的模态特定分词器进行编码。随后，编码后的表示由对不同任务共享参数的模态无关解码器进行转换。给定一个输入，统一的任务目标被定义为在该输入条件下寻找具有最大似然的目标。

缓解任务干扰。采用完全共享参数的多任务学习可能会在不同任务之间引入干扰。Uni-Perceiver-MoE [48] 提出了条件 MoE 来解决任务干扰问题。具体而言，对于每个输入标记，都会根据特定的路由策略计算路由决策，从而稀疏地激活少量专家来处理该标记。输入标记的相应输出是由路由决策选中的这些专家的线性加权组合。条件 MoE 通过允许存在冲突的模态和任务使用独立参数，同时不引入任何任务特定模块，从而缓解了干扰问题。

局限性。尽管 Uni-Perceivers 旨在用统一架构处理不同任务，但由于其编码特征中缺乏定位信息，它无法处理检测和分割任务。同时，Uni-Perceivers 未集成现成的编码器模型，因此无法受益于现有的大规模预训练编码器。这可能会增加其对预训练数据和资源的需求，从而限制其性能。

4. 方法

4.1. 将图像编码为通用区域提议

大多数现有的通用模型 [1, 48] 将图像表示为固定大小的不重叠图像块。这种设计相当粗糙，在建模图像中不同大小和形状的物体方面存在局限，使其难以处理检测和分割等定位任务。

为了实现更具表达力且更灵活的定位建模，我们提出将输入图像编码为一系列通用区域候选。具体而言，给定一幅高度为 H、宽度为 W 的输入图像 $x \in \mathbb{R}^{H\times W}$，采用网络 $f_{\text{image}}(\cdot)$ 将该图像编码为全局表示和区域表示的拼接，如下所示：

$$f_{\text{image}}(x) = \text{Concat}\left(\{q_i^{\text{global}}\}_{i=1}^{M}, \{q_j^{\text{proposal}}\}_{j=1}^{N}\right), \quad (1)$$

其中，$q_i^{\text{global}} \in \mathbb{R}^d$ 是整幅图像的全局表示，$q_j^{\text{proposal}} \in \mathbb{R}^d$ 是图像中候选目标提议的区域表示。

遵循定位任务中的常见做法，首先采用图像骨干网络（例如 ResNet [12]）来提取多尺度特征图 $\{\mathcal{F}_l\}_{l=1}^{L}$，其中 L 是特征尺度的数量（例如，$L =$ 为 4）。

区域表示。在多尺度特征图 $\{\mathcal{F}_l\}_{l=1}^{L}$ 之上应用一个基于 Transformer [36] 的区域提议网络，以提取一组 O 个候选目标提议 $\{q_j^{\text{sem}}, q_j^{\text{box}}, q_j^{\text{mask}}\}_{j=1}^{O}$，其中 $q_j^{\text{sem}} \in \mathbb{R}^d$、$q_j^{\text{box}} \in \mathbb{R}^4$ 和 $q_j^{\text{mask}} \in \mathbb{R}^{H\times W}$ 分别是第 j 个提议的语义、边界框和分割掩码表示。该区域提议网络类似于 MaskDINO [17]，但仅考虑前景-背景二分类。详细实现见附录。然后将这三种表示融合为区域表示，如下所示：

$$q_j^{\text{proposal}} = q_j^{\text{sem}} + \mathcal{B}(q_j^{\text{box}}) + \mathcal{M}(q_j^{\text{mask}}), \quad (2)$$

其中 $\mathcal{B}$ 表示框坐标的位置编码。$\mathcal{M}$ 使用自适应平均池化将掩码预测缩放到 28×28 的大小。$\mathcal{B}$ 和 $\mathcal{M}$ 后面都接有线性投影，以匹配特征维度。

全局表示。全局表示是从最后尺度的特征图 $\mathcal{F}_L \in \mathbb{R}^{h\times w}$ 中提取的，其高度为 h、宽度为 w。采用 M' 个参数化注意力池化 [27] 实例来提取全局特征。将池化后的特征与展平的特征图拼接，以获得全局表示，如下所示：

$$q^{\text{global}} = \text{Concat}\Big(\big\{\,\text{AttnPool}_i(\mathcal{F}_L)\big\}_{i=1}^{M'}, \ \text{Flatten}(\mathcal{F}_L)\Big). \quad (3)$$

4.2. 使用语言模型编码文本

使用基于 Transformer [36] 的语言模型对文本数据进行编码，例如分类任务中的类别名称、图文检索任务中的图像描述，以及图像字幕生成任务中的词汇表。具体而言，BPE 分词器 [30] 将输入文本 x 分词为一系列词嵌入，并采用 Transformer 编码器提取文本特征序列，如下所示：

$$f_{\text{text}}(x) = \text{Concat}(q_1^{\text{text}}, q_2^{\text{text}}, \cdots, q_L^{\text{text}}) \tag{4}$$

其中，$q_i^{\text{text}} \in \mathbb{R}^d$ 是第 i 个词的编码特征，L 是序列长度。在我们的实现中，我们使用预训练的 RoBERTa $_{\text{BASE}}$ [20] 作为文本编码器，并与整个网络联合微调。

4.3. 通用任务适配

我们遵循 Uni-Perceivers [1, 48]，将不同任务表述为统一的最大似然估计问题。给定输入 $x \in \mathcal{X}$ 和候选目标集 $\mathcal{Y}$，任务目标被定义为寻找具有最大似然的目标 $\hat{y} \in \mathcal{Y}$，即：

$$\hat{y} = \arg\max_{y \in \mathcal{Y}} P(x, y), \tag{5}$$

其中，似然 $P(x, y)$ 根据 x 和 y 的表示之间的余弦相似度估计为

$$P(x, y) \propto \exp\left(\cos\Big(g \circ f(x)\ ,\ g \circ f(y)\Big) / \tau \right), \tag{6}$$

其中，$f(\cdot)$ 分别是第 4.1 节和第 4.2 节中介绍的模态特定编码器 f_{image} 和 f_{text}。$g(\cdot)$ 是一个模态无关的 Transformer [36] 网络，在不同任务之间共享，而 $\tau > 0$ 是一个可学习的温度参数。

根据任务需求，输入 x 的模态特定编码表示可以是图像特征序列 $f_{\text{image}}(x)$、文本特征序列 $f_{\text{text}}(x)$，或它们的拼接，并在开头插入一个额外的 <SPE> 标记。目标 y 的编码表示以相同方式构建。

为了获得通用的任务建模能力，Uni-Perceiver v2 在各种单模态和多模态任务上进行多任务学习。将一组 K 个任务表示为 $\{\mathcal{X}_k, \mathcal{Y}_k\}_{k=1}^K$，其中 $\mathcal{X}_k$ 和 $\mathcal{Y}_k$ 分别是第 k 个任务的输入集和目标集。训练损失为

$$L = \sum_{k=1}^{K} s_k \mathop{\mathbb{E}}_{\{x,y\} \in \{\mathcal{X}_k, \mathcal{Y}_k\}} \left[-w_k \log \frac{P(x, y)}{\sum_{z \in \mathcal{Y}_k} P(x, z)} \right], \tag{7}$$

其中 s_k 和 w_k 分别表示第 k 个任务的采样比例和损失权重。采样比例被归一化为 $\sum_k s_k = 1$。详细内容请参见第 4.4 节。

采样策略的讨论。为了缓解多任务训练中的任务干扰，我们遵循 Uni-Perceiver-MoE [48]，采用具有属性级路由策略的条件 MoE，以实现有效的多任务训练。

带定位的任务。Uni-Perceiver v2 可以通过解码区域表示来执行目标检测和实例分割等定位任务。具体而言，对于每个区域提议 q_j^{proposal}，其由统一解码器 $g(\cdot)$ 输出的特征将与类别嵌入进行比较，以获得如式（5）所示的类别预测。相应的边界框 q_j^{box} 和分割掩码 q_j^{mask} 将作为定位预测。

无需定位的任务。Uni-Perceiver v2 也可以处理需要定位预测的任务，例如图像分类、图像字幕生成、图像-文本检索。对于这些任务，它遵循与 Uni-Perceiver 类似的表述方式，但有两个主要区别：（1）为图像提供更具表达力和灵活性的定位线索，从而更好地促进这些任务；（2）图像编码器和文本编码器都可以利用现成的模态特定预训练模型，从而获得更好的性能。

4.4. 采样策略与改进优化

优化通用模型遵循多任务学习范式，即在来自不同任务的数据上进行联合训练。当前方法通常在一次训练迭代中混合所有任务 [1, 23, 39]。这种混合采样策略限制了每个任务的批大小，这可能不利于那些受益于大批量训练的任务（例如，图文检索）。

一种直接的解决方案是每次迭代只采样一个任务，我们将其称为非混合采样策略。它可以实现最大的训练批大小。然而，当不同迭代采样不同任务时，由于数据和任务的差异，梯度会发生较大变化，这可能会给多任务学习带来潜在的不稳定性并导致性能下降。

为缓解非混合采样策略的不稳定性问题，我们提出了一种用于多任务训练的改进优化器，命名为 MT-AdamW。其核心思想是通过对每次迭代的梯度进行归一化，并根据任务采样比例对其进行补偿，从而平衡各个任务的梯度。

假设第 k 个任务在时间步 t 被采样，则将原始的 AdamW [22] 修改为 MT-AdamW，并按如下方式更新参数 θ：

$$\left\{\begin{array}{l} \mathbf{g}_t \leftarrow \nabla L_{t,k}\left(\theta_{t-1}\right) \\ \mathbf{m}_t = (1-\beta_1)\mathbf{m}_{t-1} + \beta_1 \mathbf{g}_t \\ \mathbf{n}_t = (1-\beta_2)\mathbf{n}_{t-1} + \beta_2 \mathbf{g}_t^2 \\ \theta_t = \theta_{t-1} - \alpha \frac{\mathbf{m}_t}{\sqrt{\mathbf{n}_t + \varepsilon}} \end{array}\right. \Rightarrow \left\{\begin{array}{l} \mathbf{g}_t \leftarrow \omega_k \frac{\nabla L_{t,k}\left(\theta_{t-1}\right)}{\|\nabla L_{t,k}\left(\theta_{t-1}\right)\|} \\ \mathbf{m}_t = (1-\beta_1)\mathbf{m}_{t-1} + \frac{\beta_1}{s_k} \mathbf{g}_t \\ \mathbf{n}_t = (1-\beta_2)\mathbf{n}_{t-1} + \frac{\beta_2}{s_k} \mathbf{g}_t^2 \\ \theta_t = \theta_{t-1} - \alpha \frac{\mathbf{m}_t}{\sqrt{\mathbf{n}_t + \varepsilon}} \end{array}\right.$$

其中，$L_{t,k}$ 是在时间步 t 采样到的第 k 个任务的损失函数，α 是学习率。为简化起见，省略了权重衰减和偏置校正。首先对原始任务梯度进行归一化，以稳定训练。缩放因子 ω_k 作为采样任务的损失权重。然后，裁剪后的梯度 $\mathbf{g}_t$ 可用于以移动平均的方式估计梯度的一阶矩 $\mathbf{m}_t$ 和二阶矩 $\mathbf{n}_t$。为进一步解耦每个任务的梯度贡献和采样比例 s_k，使用任务特定的补偿系数 $1/s_k$ 对估计值 $\mathbf{m}_t$ 和 $\mathbf{n}_t$ 进行去偏。在实践中，如果期望所有任务贡献相同，则所有缩放因子都可以设置为 $\omega_k = 1$ 。

5. 实验

5.1. 数据集

Uni-Perceiver v2 在各种任务和公开可用数据集上进行多任务训练，以实现通用任务建模能力。它使用与 Uni-Perceiver [1] 类似的数据集。具体而言，图像分类任务在 ImageNet-1k [9] 数据集上训练。对于目标检测和实例分割，使用 COCO [19] 进行训练。对于图像字幕生成和图文检索，我们使用图文对数据集的组合：SBU Captions [25]、Visual Genome [16]、COCO Caption [8]、CC3M [33]、CC12M [5] 和 YFCC [14]。我们还在训练过程中加入语言建模任务，该任务在 BookCorpus [49] 和英文维基百科（Books&Wiki）上训练。

在评估过程中，我们在表 1 所列的支柱性视觉与视觉-语言任务中最具代表性的数据集上评估通用模型。具体而言，分别使用 ImageNet-1k [9] 和 COCO Caption [8] 来评估图像分类和图像描述生成的性能。对于图像-文本检索，使用 COCO Caption 和 Flickr30k [26]。需要注意的是，Flickr30k 未参与训练。对于目标检测和实例分割，使用 COCO [19] 来评估其性能。我们在附录中列出了所有数据集的许可证。

5.2. 实现细节

我们实现了三种采用不同骨干网络的 Uni-Perceiver v2 变体，即 ResNet-50 [12]、Swin-Base [21] 和 Swin-Large。ResNet-50 在 ImageNet-1k 上进行预训练，Swin-Base 在 ImageNet-21k 上进行预训练。Swin-Large 首先在 ImageNet-21k 上进行预训练，然后在 Object365 [32] 的检测任务上进行训练。所有模型的特征尺度数量 L 均设置为 4。我们使用基于 Transformer [36] 的区域提议网络来生成通用区域提议，其架构和设置主要遵循 Mask DINO [17]。然而，我们将所有多类别分类器替换为二分类器。此外，用于提取全局特征的全局注意力池化数量设置为 $M' = 10$。我们选择预训练的 RoBERTa $_{\text{BASE}}$ [20] 作为文本编码器，它与整个网络共同调优。统一解码器也是一个基于 Transformer 的网络，其参数随机初始化并从头开始优化。其架构遵循 BERT $_{\text{BASE}}$ [10] 模型的设置，但仅包含 6 个 Transformer 层。为缓解多任务学习中的任务干扰问题，我们还在统一解码器的所有 FFN 层中采用了属性级条件 MoE [48]。更多细节请参见附录。

除非特别说明，我们采用非混合采样策略，即每次迭代仅为所有 GPU 采样一个任务。使用 MT-AdamW 优化器，基础学习率为 0.0001，权重衰减为 0.0001。由于模态特定编码器已经过预训练，其学习率乘以 0.1 。采用 Swin-Base 和 Swin-Large 骨干网络的 Uni-Perceiver v2 分别在 32 块和 64 块 NVIDIA A100 GPU 上训练 200,000 次迭代。学习率在第 160,000 次迭代时下降到 0.1×。对于使用 ResNet-50 的模型，我们仅在 16 块 NVIDIA A100 GPU 上训练 150,000 次迭代。其他训练设置也请参见附录。

5.3. 消融实验

在下文中，我们通过评估采用 ResNet-50 骨干网络的 Uni-Perceiver v2 在四项任务上的性能来评估其关键组件，即 COCO 上的图像检测、ImageNet-1k 上的图像分类、COCO caption 上的图文检索以及 COCO caption 上的图像描述生成。为节省训练成本，未包含实例分割和语言建模任务，并且训练中也排除了 YFCC 数据集。需要注意的是，这些数据集上的性能是在没有任何特定任务微调的情况下报告的。若未特别说明，消融研究使用经过 COCO 检测预训练的 ResNet-50，以加速多任务训练的收敛。

全局与区域图像表征的有效性。Uni-Perceiver v2 将图像编码为全局表征与区域表征的拼接。为了评估它们在不同任务上的有效性，我们进行了采用不同表征的实验，即仅使用全局表征、仅使用区域表征，以及同时使用二者。表 2 中的结果表明：（1）区域表征对于图像描述生成和检索任务都至关重要。我们推测，这是因为区域候选框能够提供定位线索，有助于处理这两类任务。（2）与仅使用区域表征相比，全局表征在图像分类任务上取得了更好的结果，这表明全局表征对于图像级任务非常重要。（3）结合全局表征与区域表征能够使两种表征相互补充，从而在所有任务上取得最佳的整体结果。因此，在我们后续的实验中，结合全局和区域表征

Representation Types	COCO Detection	ImageNet-1k Classification	COCO Retrieval		COCO Caption
Global	-	76.8	46.3	34.6	28.8
Regional	48.2	75.9	**52.3**	**39.2**	**31.2**
Global + Regional	**49.9**	**76.9**	51.3	38.8	30.6

表 2. 用于通用区域提议的不同表示类型的消融实验。结果报告于目标检测（mAP）、图像分类（Acc）、图像-文本检索（I2T R@1 和 T2I R@1）以及图像描述（BLEU-4）。

Tasks	COCO Detection	ImageNet-1k Classification	COCO Retrieval		COCO Caption
Single Task	50.1	76.1	50.0	37.6	30.2
All Tasks	49.8	76.3	46.0	34.7	28.9
w/o Detection	-	76.6 (+0.3)	47.0 (+1.0)	34.6 (−0.1)	30.4 (+0.5)
w/o Classification	50.1 (+0.3)	-	51.6 (+5.6)	38.6 (+3.9)	25.9 (−3.0)
w/o Retrieval	49.5 (−0.3)	76.3 (+0.0)	-	-	27.4 (−1.5)
w/o Captioning	49.7 (−0.1)	76.3 (+0.0)	51.2 (+5.2)	38.3 (+3.6)	-
All Tasks w/ MoE	49.9 (+0.1)	76.9 (+0.6)	51.3 (+5.3)	38.8 (+4.1)	30.6 (+0.7)

表 3. 任务之间协作与干扰的消融实验。除最后一行外，所有实验均未采用条件式 MoE。括号中为与“All Tasks”对应项的差距。绿色和红色表示至少 ±0.5 分的差距。

tations 被作为默认设置。

任务协作与干扰。为分析不同任务之间的协作与干扰，我们通过从表 3 的联合训练任务中分别独立移除每个任务来进行实验。如果移除某一任务能够提升（或降低）另一任务的性能，则可以反映出在联合训练过程中，前一任务对后一任务是有害的（或有益的）。为公平比较，除最后一个实验外，均不采用 Conditional MoEs。结果表明，在没有 MoEs 的情况下，其他任务会对图文检索的训练产生负面影响。然而，图文检索任务能够提升图像描述生成的性能。图像分类任务对图像描述生成也非常有帮助，但反过来并无明显效果。需要注意的是，所有模型都采用了在 COCO 检测上预训练的图像编码器，因此所有这些任务都可以受益于预训练的区域提议网络。结果表明，任务干扰确实存在于通用模型的多任务训练中，并且比任务协作更为常见，这说明解决任务干扰问题十分重要。通过采用 Conditional MoEs，任务干扰在很大程度上得到缓解，从而在所有任务上都取得了更好的结果。

采样策略与改进优化。我们在表 4 中评估了非混合采样策略（即每次迭代采样一个任务）以及所提出的 MT-AdamW 优化器的有效性。从结果来看，

Task Sampling	Gather Feature	MT-AdamW Optimizer	COCO Detection	ImageNet-1k Classification	COCO Retrieval		COCO Caption
mixed			49.6	76.7	40.1	31.9	27.6
unmixed			49.2	76.6	39.8	30.9	27.5
unmixed	✓		49.3	76.8	50.4	37.3	27.6
unmixed	✓	✓	**49.9**	**76.9**	**51.3**	**38.8**	**30.6**

表4. 采样策略和改进优化器的消融实验。“mixed”表示在一次迭代中混合不同任务的数据，而“unmixed”表示在一次迭代中只采样一个任务的数据。“Gather Feature”表示检索任务的负样本会在多个 GPU 间同步收集。

Pretrained Method	Pretrained Data	COCO Detection	ImageNet-1k Classification	COCO Retrieval		COCO Caption
Supervised	IN-1k	45.7	76.8	51.2	38.9	27.3
Supervised	IN-21k	48.3	**80.1**	55.1	41.2	30.2
Supervised	IN-1k & COCO	**49.9**	76.9	51.3	38.8	30.6
MoCo v2	IN-1k	48.3	75.0	54.8	40.5	29.6
CLIP	CLIP data	47.2	73.8	**55.3**	**41.3**	**32.0**

表5. 不同预训练图像编码器的消融实验。

我们观察到，与混合采样策略相比，普通的未混合采样策略（即使用每个 GPU 上的样本计算对比损失）会对所有任务的学习产生轻微的不利影响。通过在所有 GPU 间聚合特征来增大批量大小，检索任务的性能可以得到大幅提升。进一步引入 MT-AdamW 优化器后，多任务训练更加稳定，并且在所有任务上都能持续提升性能。

不同图像编码器预训练的影响。通过集成现成的编码器模型，Uni-Perceiver v2 能够利用已有的大规模预训练编码器。为分析不同预训练的影响，我们为图像编码器采用了不同的预训练模型。对于采用监督预训练的模型，我们使用在 ImageNet-1k 上预训练的 ResNet-50、在 ImageNet-21k 上预训练的 ResNet-50，或依次在 ImageNet-1k 和 COCO 上预训练的 ResNet-50。对于采用弱监督或无监督预训练的模型，我们使用通过 MoCo v2 [7] 或 CLIP [27] 预训练的 ResNet-50。表 5 表明，图像编码器不同的预训练数据和方法会有利于不同的下游任务。具体而言，监督预训练方法在与其相似的下游任务上表现出最明显的收益，例如，ImageNet-21k 预训练在 ImageNet-1k 分类上取得了最佳结果。此外，在大规模监督数据（ImageNet-21k）、弱监督或无监督数据（CLIP 和 MoCo v2）上的预训练，对图文检索和图像描述生成等视觉-语言任务更有帮助，这可能得益于更通用的表征。

Methods	#params	Image Classification	Object Detection	Instance Segmentation	Image Captioning		Text Retrieval		Image Retrieval	
		ImageNet-1k Acc	COCO mAP	COCO mAP	COCO B@4	COCO CIDEr	COCO R@1	Flickr30k R@1	COCO R@1	Flickr30k R@1
Pix2Seq v2 [6]	132M	-	46.5	38.2	34.9	-	-	-	-	-
UniTab [43]	185M	-	-	-	-	115.8	-	-	-	-
Unified-IO $_{\text{LARGE}}$ [23]	776M	71.8	-	-	-	-	-	-	-	-
Unified-IO $_{\text{XL}}$ [23]	2.9B	79.1	-	-		122.3	-	-	-	-
Flamingo-3B [2]	3.2B	-	-	-	-	-	65.9	89.3	48.0	79.5
Uni-Perceiver $_{\text{BASE}}$ [1]	124M	79.2	-	-	32.0	-	64.9	82.3	50.7	71.1
Uni-Perceiver $_{\text{LARGE}}$ [1]	354M	82.7	-	-	35.3	-	67.8	83.7	54.1	74.2
Uni-Perceiver-MoE $_{\text{BASE}}$ [48]	167M	80.3	-	-	33.2	-	64.6	82.1	51.6	72.4
Uni-Perceiver-MoE $_{\text{LARGE}}$ [48]	505M	83.4	-	-	35.5	-	67.9	83.6	55.3	75.9
Uni-Perceiver-v2 $_{\text{BASE}}$	308M	86.3	58.6	50.6	35.4	116.9	71.8	88.1	55.6	73.8
Uni-Perceiver-v2 $_{\text{LARGE}}$	446M	**87.2** (+3.8)	**61.9** (+15.4)	**53.6** (+15.4)	**36.5** (+1.6)	**122.5** (+0.2)	**75.0** (+7.1)	**89.3** (+0.0)	**58.5** (+3.2)	**79.6** (+0.1)

表 6. 我们的 Uni-Perceiver v2 与近期通用模型在表 1 所列六项核心视觉和视觉-语言任务上的比较。请注意，我们仅报告未进行任何任务特定微调的结果。Uni-Perceiver v2 是首个支持所有这些核心任务的通用模型，并且无需任何任务特定适配即可取得有竞争力的结果。一些仅报告经过任务特定微调结果的通用模型未被纳入，例如 OFA [39] 和 GIT [38]。“#params”表示跨模态任务中模型部署所需的参数数量。最佳性能结果以粗体标出，先前的 SoTA 结果以下划线标出。

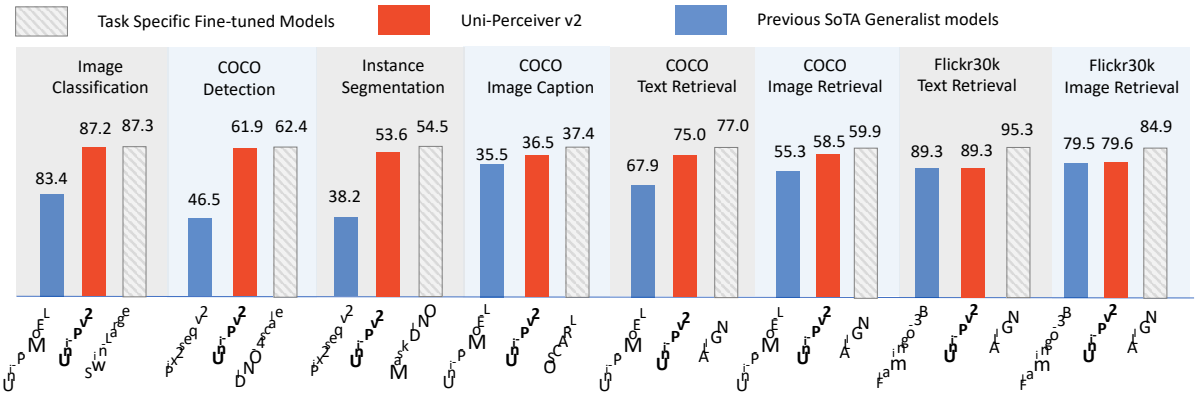


图 2. 在核心视觉和视觉-语言任务上，与通用模型以及公认的强任务专用模型进行比较。对于包括 Uni-Perceiver v2 在内的通用模型，我们仅报告未进行任何任务专用微调的结果。将 Uni-Perceiver v2（Uni-P v2）与具有竞争力的专用模型进行比较，即 Swin-large [21]、DINO [47]、Mask DINO [17]、OSCAR-L [18] 和 ALIGN [13]，以及先前的 SoTA 通用模型，即 Uni-P-MoE-L [48]、Pix2seq v2 [6] 和 Flamingo-3B [2]。

5.4. 主要结果

为进一步验证 Uni-Perceiver v2 的有效性，我们引入了更强大的骨干网络，包括 Swin-Base 和 Swin-Large，分别记为 Uni-Perceiver-v2 $_{\text{BASE}}$ 和 Uni-Perceiver-v2 $_{\text{LARGE}}$。除消融研究中包含的任务外，我们还纳入了 COCO 上的实例分割、Books&Wiki 上的语言建模，以及 YFCC 上的图像描述生成/图文检索，用于更大规模的多任务训练。

与现有通用模型的比较。我们在表 6 中列出了 Uni-Perceiver v2 以及其他通用模型在核心视觉和视觉-语言任务上的性能。由于通用模型旨在处理不同任务，并且共享架构和参数后，针对特定任务的微调会丧失通用建模能力。我们报告了共享模型在未进行任何特定任务适配情况下的性能。具体而言，Uni-Perceiver-v2 $_{\text{BASE}}$ 在除 Flickr30k 检索之外的所有任务上都能优于以往所有通用模型，即使某些方法拥有 $> 10\times$ 的模型参数，例如 Unified-IO$_{\text{XL}}$ 和 Flamingo-3B。在 Flicker30k 上的性能劣势可能是由于 Flamingo-3B 使用了私有数据。进一步扩展到 Swin-Large 骨干网络后，Uni-Perceiver-v2 $_{\text{LARGE}}$ 在所有任务上都取得了最佳性能。得益于通用区域提议的灵活性，Uni-Perceiver v2 在通用模型中支持大多数核心任务，并且能够持续取得有竞争力的结果，这表明其优越-

Uni-Perceiver v2 在通用性和性能方面都展现出更优越的通用建模性能。

与专用模型的比较。我们在表 2 的支柱任务上，将 Uni-Perceiver v2 与公认的强基线模型以及以往的 SoTA 通用模型进行了比较。结果表明，Uni-Perceiver v2 显著缩小了通用模型与公认强基线之间的性能差距，而这些强基线需要针对具体任务进行微调。除 Flickr30K 上的检索任务外，它在所有任务上都能取得相当的结果；我们推测这是因为 ALIGN [13] 使用了 18 亿个私有图文对，其规模远大于我们的训练数据。相比之下，Uni-Perceiver v2 仅使用公开数据进行训练。

6. 结论

我们提出了 Uni-Perceiver v2，这是首个在主要大规模视觉和视觉-语言任务上取得具有竞争力结果的通用模型。在单模态和多模态任务上进行联合训练后，Uni-Perceiver v2 在广泛的下游任务上取得了具有竞争力的性能。至于局限性，由于计算资源有限，我们的方法尚未在图像生成任务上得到验证。

参考文献

[1] Uni-perceiver：用于零样本和少样本任务的通用感知统一架构预训练。发表于 IEEE/CVF 计算机视觉与模式识别会议论文集，第 16804–16815 页，2022。2, 4, 5, 6, 8, 12 [2] Jean-Baptiste Alayrac, Jeff Donahue, Pauline Luc, Antoine Miech, Iain Barr, Yana Hasson, Karel Lenc, Arthur Mensch, Katie Millican, Malcolm Reynolds 等。Flamingo：用于少样本学习的视觉语言模型。arXiv 预印本 arXiv:2204.14198，2022。2, 3, 8 [3] Rishi Bommasani, Drew A Hudson, Ehsan Adeli, Russ Altman, Simran Arora, Sydney von Arx, Michael S Bernstein, Jeannette Bohg, Antoine Bosselut, Emma Brunskill 等。关于基础模型的机遇与风险。arXiv 预印本 arXiv:2108.07258，2021。1, 3 [4] Nicolas Carion, Francisco Massa, Gabriel Synnaeve, Nicolas Usunier, Alexander Kirillov, and Sergey Zagoruyko。使用 Transformer 的端到端目标检测。发表于欧洲计算机视觉会议，第 213–229 页。Springer，2020。3 [5] Soravit Changpinyo, Piyush Sharma, Nan Ding, and Radu Soricut。Conceptual 12M：推动网络规模图像-文本预训练以识别长尾视觉概念。发表于 CVPR，2021。6, 13 [6] Ting Chen, Saurabh Saxena, Lala Li, Tsung-Yi Lin, David J Fleet, and Geoffrey Hinton。用于视觉任务的统一序列接口。arXiv 预印本 arXiv:2206.07669，2022。2, 3, 8 [7] Xinlei Chen, Haoqi Fan, Ross Girshick, and Kaiming He。通过动量对比学习改进基线。arXiv 预印本 arXiv:2003.04297，2020。7

[8] Xinlei Chen、Hao Fang、Tsung-Yi Lin、Ramakrishna Vedan- tam、Saurabh Gupta、Piotr Dollár 和 C. Lawrence Zit- nick。Microsoft coco captions：数据收集与评估服务器。arXiv 预印本 arXiv:1504.00325，2015。6，13 [9] Jia Deng、Wei Dong、Richard Socher、Li-Jia Li、Kai Li 和 Li Fei-Fei。Imagenet：大规模层次化图像数据库。载于 2009 IEEE 计算机视觉与模式识别会议，页 248–255。IEEE，2009。3，6，12，13 [10] Jacob Devlin、Ming-Wei Chang、Kenton Lee 和 Kristina Toutanova。Bert：用于语言理解的深度双向 Transformer 预训练。arXiv 预印本 arXiv:1810.04805，2018。6 [11] Tanmay Gupta、Amita Kamath、Aniruddha Kembhavi 和 Derek Hoiem。迈向通用视觉系统。arXiv 预印本 arXiv:2104.00743，2021。2，3 [12] Kaiming He、Xiangyu Zhang、Shaoqing Ren 和 Jian Sun。用于图像识别的深度残差学习。载于 IEEE 计算机视觉与模式识别会议论文集，页 770–778，2016。4，6，11 [13] Chao Jia、Yinfei Yang、Ye Xia、Yi-Ting Chen、Zarana Parekh、Hieu Pham、Quoc Le、Yun-Hsuan Sung、Zhen Li 和 Tom Duerig。利用噪声文本监督扩展视觉和视觉-语言表征学习。载于国际机器学习会议，页 4904–4916。PMLR，2021。3，8，9 [14] Sebastian Kalkowski、Christian Schulze、Andreas Dengel 和 Damian Borth。yfcc100m 数据集的实时分析与可视化。载于 2015 年社区组织多模态挖掘研讨会论文集：新颖解决方案的机会，页 25–30，2015。6，12，13 [15] Amita Kamath、Christopher Clark、Tanmay Gupta、Eric Kolve、Derek Hoiem 和 Aniruddha Kembhavi。面向通用视觉模型的网络监督概念扩展。arXiv 预印本 arXiv:2202.02317，2022。2 [16] Ranjay Krishna、Yuke Zhu、Oliver Groth、Justin Johnson、Kenji Hata、Joshua Kravitz、Stephanie Chen、Yannis Kalan- tidis、Li-Jia Li、David A Shamma 等。Visual genome：使用众包密集图像标注连接语言与视觉。IJCV，123(1):32–73，2017。6，13 [17] Feng Li、Hao Zhang、Shilong Liu、Lei Zhang、Lionel M Ni、Heung-Yeung Shum 等。Mask dino：迈向基于 Transformer 的统一目标检测与分割框架。arXiv 预印本 arXiv:2206.02777，2022。4，6，8，11，12 [18] Xiujun Li、Xi Yin、Chunyuan Li、Pengchuan Zhang、Xiaowei Hu、Lei Zhang、Lijuan Wang、Houdong Hu、Li Dong、Furu Wei 等。Oscar：面向视觉-语言任务的对象语义对齐预训练。载于 ECCV，2020。8 [19] Tsung-Yi Lin、Michael Maire、Serge Belongie、James Hays、Pietro Perona、Deva Ramanan、Piotr Dollár 和 C Lawrence Zitnick。Microsoft coco：上下文中的常见对象。载于 ECCV，2014。6，12，13 [20] Yinhan Liu、Myle Ott、Naman Goyal、Jingfei Du、Mandar Joshi、Danqi Chen、Omer Levy、Mike Lewis、Luke Zettle- moyer 和 Veselin Stoyanov。Roberta：一种鲁棒优化的 BERT 预训练方法。arXiv 预印本 arXiv:1907.11692，2019。5，6 [21] Ze Liu、Yutong Lin、Yue Cao、Han Hu、Yixuan Wei、Zheng Zhang、Stephen Lin 和 Baining Guo。Swin transformer:

使用移位窗口的层次化视觉 Transformer。发表于 IEEE/CVF 国际计算机视觉会议论文集，第 10012–10022 页，2021。6, 8, 11 [22] Ilya Loshchilov 和 Frank Hutter。解耦权重衰减正则化。arXiv 预印本 arXiv:1711.05101，2017。5 [23] Jiasen Lu、Christopher Clark、Rowan Zellers、Roozbeh Mot-tagi 和 Aniruddha Kembhavi。Unified-io：用于视觉、语言和多模态任务的统一模型。arXiv 预印本 arXiv:2206.08916，2022。2, 3, 5, 8 [24] Dhruv Mahajan、Ross Girshick、Vignesh Ramanathan、Kaiming He、Manohar Paluri、Yixuan Li、Ashwin Bharambe 和 Laurens Van Der Maaten。探索弱监督预训练的极限。发表于欧洲计算机视觉会议（ECCV）论文集，第 181–196 页，2018。3 [25] Vicente Ordonez、Girish Kulkarni 和 Tamara Berg。Im2text：使用 100 万张带标题的照片描述图像。NeurIPS，2011。6, 13 [26] Bryan A Plummer、Liwei Wang、Chris M Cervantes、Juan C Caicedo、Julia Hockenmaier 和 Svetlana Lazebnik。Flickr30k 实体：为更丰富的图像到句子模型收集区域到短语的对应关系。发表于 ICCV，2015。6 [27] Alec Radford、Jong Wook Kim、Chris Hallacy、Aditya Ramesh、Gabriel Goh、Sandhini Agarwal、Girish Sastry、Amanda Askell、Pamela Mishkin、Jack Clark 等。从自然语言监督中学习可迁移的视觉模型。arXiv 预印本 arXiv:2103.00020，2021。3, 4, 7 [28] Alec Radford、Karthik Narasimhan、Tim Salimans、Ilya Sutskever 等。通过生成式预训练改进语言理解。2018。3 [29] Scott Reed、Konrad Zolna、Emilio Parisotto、Sergio Gomez Colmenarejo、Alexander Novikov、Gabriel Barth-Maron、Mai Gimenez、Yury Sulsky、Jackie Kay、Jost Tobias Springenberg 等。通用智能体。arXiv 预印本 arXiv:2205.06175，2022。2, 3 [30] Rico Sennrich、Barry Haddow 和 Alexandra Birch。使用子词单元进行稀有词的神经机器翻译。arXiv 预印本 arXiv:1508.07909，2015。5 [31] Jing Shao、Siyu Chen、Yangguang Li、Kun Wang、Zhenfei Yin、Yinan He、Jianing Teng、Qinghong Sun、Mengya Gao、Jihao Liu 等。Intern：迈向通用视觉的新学习范式。arXiv 预印本 arXiv:2111.08687，2021。3 [32] Shuai Shao、Zeming Li、Tianyuan Zhang、Chao Peng、Gang Yu、Xiangyu Zhang、Jing Li 和 Jian Sun。Objects365：用于目标检测的大规模高质量数据集。发表于 IEEE/CVF 国际计算机视觉会议论文集，第 8430–8439 页，2019。6 [33] Piyush Sharma、Nan Ding、Sebastian Goodman 和 Radu Soricut。Conceptual Captions：用于自动图像描述的清洗过、上位词化的图像替代文本数据集。发表于 ACL，2018。6, 13 [34] Amanpreet Singh、Ronghang Hu、Vedanuj Goswami、Guillaume Couairon、Wojciech Galuba、Marcus Rohrbach 和 Douwe Kiela。Flava：基础性的语言与视觉对齐模型。arXiv 预印本 arXiv:2112.04482，2021。3 [35] Chen Sun、Abhinav Shrivastava、Saurabh Singh 和 Abhinav Gupta。重新审视深度学习时代数据的不合理有效性。发表于 IEEE 国际会议论文集

计算机视觉会议，第843–852页，2017。3 [36] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N Gomez， ukasz Kaiser, and Illia Polosukhin。Attention is all you need。神经信息处理系统进展，30，2017。2, 4, 5, 6 [37] Junke Wang, Dongdong Chen, Zuxuan Wu, Chong Luo, Luowei Zhou, Yucheng Zhao, Yujia Xie, Ce Liu, Yu-Gang Jiang, and Lu Yuan。Omnivl：用于图像-语言和视频-语言任务的基础模型。arXiv 预印本 arXiv:2209.07526，2022。3 [38] Jianfeng Wang, Zhengyuan Yang, Xiaowei Hu, Linjie Li, Kevin Lin, Zhe Gan, Zicheng Liu, Ce Liu, and Lijuan Wang。Git：用于视觉与语言的生成式图像到文本 Transformer。arXiv 预印本 arXiv:2205.14100，2022。3, 8 [39] Peng Wang, An Yang, Rui Men, Junyang Lin, Shuai Bai, Zhikang Li, Jianxin Ma, Chang Zhou, Jingren Zhou, and Hongxia Yang。通过简单的序列到序列学习框架统一架构、任务和模态。arXiv 预印本 arXiv:2202.03052，2022。2, 3, 5, 8 [40] Wenhui Wang, Hangbo Bao, Li Dong, Johan Bjorck, Zhiliang Peng, Qiang Liu, Kriti Aggarwal, Owais Khan Mohammed, Saksham Singhal, Subhojit Som, et al。将图像作为外语：用于所有视觉和视觉-语言任务的 Beit 预训练。arXiv 预印本 arXiv:2208.10442，2022。1, 3 [41] Zirui Wang, Jiahui Yu, Adams Wei Yu, Zihang Dai, Yulia Tsvetkov, and Yuan Cao。Simvlm：使用弱监督进行简单视觉语言模型预训练。arXiv 预印本 arXiv:2108.10904，2021。3 [42] Jianwei Yang, Chunyuan Li, Pengchuan Zhang, Bin Xiao, Ce Liu, Lu Yuan, and Jianfeng Gao。图像-文本-标签空间中的统一对比学习。收录于 IEEE/CVF 计算机视觉与模式识别会议论文集，第19163–19173页，2022。3 [43] Zhengyuan Yang, Zhe Gan, Jianfeng Wang, Xiaowei Hu, Faisal Ahmed, Zicheng Liu, Yumao Lu, and Lijuan Wang。Unitab：为具备定位能力的视觉-语言建模统一文本和边框输出。收录于欧洲计算机视觉会议，第521–539页。Springer，2022。2, 3, 8 [44] Jiahui Yu, Zirui Wang, Vijay Vasudevan, Legg Yeung, Mojtaba Seyedhosseini, and Yonghui Wu。Coca：对比式字幕生成器是图像-文本基础模型。arXiv 预印本 arXiv:2205.01917，2022。1, 3 [45] Lu Yuan, Dongdong Chen, Yi-Ling Chen, Noel Codella, Xiyang Dai, Jianfeng Gao, Houdong Hu, Xuedong Huang, Boxin Li, Chunyuan Li, et al。Florence：一种新的计算机视觉基础模型。arXiv 预印本 arXiv:2111.11432，2021。1, 3 [46] Xiaohua Zhai, Alexander Kolesnikov, Neil Houlsby, and Lucas Beyer。扩展视觉 Transformer。收录于 IEEE/CVF 计算机视觉与模式识别会议论文集，第12104–12113页，2022。3 [47] Hao Zhang, Feng Li, Shilong Liu, Lei Zhang, Hang Su, Jun Zhu, Lionel M Ni, and Heung-Yeung Shum。Dino：用于端到端目标检测的、带有改进去噪锚框的 Detr。arXiv 预印本 arXiv:2203.03605，2022。4, 8 [48] Jinguo Zhu, Xizhou Zhu, Wenhai Wang, Xiaohua Wang, Hongsheng Li, Xiaogang Wang, and Jifeng Dai。Uni-perceiver-moe：使用 con- 学习稀疏通用模型

ditional moes. *arXiv preprint arXiv:2206.04674*, 2022. 2, 4, 5, 6, 8, 12, 13

[49] Yukun Zhu, Ryan Kiros, Rich Zemel, Ruslan Salakhutdinov, Raquel Urtasun, Antonio Torralba, and Sanja Fidler. Aligning books and movies: Towards story-like visual explanations by watching movies and reading books. In *ICCV*, pages 19–27, 2015. 6, 12, 13

A. 图像编码器的架构细节

如图 3 所示，我们的 Uni-Perceiver v2 由三个主要部分组成：图像编码器、文本编码器和统一解码器。在本节中，我们描述图像编码器的架构细节。

骨干网络。给定一个高度为 H、宽度为 W 的输入图像 $x \in \mathbb{R}^{H\times W}$，首先采用骨干网络（例如 ResNet [12]、Swin-Transformer [21]）来提取多尺度特征图 $\{\mathcal{F}_l\}_{l=0}^{L-1}$，其中 $L=4$ 是特征尺度的数量，特征图的空间形状分别为 $\frac{H}{4}\times\frac{W}{4}$、$\frac{H}{8}\times\frac{W}{8}$、$\frac{H}{16}\times\frac{W}{16}$ 和 $\frac{H}{32}\times\frac{W}{32}$。通过 1×1 卷积对特征图进行变换，以匹配后续基于 Transformer 的区域提议网络的隐藏维度。变换后的特征图记为 $\mathcal{F}'_l$。在 $\mathcal{F}_3$ 上应用一个额外的 3×3、步幅为 2 的卷积层，以提取更小的特征图 $\mathcal{F}'_4 \in \mathbb{R}^{\frac{H}{64}\times\frac{W}{64}\times d}$。$d=256$ 是 Transformer 的隐藏维度。

区域候选网络。在多尺度特征图之上应用基于 Transformer 的区域候选网络，以生成区域表示。具体而言，在 Uni-Perceiver v2 采用的 4 尺度设置中，Transformer 编码器的输入是除第一尺度 $\{\mathcal{F}'_l\}_{l=1}^{L=4}$ 之外的骨干网络特征图。采用可变形 Transformer [59] 编码器来提取多尺度编码特征 $\{\mathcal{F}_l^{\text{enc}}\}_{l=1}^{L=4}$，其空间形状和维度与相应的输入特征相同。为了生成区域候选，我们在多尺度编码特征上应用可变形 Transformer 解码器。为了构建 Transformer 解码器的 N 个输入对象查询（例如，$N=900$），我们预测编码特征图 $\{\mathcal{F}_l^{\text{enc}}\}_{l=1}^{L=4}$ 中每个特征像素的目标性和边界框，并根据其目标性选择前 N 个特征。所选特征被添加到 N 个随机初始化的对象查询中，作为 Transformer 解码器的输入，并且它们的位置作为区域候选边界框的初始估计。

Transformer 解码器生成一组 N 个候选目标提案 $\{q_j^{\text{sem}}, q_j^{\text{box}}, q_j^{\text{mask}}\}_{j=1}^{N}$，其中 $q_j^{\text{sem}} \in \mathbb{R}^d$、$q_j^{\text{box}} \in \mathbb{R}^4$ 和 $q_j^{\text{mask}} \in \mathbb{R}^{H\times W}$ 分别是第 j 个提案的语义、边界框和分割掩码表示。遵循 Mask2Former [51] 和 MaskDINO [17]，分割掩码表示通过最终层隐藏表示的点积获得

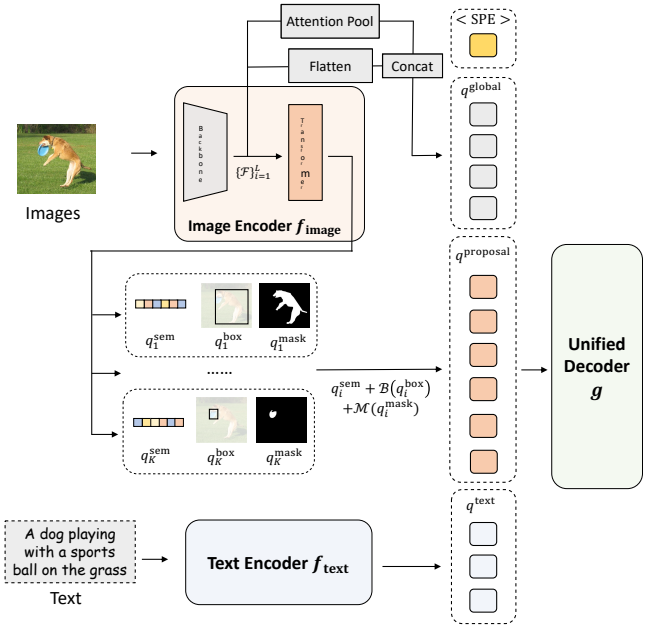


图 3. 我们的 Uni-Perceiver v2 的架构概览。

第 j 个候选方案 q_j 的状态以及逐像素特征图，

$$q_i^{\text{mask}} = \text{Upsample}\Big(\text{MLP}(q_i) \odot \mathcal{R}\big(\mathcal{G}(\mathcal{F}_0) + \mathcal{H}(\mathcal{F}_1^{\text{enc}})\big)\Big), \tag{8}$$

其中，$\mathcal{G}$ 是一个 1×1 卷积层，后接组归一化（GN）[58]；$\mathcal{H}$ 是一个 1×1 卷积，后接 GN 和双线性上采样；$\mathcal{R}$ 是一个 3×3 卷积，后接 GN、ReLU 和一个 1×1 卷积。

区域表示通过融合语义、边界框和分割掩码表示获得。

$$q_j^{\text{proposal}} = q_j^{\text{sem}} + \mathcal{B}(q_j^{\text{box}}) + \mathcal{M}(q_j^{\text{mask}}), \tag{9}$$

其中 $\mathcal{B}$ 表示框坐标的位置编码。$\mathcal{M}$ 使用自适应平均池化将掩码预测缩放到 28×28 的大小。$\mathcal{B}$ 和 $\mathcal{M}$ 都随后经过线性投影以匹配特征维度。注意，在融合之前，边界框和分割掩码表示会被分离。

为了降低计算成本，我们为每个候选区域 q_j^{proposal} 预测其物体性，并选择排名前 O 的候选区域作为最终的区域表示。在 Uni-Perceiver v2 中，O 默认设置为 200。

损失函数。在图像分类等非定位任务中，监督仅施加于统一解码器的最终预测上，如式 7 所示，而对于图像编码器的候选区域生成没有特殊监督。在目标检测等定位任务中，会为区域候选网络的训练施加额外监督。具体而言，我们采用了 con-

MaskDINO [17] 中的对比查询去噪用于训练 Transforme r 解码器。为了使区域提议网络更好地收敛，我们在 Tr ansformer 编码器的输出以及每个 Transformer 解码器层的输出处，为每个提议预测目标性、边界框和分割掩码，并将带有二分类（即预测目标性而非类别）的检测损失应用于每个输出，作为中间监督。

B. 实现细节

区域提议网络。我们的区域提议网络中使用的超参数列于表 7。这些数值主要遵循 Mask DINO [17]，但做了少量修改。用于生成区域表示的候选目标提议数量（表 7 中的“num queries”）对于 ResNet-50 骨干网络和 Swin 骨干网络分别为 300 和 900。为降低统一解码器的计算成本，区域提议会根据其目标性分数进行筛选，并且仅选择 $O = 200$ 个区域表示作为统一解码器的输入（表 7 中的“topk queries”）。此外，为节省计算成本，采用 Mask2former [51] 中使用的点损失来计算掩码损失，其中采样点数量为 112×112。

Item	Value
enc_layers	6
dec_layers	6
dim_feedforward	2048
hidden_dim	256
dropout	0.0
nheads	8
num_queries	300/900
topk_queries	200
enc_n_points	4
dec_n_points	4
cls_cost_coef	2.0
bbox_cost_coef	5.0
giou_cost_coef	2.0
mask_cost_coef	5.0
dice_cost_coef	5.0
cls_loss_coef	2.0
bbox_loss_coef	5.0
giou_loss_coef	2.0
mask_loss_coef	5.0
dice_loss_coef	5.0
dn_box_noise_scale	1.0
dn_label_noise_ratio	0.5

表 7. 我们的区域提议网络中使用的超参数。

统一解码器。对于基于 Transformer 的统一解码器，所有层均采用统一的随机深度丢弃率，其值设为 0.1。与 Uni-Perceiver 系列 [1, 48] 不同，由于在训练 6 层统一解码器时未观察到不稳定现象，因此未启用 layer-scale 技术 [56]。此外，当在统一解码器中采用 Conditional MoE 时，每层的专家数量设为 8。

数据增强。对于除图像检测和分割之外的所有任务，我们采用与 Uni-Perceiver [1] 类似的数据增强技术。不过，对于 Swin 骨干网络和 ResNet-50 骨干网络，图像分辨率分别设置为 384×384 和 224×224。而对于目标检测和实例分割任务，我们首先随机调整输入图像的大小，使其短边在 200 到 1800 像素之间，长边最多为 2400。然后在训练期间将图像裁剪为固定大小 1600 ×1600。评估时，短边设置为 1400，最大长边设置为 1600。

其他。表8列出了联合训练中每个任务和数据集的批大小、采样权重s_k和缩放因子ω_k。

C. 新类别检测

得益于 Uni-Perceiver v2 的通用任务建模，不同任务可以相互借鉴知识。对于例如，目标检测任务可以泛化到图像分类数据集中的新类别。图 4 展示了 Uni-Perceiver v2 在 ImageNet-1k 验证集图像上的检测结果，这些图像的类别不存在于 COCO 数据集中。这证明了 Uni-Perceiver v2 的泛化能力，表明通用任务建模的优势。

D. 数据集的许可证

ImageNet-1k [9] 受 ImageNet 使用条款 [57] 约束。

COCO [19] 这些图像受 Flickr 使用条款 [52] 约束。

BookCorpus [49] 复刻版 Toronto BookCorpus 是开源的，并根据 GNU GPL 第 3 版授权。
维基百科的大部分文本均依据知识共享署名-相同方式共享 3.0 未本地化许可协议（CC BY-SA）和 GNU 自由文档许可证（GFDL）（无版本号，且无不变章节、封面文本或封底文本）进行双重许可。部分文本仅依据 CC BY-SA 及与 CC BY-SA 兼容的许可协议导入，不能在 GFDL 下重复使用。

YFCC [14] YFCC 数据集中提供的所有照片和视频均采用知识共享版权许可之一授权。

task	dataset	#data	batch size / GPU	sampling weight s_k	scaling factor ω_k
Image Classification	ImageNet-1k [9]	1.28M	28	0.1	1.0
Object Detection & Instance Segmentation	COCO [19]	118K	1	0.25	1.0
Masked Language Modeling	Books&Wiki [49]	-	256	0.05	0.5
Image Captioning	YFCC [14]	14.8M	24	0.09831	0.16385
	CC12M [5]	11.1M	24	0.08514	0.1419
	CC3M [33]	3M	24	0.04428	0.0738
	Visual Genome [16]	108K	24	0.02973	0.04955
	COCO Caption [8]	113K	24	0.0192	0.032
	SBU [25]	830K	24	0.02328	0.0388
	sum	29.9M	-	0.3	0.5
Image-Text Retrieval	YFCC [14]	14.8M	28	0.09831	0.3277
	CC12M [5]	11.1M	28	0.08514	0.2838
	CC3M [33]	3M	28	0.04428	0.1476
	Visual Genome [16]	108K	28	0.02973	0.0991
	COCO Caption [8]	113K	28	0.0192	0.064
	SBU [25]	830K	28	0.02328	0.0776
	sum	29.9M	-	0.3	1.0

表8. 用于联合训练的任务和数据集。“#data”表示视觉训练样本的数量。对于图像描述生成和图像-文本检索任务，训练时使用了图像-文本对数据集的组合；在过滤掉与验证集重叠的数据后，该组合约包含29.9M个视觉样本。为缓解多任务训练中图像-文本对数据集组合的数据不平衡问题，每个数据集的采样权重s_k被设置为与数据集规模的平方根成正比，这已被证明是有效的[48]。

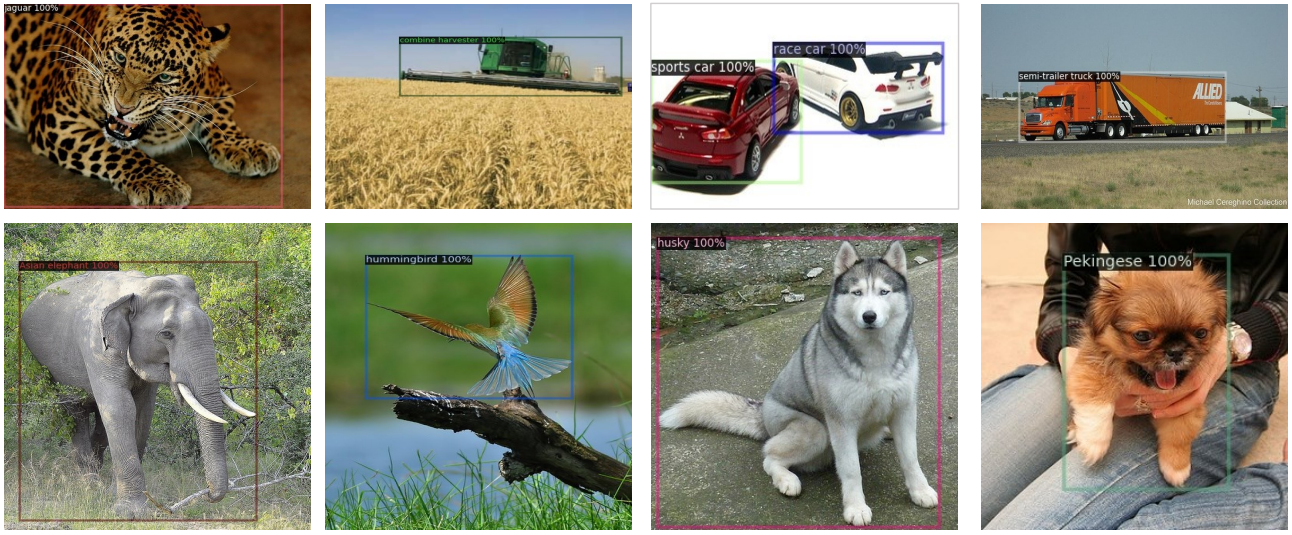


图4. 新类别上的检测结果。我们展示了 ImageNet-1k 验证集图像的检测结果。请注意，Uni-Perceiver v2 仅使用 COCO 数据集进行图像检测任务的训练，而 ImageNet-1k 中的大多数类别在训练中并未出现。

CC12M [5] 根据 Conceptual 12M [54] 的使用条款授权。

CC3M [33] 根据 Conceptual Captions 使用条款 [55] 获得许可。

Visual Genome [16] 采用知识共享署名 4.0 国际许可协议 [53] 授权。

COCO Captions [8] 图像受 Flickr 使用条款 [52] 约束。

SBU Caption [25] 这些图像受 Flickr 约束使用条款 [52]

附录参考文献

[50] Soravit Changpinyo、Piyush Sharma、Nan Ding 和 Radu Soricut。Conceptual 12M：推动网络规模图像-文本预训练以识别长尾视觉概念。发表于 CVPR，2021。6，13

[51] Bowen Cheng、Ishan Misra、Alexander G Schwing、Alexan- der Kirillov 和 Rohit Girdhar。用于通用图像分割的掩码注意力掩码 Transformer。载于 IEEE/CVF 计算机视觉与模式识别会议论文集，第 1290–1299 页，2022 年。[52] Inc. Flickr。Flickr 使用条款与条件。https:// www.flickr.com/help/terms。[53] Ranjay Krishna。Visual Genome 使用条款与条件。https:// visualgenome.org/about。[54] Google LLC。Conceptual 12m 使用条款与条件。https : / / github . com / google - research - datasets / conceptual - 12m / blob / main / LICENSE。[55] Google LLC。Conceptual Captions 使用条款与条件。https : / / github . com / google - research - datasets / conceptual - captions / blob/master/LICENSE。[56] Hugo Touvron、Matthieu Cord、Alexandre Sablayrolles、Gabriel Synnaeve 和 Hervé Jégou。使用图像 Transformer 走向更深层。arXiv 预印本 arXiv:2103.17239，2021 年。[57] 普林斯顿大学和斯坦福大学。ImageNet 使用条款与条件。https://image-net.org/ download。[58] Yuxin Wu 和 Kaiming He。组归一化。载于欧洲计算机视觉会议（ECCV）论文集，第 3–19 页，2018 年。[59] Xizhou Zhu、Weijie Su、Lewei Lu、Bin Li、Xiaogang Wang 和 Jifeng Dai。Deformable DETR：用于端到端目标检测的可变形 Transformer。arXiv 预印本 arXiv:2010.04159，2020 年。