2202 guA 13]VC.sc[2v24401.8022:viXra

图像即外语：面向所有视觉和视觉-语言任务的 BEIT 预训练

王文辉*、包航博*、董立*、Johan Bjorck、彭志良、刘强、Kriti Aggarwal、Owais Khan Mohammed、Saksham Singhal、Subhojit Som、韦福如† 微软公司 https://aka.ms/beit-3

摘要

语言、视觉与多模态预训练正在出现大融合。在这项工作中，我们提出了通用多模态基础模型 BEIT-3，它在视觉任务和视觉-语言任务上都实现了最先进的迁移性能。具体而言，我们从三个方面推进了这种大融合：骨干架构、预训练任务以及模型规模扩展。我们引入了用于通用建模的 Multi-way Transformers，其模块化架构同时支持深度融合和特定模态编码。基于共享骨干，我们以统一方式对图像（Imglish）、文本（English）以及图像-文本对（“平行句子”）执行掩码“语言”建模。实验结果表明，BEIT-3 在目标检测（COCO）、语义分割（ADE20K）、图像分类（ImageNet）、视觉推理（NLVR2）、视觉问答（VQAv2）、图像描述生成（COCO）以及跨模态检索（Flickr30K、COCO）上取得了最先进的性能。

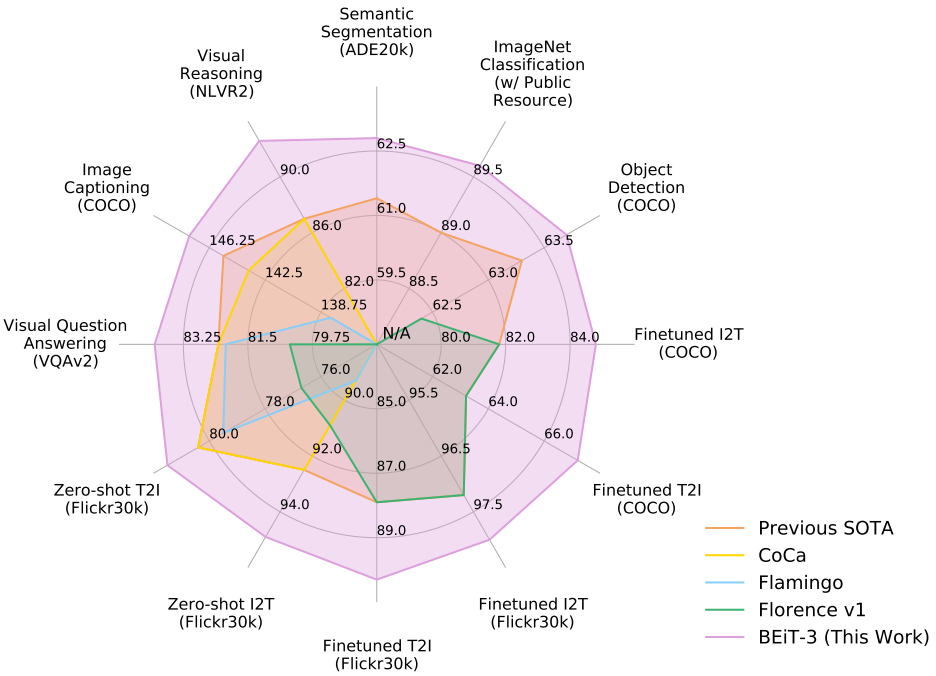


图 1：与其他定制模型或基础模型相比，BEIT-3 在广泛任务上实现了最先进的性能。I2T/T2I 是图文检索/文图检索的缩写。

* Equal contribution. † Corresponding author.

Category	Task	Dataset	Metric	Previous SOTA	BEIT-3
Vision	Semantic Segmentation	ADE20K	mIoU	61.4 (FD-SwinV2)	**62.8 (+1.4)**
	Object Detection	COCO	AP	63.3 (DINO)	**63.7 (+0.4)**
	Instance Segmentation	COCO	AP	54.7 (Mask DINO)	**54.8 (+0.1)**
	Image Classification	ImageNet†	Top-1 acc.	89.0 (FD-CLIP)	**89.6 (+0.6)**
Vision-Language	Visual Reasoning	NLVR2	Acc.	87.0 (CoCa)	**92.6 (+5.6)**
	Visual QA	VQAv2	VQA acc.	82.3 (CoCa)	**84.0 (+1.7)**
	Image Captioning	COCO‡	CIDEr	145.3 (OFA)	**147.6 (+2.3)**
	Finetuned Retrieval	COCO	R@1	72.5 (Florence)	**76.0 (+3.5)**
		Flickr30K		92.6 (Florence)	**94.2 (+1.6)**
	Zero-shot Retrieval	Flickr30K	R@1	86.5 (CoCa)	**88.2 (+1.7)**

表 1：BEIT-3 在各种视觉和视觉-语言基准上的结果概览。我们与以往最先进的模型进行比较，包括 FD-SwinV2 [WHX+22]、DINO [ZLL+22]、Mask DINO [ZLL+22]、FD-CLIP [WHX+22]、CoCa [YWV+22]、OFA [WYM+22]、Florence [YCC+21]。对于检索任务，我们报告图像到文本和文本到图像 top-1 结果的平均值。“†”表示仅使用公开可访问资源的 ImageNet 结果。“‡”表示未进行 CIDEr 优化的图像描述生成结果。

1 引言：大融合

近年来，语言 [RNSS18, DCLT19, DYW+19]、视觉 [BDPW22, PDB+22] 和多模态 [WBDW21, RKH+21, YWV+22] 预训练呈现出大融合的趋势。通过在海量数据上进行大规模预训练，我们可以轻松地将模型迁移到各种下游任务。能够预训练一个处理多种模态的通用基础模型是很有吸引力的。在这项工作中，我们从以下三个方面推进视觉-语言预训练的融合趋势。

首先，Transformer [VSP+17] 的成功从语言领域迁移到了视觉 [DBK+20] 和多模态 [KSK21, WBDW21] 问题中。网络架构的统一使我们能够无缝处理多种模态。对于视觉-语言建模，由于下游任务的性质不同，应用 Transformer 的方式多种多样。例如，双编码器架构用于高效检索 [RKH+21]，编码器-解码器网络用于生成任务 [WYY+21]，而融合编码器架构用于图像-文本编码 [KSK21]。然而，大多数基础模型必须根据特定架构手动转换最终任务的格式。此外，参数通常无法在不同模态之间有效共享。在这项工作中，我们采用 Multiway Transformers [WBDW21] 进行通用建模，即用一种统一架构共享于各种下游任务。该模块化网络还全面考虑了模态特定编码和跨模态融合。

其次，基于掩码数据建模的预训练任务已成功应用于多种模态，例如文本 [DCLT19]、图像 [BDPW22, PDB+22] 以及图像-文本对 [BWDW22]。当前的视觉-语言基础模型通常会同时执行其他预训练目标（如图像-文本匹配），这使得规模扩展不友好且效率低下。相比之下，我们仅使用一个预训练任务，即先掩码后预测，来训练一个通用的多模态基础模型。通过将图像视为一种外语（即 *Imglish*），我们以相同的方式处理文本和图像，而不存在根本性的建模差异。因此，图像-文本对被用作“平行句子”，以学习模态之间的对齐。我们还表明，这种简单而有效的方法能够学习到强大的可迁移表示，并在视觉任务和视觉-语言任务上都取得了最先进的性能。这一显著成功证明了生成式预训练的优越性 [DCLT19, BDPW22]。

第三，扩大模型规模和数据规模通常能够提升基础模型的泛化质量，从而使我们能够将其迁移到各种下游任务中。我们遵循这一理念，将模型规模扩展到数十亿参数。此外，在实验中，我们扩大了预训练数据规模，同时仅使用公开可获取的学术资源。

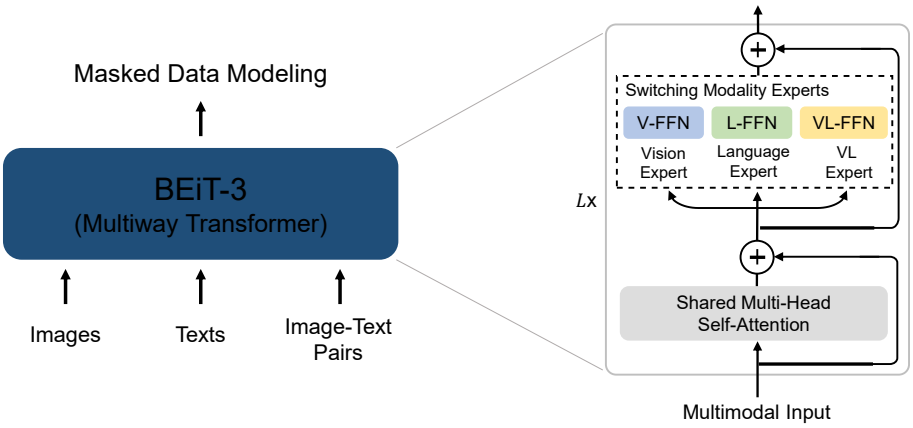


图2：BEIT-3 预训练概览。我们以共享的 Multiway Transformer 作为骨干网络，对单模态（即图像和文本）和多模态（即图像-文本对）数据进行掩码数据建模。

可复现性。尽管没有使用任何私有数据，我们的方法仍以相当可观的优势优于依赖内部数据的最先进基础模型。此外，将图像视为一门外语有利于规模扩展，因为我们可以直接复用为大规模语言模型预训练而开发的流程。

在这项工作中，我们利用上述思想来预训练一个通用多模态基础模型 BEIT-3。我们通过对图像、文本以及图文对进行掩码数据建模来预训练一个 Multiway Transformer。在预训练过程中，我们会随机掩盖一定比例的文本词元或图像块。自监督学习目标是在给定被破坏输入的情况下恢复原始词元（即文本词元或视觉词元）。该模型之所以是通用的，是因为无论输入模态或输出格式如何，它都可以被重新用于各种任务。

如图 1 和表 1 所示，BEIT-3 在广泛的视觉和视觉-语言任务中实现了最先进的迁移性能。我们在大量下游任务和数据集上评估了 BEIT-3，即目标检测（COCO）、实例分割（COCO）、语义分割（ADE20K）、图像分类（ImageNet）、视觉推理（NLVR2）、视觉问答（VQAv2）、图像描述生成（COCO）以及跨模态检索（Flickr30K、COCO）。具体而言，尽管我们仅使用公开资源进行预训练和微调，我们的模型仍优于以往强大的基础模型 [YWV+22, ADL+22, YCC+21]。该模型还取得了比专用模型更好的结果。此外，BEIT-3 不仅在视觉-语言任务上表现良好，也在视觉任务（如目标检测和语义分割）上表现出色。

2 BEIT-3：通用多模态基础模型

如图 2 所示，BEIT-3 使用共享的 Multiway Transformer 网络，通过在单模态和多模态数据上进行掩码数据建模来进行预训练。该模型可以迁移到各种视觉和视觉-语言下游任务。

2.1 主干网络：多路 Transformer

我们使用 Multiway Transformers [WBDW21] 作为骨干模型来编码不同模态。如图 2 所示，每个 Multiway Transformer 块由一个共享的自注意力模块和一组用于不同模态的前馈网络（即模态专家）组成。我们根据每个输入 token 的模态将其路由到相应的专家。在我们的实现中，每一层都包含一个视觉专家和一个语言专家。此外，最顶端的三层还包含专为融合编码器设计的视觉-语言专家。更详细的建模布局请参见图 3 (a)(b)(c)。使用一组模态专家有助于模型捕获更多模态特定的信息。共享的自注意力模块学习不同模态之间的对齐关系，并为多模态（如视觉-语言）任务实现深度融合。

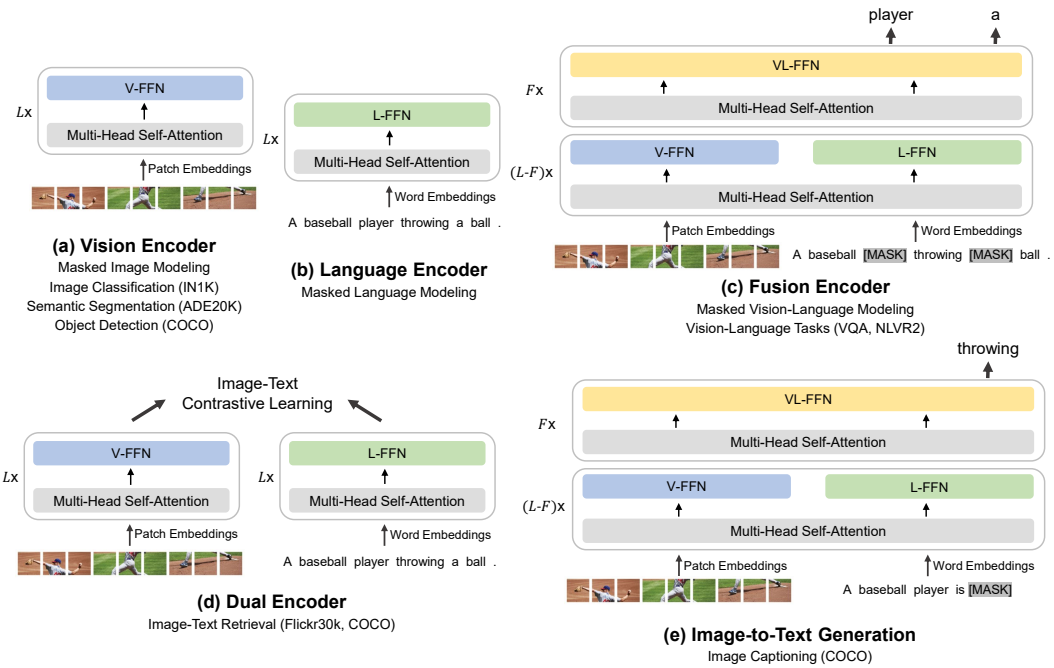


图 3：BEIT-3 可以迁移到各种视觉和视觉-语言下游任务。借助共享的 Multiway Transformer，我们可以将该模型复用为：(a)(b) 视觉或语言编码器；(c) 融合编码器，用于联合编码图像-文本对以进行深度交互；(d) 双编码器，用于分别编码不同模态以实现高效检索；(e) 序列到序列学习，用于图像到文本生成。

如图3所示，统一架构使 BEIT-3 能够支持广泛的下游任务。例如，BEIT-3 可作为各种视觉任务的图像骨干网络，包括图像分类、目标检测、实例分割和语义分割。它还可以被微调为双编码器，用于高效的图像-文本检索，以及作为融合模型用于多模态理解和生成任务。

2.2 预训练任务：掩码数据建模

我们通过在单模态数据（即图像和文本）以及多模态数据（即图文对）上采用统一的掩码数据建模 [BWDW22] 目标来预训练 BEIT-3。在预训练期间，我们随机掩蔽一定比例的文本标记或图像块，并训练模型恢复被掩蔽的标记。统一的“先掩蔽后预测”任务不仅学习表征，还学习不同模态之间的对齐。具体而言，文本数据由 SentencePiece 分词器 [KR18] 进行标记化。图像数据由 BEIT v2 [PDB+22] 的分词器进行标记化，以获得离散的视觉标记作为重建目标。我们随机掩蔽单模态文本中 15% 的标记，以及图文对中文本的 50% 标记。对于图像，我们采用与 BEIT [BDPW22, PDB+22] 中相同的按块掩蔽策略，掩蔽 40% 的图像块。

我们只使用一个预训练任务，这使得训练过程便于扩展。相比之下，先前的视觉-语言模型 [LYL+20, ZLH+21, KSK21, LSG+21, WBDW21, LLXH22, YWV+22] 通常采用多个预训练任务，例如图像-文本对比、图像-文本匹配以及词-图像块/区域对齐。我们表明，在遮蔽再预测任务中可以使用小得多的预训练批量大小。相比之下，基于对比学习的模型 [RKH+21, JYX+21, YCC+21, YWV+22] 通常需要非常大的批量大小[2]来进行预训练，这带来了更多工程挑战，例如 GPU 内存成本。

[2]For example, CoCa [YWV+22] uses 65k batch size, CLIP [RKH+21] uses 32k batch size, and Florence [YCC+21] uses 24k batch size. BEIT-3 uses a much smaller 6k batch size for pretraining.

Model	#Layers	Hidden Size	MLP Size	#Parameters				
				V-FFN	L-FFN	VL-FFN	Shared Attention	Total
BEIT-3	40	1408	6144	692M	692M	52M	317M	1.9B

表 2：BEIT-3 的模型配置。架构布局遵循 ViT-giant [ZKHB21]。

Data	Source	Size
Image-Text Pair	CC12M, CC3M, SBU, COCO, VG	21M pairs
Image	ImageNet-21K	14M images
Text	English Wikipedia, BookCorpus, OpenWebText, CC-News, Stories	160GB documents

表 3：BEIT-3 的预训练数据。所有数据均可通过学术途径获取。

2.3 扩展规模：BEIT-3 预训练

骨干网络 BEIT-3 是一个遵循 ViT-giant [ZKHB21] 设置的巨型基础模型。如表 2 所示，该模型由一个 40 层的 Multiway Transformer 组成，隐藏层维度为 1408，中间层维度为 6144，并具有 16 个注意力头。所有层都包含视觉专家和语言专家。在最上面的三层 Multiway Transformer 中还采用了视觉-语言专家。自注意力模块在不同模态之间共享。BEIT-3 总共包含 1.9B 个参数，其中视觉专家有 692M 个参数，语言专家有 692M 个参数，视觉-语言专家有 52M 个参数，共享自注意力模块有 317M 个参数。请注意，当该模型用作视觉编码器时，仅激活与视觉相关的参数（即规模与 ViT-giant 相当；约 1B）。

预训练数据 BEIT-3 在表 3 所示的单模态和多模态数据上进行预训练。对于多模态数据，包含约 1500 万张图像和 2100 万个图像-文本对，收集自五个公开数据集：Conceptual 12M (CC 12M) [CSDS21]、Conceptual Captions (CC3M) [SDGS18]、SBU Captions (SBU) [OKB11]、COCO [LMB+14] 和 Visual Genome (VG) [KZG+17]。对于单模态数据，我们使用来自 ImageNet-21K 的 1400 万张图像，以及来自英文维基百科、BookCorpus [ZKZ+15]、OpenWebText[3]、CC-News [LOG+19] 和 Stories [TL18] 的 160GB 文本语料库 [BDW+20]。

预训练设置 我们对 BEIT-3 进行 1M 步的预训练。每个批次总共包含 6144 个样本，包括 2048 张图像、2048 段文本和 2048 个图像-文本对。其批量大小远小于对比式模型 [RKH+21, JYX+21, YWV+22]。BEIT-3 使用 14×14 的 patch 大小，并在 224×224 的分辨率下进行预训练。我们使用与 BEIT [BDPW22] 相同的图像增强方法，包括随机缩放裁剪、水平翻转和颜色抖动 [WXYL18]。采用词表大小为 64k 的 SentencePiece 分词器 [KR18] 对文本数据进行分词。我们使用 AdamW [LH19] 优化器进行优化，其中 $\beta_1 = 0.9$、$\beta_2 = 0.98$，且 ϵ =1e-6。我们使用余弦学习率衰减调度器，峰值学习率为 1e-3，并进行 10k 步的线性预热。权重衰减为 0.05。使用随机深度 [HSL+16]，其比率为 0.1。采用 BEiT 初始化算法[4] [BDPW22] 来稳定 Transformer 训练。

3 视觉和视觉-语言任务实验

我们在主要的公开基准上对 BEIT-3 进行了广泛评估，涵盖视觉-语言任务和视觉任务。表 1 给出了结果概览。BEIT-3 在广泛的视觉和视觉-语言任务上取得了最先进的性能。

[3] `http://skylion007.github.io/OpenWebTextCorpus`

[4] We first randomly initialize the parameters within a small range, e.g., $[-0.02, 0.02]$. Next, we rescale the l-th Transformer layer's output matrices (i.e., the last linear projection within each sublayer) of self-attention and FFN by $\frac{1}{\sqrt{2l}}$.

Model	VQAv2		NLVR2		COCO Captioning			
	test-dev	test-std	dev	test-P	B@4	M	C	S
Oscar [LYL+20]	73.61	73.82	79.12	80.37	37.4	30.7	127.8	23.5
VinVL [ZLH+21]	76.52	76.60	82.67	83.98	38.5	30.4	130.8	23.4
ALBEF [LSG+21]	75.84	76.04	82.55	83.14	-	-	-	-
BLIP [LLXH22]	78.25	78.32	82.15	82.24	40.4	-	136.7	-
SimVLM [WYY+21]	80.03	80.34	84.53	85.15	40.6	33.7	143.3	**25.4**
Florence [YCC+21]	80.16	80.36	-	-	-	-	-	-
OFA [WYM+22]	82.00	82.00	-	-	43.9	31.8	145.3	24.8
Flamingo [ADL+22]	82.00	82.10	-	-	-	-	138.1	-
CoCa [YWV+22]	82.30	82.30	86.10	87.00	40.9	**33.9**	143.6	24.7
BEIT-3	**84.19**	**84.03**	**91.51**	**92.58**	**44.1**	32.4	**147.6**	**25.4**

表 4：视觉问答、视觉推理和图像描述任务的结果。我们报告了 VQAv2 test-dev 和 test-standard 划分上的 *vqa-score*，以及 NLVR2 开发集和公开测试集（test-P）上的准确率。对于 COCO 图像描述，我们报告 Karpathy 测试划分上的 BLEU@4（B@4）、METEOR（M）、CIDEr（C）和 SPICE（S）。为简化起见，我们报告未使用 CIDEr 优化的图像描述结果。

3.1 视觉-语言下游任务

我们在广泛使用的视觉-语言理解与生成基准上评估 BEIT-3 的能力，包括视觉问答 [GKS+17]、视觉推理 [SZZ+19]、图文检索 [PWC+15, LMB+14] 和图像描述生成 [LMB+14]。

视觉问答（VQA）该任务要求模型回答关于输入图像的自然语言问题。遵循以往工作 [AHB+18, ZLH+21, KSK21]，我们在 VQA v2.0 数据集 [GKS+17] 上进行微调实验，并将该任务表述为一个分类问题。模型经过训练，从训练集中最常见的 3129 个候选答案中预测答案。BEIT-3 被微调为一个融合编码器，用于为 VQA 任务建模图像与问题之间的深层交互。我们将给定问题和图像的嵌入进行拼接，然后将输入嵌入送入 Multiway Transformers，以联合编码图像-问题对。最终的池化输出被输入到分类器层以预测答案。结果见表 4，BEIT-3 以较大优势（超过 1.7 个点）优于所有先前模型，将单模型的最新水平提升至 84.03。

视觉推理 该任务需要模型对图像和自然语言描述进行联合推理。我们在流行的 NLVR2 [SZZ+19] 基准上评估模型，该基准旨在判断一段文本描述对于一对图像是否为真。遵循先前工作 [ZLH+21, KSK21]，我们基于三元组输入构建两个图文对。我们将 BEIT-3 微调为融合编码器，以联合编码图文对。两个图文对的最终池化输出被拼接在一起，然后输入分类器层以预测标签。如表 4 所示，BEIT-3 在视觉推理任务上取得了新的最先进结果，比 CoCa 高出约 5.6 个点。NLVR2 上的性能首次超过 90%。

图像描述生成 该任务旨在为给定图像生成自然语言描述。我们使用 COCO [LMB+14] 基准，并在 Karpathy 划分 [KF15] 上对模型进行微调和评估。遵循 UNILM [DYW+19] 和 s2s-ft [BDW+21]，BEIT-3 通过掩码微调被用作条件生成模型。更具体地说，图像描述生成任务采用了一种特殊的自注意力掩码。图像 token（即图像块）只能在图像序列内部彼此进行双向注意力。描述文本的 token 可以关注图像 token、其左侧的描述 token 以及自身。在微调过程中，我们随机掩码一定比例的描述 token。模型被训练为基于图像线索及其左侧描述上下文来恢复这些 token。我们还会掩码特殊边界 token [SEP]，以帮助模型学习终止生成。为简单起见，BEIT-3 使用简单的交叉熵损失进行训练，而不使用 CIDEr 优化。在推理过程中，我们以自回归方式逐个生成描述 token

Model	MSCOCO (5K test set)						Flickr30K (1K test set)					
	Image → Text			Text → Image			Image → Text			Text → Image		
	R@1	R@5	R@10	R@1	R@5	R@10	R@1	R@5	R@10	R@1	R@5	R@10
Fusion-encoder models												
UNITER [CLY+20]	65.7	88.6	93.8	52.9	79.9	88.0	87.3	98.0	99.2	75.6	94.1	96.8
VILLA [GCL+20]	-	-	-	-	-	-	87.9	97.5	98.8	76.3	94.2	96.8
Oscar [LYL+20]	73.5	92.2	96.0	57.5	82.8	89.8	-	-	-	-	-	-
VinVL [ZLH+21]	75.4	92.9	96.2	58.8	83.5	90.3	-	-	-	-	-	-
Dual encoder + Fusion encoder reranking												
ALBEF [LSG+21]	77.6	94.3	97.2	60.7	84.3	90.5	95.9	99.8	**100.0**	85.6	97.5	98.9
BLIP [LLXH22]	82.4	95.4	97.9	65.1	86.3	91.8	97.4	99.8	99.9	87.6	97.7	99.0
Dual-encoder models												
ALIGN [JYX+21]	77.0	93.5	96.9	59.9	83.3	89.8	95.3	99.8	**100.0**	84.9	97.4	98.6
FILIP [YHH+21]	78.9	94.4	97.4	61.2	84.3	90.6	96.6	**100.0**	**100.0**	87.1	97.7	99.1
Florence [YCC+21]	81.8	95.2	-	63.2	85.7	-	97.2	99.9	-	87.9	98.1	-
BEIT-3	**84.8**	**96.5**	**98.3**	**67.2**	**87.7**	**92.8**	**98.0**	**100.0**	**100.0**	**90.3**	**98.7**	**99.5**

表 5：在 COCO 和 Flickr30K 上进行图像到文本检索和文本到图像检索的微调结果。请注意，对于检索任务，双编码器模型比基于融合编码器的模型更高效。

Model	Flickr30K (1K test set)					
	Image → Text			Text → Image		
	R@1	R@5	R@10	R@1	R@5	R@10
FLAVA [SHG+21]	67.7	94.0	-	65.2	89.4	-
CLIP [RKH+21]	88.0	98.7	99.4	68.7	90.6	95.2
ALIGN [JYX+21]	88.6	98.7	99.7	75.7	93.8	96.8
FILIP [YHH+21]	89.8	99.2	99.8	75.0	93.4	96.3
Florence [YCC+21]	90.9	99.1	-	76.7	93.6	-
Flamingo [ADL+22]	89.3	98.8	99.7	79.5	95.3	**97.9**
CoCa [YWV+22]	92.5	99.5	99.9	80.4	**95.7**	97.7
BEIT-3	**94.9**	**99.9**	**100.0**	**81.5**	95.6	97.8

表 6：在 Flickr30K 上的零样本图像到文本检索和文本到图像检索。

方式。表4展示了在 COCO 图像描述任务上的结果。BEIT-3 优于所有先前使用交叉熵损失训练的模型，创造了新的最先进图像描述结果。这些结果证明了 BEIT-3 在视觉-语言生成方面的优越性。

图文检索 该任务旨在衡量图像与文本之间的相似性。根据检索目标的模态不同，有两个方向：图像到文本检索和文本到图像检索。我们使用两个常用的检索基准，即 COCO [LMB+14] 和 Flickr30K [PWC+15]，来评估模型。遵循以往工作 [ZLH+21, KSK21]，我们在这两个基准上使用 Karpathy 划分 [KF15]。BEIT-3 被微调为双编码器，以实现高效的图文检索。双编码器模型分别对图像和文本进行编码，以获得它们的表示。然后我们计算这些表示的余弦相似度分数。双编码器模型比融合编码器模型更高效，因为它们不必联合编码所有可能的图文对。

我们直接在 COCO 和 Flickr30K 上对 BEIT-3 进行微调，尽管该模型并未使用图文对比损失进行预训练。令人惊讶的是，BEIT-3 仅使用少量对比训练就超越了以往的最先进模型。结果表明，BEIT-3 通过掩码数据建模有效地学习了图像与文本之间的对齐关系。为了提升性能，我们在预训练的图文对上使用图文对比目标进行中间微调。我们使用比预训练少得多的步数对模型进行微调。然后，我们使用该模型评估零样本和微调后的图文检索。微调结果如下。

Model	Extra OD Data	Maximum Image Size	COCO test-dev AP^{box}	COCO test-dev AP^{mask}
ViT-Adapter [CDW+22]	-	1600	60.1	52.1
DyHead [DCX+21]	ImageNet-Pseudo Labels	2000	60.6	-
Soft Teacher [XZH+21]	Object365	-	61.3	53.0
GLIP [LZZ+21]	FourODs	-	61.5	-
GLIPv2 [ZZH+22]	FourODs	-	62.4	-
Florence [YCC+21]	FLOD-9M	2500	62.4	-
SwinV2-G [LHL+21]	Object365	1536	63.1	54.4
Mask DINO [LZX+22]	Object365	1280	-	54.7
DINO [ZLL+22]	Object365	2000	63.3	-
BEIT-3	Object365	1280	**63.7**	**54.8**

表 7：COCO 基准上目标检测和实例分割的结果。BEIT-3 使用 Cascade Mask R-CNN [CV21] 作为检测头。我们的结果采用多尺度评估报告。我们报告了训练中使用的最大图像尺寸。FLOD-9M 和 FourODs 也包含 Object365。对比系统的结果来自 paperswithcode.com 排行榜（时间戳：2022 年 08 月 22 日）。

在表 5 中，双编码器 BEIT-3 大幅优于以往模型，在 COCO top-1 图像到文本/文本到图像检索上实现了 3.0/4.0 的绝对提升，在 Flickr30K top-1 图像到文本/文本到图像检索上实现了 0.8/2.4 的绝对提升。BEIT-3 也显著优于基于融合编码器的模型，后者在推理时需要更高的计算成本。如表 6 所示，BEIT-3 在 Flickr30K 零样本检索上也取得了比以往模型更好的性能。

3.2 视觉下游任务

除了视觉-语言下游任务之外，BEIT-3 还可以迁移到广泛的视觉下游任务，包括目标检测、实例分割、语义分割和图像分类。当 BEIT-3 用作视觉编码器时，其有效参数数量与 ViT-giant [ZKHB21] 相当，即约 10 亿。

目标检测与实例分割 我们在 COCO 2017 基准 [LMB+14] 上进行了微调实验，该基准包含 118k 张训练图像、5k 张验证图像和 20k 张 test-dev 图像。我们使用 BEIT-3 作为骨干网络，并遵循 ViTDet [LMGH22]，包括简单的特征金字塔和窗口注意力，用于目标检测和实例分割任务。按照常见做法 [LHL+21, ZLL+22]，我们首先在 Objects365 [SLZ+19] 数据集上进行中间微调。然后我们在 COCO 数据集上对模型进行微调。推理过程中使用 Soft-NMS [BSCD17]。表 7 将 BEIT-3 与此前在 COCO 目标检测和实例分割上的最先进模型进行了比较。BEIT-3 在用于微调的图像尺寸更小的情况下，在 COCO test-dev 集上取得了最佳结果，达到 63.7 的 box AP 和 54.8 的 mask AP。

语义分割 语义分割旨在预测给定图像中每个像素的标签。我们在具有挑战性的 ADE20K 数据集 [ZZP+19] 上评估 BEIT-3，该数据集包含 150 个语义类别。ADE20K 包含 2 万张训练图像和 2 千张验证图像。我们直接遵循 ViT-Adapter [CDW+22] 的任务迁移设置。我们使用密集预测任务适配器，并采用 Mask2Former [CMS+21] 作为分割框架。如表 8 所示，BEIT-3 以 62.8 mIoU 创造了新的最先进结果，比拥有 30 亿参数的 FD-SwinV2 [WHX+22] 巨型模型高出 1.4 个点。这表明 BEIT-3 在密集预测任务上实现了卓越性能。

图像分类 我们在 ImageNet-1K [RDS+15] 上评估模型，该数据集包含 1k 个类别中的 1.28M 张训练图像和 50k 张验证图像。我们没有像 [DBK+20, BDPW22] 那样在视觉编码器后附加一个任务层，而是将该任务表述为图像到文本检索任务。我们使用类别名称作为文本来构建图像-文本对。BEIT-3 被训练为双编码器，以找到与图像最相关的标签。在推理过程中，我们首先计算特征嵌入

Model	Crop Size	ADE20K	
		mIoU	+MS
HorNet [RZT+22]	640^2	57.5	57.9
SeMask [JSO+21]	640^2	57.0	58.3
SwinV2-G [LHL+21]	896^2	59.3	59.9
ViT-Adapter [CDW+22]	896^2	59.4	60.5
Mask DINO [LZX+22]	-	59.5	60.8
FD-SwinV2-G [WHX+22]	896^2	-	61.4
BEIT-3	896^2	**62.0**	**62.8**

表 8：ADE20K 上语义分割的结果。“MS”是多尺度的缩写。对比系统的结果来自 paperswithcode.com 排行榜（时间戳：2022 年 08 月 22 日）。

Model	Extra Data	Image Size	ImageNet
*With extra **private** image-tag data*			
SwinV2-G [LHL+21]	IN-22K-ext-70M	640^2	90.2
ViT-G [ZKHB21]	JFT-3B	518^2	90.5
CoAtNet-7 [DLLT21]	JFT-3B	512^2	90.9
Model Soups [WIG+22]	JFT-3B	500^2	91.0
CoCa [YWV+22]	JFT-3B	576^2	91.0
*With only **public** image-tag data*			
BEIT [BDPW22]	IN-21K	512^2	88.6
CoAtNet-4 [DLLT21]	IN-21K	512^2	88.6
MaxViT [TTZ+22]	IN-21K	512^2	88.7
MViTv2 [LWF+22]	IN-21K	512^2	88.8
FD-CLIP [WHX+22]	IN-21K	336^2	89.0
BEIT-3	IN-21K	336^2	**89.6**

表 9：ImageNet-1K 上的 Top-1 准确率。

可能类别名称的文本嵌入与图像的特征嵌入。随后计算它们的余弦相似度分数，以预测每张图像最可能的标签。表 9 报告了在 ImageNet-1K 上的结果。我们首先在 ImageNet-21K 上进行中间微调，然后在 ImageNet-1K 上训练模型。为公平比较，我们仅与使用公共图像-标签数据的先前模型进行比较。BEIT-3 超越了以往模型，在仅使用公共图像-标签数据的情况下取得了新的最先进结果。

4 结论

在本文中，我们提出了 BEIT-3，这是一种通用多模态基础模型，在广泛的视觉和视觉-语言基准测试中实现了最先进的性能。BEIT-3 的核心思想是可以将图像建模为一种外语，从而能够以统一的方式对图像、文本以及图文对进行掩码“语言”建模。我们还证明，Multiway Transformers 能够有效建模不同的视觉和视觉-语言任务，使其成为通用建模的一个颇具吸引力的选择。BEIT-3 简单而有效，是扩展多模态基础模型的一个有前景的方向。对于未来工作，我们正在进行多语言 BEIT-3 的预训练，并将更多模态（例如音频）纳入 BEIT-3，以促进跨语言和跨模态迁移，并推动跨任务、语言和模态的大规模预训练的大融合。我们还希望通过结合 BEIT-3 和 MetaLM [HSD+22] 的优势，为多模态基础模型赋予上下文学习能力。

参考文献

[ADL+22] Jean-Baptiste Alayrac、Jeff Donahue、Pauline Luc、Antoine Miech、Iain Barr、Yana Hasson、Karel Lenc、Arthur Mensch、Katie Millican、Malcolm Reynolds、Roman Ring、Eliza Rutherford、Serkan Cabi、Tengda Han、Zhitao Gong、Sina Samangooei、Marianne Monteiro、Jacob Menick、Sebastian Borgeaud、Andrew Brock、Aida Nematzadeh、Sahand Sharifzadeh、Mikolaj Binkowski、Ricardo Barreira、Oriol Vinyals、Andrew Zisserman 和 Karen Simonyan。Flamingo：用于少样本学习的视觉语言模型。*CoRR*，abs/2204.14198，2022。

[AHB+18] Peter Anderson、Xiaodong He、Chris Buehler、Damien Teney、Mark Johnson、Stephen Gould 和 Lei Zhang。用于图像字幕生成和视觉问答的自下而上与自上而下注意力。在 *2018 IEEE Conference on Computer Vision and Pattern Recognition, CVPR 2018, Salt Lake City, UT, USA, June 18-22, 2018* 中，第 6077–6086 页。计算机视觉基金会 / IEEE 计算机协会，2018。

[BDPW22] 鲍杭波、董力、朴松昊和韦福如。BEiT：图像 Transformer 的 BERT 预训练。发表于 *International Conference on Learning Representations*，2022。

[BDW+20] Hangbo Bao、Li Dong、Furu Wei、Wenhui Wang、Nan Yang、Xiaodong Liu、Yu Wang、Jianfeng Gao、Songhao Piao、Ming Zhou 和 Hsiao-Wuen Hon。UniLMv2：用于统一语言模型预训练的伪掩码语言模型。见 *Proceedings of the 37th International Conference on Machine Learning, ICML 2020, 13-18 July 2020, Virtual Event*，*Proceedings of Machine Learning Research* 第 119 卷，第 642–652 页。PMLR，2020。

[BDW+21] 包航波、董力、王文辉、杨楠和韦福如。s2s-ft：针对序列到序列学习微调预训练的 Transformer 编码器。*CoRR*，abs/2110.13640，2021年。

[BSCD17] Navaneeth Bodla、Bharat Singh、Rama Chellappa 和 Larry S. Davis。Soft-nms——用一行代码改进目标检测。载于 *IEEE International Conference on Computer Vision, ICCV 2017, Venice, Italy, October 22-29, 2017*，第 5562–5570 页。IEEE Computer Society，2017。

[BWDW22] Hangbo Bao、Wenhui Wang、Li Dong 和 Furu Wei。VL-BEiT：生成式视觉-语言预训练。*ArXiv*，abs/2206.01127，2022。

[CDW+22] 陈哲、段宇辰、王文海、何俊俊、卢彤、戴季峰和乔宇。用于密集预测的视觉 Transformer 适配器。*CoRR*, abs/2205.08534, 2022.

[CLY+20] Yen-Chun Chen, Linjie Li, Licheng Yu, Ahmed El Kholy, Faisal Ahmed, Zhe Gan, Yu Cheng, and Jingjing Liu. UNITER：通用图像-文本表征学习。见 Andrea Vedaldi、Horst Bischof、Thomas Brox 和 Jan-Michael Frahm 编，*Computer Vision - ECCV 2020 - 16th European Conference, Glasgow, UK, August 23-28, 2020, Proceedings, Part XXX*，*Lecture Notes in Computer Science* 第 12375 卷，第 104–120 页。Springer，2020。

[CMS+21] 程博文、Ishan Misra、Alexander G. Schwing、Alexander Kirillov 和 Rohit Girdhar。用于通用图像分割的掩码注意力掩码 Transformer。*CoRR*，abs/2112.01527，2021。

[CSDS21] Soravit Changpinyo、Piyush Sharma、Nan Ding 和 Radu Soricut。Conceptual 12M：推动网络规模的图像-文本预训练以识别长尾视觉概念。载于 *IEEE Conference on Computer Vision and Pattern Recognition, CVPR 2021, virtual, June 19-25, 2021*，第 3558–3568 页。计算机视觉基金会 / IEEE，2021 年。

[CV21] Zhaowei Cai 和 Nuno Vasconcelos。Cascade R-CNN：高质量目标检测与实例分割。*IEEE Trans. Pattern Anal. Mach. Intell.*, 43(5):1483–1498, 2021.

[DBK+20] Alexey Dosovitskiy、Lucas Beyer、Alexander Kolesnikov、Dirk Weissenborn、Xiaohua Zhai、Thomas Unterthiner、Mostafa Dehghani、Matthias Minderer、Georg Heigold、Syl- vain Gelly 等。一张图像胜过 16x16 个词：用于大规模图像识别的 Transformer。*preprint arXiv:2010.11929*，2020。

[DCLT19] Jacob Devlin、Ming-Wei Chang、Kenton Lee 和 Kristina Toutanova。BERT：用于语言理解的深度双向 Transformer 预训练。载于 Jill Burstein、Christy Doran 和 Thamar Solorio 编，*Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, NAACL-HLT 2019, Minneapolis, MN, USA, June 2-7, 2019, Volume 1 (Long and Short Papers)*，第 4171–4186 页。计算语言学协会，2019。

[DCX+21] 戴熙阳、陈胤鹏、肖斌、陈东东、刘梦辰、Yuan Lu 和张磊。Dynamic head：用注意力统一目标检测头。载于 *IEEE Conference on Computer Vision and Pattern Recognition, CVPR 2021, virtual, June 19-25, 2021*，第 7373–7382 页。Computer Vision Foundation / IEEE，2021。

[DLLT21] Zihang Dai、Hanxiao Liu、Quoc V. Le 和 Mingxing Tan。Coatnet：将卷积与注意力结合用于所有数据规模。收录于 Marc’Aurelio Ranzato、Alina Beygelzimer、Yann N. Dauphin、Percy Liang 和 Jennifer Wortman Vaughan 编，*Advances in Neural Information Processing Systems 34: Annual Conference on Neural Information Processing Systems 2021, NeurIPS 2021, December 6-14, 2021, virtual*，第 3965–3977 页，2021。

[DYW+19] Li Dong、Nan Yang、Wenhui Wang、Furu Wei、Xiaodong Liu、Yu Wang、Jianfeng Gao、Ming Zhou 和 Hsiao-Wuen Hon。用于自然语言理解与生成的统一语言模型预训练。载于 *Advances in Neural Information Processing Systems 32: Annual Conference on Neural Information Processing Systems 2019, NeurIPS 2019, December 8-14, 2019, Vancouver, BC, Canada*，第 13042–13054 页，2019 年。[GCL+20] Zhe Gan、Yen-Chun Chen、Linjie Li、Chen Zhu、Yu Cheng 和 Jingjing Liu。用于视觉与语言表示学习的大规模对抗训练。载于 Hugo Larochelle、Marc’Aurelio Ranzato、Raia Hadsell、Maria-Florina Balcan 和 Hsuan-Tien Lin 编，*Advances in Neural Information Processing Systems 33: Annual Conference on Neural Information Processing Systems 2020, NeurIPS 2020, December 6-12, 2020, virtual*，2020 年。

[GKS+17] Yash Goyal、Tejas Khot、Douglas Summers-Stay、Dhruv Batra 和 Devi Parikh。让 VQA 中的 V 变得重要：提升图像理解在视觉问答中的作用。发表于 *2017 IEEE Conference on Computer Vision and Pattern Recognition, CVPR 2017, Honolulu, HI, USA, July 21-26, 2017*，第 6325–6334 页。IEEE 计算机学会，2017。

[HSD+22] 郝雅茹、宋昊宇、董理、黄少涵、池泽文、王文慧、马树英和韦福如。语言模型是通用接口。*ArXiv*，abs/2206.06336，2022。

[HSL+16] Gao Huang、Yu Sun、Zhuang Liu、Daniel Sedra 和 Kilian Q. Weinberger。具有随机深度的深度网络。收录于 Bastian Leibe、Jiri Matas、Nicu Sebe 和 Max Welling 编辑的 *Computer Vision - ECCV 2016 - 14th European Conference, Amsterdam, The Netherlands, October 11-14, 2016, Proceedings, Part IV*，*Lecture Notes in Computer Science* 第 9908 卷，第 646–661 页。Springer，2016。

[JSO+21] Jitesh Jain、Anukriti Singh、Nikita Orlov、Zilong Huang、Jiachen Li、Steven Walton 和 Humphrey Shi。Semask：用于有效语义分割的语义掩蔽 Transformer 骨干网络。*arXiv*，2021。

[JYX+21] Chao Jia、Yinfei Yang、Ye Xia、Yi-Ting Chen、Zarana Parekh、Hieu Pham、Quoc V. Le、Yun-Hsuan Sung、Zhen Li 和 Tom Duerig。利用噪声文本监督扩展视觉和视觉-语言表征学习。收录于 Marina Meila 和 Tong Zhang，

编者，*Proceedings of the 38th International Conference on Machine Learning, ICML 2021, 18-24 July 2021, Virtual Event*，*Proceedings of Machine Learning Research* 第 139 卷，第 4904–4916 页。PMLR，2021。

[KF15] 安德烈·卡帕西和李飞飞。用于生成图像描述的深度视觉-语义对齐。载于 *IEEE Conference on Computer Vision and Pattern Recognition, CVPR 2015, Boston, MA, USA, June 7-12, 2015*，第3128–3137页。IEEE 计算机学会，2015年。

[KR18] Taku Kudo 和 John Richardson。SentencePiece：一种用于神经文本处理的简单且语言无关的子词分词器和去分词器。收录于 *Proceedings of the 2018 Conference on Empirical Methods in Natural Language Processing: System Demonstrations*，第 66–71 页，比利时布鲁塞尔，2018 年 11 月。计算语言学协会。

[KSK21] Wonjae Kim、Bokyung Son 和 Ildoo Kim。ViLT：无卷积或区域监督的视觉-语言 Transformer。收录于 Marina Meila 和 Tong Zhang 编辑的 *Proceedings of the 38th International Conference on Machine Learning, ICML 2021, 18-24 July 2021, Virtual Event*，*Proceedings of Machine Learning Research* 第 139 卷，页 5583–5594。PMLR，2021。

[KZG+17] Ranjay Krishna、Yuke Zhu、Oliver Groth、Justin Johnson、Kenji Hata、Joshua Kravitz、Stephanie Chen、Yannis Kalantidis、Li-Jia Li、David A. Shamma、Michael S. Bernstein 和 Li Fei-Fei。Visual Genome：使用众包密集图像标注连接语言与视觉。*Int. J. Comput. Vis.*，123(1):32–73，2017。

[LH19] Ilya Loshchilov 和 Frank Hutter。解耦权重衰减正则化。收录于 *7th International Conference on Learning Representations, ICLR 2019, New Orleans, LA, USA, May 6-9, 2019*。OpenReview.net，2019。

[LHL+21] 刘泽、胡瀚、林雨桐、姚祝良、谢志达、魏逸轩、宁佳、曹越、张峥、董力、韦福如和郭百宁。Swin Transformer V2：扩展容量和分辨率。*CoRR*，abs/2111.09883，2021。

[LLXH22] Junnan Li、Dongxu Li、Caiming Xiong 和 Steven C. H. Hoi。BLIP：用于统一视觉-语言理解与生成的语言-图像预训练自举方法。收录于 Kamalika Chaudhuri、Stefanie Jegelka、Le Song、Csaba Szepesvári、Gang Niu 和 Sivan Sabato 主编的 *International Conference on Machine Learning, ICML 2022, 17-23 July 2022, Baltimore, Maryland, USA*，*Proceedings of Machine Learning Research* 第 162 卷，第 12888–12900 页。PMLR，2022。

[LMB+14] Tsung-Yi Lin、Michael Maire、Serge J. Belongie、James Hays、Pietro Perona、Deva Ramanan、Piotr Dollár 和 C. Lawrence Zitnick。Microsoft COCO：情境中的常见物体。收录于 David J. Fleet、Tomás Pajdla、Bernt Schiele 和 Tinne Tuytelaars 编辑的 *Computer Vision - ECCV 2014 - 13th European Conference, Zurich, Switzerland, September 6-12, 2014, Proceedings, Part V*，*Lecture Notes in Computer Science* 第 8693 卷，第 740–755 页。Springer，2014。

[LMGH22] Yanghao Li、Hanzi Mao、Ross B. Girshick 和 Kaiming He。探索用于目标检测的朴素视觉 Transformer 骨干网络。*CoRR*，abs/2203.16527，2022。

[LOG+19] 尹瀚、Myle Ott、Naman Goyal、Jingfei Du、Mandar Joshi、Danqi Chen、Omer Levy、Mike Lewis、Luke Zettlemoyer 和 Veselin Stoyanov。Roberta：一种经过鲁棒优化的 BERT 预训练方法。*CoRR*，abs/1907.11692，2019。

[LSG+21] Junnan Li、Ramprasaath R. Selvaraju、Akhilesh Deepak Gotmare、Shafiq R. Joty、Caiming Xiong 和 Steven C. H. Hoi。先对齐再融合：基于动量蒸馏的视觉与语言表示学习。*CoRR*，abs/2107.07651，2021。

[LWF+22] Yanghao Li、Chao-Yuan Wu、Haoqi Fan、Karttikeya Mangalam、Bo Xiong、Jitendra Malik 和 Christoph Feichtenhofer。Mvitv2：用于分类和检测的改进型多尺度视觉 Transformer。载于 *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*，第 4804–4814 页，2022 年。

[LYL+20] Xiujun Li、Xi Yin、Chunyuan Li、Pengchuan Zhang、Xiaowei Hu、Lei Zhang、Lijuan Wang、Houdong Hu、Li Dong、Furu Wei、Yejin Choi 和 Jianfeng Gao。Oscar：用于视觉-语言任务的对象-语义对齐预训练。载于 Andrea Vedaldi、Horst Bischof、Thomas Brox 和 Jan-Michael Frahm 编，*Computer Vision - ECCV 2020 - 16th European Conference, Glasgow, UK, August 23-28, 2020, Proceedings, Part XXX*，*Lecture Notes in Computer Science* 第 12375 卷，第 121–137 页。Springer，2020。

[LZX+22] Feng Li, Hao Zhang, Huaizhe Xu, Shilong Liu, Lei Zhang, Lionel M. Ni 和 Heung-Yeung Shum。Mask DINO：迈向一个用于目标检测与分割的统一的基于 Transformer 的框架。*CoRR*, abs/2206.02777, 2022.

[LZZ+21] Liunian Harold Li, Pengchuan Zhang, Haotian Zhang, Jianwei Yang, Chunyuan Li, Yiwu Zhong, Lijuan Wang, Lu Yuan, Lei Zhang, Jenq-Neng Hwang, Kai-Wei Chang, and Jianfeng Gao. 基于定位的语言-图像预训练。*CoRR*, abs/2112.03857, 2021.

[OKB11] Vicente Ordonez、Girish Kulkarni 和 Tamara L. Berg。Im2text：使用 100 万张带说明文字的照片描述图像。载 John Shawe-Taylor、Richard S. Zemel、Peter L. Bartlett、Fernando C. N. Pereira 和 Kilian Q. Weinberger 编，*Advances in Neural Information Processing Systems 24: 25th Annual Conference on Neural Information Processing Systems 2011. Proceedings of a meeting held 12-14 December 2011, Granada, Spain*，第 1143–1151 页，2011 年。

[PDB+22] 彭志亮、董立、包航波、叶启祥和韦福如。Beit v2：使用向量量化视觉分词器的掩码图像建模。*CoRR*, abs/2208.06366, 2022.

[PWC+15] Bryan A. Plummer、Liwei Wang、Chris M. Cervantes、Juan C. Caicedo、Julia Hockenmaier 和 Svetlana Lazebnik。Flickr30k 实体：收集区域到短语的对应关系，以构建更丰富的图像到句子模型。收录于 *2015 IEEE International Conference on Computer Vision, ICCV 2015, Santiago, Chile, December 7-13, 2015*，第 2641–2649 页。IEEE Computer Society，2015。

[RDS+15] Olga Russakovsky、Jia Deng、Hao Su、Jonathan Krause、Sanjeev Satheesh、Sean Ma、Zhiheng Huang、Andrej Karpathy、Aditya Khosla、Michael Bernstein、Alexander C Berg 和 Li Fei-Fei。ImageNet 大规模视觉识别挑战赛。*IJCV*，2015。

[RKH+21] Alec Radford、Jong Wook Kim、Chris Hallacy、Aditya Ramesh、Gabriel Goh、Sandhini Agarwal、Girish Sastry、Amanda Askell、Pamela Mishkin、Jack Clark、Gretchen Krueger 和 Ilya Sutskever。通过自然语言监督学习可迁移的视觉模型。收录于 Marina Meila 和 Tong Zhang（编辑），*Proceedings of the 38th International Conference on Machine Learning, ICML 2021, 18-24 July 2021, Virtual Event*，*Proceedings of Machine Learning Research* 第 139 卷，第 8748–8763 页。PMLR，2021。

[RNSS18] Alec Radford、Karthik Narasimhan、Tim Salimans 和 Ilya Sutskever。通过生成式预训练改进语言理解。2018。

[RZT+22] Yongming Rao, Wenliang Zhao, Yansong Tang, Jie Zhou, Ser Nam Lim, and Jiwen Lu. HorNet：通过递归门控卷积实现高效的高阶空间交互。*ArXiv*, abs/2207.14284, 2022.

[SDGS18] Piyush Sharma、Nan Ding、Sebastian Goodman 和 Radu Soricut。概念字幕：一个经过清洗、上位词化的图像替代文本数据集，用于自动图像字幕生成。收录于 Iryna Gurevych 和 Yusuke Miyao 编，*Proceedings of the 56th Annual Meeting of the Association for Computational Linguistics, ACL 2018, Melbourne, Australia, July 15-20, 2018, Volume 1: Long Papers*，第 2556–2565 页。计算语言学协会，2018 年。

[SHG+21] Amanpreet Singh、Ronghang Hu、Vedanuj Goswami、Guillaume Couairon、Wojciech Galuba、Marcus Rohrbach 和 Douwe Kiela。FLAVA：一种基础性语言与视觉对齐模型。*CoRR*，abs/2112.04482，2021。

[SLZ+19] 邵帅、李泽明、张天元、彭超、俞刚、张祥雨、李静和孙剑。Objects365：用于目标检测的大规模高质量数据集。发表于 *2019 IEEE/CVF International Conference on Computer Vision, ICCV 2019, Seoul, Korea (South), October 27 - November 2, 2019*，第 8429–8438 页。IEEE，2019。

[SZZ+19] Alane Suhr、Stephanie Zhou、Ally Zhang、Iris Zhang、Huajun Bai 和 Yoav Artzi。一个用于推理基于照片的自然语言的语料库。载于 Anna Korhonen、David R. Traum 和 Lluís Màrquez（编），*Proceedings of the 57th Conference of the Association for Computational Linguistics, ACL 2019, Florence, Italy, July 28- August 2, 2019, Volume 1: Long Papers*，第 6418–6428 页。计算语言学协会，2019。

[TL18] Trieu H. Trinh 和 Quoc V. Le。一种用于常识推理的简单方法。*ArXiv*, abs/1806.02847, 2018.

[TTZ+22] Zhengzhong Tu、Hossein Talebi、Han Zhang、Feng Yang、Peyman Milanfar、Alan Bovik 和 Yinxiao Li。Maxvit：多轴视觉 Transformer。*CoRR*，abs/2204.01697，2022。

[VSP+17] Ashish Vaswani、Noam Shazeer、Niki Parmar、Jakob Uszkoreit、Llion Jones、Aidan N. Gomez、Lukasz Kaiser 和 Illia Polosukhin。注意力就是你所需要的一切。收录于 Isabelle Guyon、Ulrike von Luxburg、Samy Bengio、Hanna M. Wallach、Rob Fergus、S. V. N. Vishwanathan 和 Roman Garnett 编辑的 *Advances in Neural Information Processing Systems 30: Annual Conference on Neural Information Processing Systems 2017, December 4-9, 2017, Long Beach, CA, USA*，第 5998–6008 页，2017 年。

[WBDW21] 王文辉、包航波、董力和韦福如。VLMo：基于模态专家混合的统一视觉-语言预训练。*CoRR*，abs/2111.02358，2021。

[WHX+22] 魏一轩、胡瀚、谢振达、张政、曹越、鲍建民、陈东和郭百宁。通过特征蒸馏，对比学习在微调中可媲美掩码图像建模。*CoRR*, abs/2205.14141, 2022.

[WIG+22] Mitchell Wortsman、Gabriel Ilharco、Samir Ya Gadre、Rebecca Roelofs、Raphael Gon-tijo Lopes、Ari S. Morcos、Hongseok Namkoong、Ali Farhadi、Yair Carmon、Simon Kornblith 和 Ludwig Schmidt。模型汤：对多个微调模型的权重进行平均可在不增加推理时间的情况下提高准确率。载于 Kamalika Chaudhuri、Stefanie Jegelka、Le Song、Csaba Szepesvári、Gang Niu 和 Sivan Sabato（编辑），*International Conference on Machine Learning, ICML 2022, 17-23 July 2022, Baltimore, Maryland, USA*，*Proceedings of Machine Learning Research* 第 162 卷，第 23965–23998 页。PMLR，2022。

[WXYL18] Zhirong Wu、Yuanjun Xiong、Stella X. Yu 和 Dahua Lin。通过非参数实例判别进行无监督特征学习。载于 *2018 IEEE Conference on Computer Vision and Pattern Recognition, CVPR 2018, Salt Lake City, UT, USA, June 18-22, 2018*，第 3733–3742 页。Computer Vision Foundation / IEEE Computer Society，2018。

[WYM+22] Peng Wang、An Yang、Rui Men、Junyang Lin、Shuai Bai、Zhikang Li、Jianxin Ma、Chang Zhou、Jingren Zhou 和 Hongxia Yang。通过简单的序列到序列学习框架统一架构、任务和模态。*CoRR*，abs/2202.03052，2022。

[WYY+21] Zirui Wang、Jiahui Yu、Adams Wei Yu、Zihang Dai、Yulia Tsvetkov 和 Yuan Cao。SimVLM：基于弱监督的简单视觉语言模型预训练。*CoRR*，abs/2108.10904，2021。

[XZH+21] Mengde Xu, Zheng Zhang, Han Hu, Jianfeng Wang, Lijuan Wang, Fangyun Wei, Xiang Bai, and Zicheng Liu. 基于软教师的端到端半监督目标检测。载于 *2021 IEEE/CVF International Conference on Computer Vision, ICCV 2021, Montreal, QC, Canada, October 10-17, 2021*，第 3040–3049 页。IEEE，2021。

[YCC+21] Lu Yuan、Dongdong Chen、Yi-Ling Chen、Noel Codella、Xiyang Dai、Jianfeng Gao、Houdong Hu、Xuedong Huang、Boxin Li、Chunyuan Li、Ce Liu、Mengchen Liu、Zicheng Liu、Yumao Lu、Yu Shi、Lijuan Wang、Jianfeng Wang、Bin Xiao、Zhen Xiao、Jianwei Yang、Michael Zeng、Luowei Zhou 和 Pengchuan Zhang。Florence：一种用于计算机视觉的新基础模型。*CoRR*，abs/2111.11432，2021。

[YHH+21] 姚乐为、黄润辉、侯璐、卢冠松、牛敏哲、徐航、梁晓丹、李振国、姜鑫和徐春景。FILIP：细粒度交互式语言-图像预训练。*CoRR*，abs/2111.07783，2021。

[YWV+22] Jiahui Yu、Zirui Wang、Vijay Vasudevan、Legg Yeung、Mojtaba Seyedhosseini 和 Yonghui Wu。Coca：对比式字幕生成器是图像-文本基础模型。*CoRR*，abs/2205.01917，2022。[ZKHB21] Xiaohua Zhai、Alexander Kolesnikov、Neil Houlsby 和 Lucas Beyer。扩展视觉 Transformer。*arXiv preprint arXiv:2106.04560*，2021。[ZKZ+15] Yukun Zhu、Ryan Kiros、Rich Zemel、Ruslan Salakhutdinov、Raquel Urtasun、Antonio Torralba 和 Sanja Fidler。对齐书籍与电影：通过观看电影和阅读书籍实现故事式视觉解释。在 *Proceedings of the IEEE international conference on computer vision* 中，第 19–27 页，2015。[ZLH+21] Pengchuan Zhang、Xiujun Li、Xiaowei Hu、Jianwei Yang、Lei Zhang、Lijuan Wang、Yejin Choi 和 Jianfeng Gao。VinVL：重新审视视觉-语言模型中的视觉表示。在
IEEE Conference on Computer Vision and Pattern Recognition,
CVPR 2021, virtual, June 19-25, 2021 中，第 5579–5588 页。计算机视觉基金会 / IEEE，2021。

[ZLL+22] Hao Zhang、Feng Li、Shilong Liu、Lei Zhang、Hang Su、Jun Zhu、Lionel M. Ni 和 Heung-Yeung Shum。DINO：用于端到端目标检测的改进去噪锚框 DETR。*CoRR*，abs/2203.03605，2022。

[ZZH+22] Haotian Zhang, Pengchuan Zhang, Xiaowei Hu, Yen-Chun Chen, Liunian Harold Li, Xiyang Dai, Lijuan Wang, Lu Yuan, Jenq-Neng Hwang, and Jianfeng Gao. Glipv2：统一定位与视觉-语言理解。*CoRR*, abs/2206.05836, 2022.

[ZZP+19] Bolei Zhou、Hang Zhao、Xavier Puig、Tete Xiao、Sanja Fidler、Adela Barriuso 和 Antonio Torralba。通过 ADE20K 数据集实现场景的语义理解。*Int. J. Comput. Vis.*，127(3):302–321，2019。

A 中间微调对检索的影响

如表 10 所示，我们直接在 COCO 和 Flickr30K 上对 BEIT-3 进行微调。即使在预训练期间未使用图文对比目标，BEIT-3 仍然优于此前最先进的模型。结果证明了掩码数据建模在学习跨模态表示方面的有效性。接下来，我们在预训练图文对上进行 5 个 epoch 的中间微调，批量大小为 16k。峰值学习率为 3e-5，并在第一个 epoch 内进行线性预热。图像输入大小为 224 × 224。权重衰减设置为 0.05。与预训练一样，我们禁用 dropout，并使用比率为 0.3 的 drop path。逐层学习率衰减为 0.95。我们使用 AdamW [LH19] 优化器，其中 $\beta_1 = 0.9$，$\beta_2 = 0.999$。

Model	MSCOCO (5K test set)						Flickr30K (1K test set)					
	Image → Text			Text → Image			Image → Text			Text → Image		
	R@1	R@5	R@10	R@1	R@5	R@10	R@1	R@5	R@10	R@1	R@5	R@10
BEIT-3	82.7	96.0	98.2	65.1	86.6	92.3	97.5	99.9	100.0	89.1	98.6	99.3
+ Intermediate Finetuning	**84.8**	**96.5**	**98.3**	**67.2**	**87.7**	**92.8**	**98.0**	**100.0**	**100.0**	**90.3**	**98.7**	**99.5**

表 10：在 COCO 和 Flickr30K 上进行图文检索的微调结果。BEIT-3 直接在下游基准上进行微调，而未在预训练数据上进行中间微调。

B 用于预训练的超参数

Hyperparameters	BEIT-3
Layers	40
Hidden size	1408
FFN inner hidden size	6144
Attention heads	16
Patch size	14×14
Relative positional embeddings	✗
Training steps	1M
Batch size	6144
AdamW ϵ	1e-6
AdamW β	(0.9, 0.98)
Peak learning rate	1e-3
Learning rate schedule	Cosine
Warmup steps	10k
Gradient clipping	3.0
Dropout	✗
Drop path	0.1
Weight decay	0.05
Data Augment	RandomResizeAndCrop
Input resolution	224^2
Color jitter	0.4

表 11：预训练 BEIT-3 的超参数。

C Hyperparameters Used for Finetuning

Hyperparameters	NLVR2	VQAv2
Peak learning rate	1e-3	1e-5
Fine-tuning epochs	20	10
Warmup epochs	5	1
Layer-wise learning rate decay	0.8	1.0
Batch size	256	128
AdamW ϵ	1e-8	
AdamW β	(0.9, 0.999)	
Weight decay	0.05	0.01
Drop path	0.4	
Dropout	✗	
Input resolution	224^2	756^2

表 12：在 NLVR2 和 VQAv2 上微调 BEIT-3 的超参数。

Hyperparameters	COCO Captioning
Peak learning rate	8e-6
Fine-tuning steps	16k
Warmup steps	1600
Layer-wise learning rate decay	1.0
Batch size	256
AdamW ϵ	1e-8
AdamW β	(0.9, 0.999)
Weight decay	0.01
Drop path	0.3
Dropout	✗
Input resolution	392^2
Mask prob	0.6
Label smoothing ε	0.1
Beam size	3

表 13：在 COCO 图像描述任务上微调 BEIT-3 的超参数。

Hyperparameters	COCO	Flickr30K
Peak learning rate	1e-5	
Fine-tuning epochs	15	20
Warmup epochs	3	5
Layer-wise learning rate decay	0.95	
Batch size	3k	
AdamW ϵ	1e-8	
AdamW β	(0.9, 0.999)	
Weight decay	0.05	
Drop path	0.3	
Dropout	✗	
Input resolution	420^2	

表 14：在图文检索上微调 BEIT-3 的超参数。

Hyperparameters	**ADE20K**
Peak learning rate	1e-5
Fine-tuning steps	80k
Warmup steps	1500
Layer-wise learning rate decay	0.95
Batch size	16
AdamW ϵ	1e-8
AdamW β	(0.9, 0.999)
Weight decay	0.05
Drop path	0.5
Dropout	✗
Input resolution	896^2

表15：在语义分割上微调 BEIT-3 的超参数。

Hyperparameters	**Object365**	**COCO**
Learning rate	1e-4	5e-5
Fine-tuning epochs	15	20
Warmup steps	250	
Layer-wise learning rate decay	0.9	
Batch size	64	
AdamW ϵ	1e-8	
AdamW β	(0.9, 0.999)	
Weight decay	0.1	
Drop path	0.6	
Input resolution	1024^2	1280^2

表 16：在目标检测任务上微调 BEIT-3 的超参数。

Hyperparameters	**ImageNet-21K**	**ImageNet-1K**
Peak learning rate	5e-5	3e-5
Fine-tuning epochs	50	15
Warmup epochs	5	3
Layer-wise learning rate decay	0.85	0.95
Batch size	16k	2k
AdamW ϵ	1e-6	1e-8
AdamW β	(0.9, 0.98)	(0.9, 0.999)
Weight decay	0.05	
Drop path	0.4	
Dropout	✗	
Input resolution	224^2	336^2
Label smoothing ε	0.1	

表 17：在图像分类上微调 BEIT-3 的超参数。